Politechnika Łódzka
Wydział Fizyki Technicznej, Informatyki i Matematyki Stosowanej

Analiza danych złożonych z detekcją wyjątków

Zadanie 1

Porównanie klasycznych metod detekcji wyjątków

Jędrzej Kostyk
nr indeksu 264339

Rok akademicki 2026/2027

Spis treści

1 Cel i zakres **2**

2 Dane **2**

2.1 Zbiory danych 2

2.2 Wstępna analiza danych 3

3 Protokół eksperymentalny **5**

4 Metody i badane hiperparametry **6**

5 Wyniki **7**

5.1 Miary jakości i pułapka Accuracy 7

5.2 Wyniki poszczególnych detektorów 8

5.2.1 Isolation Forest 8

5.2.2 LOF 10

5.2.3 COF 11

5.2.4 One-Class SVM 13

5.2.5 DBSCAN 15

5.2.6 Próg contamination (IForest, LOF, COF) 18

5.3 Porównanie najlepszych konfiguracji 19

5.4 Anomalie lokalne i globalne 20

5.5 Zgodność wykrytych zbiorów 21

5.6 Jakość a czas działania 22

6 Wnioski **22**

A Wyniki wszystkich ustawień **23**

1 Cel i zakres

Celem zadania jest porównanie pięciu klasycznych metod detekcji wyjątków o różnych mechanizmach działania: Isolation Forest (izolacja przez losowe podziały), Local Outlier Factor (lokalna gęstość), Connectivity-based Outlier Factor (lokalna spójność sąsiedztwa), One-Class SVM (granica obszaru danych w przestrzeni jądrowej) oraz DBSCAN (punkty szumu w klasteryzacji gęstościowej). Szczególną uwagę poświęcono wpływowi hiperparametrów na liczbę i rodzaj wykrywanych wyjątków, problemowi silnego niezbalansowania klas, różnicy między wyjątkami globalnymi i lokalnymi oraz zgodności zbiorów obserwacji wskazywanych przez poszczególne detektory.

Eksperymenty przeprowadzono na pięciu zbiorach danych z publicznych benchmarków detekcji anomalii, dla 84 ustawień metod wymagających uczenia modelu (154 po uwzględnieniu parametru `contamination`, czyli zakładanego odsetka anomalii, opisanego w sekcji 4) i łącznie 90 podziałów danych (7560 wytrenowanych modeli). Cały kod znajduje się w katalogach `common/` i `task1_classical/` repozytorium.

2 Dane

W tej sekcji przedstawiono użyte zbiory danych i ich najważniejsze właściwości, które pomagają zrozumieć późniejsze wyniki.

2.1 Zbiory danych

Użyto pięciu gotowych zbiorów danych z benchmarków ADBench [1] i DAMI [3] (tabela 1). Etykiety anomalii pochodzą od autorów benchmarków; zbiory nie były w żaden sposób zmieniane. Oryginalnym źródłem danych jest repozytorium UCI [4, 5, 8, 12, 9], a w przypadku Mammography praca Woods i in. [7].

Tabela 1: Zbiory danych użyte w zadaniu.

Zbiór danych	Źródło	Co zawiera	Obserwacje	Cechy	Anomalie
Breastw	ADBench	biopsje piersi; anomalia = guz złośliwy	683	9	239 (35,0 %)
Mammography	ADBench	fragmenty mammogramów; anomalia = mikrozwapnienie	11 183	6	260 (2,3 %)
Wine	ADBench	analiza chemiczna win; anomalia = wino z odmiany 1	129	13	10 (7,8 %)
Statlog Heart	DAMI	badania kardiologiczne; anomalia = choroba serca	157	13	7 (4,5 %)
Cardio	ADBench	zapisy KTG płodu; anomalia = zapis patologiczny	1 831	21	176 (9,6 %)

Tabela 2 pokazuje, jak wyglądają dane: po jednej obserwacji normalnej i jednej anomalii z każdego zbioru danych (pierwsze pięć cech). W Mammography i Cardio autorzy benchmarku udostępnili cechy już przeskalowane i bez nazw, dlatego oznaczono je numerami.

Tabela 2: Przykładowe obserwacje (pierwsze pięć cech; „…” – pozostałe cechy).

Breastw

grubość skupisk	jednorodność rozmiaru	jednorodność kształtu	przyleganie brzeżne	rozmiar komórki nabł.	…	Anomalia
5	1	1	1	2	…	nie
8	10	10	8	7	…	tak

Mammography

cecha 1	cecha 2	cecha 3	cecha 4	cecha 5	…	Anomalia
0,23	5,07	−0,28	0,83	−0,38	…	nie
−0,34	−0,45	−0,59	0,82	−0,38	…	tak

Wine

alkohol	kwas jabłkowy	popiół	zasadowość popiołu	magnez	…	Anomalia
12,37	0,94	1,36	10,60	88	…	nie
13,29	1,97	2,68	16,80	102	…	tak

Statlog Heart

wiek	płeć	typ bólu w klatce	ciśnienie spoczynkowe	cholesterol	…	Anomalia
67	0	3	115	564	…	nie
77	1	4	125	304	…	tak

Cardio

cecha 1	cecha 2	cecha 3	cecha 4	cecha 5	…	Anomalia
0,00	0,69	−0,20	0,60	0,35	…	nie
0,22	−0,65	−0,20	2,03	2,39	…	tak

2.2 Wstępna analiza danych

Tu sprawdzono, jak rozkładają się cechy i czy anomalie odróżniają się od obserwacji normalnych już na pierwszy rzut oka. Żaden zbiór danych nie ma braków.

Tabela 3: Wskaźniki opisujące kształt danych.

Zbiór danych	Średnia skośność cech	Wartości skrajne [%]	Najsilniejsza korelacja	Składowe PCA na 90 % informacji
Breastw	1,46	1,01	0,91	6 z 9
Mammography	4,44	1,33	0,87	5 z 6
Wine	0,61	0,83	0,81	8 z 13
Statlog Heart	1,14	0,54	0,51	10 z 13
Cardio	2,27	1,11	0,94	12 z 21

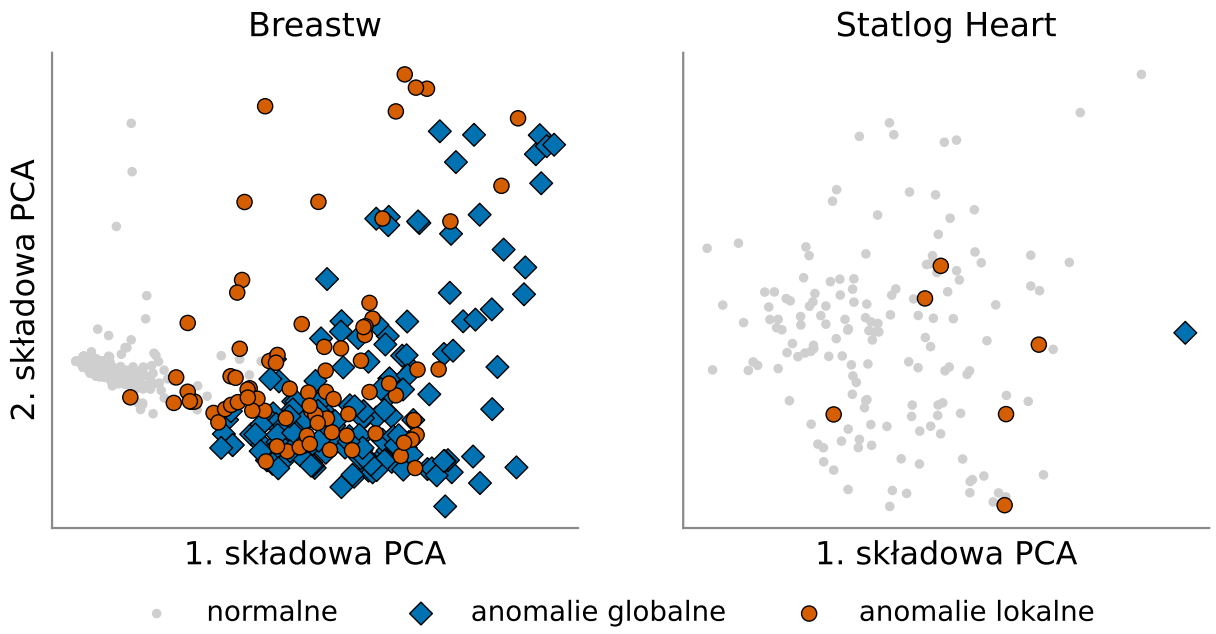
Znaczenie kolumn tabeli 3:

- **Średnia skośność cech** – jak bardzo asymetryczne są rozkłady cech (0 = symetryczny, powyżej 1 = silnie skośny, czyli z długim „ogonem” dużych wartości).
- **Wartości skrajne** – odsetek wartości odległych od średniej o więcej niż trzy odchylenia

standardowe; takie wartości występują także w obserwacjach normalnych.

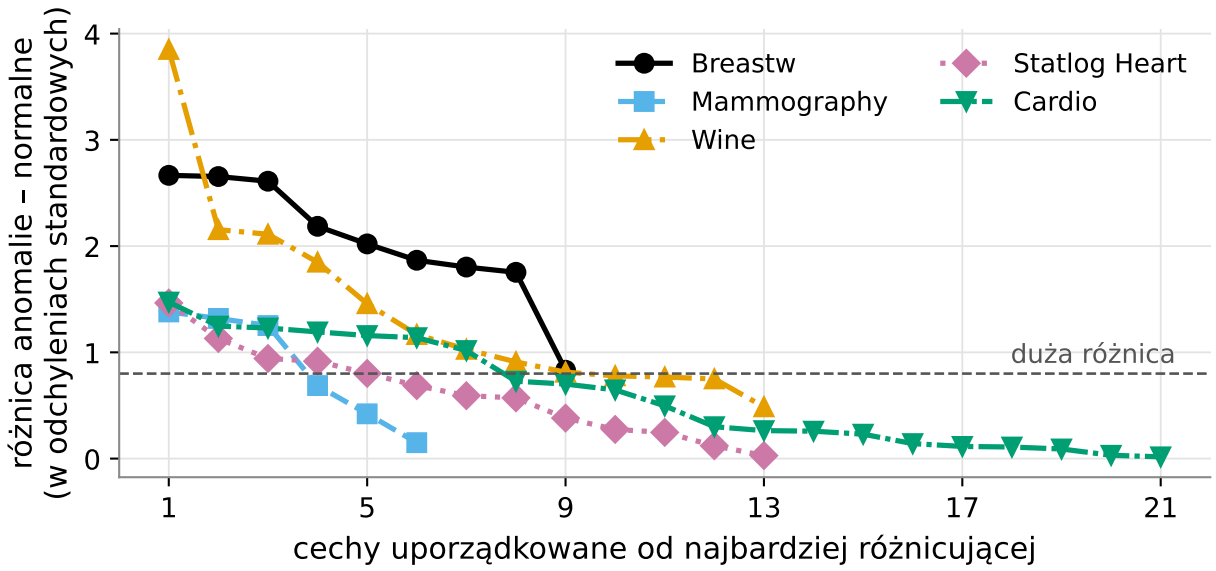
- **Najsilniejsza korelacja** – największa zależność liniowa między dwiema cechami (0 = brak, 1 = cechy są prawie swoimi kopiami).
- **Składowe PCA na 90 % informacji** – PCA (analiza składowych głównych) zastępuje cechy ich kombinacjami uporządkowanymi od najważniejszej; kolumna mówi, ile takich kombinacji wystarcza, by zachować 90 % zmienności danych.

Mammography i Cardio mają silnie skośne cechy, a w czterech zbiorach danych niektóre cechy są prawie duplikatami (korelacja 0,81–0,94). **Wniosek: danych nie da się opisać prostym rozkładem normalnym, a pojedyncze skrajne wartości nie wskazują jeszcze anomalii.**



Rysunek 1: Rzut dwóch zbiorów danych na płaszczyznę dwóch pierwszych składowych PCA.

Na rysunku 1 **anomalie Breastw tworzą osobny, duży obszar**, a w Statlog Heart są wymieszane z obserwacjami normalnymi. Podział na anomalie globalne i lokalne wyjaśniono w sekcji 5.4.



Rysunek 2: Jak mocno każda cecha osobno różni anomalie od obserwacji normalnych.

Rysunek 2 pokazuje różnicę średnich anomalii i obserwacji normalnych, wyrażoną w odchyleniach standardowych (tzw. *d* Cohena). W Breastw prawie wszystkie cechy przekraczają umowną granicę dużej różnicy (0,8), a w Statlog Heart i Mammography – tylko pojedyncze. **Tam, gdzie żadna cecha osobno nie odróżnia anomalii, detektor musi patrzeć na wiele cech naraz.**

3 Protokół eksperymentalny

Ta sekcja opisuje, jak przygotowano eksperyment, żeby wyniki były uczciwe i porównywalne – bez „podglądania" danych, na których ocenia się metody.

Podział na trzy części. Każdy zbiór danych dzielimy losowo na część uczącą (50 %), walidacyjną (25 %) i testową (25 %). Przykład: z 1000 obserwacji 500 trafia do uczenia, 250 do walidacji i 250 do testu. Każda część służy do czegoś innego:

- **uczenie** – detektor uczy się, jak wyglądają dane, *bez* informacji, które obserwacje są anomaliami (tak jak w praktyce, gdy etykiet nie ma);
- **walidacja** – na niej wybieramy ustawienia metody (hiperparametry) i próg decyzji „anomalia / nie anomalia";
- **test** – oceniamy na nim wynik tylko raz, na końcu; nie wpływa na żaden wybór.

Podział jest *warstwowy*: w każdej części udział anomalii jest taki sam jak w całym zbiorze danych.

Skalowanie tylko na części uczącej. Cechy mają różne jednostki (np. wiek w latach i cholesterol w mg/dl), więc przed uczeniem każdą cechę standaryzujemy: odejmujemy średnią i dzielimy przez odchylenie standardowe. Średnią i odchylenie liczymy *tylko* na części uczącej i tymi samymi liczbami przekształcamy walidację i test. Przykład: jeśli na części uczącej średni cholesterol to 250, a odchylenie 50, to wartość 300 w teście staje się $(300 - 250)/50 = 1$. Gdyby średnią liczyć na całych danych, informacja z testu wpłynęłaby na model.

Ziarno losowe i wiele podziałów. *Ziarno* (ang. seed) to liczba startowa generatora losowego: to samo ziarno daje zawsze ten sam podział. Jeden podział to loteria. Wine ma tylko 10 anomalii,

więc w części testowej są 3, a Statlog Heart – 2. Jedno trafienie więcej lub mniej zmienia wtedy wynik o kilkadziesiąt punktów procentowych. Dlatego:

- Breastw, Mammography i Cardio dzielimy 10 razy (ziarna 0–9),
- Wine i Statlog Heart – 30 razy (ziarna 0–29),

a raportujemy średnią i odchylenie standardowe wyników z tych podziałów. Kod sprawdza, czy każda część zawiera co najmniej jedną anomalię, i odrzuca podział, który tego nie spełnia (przy podziale warstwowym taki przypadek nie wystąpił). Te same ziarna dają te same podziały w zadaniach 1–3, więc ich wyniki można porównywać.

Wybór ustawień i progu. Detektor daje każdej obserwacji *wynik anomalii* – liczbę, która jest tym większa, im bardziej obserwacja jest podejrzana. Spośród wszystkich ustawień metody wybieramy to, które ma najwyższą średnią PR-AUC na walidacji. PR-AUC (od 0 do 1) mówi, jak dobrze detektor ustawia anomalie na początku listy najbardziej podejrzanych obserwacji; dokładniej opisano ją w sekcji 5.1. Następnie na walidacji wybieramy próg wyniku, powyżej którego obserwację uznajemy za anomalię – taki, który daje najwyższe F1 (miarę łączącą trafność zgłoszeń i odsetek wykrytych anomalii, też opisaną w sekcji 5.1).

4 Metody i badane hiperparametry

Tabela 4 krótko opisuje, jak działa każda z pięciu metod, oraz jakie wartości jej parametrów sprawdzono.

Trzy metody (IForest, LOF, COF) mają dodatkowo parametr **contamination** c, czyli *zakładany odsetek anomalii*. Nie zmienia on samego modelu ani wyników anomalii – przesuwa tylko próg: za anomalie uznaje się $c \cdot 100\,\%$ obserwacji uczących z najwyższym wynikiem. Przykład: przy $c = 0{,}1$ detektor oznacza $10\,\%$ najbardziej podejrzanych obserwacji. Badano $c \in \{0{,}02;\ 0{,}05;\ 0{,}1;\ 0{,}15;\ 0{,}2;\ 0{,}35\}$; jego wpływ pokazano osobno w sekcji 5.2.6.

Tabela 4: Metody i sprawdzone wartości parametrów.

Metoda	Jak działa	Parametry (sprawdzone wartości)
Isolation Forest (IForest)	Buduje wiele drzew, które dzielą dane losowymi cięciami. Anomalię da się „odciąć" od reszty po niewielu cięciach, więc im krótsza ścieżka, tym bardziej podejrzany punkt.	liczba drzew T: 50, 100, 200, 500; c
LOF	Porównuje gęstość punktu (jak blisko ma sąsiadów) z gęstością jego sąsiadów. Punkt wyraźnie rzadszy niż jego otoczenie jest podejrzany, nawet jeśli leży blisko innych danych.	liczba sąsiadów k: 5, 10, 20, 35, 50; c
COF	Odmiana LOF: zamiast gęstości bada, jak „spójnie" punkt łączy się ze swoimi sąsiadami (łańcuch najbliższych połączeń). Implementacja własna, bo dostępne biblioteki nie oceniają nowych punktów.	liczba sąsiadów k: 5, 10, 20, 35, 50; c
One-Class SVM (OCSVM)	Wyznacza granicę wokół obszaru, w którym leży większość danych; punkty poza granicą są anomaliami. Kształt granicy zależy od *jądra* – funkcji mierzącej podobieństwo punktów.	jądro: RBF (gaussowskie – podobieństwo maleje z odległością), wielomianowe, sigmoidalne, liniowe; ν (górny limit odsetka punktów uczących poza granicą): 0,01; 0,05; 0,1; 0,2; 0,5; γ (szerokość jądra; większe = ciaśniejsza granica): $0{,}1/d$, $1/d$, $10/d$, gdzie d to liczba cech
DBSCAN	Grupuje punkty leżące gęsto obok siebie. Punkt, który nie należy do żadnej grupy, jest *szumem*, czyli anomalią. Nowy punkt jest szumem, gdy do najbliższego punktu z wnętrza grupy ma dalej niż promień ε.	minPts (ilu sąsiadów w promieniu ε potrzeba, by punkt był wnętrzem grupy): 3, 5, 10, 20; ε ustalany jako kwantyl q_ε odległości do minPts-tego sąsiada: 0,5; 0,75; 0,9; 0,95; 0,99

Kwantyl $q_\varepsilon = 0{,}9$ oznacza, że promień ε jest taki, iż 90 % punktów uczących ma minPts-tego sąsiada bliżej niż ε. Dzięki temu jedna siatka wartości pasuje do zbiorów danych o różnych skalach.

5 Wyniki

W tej sekcji najpierw wyjaśniono miary jakości, potem omówiono każdą metodę osobno, a na końcu porównano metody ze sobą.

5.1 Miary jakości i pułapka Accuracy

Anomalii jest mało (od 2 do 35 % danych), więc popularna miara Accuracy myli. Tabela 5 wyjaśnia miary użyte w raporcie na przykładzie OCSVM na części testowej Cardio (458 obserwacji, w tym 44 anomalie; detektor zgłosił 43 obserwacje, z czego 30 to prawdziwe anomalie).

Tabela 5: Miary jakości użyte w raporcie.

Miara	Co mówi	Przykład (OCSVM, Cardio)
Accuracy	odsetek wszystkich obserwacji ocenionych poprawnie	$(458 - 13 - 14)/458 = 0{,}94$
Precision	ile zgłoszonych obserwacji to naprawdę anomalie	$30/43 = 0{,}70$
Recall	ile prawdziwych anomalii wykryto	$30/44 = 0{,}68$
F1	jedna liczba łącząca Precision i Recall (ich średnia harmoniczna); wysoka tylko wtedy, gdy obie są wysokie	0,69
ROC-AUC	szansa, że losowa anomalia dostanie wyższy wynik niż losowa obserwacja normalna; 0,5 = zgadywanie	0,92 (średnio po podziałach)
PR-AUC	jak wysoko na liście najbardziej podejrzanych obserwacji są anomalie, uśrednione po wszystkich progach; zgadywanie daje wynik równy udziałowi anomalii	0,76 (średnio po podziałach; zgadywanie: 0,10)

Tabela 6: Detektor, który zawsze odpowiada „normalne”, ma wysoką Accuracy, choć nie wykrywa niczego (jego F1 = 0).

Zbiór danych	Udział anomalii w teście	Accuracy „wszystko normalne”	Najlepszy detektor (F1)	Jego Accuracy	Jego F1
Breastw	35,1 %	0,649	DBSCAN	0,960	0,944
Mammography	2,3 %	0,977	DBSCAN	0,974	0,290
Wine	9,1 %	0,909	OCSVM	0,957	0,769
Statlog Heart	5,0 %	0,950	LOF	0,889	0,282
Cardio	9,6 %	0,904	OCSVM	0,946	0,728

Na Mammography i Statlog Heart odpowiedź „wszystko normalne” ma wyższą Accuracy niż najlepszy detektor, choć nie znajduje żadnej anomalii (tabela 6). Dlatego metody porównujemy za pomocą PR-AUC i F1. ROC-AUC też bywa zbyt optymistyczna: na Mammography IForest ma ROC-AUC 0,85, ale F1 tylko 0,24, bo fałszywe alarmy giną wśród tysięcy obserwacji normalnych.

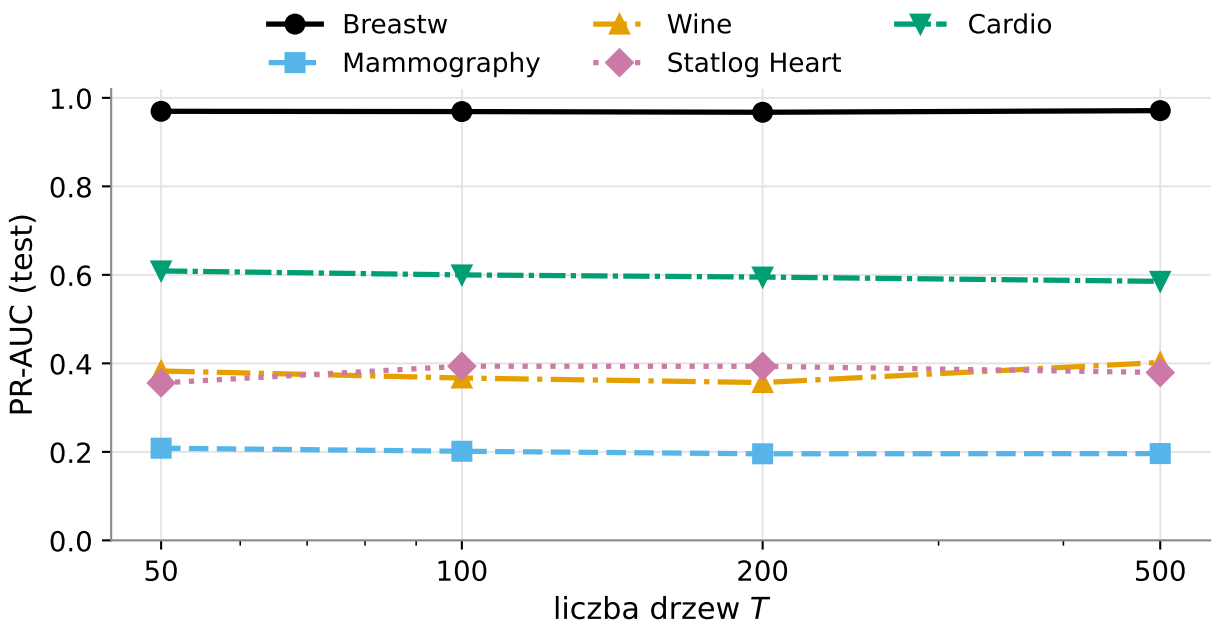
5.2 Wyniki poszczególnych detektorów

Każdą metodę omówiono w tym samym układzie: wpływ jej parametrów na wszystkich zbiorach danych, krótka tabela z ustawieniem wybranym na walidacji oraz rysunek pokazujący, co metoda wykryła w części testowej Cardio.

Rysunki „co wykryto” dotyczą jednego podziału (ziarno 0) części testowej Cardio, rzutowanej na dwie pierwsze składowe PCA. Ustawienie i próg detektora wybrano na walidacji. Kolory oznaczają: **TP** – wykryta anomalia, **FN** – przeoczona anomalia, **FP** – fałszywy alarm (obserwacja normalna uznana za anomalię); szare punkty to obserwacje normalne, których detektor słusznie nie zgłosił.

5.2.1 Isolation Forest

Sprawdzono, czy liczba drzew T zmienia jakość wykrywania.

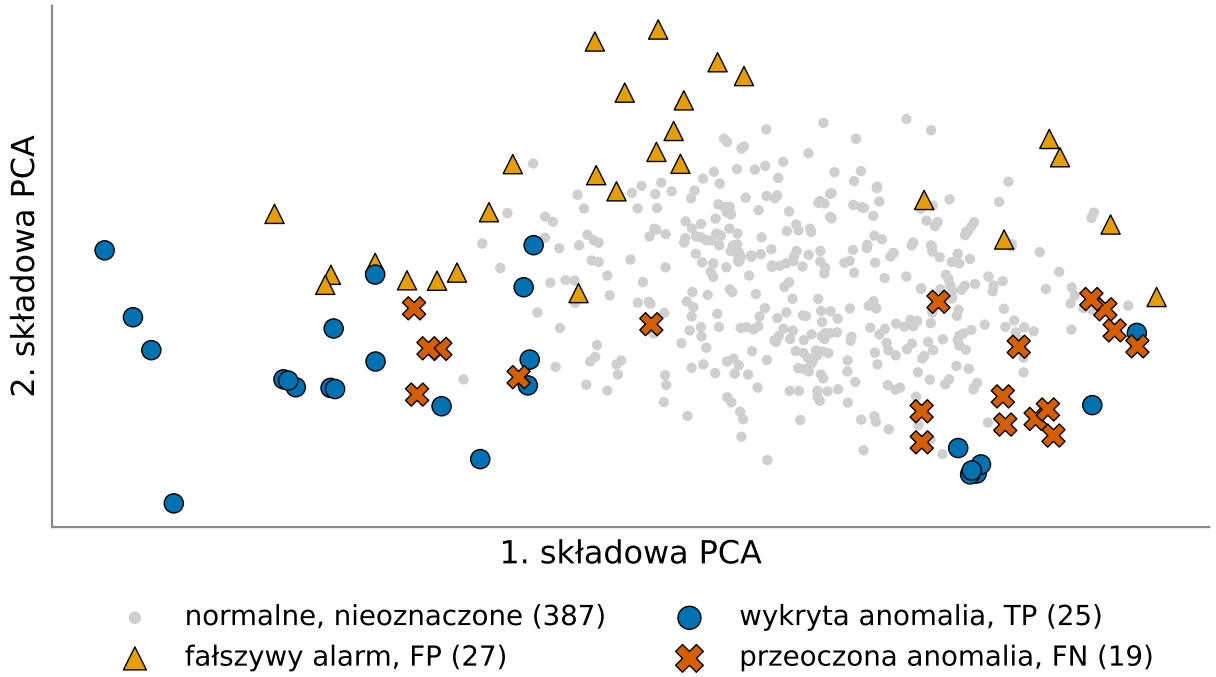


Rysunek 3: Isolation Forest: liczba drzew prawie nie zmienia PR-AUC.

Tabela 7: Isolation Forest: ustawienie wybrane na walidacji i rozrzut wyników między ustawieniami.

Zbiór danych	Ustawienie wybrane na walidacji	PR-AUC przy tym ustawieniu	PR-AUC: najsłabsze – najlepsze ustawienie
Breastw	T=500	0,971	0,967 – 0,971
Mammography	T=50	0,208	0,196 – 0,208
Wine	T=50	0,383	0,357 – 0,402
Statlog Heart	T=100	0,394	0,356 – 0,394
Cardio	T=100	0,600	0,585 – 0,609

Wszystkie zbiory danych: liczba drzew T → zmiana PR-AUC najwyżej o 0,045. IForest jest więc niewrażliwy na swój główny parametr; różnice między zbiorami danych (0,20 do 0,97) są wielokrotnie większe.

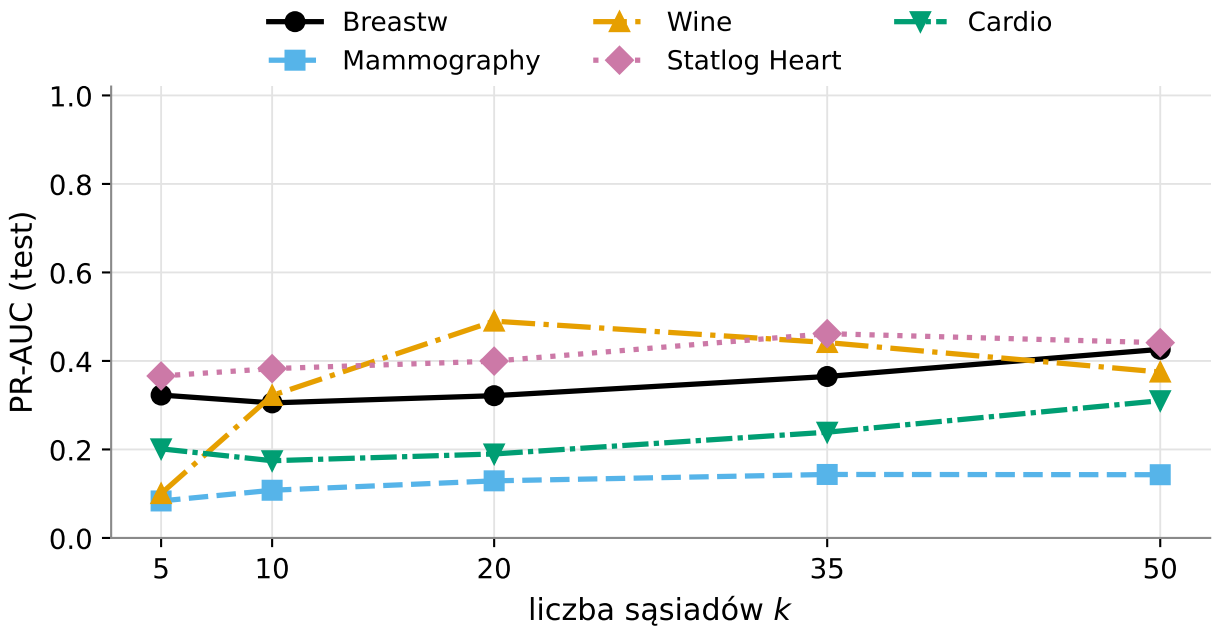


Rysunek 4: Co wykrył Isolation Forest na Cardio (TP = 25, FN = 19, FP = 27).

IForest wykrywa anomalie leżące daleko od masy danych (po lewej stronie rysunku 4), a **przeocza te, które leżą tuż przy obserwacjach normalnych**.

5.2.2 LOF

Sprawdzono, jak liczba sąsiadów k, z którymi LOF porównuje punkt, wpływa na wynik.

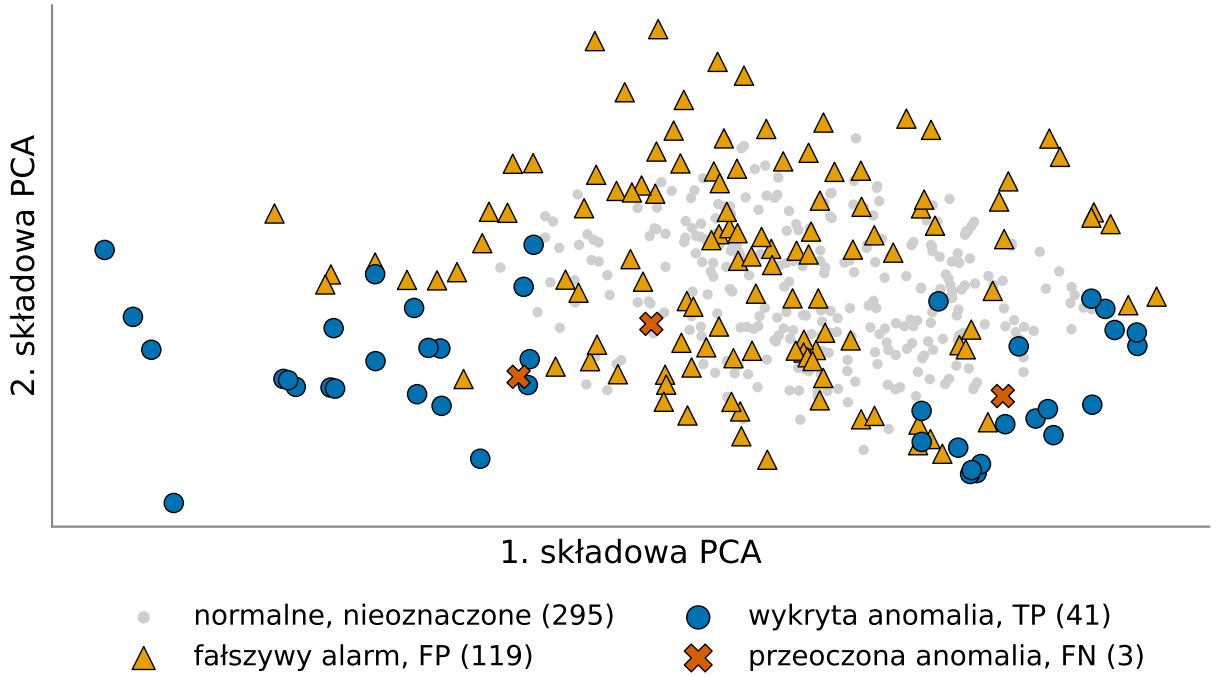


Rysunek 5: LOF: większa liczba sąsiadów zwykle poprawia PR-AUC, najbardziej na Wine.

Tabela 8: LOF: ustawienie wybrane na walidacji i rozrzut wyników między ustawieniami.

Zbiór danych	Ustawienie wybrane na walidacji	PR-AUC przy tym ustawieniu	PR-AUC: najsłabsze – najlepsze ustawienie
Breastw	k=50	0,426	0,305 – 0,426
Mammography	k=35	0,143	0,084 – 0,143
Wine	k=20	0,490	0,100 – 0,490
Statlog Heart	k=50	0,441	0,366 – 0,462
Cardio	k=50	0,310	0,175 – 0,310

Wine: liczba sąsiadów $k = 5 \rightarrow 20 \Rightarrow$ PR-AUC 0,10 $\rightarrow$ 0,49. Anomalie Wine tworzą małą grupę (ok. 5 punktów w części uczącej). Przy $k = 5$ sąsiadami anomalii są inne anomalie, więc wyglądają normalnie; dopiero większe k sięga do obserwacji normalnych. Na Breastw LOF jest słaby przy każdym k (najwyżej 0,43 przy poziomie zgadywania 0,35), bo 239 anomalii tworzy tam własny gęsty obszar.

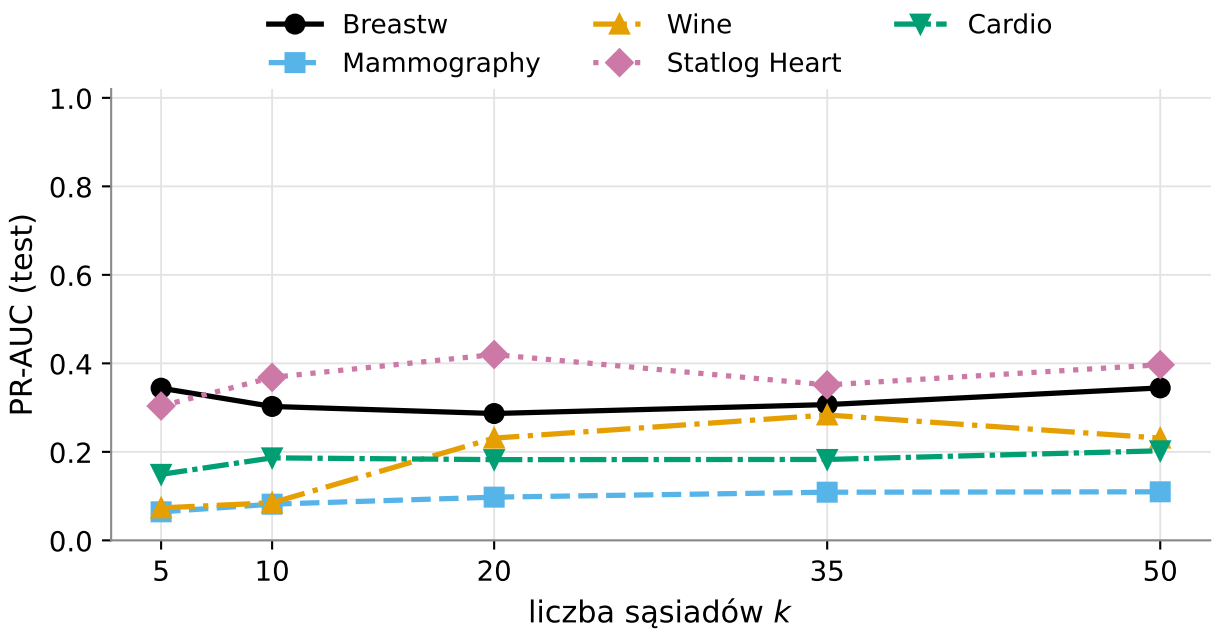


Rysunek 6: Co wykrył LOF na Cardio (TP = 41, FN = 3, FP = 119).

LOF wykrywa prawie wszystkie anomalie (41 z 44), ale kosztem wielu fałszywych alarmów (119) – zgłasza każdy punkt, który jest rzadszy od swoich sąsiadów, także na obrzeżach danych normalnych.

5.2.3 COF

Jak w LOF, badanym parametrem jest liczba sąsiadów k.

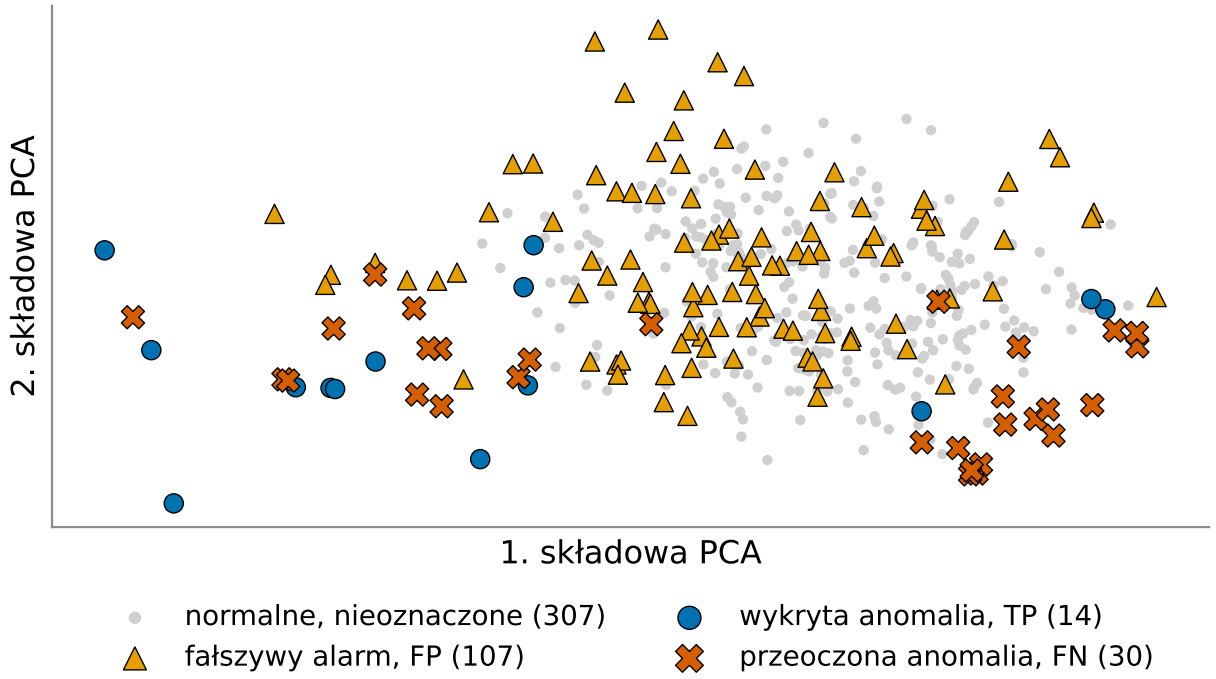


Rysunek 7: COF: wpływ liczby sąsiadów jest podobny jak w LOF, ale wyniki są niższe.

Tabela 9: COF: ustawienie wybrane na walidacji i rozrzut wyników między ustawieniami.

Zbiór danych	Ustawienie wybrane na walidacji	PR-AUC przy tym ustawieniu	PR-AUC: najsłabsze – najlepsze ustawienie
Breastw	k=50	0,345	0,287 – 0,345
Mammography	k=35	0,109	0,065 – 0,110
Wine	k=35	0,283	0,073 – 0,283
Statlog Heart	k=20	0,420	0,304 – 0,420
Cardio	k=50	0,202	0,149 – 0,202

Wine: $k = 5 \rightarrow 35 \Rightarrow$ PR-AUC 0,07 $\rightarrow$ 0,28; na każdym zbiorze danych COF jest słabszy od LOF. Łańcuch połączeń przy dużym k przechodzi przez sąsiednie skupiska i zaciera lokalną strukturę.

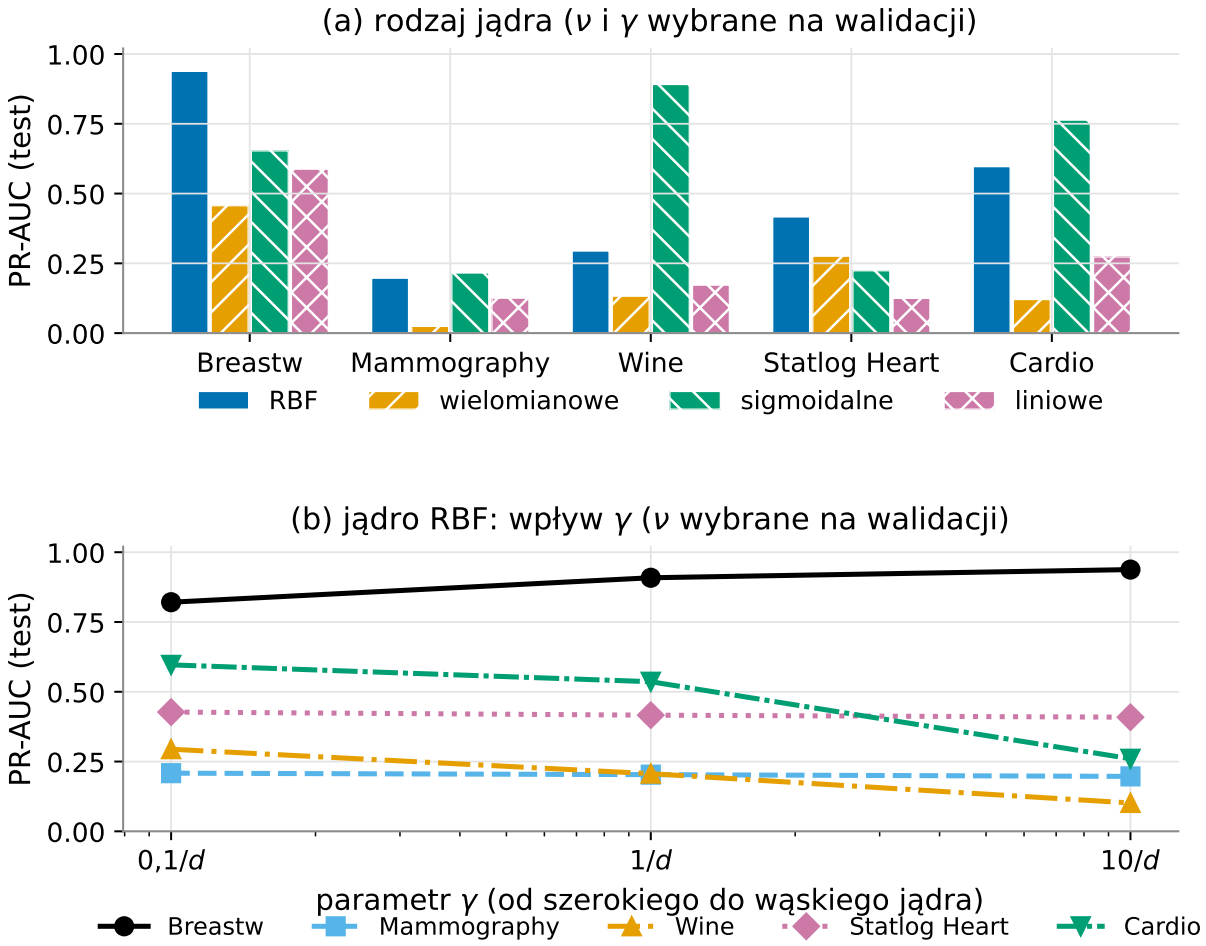


Rysunek 8: Co wykrył COF na Cardio (TP = 14, FN = 30, FP = 107).

COF przeocza ponad połowę anomalii Cardio (30 z 44) i zgłasza 107 fałszywych alarmów – jego wynik słabo odróżnia anomalie od zwykłych punktów brzegowych.

5.2.4 One-Class SVM

Sprawdzono trzy parametry: rodzaj jądra, szerokość jądra γ i limit ν.



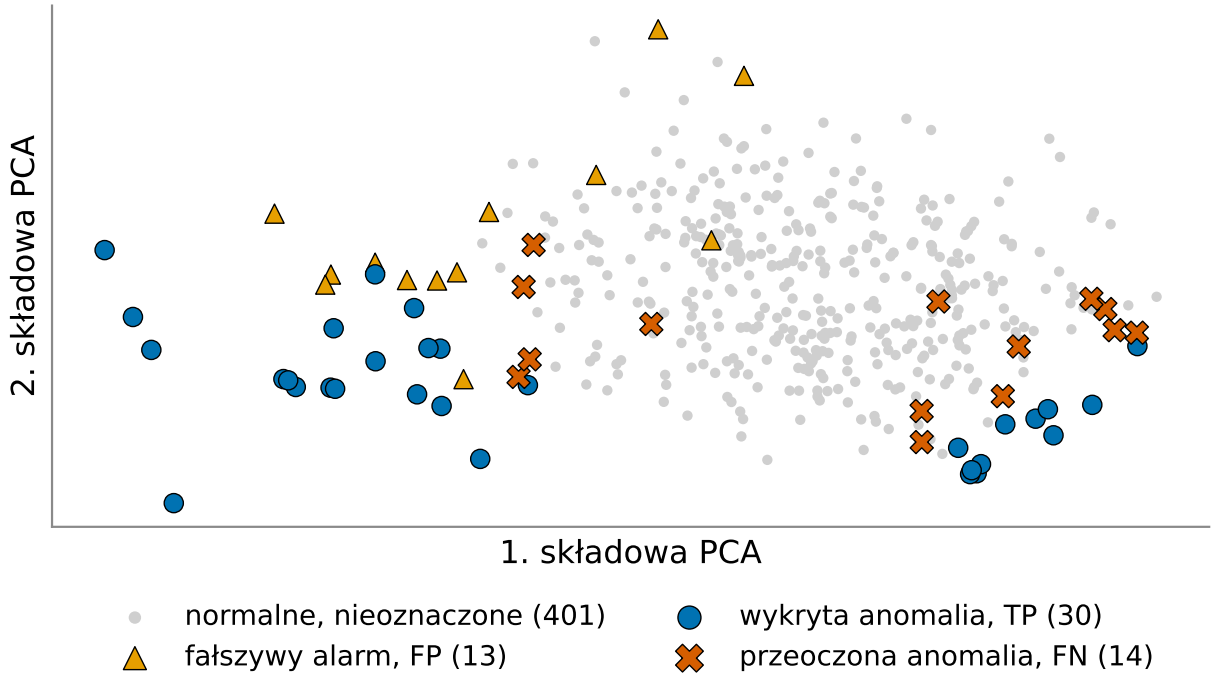
Rysunek 9: OCSVM: najważniejsze są rodzaj jądra (a) i szerokość jądra γ (b).

Tabela 10: OCSVM: ustawienie wybrane na walidacji i rozrzut wyników między ustawieniami.

Zbiór danych	Ustawienie wybrane na walidacji	PR-AUC przy tym ustawieniu	PR-AUC: najsłabsze – najlepsze ustawienie
Breastw	rbf, ν=0,50, γ=10,0/d	0,938	0,228 – 0,938
Mammography	sigmoid, ν=0,50, γ=0,1/d	0,215	0,013 – 0,215
Wine	sigmoid, ν=0,50, γ=10,0/d	0,891	0,071 – 0,891
Statlog Heart	rbf, ν=0,50, γ=1,0/d	0,416	0,066 – 0,428
Cardio	sigmoid, ν=0,50, γ=1,0/d	0,763	0,083 – 0,763

- **Jądro – Wine: sigmoidalne ⇒ PR-AUC 0,89 (RBF tylko 0,29).** Jądro RBF wygrywa na Breastw i Statlog Heart, sigmoidalne na Wine, Cardio i Mammography, a liniowe i wielomianowe są zawsze słabe.
- γ – **Breastw: wąskie jądro ($\gamma = 10/d$) ⇒ 0,94; Cardio: szerokie ($\gamma = 0{,}1/d$) ⇒ 0,60 (przy $10/d$ tylko 0,26).** Wąskie jądro opina dane ciasno, szerokie daje gładką granicę; który wariant jest lepszy, zależy od zbioru danych.
- ν – **Wine i Statlog Heart: nawet przy $\nu = 0{,}01$ OCSVM oznacza 41–46 % punktów testowych.** ν ogranicza odsetek punktów poza granicą tylko na części uczącej; na małych zbiorach danych (64–78 punktów uczących) granica jest tak ciasna, że nowe punkty często leżą poza nią.

Rozrzut w tabeli 10 (np. Wine 0,07–0,89) pokazuje, że **OCSVM jest najbardziej wrażliwy na ustawienia ze wszystkich metod**.

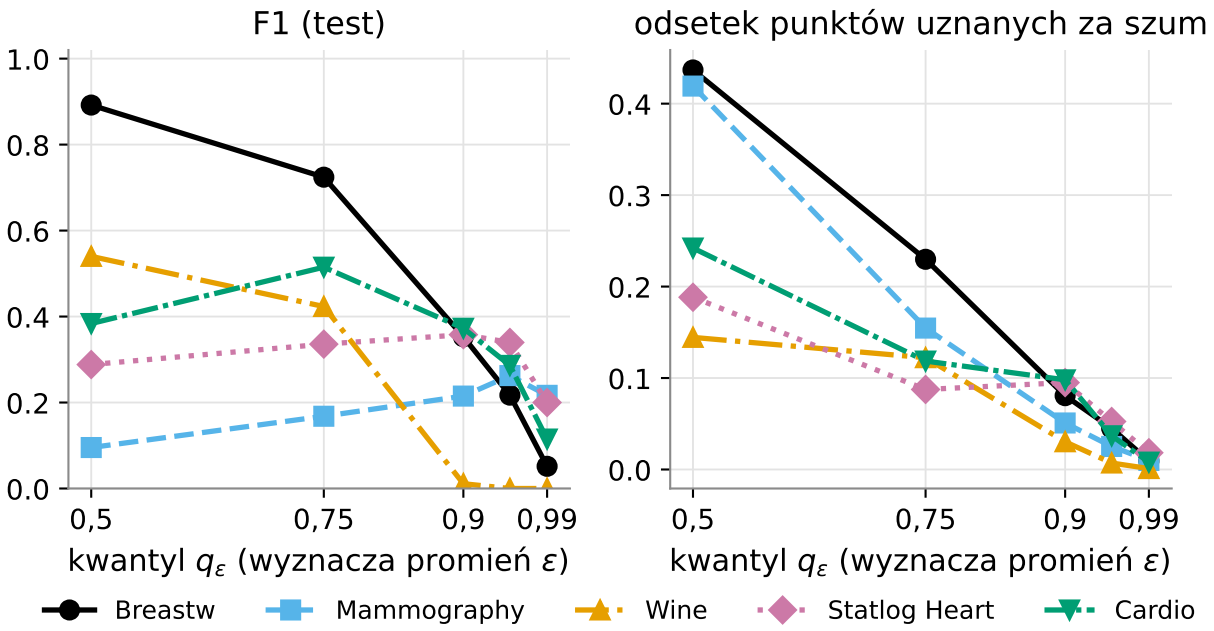


Rysunek 10: Co wykrył OCSVM na Cardio (TP = 30, FN = 14, FP = 13).

OCSVM ma najlepszą równowagę: wykrywa 30 z 44 anomalii przy tylko 13 fałszywych alarmach. Przeocza głównie anomalie leżące wewnątrz chmury obserwacji normalnych.

5.2.5 DBSCAN

DBSCAN jest algorytmem grupowania: dzieli dane na grupy (klastry) gęsto położonych punktów, a punkty, które nie pasują do żadnej grupy, nazywa szumem. To właśnie szum traktujemy jako anomalie. Sprawdzono wpływ promienia ε (przez kwantyl q_ε) i parametru minPts.

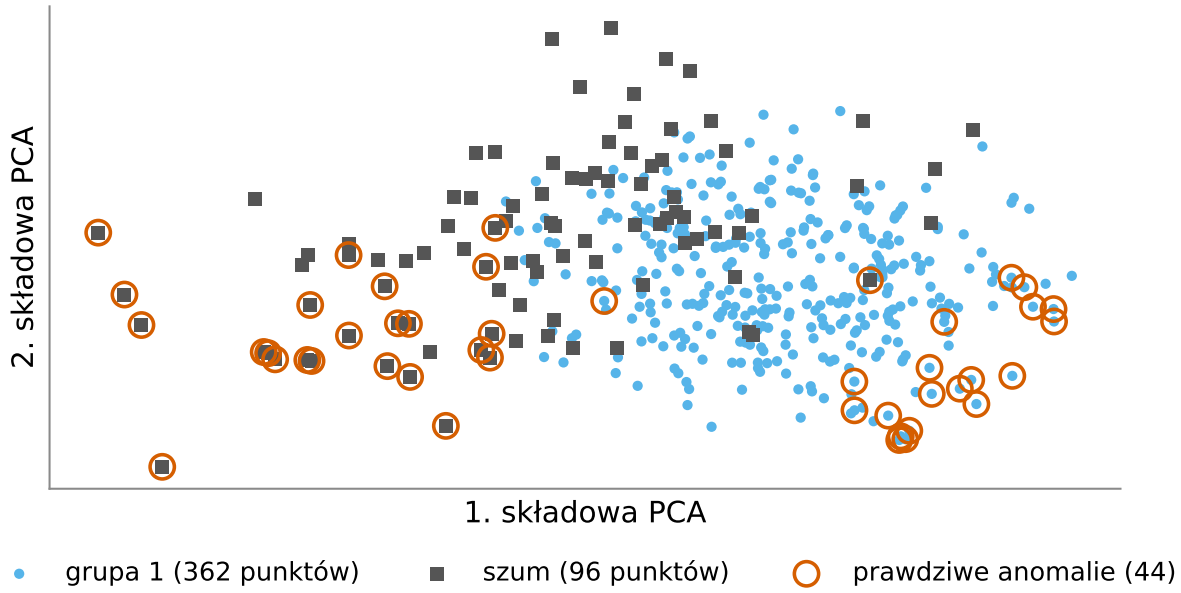


Rysunek 11: DBSCAN: F1 jest najwyższe, gdy odsetek szumu jest bliski udziałowi anomalii.

Tabela 11: DBSCAN: ustawienie wybrane na walidacji i rozrzut wyników między ustawieniami.

Zbiór danych	Ustawienie wybrane na walidacji	PR-AUC przy tym ustawieniu	PR-AUC: najsłabsze – najlepsze ustawienie
Breastw	minPts=20, q_ε=0,50	0,986	0,915 – 0,986
Mammography	minPts=3, q_ε=0,50	0,225	0,160 – 0,229
Wine	minPts=10, q_ε=0,50	0,604	0,091 – 0,604
Statlog Heart	minPts=10, q_ε=0,75	0,424	0,406 – 0,496
Cardio	minPts=20, q_ε=0,50	0,509	0,255 – 0,509

Promień ε decyduje o tym, ile punktów jest szumem, a F1 jest najlepsze, gdy szumu jest mniej więcej tyle, ile anomalii: Breastw 44 % szumu przy 35 % anomalii (F1 0,89), Cardio 12 % przy 9,6 % (0,52), Mammography 2,5 % przy 2,3 % (0,26). minPts musi być większe niż grupka anomalii: na Wine walidacja wybiera minPts $\geq$ 10, bo przy mniejszym anomalie tworzą własną grupę i nie są szumem.

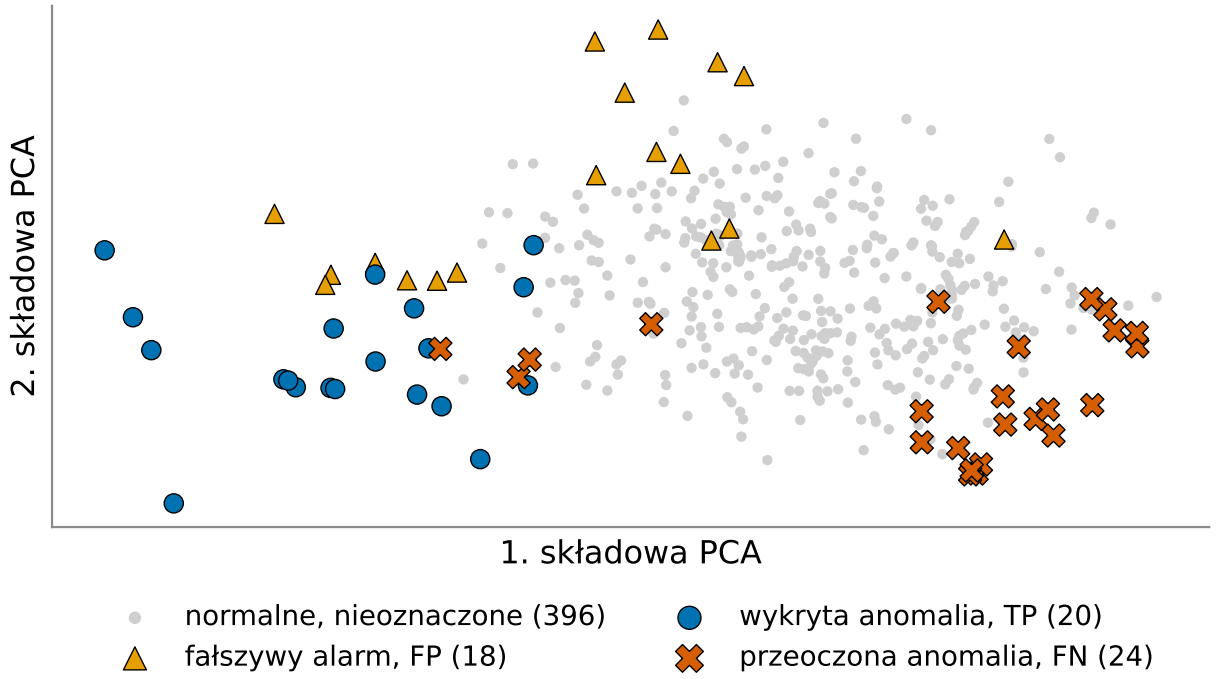


Rysunek 12: Grupy i szum znalezione przez DBSCAN w części testowej Cardio.

Tabela 12: DBSCAN na części testowej Cardio: liczba punktów w grupie i w szumie.

Grupa	Punkty testowe	w tym prawdziwe anomalie
grupa 1	362	20
szum (poza grupami)	96	24

Z ustawieniem wybranym na walidacji (minPts = 20, $q_\varepsilon = 0{,}5$) DBSCAN tworzy na Cardio **jedną dużą grupę, a 96 punktów zostaje szumem; 24 z nich to prawdziwe anomalie** (tabela 12). Szum obejmuje więc ponad połowę anomalii, ale też wiele punktów brzegowych. Rysunek „co wykryto” (rys. 13) używa progu wybranego na walidacji zamiast samego promienia ε, dlatego zgłasza mniej punktów.

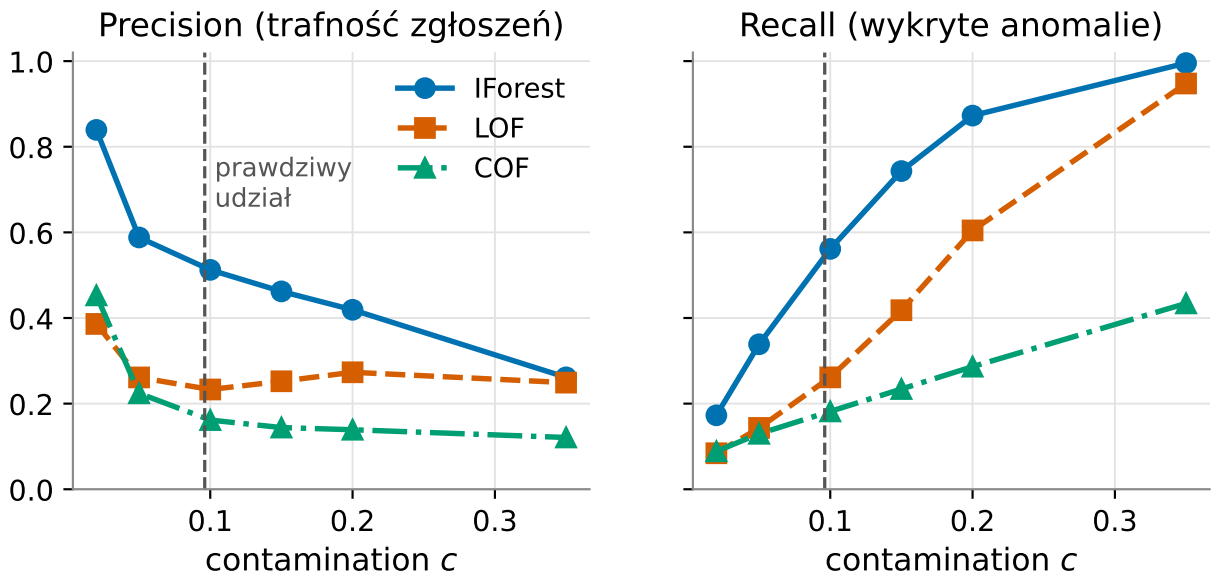


Rysunek 13: Co wykrył DBSCAN na Cardio (TP = 20, FN = 24, FP = 18).

DBSCAN wykrywa anomalie odległe od grupy, ale przeocza ponad połowę anomalii leżących przy jej brzegu (24 z 44).

5.2.6 Próg contamination (IForest, LOF, COF)

Parametr c nie jest osobną metodą, tylko progiem: pokazano tu, jak jego wartość przesuwa równowagę między trafnością zgłoszeń a wykrywaniem anomalii.



Rysunek 14: Cardio: większe c to więcej wykrytych anomalii, ale mniej trafne zgłoszenia.

Tabela 13: Wartość c wybrana na walidacji (wg F1) i F1 na teście.

Zbiór danych	Prawdziwy udział	IForest	LOF	COF
Breastw	35,0 %	c=0,35 (F1 0,93)	c=0,35 (F1 0,42)	c=0,35 (F1 0,28)
Mammography	2,3 %	c=0,02 (F1 0,25)	c=0,02 (F1 0,24)	c=0,02 (F1 0,19)
Wine	7,8 %	c=0,15 (F1 0,38)	c=0,15 (F1 0,51)	c=0,15 (F1 0,25)
Statlog Heart	4,5 %	c=0,10 (F1 0,28)	c=0,05 (F1 0,33)	c=0,10 (F1 0,28)
Cardio	9,6 %	c=0,15 (F1 0,57)	c=0,35 (F1 0,39)	c=0,35 (F1 0,19)

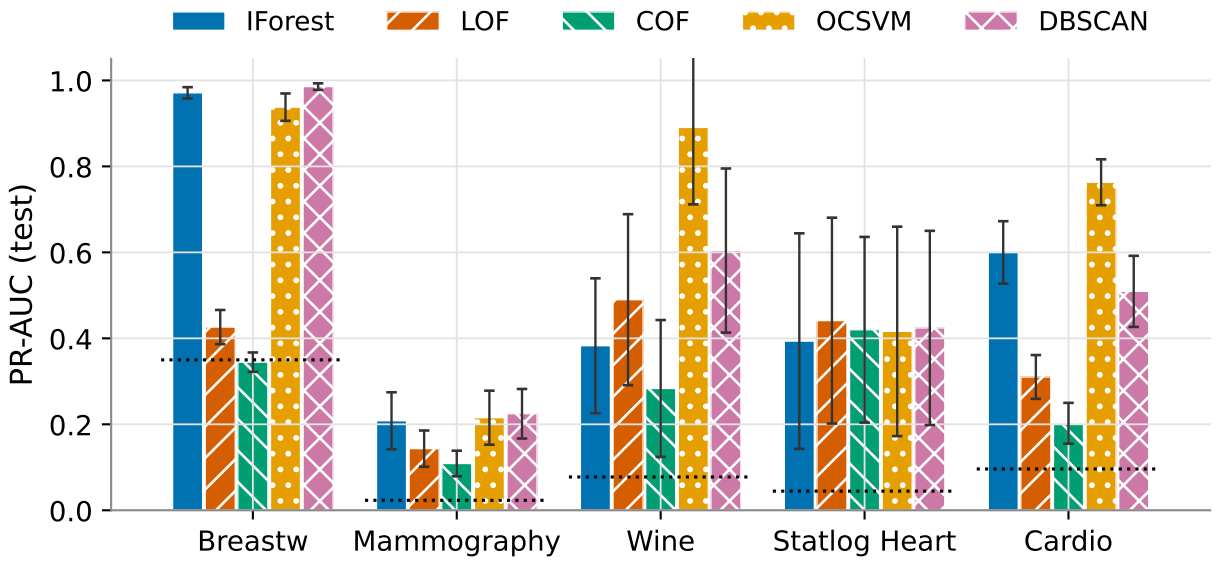
Cardio, IForest: c = 0,02 → 0,35 ⇒ Recall 0,17 → 0,995, Precision 0,84 → 0,26. Ranking obserwacji się nie zmienia, przesuwa się tylko próg. Wybrane na walidacji c jest zwykle bliskie prawdziwemu udziałowi anomalii (tabela 13); wyjątkiem są LOF i COF na Cardio, które przy słabym rankingu „łapią" anomalie dopiero przy bardzo wielu zgłoszeniach.

5.3 Porównanie najlepszych konfiguracji

Tu zestawiono wszystkie metody z ustawieniami i progami wybranymi na walidacji.

Tabela 14: Najlepsze ustawienia (wybrane na walidacji) – wyniki na teście, średnia ± odchylenie standardowe po podziałach; Czas – uczenie i ocena części testowej w milisekundach; pogrubienie – najlepsza metoda na zbiorze danych.

Zbiór danych	Metoda	Ustawienie (z walidacji)	Precision	Recall	F1	ROC-AUC	PR-AUC	Czas [ms]
Breastw	IForest	T=500	0,899	0,965	0,930 ± 0,020	0,987	0,971 ± 0,013	624,9
	LOF	k=50	0,430	0,910	0,582 ± 0,029	0,628	0,426 ± 0,040	9,1
	COF	k=50	0,438	0,980	0,605 ± 0,019	0,527	0,345 ± 0,023	162,3
	OCSVM	rbf, ν=0,50, γ=10,0/d	0,865	0,958	0,908 ± 0,035	0,976	0,938 ± 0,032	6,1
	DBSCAN	minPts=20, q_ε=0,50	0,933	0,955	**0,944 ± 0,021**	0,992	**0,986 ± 0,008**	9,1
Mammography	IForest	T=50	0,262	0,254	0,241 ± 0,073	0,854	0,208 ± 0,066	93,1
	LOF	k=35	0,270	0,226	0,229 ± 0,059	0,774	0,143 ± 0,042	161,5
	COF	k=35	0,274	0,174	0,203 ± 0,053	0,737	0,109 ± 0,030	969,2
	OCSVM	sigmoid, ν=0,50, γ=0,1/d	0,265	0,326	0,284 ± 0,058	0,820	0,215 ± 0,063	1378,1
	DBSCAN	minPts=3, q_ε=0,50	0,404	0,232	**0,290 ± 0,060**	0,844	**0,225 ± 0,058**	265,8
Wine	IForest	T=50	0,274	0,444	0,312 ± 0,193	0,795	0,383 ± 0,157	56,9
	LOF	k=20	0,361	0,622	0,423 ± 0,215	0,907	0,490 ± 0,199	2,0
	COF	k=35	0,182	0,456	0,241 ± 0,215	0,735	0,283 ± 0,159	14,9
	OCSVM	sigmoid, ν=0,50, γ=10,0/d	0,872	0,756	**0,769 ± 0,186**	0,968	**0,891 ± 0,179**	1,3
	DBSCAN	minPts=10, q_ε=0,50	0,500	0,700	0,540 ± 0,186	0,932	0,604 ± 0,191	3,4
Statlog Heart	IForest	T=100	0,123	0,333	0,167 ± 0,196	0,795	0,394 ± 0,251	115,8
	LOF	k=50	0,242	0,483	**0,282 ± 0,229**	0,815	**0,441 ± 0,239**	3,0
	COF	k=20	0,190	0,433	0,218 ± 0,214	0,797	0,420 ± 0,216	7,1
	OCSVM	rbf, ν=0,50, γ=1,0/d	0,198	0,433	0,236 ± 0,246	0,808	0,416 ± 0,244	1,4
	DBSCAN	minPts=10, q_ε=0,75	0,265	0,433	0,280 ± 0,256	0,811	0,424 ± 0,226	4,0
Cardio	IForest	T=100	0,483	0,705	0,568 ± 0,054	0,937	0,600 ± 0,073	144,2
	LOF	k=50	0,266	0,848	0,403 ± 0,023	0,848	0,310 ± 0,051	21,7
	COF	k=50	0,235	0,398	0,186 ± 0,054	0,600	0,202 ± 0,047	788,4
	OCSVM	sigmoid, ν=0,50, γ=1,0/d	0,716	0,748	**0,728 ± 0,032**	0,920	**0,763 ± 0,053**	55,7
	DBSCAN	minPts=20, q_ε=0,50	0,548	0,536	0,540 ± 0,069	0,820	0,509 ± 0,083	22,3



Rysunek 15: PR-AUC najlepszych ustawień każdej metody (kreska kropkowana – poziom zgadywania).

Żadna metoda nie wygrywa wszędzie: OCSVM jest najlepszy na Cardio (0,76) i Wine (0,89), DBSCAN na Breastw (0,99) i Mammography (0,23), a na Statlog Heart wszystkie metody mają 0,39–0,44 przy odchyleniu ok. 0,24, więc nie da się ich uporządkować. LOF i COF są najsłabsze tam, gdzie anomalie tworzą duże skupisko (Breastw).

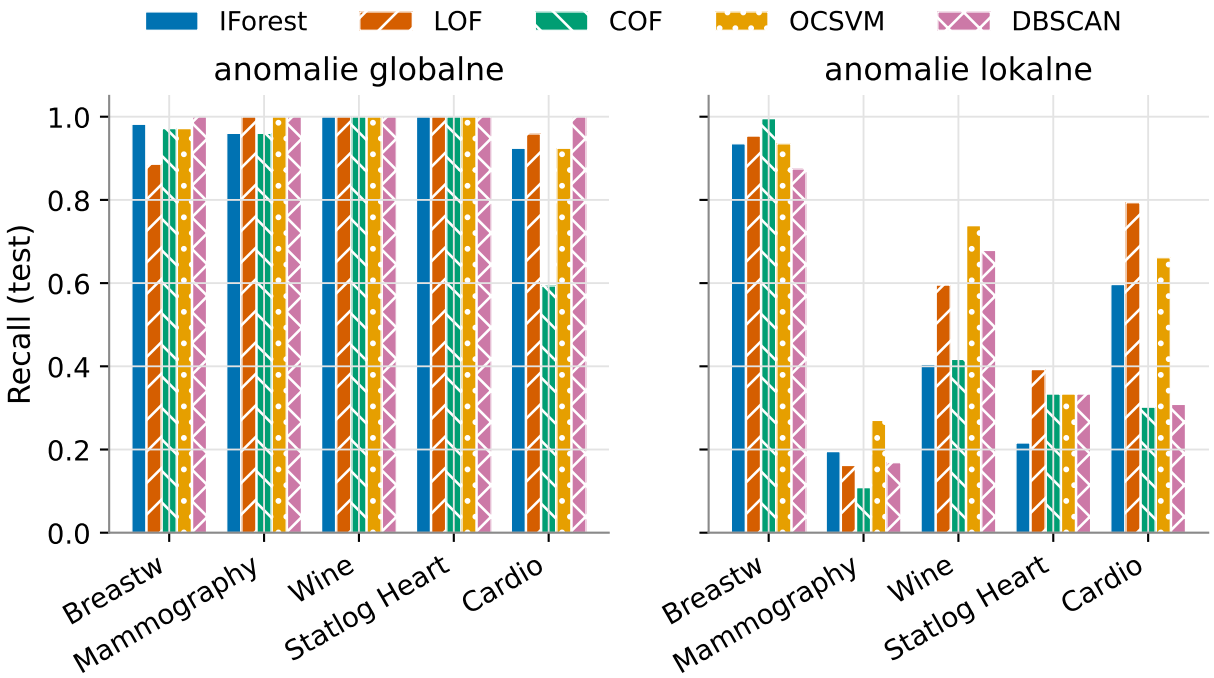
5.4 Anomalie lokalne i globalne

Ta część sprawdza, czy metody różnią się tym, *jakie* anomalie wykrywają.

Benchmarki nie mówią, czy anomalia jest „daleko od wszystkiego", czy tylko „nie pasuje do sąsiadów", więc przyjęto własną definicję. Dla każdej anomalii liczymy jej odległość od środka obserwacji normalnych w sposób, który uwzględnia zależności między cechami i nie daje się zaburzyć skrajnym punktom (*odporna odległość Mahalanobisa*). Anomalia jest **globalna**, jeśli leży dalej niż 99 % obserwacji normalnych, a **lokalna** – jeśli leży wewnątrz ich obszaru. Przykład: pacjent z ciśnieniem 250 przy normie 120–140 to anomalia globalna; pacjent o typowych wartościach każdej cechy, ale nietypowym ich połączeniu – lokalna.

Tabela 15: Procent wykrytych anomalii globalnych i lokalnych (Liczba – anomalie danego typu zsumowane po częściach testowych wszystkich podziałów).

Zbiór danych	Typ	Liczba	IForest	LOF	COF	OCSVM	DBSCAN
Breastw	globalne	385	98	89	97	97	**100**
	lokalne	215	93	95	**100**	93	87
Mammography	globalne	50	96	**100**	96	**100**	**100**
	lokalne	600	20	16	11	**27**	17
Wine	globalne	6	**100**	**100**	**100**	**100**	**100**
	lokalne	84	40	60	42	**74**	68
Statlog Heart	globalne	9	**100**	**100**	**100**	**100**	**100**
	lokalne	51	22	**39**	33	33	33
Cardio	globalne	145	92	96	59	92	**100**
	lokalne	295	60	**79**	30	66	31



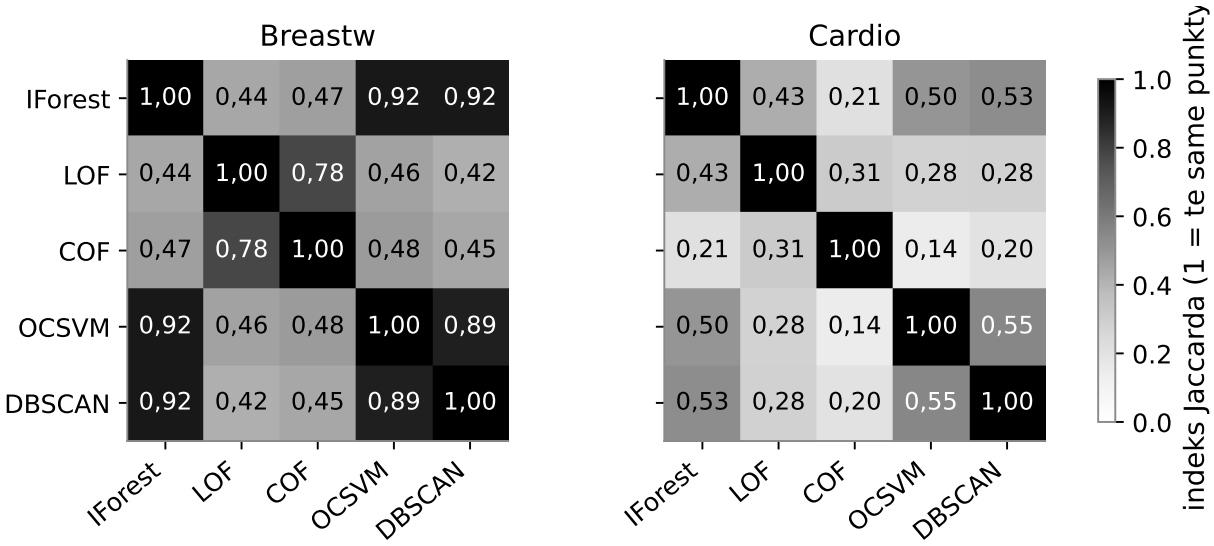
Rysunek 16: Anomalie globalne wykrywają wszystkie metody, lokalne – tylko niektóre.

Anomalie globalne wykrywa prawie każda metoda (89–100 %), a różnice dotyczą lokalnych: na Cardio LOF wykrywa ich 79 %, OCSVM 66 %, IForest 60 %, a DBSCAN i COF ok. 30 %. Na Mammography, gdzie 93 % anomalii jest lokalnych, żadna metoda nie przekracza 27 %, co tłumaczy niskie wyniki na tym zbiorze danych.

5.5 Zgodność wykrytych zbiorów

Tu sprawdzono, czy różne metody wskazują te same obserwacje.

Zgodność mierzymy *indeksem Jaccarda*: liczba obserwacji wskazanych przez obie metody podzielona przez liczbę obserwacji wskazanych przez którąkolwiek z nich (1 = te same punkty, 0 = zupełnie różne).

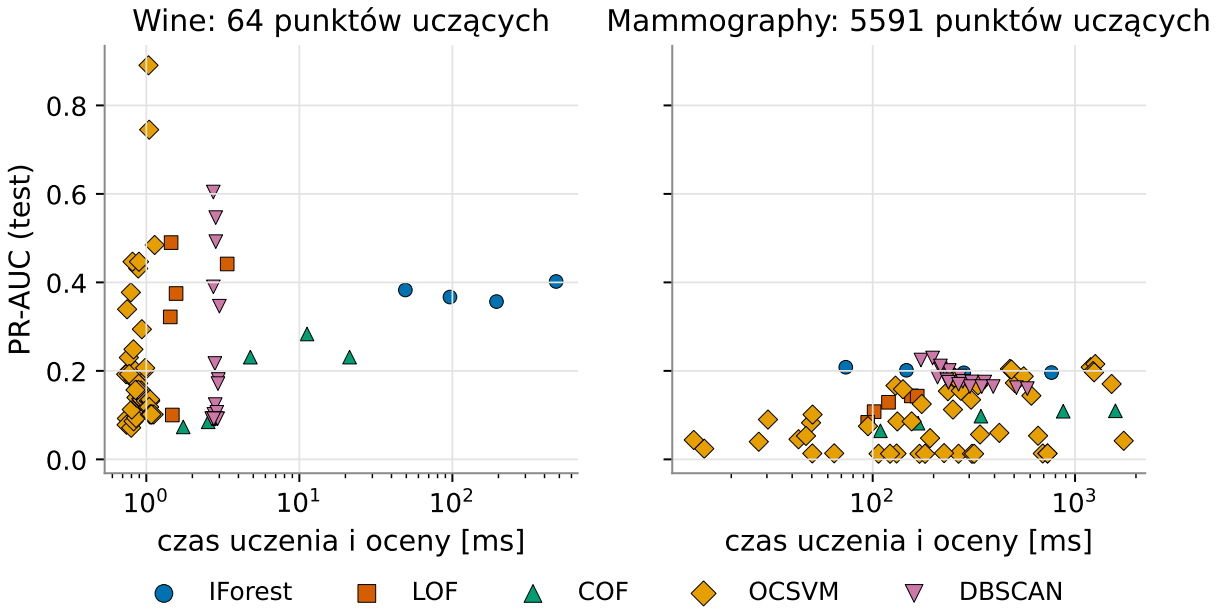


Rysunek 17: Metody tworzą dwie rodziny, które wskazują różne obserwacje.

IForest, OCSVM i DBSCAN wskazują w dużej mierze te same punkty (Breastw: 0,89–0,92), a LOF i COF – inne (z rodziną IForest tylko 0,42–0,48). Pierwsza rodzina patrzy na dane całościowo, druga porównuje punkt z sąsiadami. Na Cardio zgodność jest niższa (0,14–0,55), więc metody częściej popełniają różne błędy.

5.6 Jakość a czas działania

Ta część porównuje czas uczenia i oceny z jakością na małym i na dużym zbiorze danych.



Rysunek 18: Na małym zbiorze danych najszybsze są OCSVM i LOF, na dużym ich przewaga znika.

Na Wine OCSVM i LOF działają w ok. 1–2 ms, a IForest ok. 145 ms; na Mammography mediana czasu OCSVM rośnie do ok. 250 ms (maksymalnie 1,7 s), a IForest prawie się nie zmienia (ok. 210 ms). Koszt OCSVM rośnie szybciej niż liczba obserwacji, a IForest buduje każde drzewo na stałej próbce 256 punktów, więc przy dużych zbiorach danych zyskuje przewagę.

6 Wnioski

Najważniejsze wnioski z zadania, każdy poparty liczbami z sekcji 5.

1. **Żadna metoda nie jest najlepsza wszędzie.** OCSVM wygrywa na Cardio (PR-AUC 0,76) i Wine (0,89), DBSCAN na Breastw (0,99) i Mammography (0,23).
2. **Największy wpływ ma dopasowanie metody do typu anomalii.** Anomalie globalne wykrywa każda metoda (89–100 %); o wyniku decydują lokalne, które najlepiej wykrywa LOF (Cardio: 79 % wobec ok. 30 % dla DBSCAN i COF). Gdy anomalie tworzą duże skupisko (Breastw), LOF i COF zawodzą (0,43 i 0,35).
3. **Parametry są równie ważne jak wybór metody, ale nie we wszystkich metodach.** OCSVM na Wine daje od 0,07 do 0,89 PR-AUC zależnie od jądra i γ, LOF od 0,10 do 0,49 zależnie od k, a Isolation Forest zmienia się najwyżej o 0,045 – jest najbezpieczniejszy bez strojenia.

4. **Parametry progowe (c, ν, ε) ustalają liczbę zgłoszeń, a nie jakość rankingu.** Najlepsze F1 uzyskuje się, gdy odsetek zgłoszeń jest bliski prawdziwemu udziałowi anomalii.
5. **Accuracy nie nadaje się do oceny.** Na Mammography i Statlog Heart odpowiedź „wszystko normalne" ma wyższą Accuracy niż najlepszy detektor; podstawą oceny powinny być PR-AUC i F1.
6. **Metody tworzą dwie rodziny**: globalną (IForest, OCSVM, DBSCAN) i lokalną (LOF, COF), które wskazują różne obserwacje – to przesłanka do łączenia detektorów w zadaniu 3.
7. **Przy kilku anomaliach w teście metod nie da się porównać**: na Statlog Heart wszystkie mają 0,39–0,44 PR-AUC przy odchyleniu ok. 0,24 mimo 30 podziałów.

A Wyniki wszystkich ustawień

Tabele podają średnią PR-AUC i F1 (część testowa, F1 dla wbudowanej reguły metody: c, granicy OCSVM lub promienia ε) dla każdego sprawdzonego ustawienia.

Isolation Forest

Ustawienie	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
T=100, c=0,02	0,969	0,230	0,201	0,221	0,367	0,024	0,394	0,200	0,600	0,279
T=100, c=0,05	0,969	0,389	0,201	0,212	0,367	0,114	0,394	0,268	0,600	0,425
T=100, c=0,10	0,969	0,573	0,201	0,202	0,367	0,300	0,394	0,281	0,600	0,534
T=100, c=0,15	0,969	0,710	0,201	0,169	0,367	0,413	0,394	0,231	0,600	0,569
T=100, c=0,20	0,969	0,780	0,201	0,150	0,367	0,367	0,394	0,222	0,600	0,566
T=100, c=0,35	0,969	0,934	0,201	0,111	0,367	0,293	0,394	0,168	0,600	0,414
T=200, c=0,02	0,967	0,222	0,196	0,208	0,357	0,024	0,393	0,223	0,595	0,278
T=200, c=0,05	0,967	0,380	0,196	0,213	0,357	0,105	0,393	0,244	0,595	0,435
T=200, c=0,10	0,967	0,578	0,196	0,204	0,357	0,285	0,393	0,288	0,595	0,534
T=200, c=0,15	0,967	0,705	0,196	0,170	0,357	0,401	0,393	0,249	0,595	0,560
T=200, c=0,20	0,967	0,779	0,196	0,153	0,357	0,367	0,393	0,215	0,595	0,549
T=200, c=0,35	0,967	0,932	0,196	0,112	0,357	0,294	0,393	0,165	0,595	0,414
T=500, c=0,02	0,971	0,221	0,196	0,203	0,402	0,036	0,379	0,179	0,585	0,291
T=500, c=0,05	0,971	0,408	0,196	0,206	0,402	0,142	0,379	0,247	0,585	0,438
T=500, c=0,10	0,971	0,560	0,196	0,200	0,402	0,378	0,379	0,276	0,585	0,526
T=500, c=0,15	0,971	0,701	0,196	0,169	0,402	0,409	0,379	0,241	0,585	0,550
T=500, c=0,20	0,971	0,778	0,196	0,152	0,402	0,384	0,379	0,207	0,585	0,532
T=500, c=0,35	0,971	0,929	0,196	0,111	0,402	0,300	0,379	0,170	0,585	0,409
T=50, c=0,02	0,970	0,244	0,208	0,248	0,383	0,063	0,356	0,196	0,609	0,315
T=50, c=0,05	0,970	0,391	0,208	0,220	0,383	0,160	0,356	0,241	0,609	0,424
T=50, c=0,10	0,970	0,572	0,208	0,200	0,383	0,365	0,356	0,209	0,609	0,544
T=50, c=0,15	0,970	0,701	0,208	0,167	0,383	0,378	0,356	0,202	0,609	0,585
T=50, c=0,20	0,970	0,784	0,208	0,148	0,383	0,374	0,356	0,187	0,609	0,564
T=50, c=0,35	0,970	0,928	0,208	0,110	0,383	0,288	0,356	0,173	0,609	0,418

LOF

Ustawienie	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
k=10, c=0,02	0,305	0,000	0,108	0,189	0,322	0,017	0,383	0,178	0,175	0,104
k=10, c=0,05	0,305	0,000	0,108	0,175	0,322	0,028	0,383	0,293	0,175	0,146
k=10, c=0,10	0,305	0,017	0,108	0,136	0,322	0,147	0,383	0,317	0,175	0,173
k=10, c=0,15	0,305	0,056	0,108	0,117	0,322	0,283	0,383	0,274	0,175	0,184
k=10, c=0,20	0,305	0,078	0,108	0,103	0,322	0,360	0,383	0,225	0,175	0,188
k=10, c=0,35	0,305	0,229	0,108	0,077	0,322	0,385	0,383	0,165	0,175	0,191
k=20, c=0,02	0,321	0,012	0,129	0,229	0,490	0,084	0,400	0,188	0,190	0,113
k=20, c=0,05	0,321	0,053	0,129	0,196	0,490	0,152	0,400	0,334	0,190	0,147

Ustawienie	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
k=20, c=0,10	0,321	0,094	0,129	0,150	0,490	0,500	0,400	0,347	0,190	0,167
k=20, c=0,15	0,321	0,102	0,129	0,128	0,490	0,505	0,400	0,314	0,190	0,198
k=20, c=0,20	0,321	0,114	0,129	0,110	0,490	0,503	0,400	0,271	0,190	0,208
k=20, c=0,35	0,321	0,255	0,129	0,083	0,490	0,398	0,400	0,189	0,190	0,210
k=35, c=0,02	0,365	0,027	0,143	0,243	0,442	0,079	0,462	0,200	0,239	0,135
k=35, c=0,05	0,365	0,077	0,143	0,209	0,442	0,225	0,462	0,363	0,239	0,174
k=35, c=0,10	0,365	0,138	0,143	0,162	0,442	0,512	0,462	0,374	0,239	0,183
k=35, c=0,15	0,365	0,178	0,143	0,136	0,442	0,503	0,462	0,332	0,239	0,223
k=35, c=0,20	0,365	0,228	0,143	0,120	0,442	0,447	0,462	0,289	0,239	0,260
k=35, c=0,35	0,365	0,346	0,143	0,087	0,442	0,320	0,462	0,195	0,239	0,294
k=50, c=0,02	0,426	0,037	0,143	0,237	0,375	0,077	0,441	0,233	0,310	0,136
k=50, c=0,05	0,426	0,085	0,143	0,201	0,375	0,129	0,441	0,330	0,310	0,184
k=50, c=0,10	0,426	0,187	0,143	0,162	0,375	0,377	0,441	0,375	0,310	0,246
k=50, c=0,15	0,426	0,273	0,143	0,146	0,375	0,439	0,441	0,323	0,310	0,314
k=50, c=0,20	0,426	0,307	0,143	0,127	0,375	0,401	0,441	0,288	0,310	0,376
k=50, c=0,35	0,426	0,415	0,143	0,095	0,375	0,305	0,441	0,190	0,310	0,394
k=5, c=0,02	0,323	0,000	0,084	0,136	0,100	0,000	0,366	0,202	0,201	0,151
k=5, c=0,05	0,323	0,000	0,084	0,124	0,100	0,000	0,366	0,239	0,201	0,197
k=5, c=0,10	0,323	0,000	0,084	0,106	0,100	0,000	0,366	0,273	0,201	0,213
k=5, c=0,15	0,323	0,017	0,084	0,094	0,100	0,000	0,366	0,248	0,201	0,197
k=5, c=0,20	0,323	0,045	0,084	0,085	0,100	0,000	0,366	0,223	0,201	0,193
k=5, c=0,35	0,323	0,235	0,084	0,073	0,100	0,004	0,366	0,158	0,201	0,185

COF

Ustawienie	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
k=10, c=0,02	0,303	0,000	0,082	0,132	0,085	0,000	0,368	0,188	0,186	0,147
k=10, c=0,05	0,303	0,000	0,082	0,124	0,085	0,000	0,368	0,292	0,186	0,167
k=10, c=0,10	0,303	0,013	0,082	0,111	0,085	0,000	0,368	0,309	0,186	0,182
k=10, c=0,15	0,303	0,032	0,082	0,094	0,085	0,000	0,368	0,265	0,186	0,187
k=10, c=0,20	0,303	0,042	0,082	0,088	0,085	0,000	0,368	0,227	0,186	0,183
k=10, c=0,35	0,303	0,102	0,082	0,080	0,085	0,024	0,368	0,164	0,186	0,180
k=20, c=0,02	0,287	0,000	0,098	0,183	0,231	0,000	0,420	0,244	0,182	0,132
k=20, c=0,05	0,287	0,008	0,098	0,152	0,231	0,024	0,420	0,293	0,182	0,159
k=20, c=0,10	0,287	0,040	0,098	0,115	0,231	0,112	0,420	0,283	0,182	0,189
k=20, c=0,15	0,287	0,057	0,098	0,100	0,231	0,190	0,420	0,259	0,182	0,192
k=20, c=0,20	0,287	0,070	0,098	0,095	0,231	0,216	0,420	0,261	0,182	0,196
k=20, c=0,35	0,287	0,104	0,098	0,082	0,231	0,274	0,420	0,190	0,182	0,172
k=35, c=0,02	0,307	0,015	0,109	0,195	0,283	0,000	0,351	0,223	0,183	0,139
k=35, c=0,05	0,307	0,036	0,109	0,161	0,283	0,102	0,351	0,244	0,183	0,159
k=35, c=0,10	0,307	0,075	0,109	0,124	0,283	0,194	0,351	0,236	0,183	0,169
k=35, c=0,15	0,307	0,078	0,109	0,106	0,283	0,247	0,351	0,232	0,183	0,169
k=35, c=0,20	0,307	0,101	0,109	0,096	0,283	0,262	0,351	0,241	0,183	0,165
k=35, c=0,35	0,307	0,195	0,109	0,083	0,283	0,294	0,351	0,198	0,183	0,153
k=50, c=0,02	0,345	0,021	0,110	0,190	0,231	0,000	0,397	0,210	0,202	0,146
k=50, c=0,05	0,345	0,063	0,110	0,157	0,231	0,010	0,397	0,235	0,202	0,163
k=50, c=0,10	0,345	0,104	0,110	0,126	0,231	0,088	0,397	0,242	0,202	0,170
k=50, c=0,15	0,345	0,123	0,110	0,105	0,231	0,147	0,397	0,242	0,202	0,178
k=50, c=0,20	0,345	0,142	0,110	0,096	0,231	0,196	0,397	0,262	0,202	0,187
k=50, c=0,35	0,345	0,278	0,110	0,082	0,231	0,245	0,397	0,196	0,202	0,189
k=5, c=0,02	0,344	0,000	0,065	0,094	0,073	0,000	0,304	0,136	0,149	0,075
k=5, c=0,05	0,344	0,000	0,065	0,092	0,073	0,000	0,304	0,208	0,149	0,143
k=5, c=0,10	0,344	0,002	0,065	0,089	0,073	0,000	0,304	0,268	0,149	0,163
k=5, c=0,15	0,344	0,017	0,065	0,080	0,073	0,000	0,304	0,228	0,149	0,165
k=5, c=0,20	0,344	0,035	0,065	0,079	0,073	0,000	0,304	0,204	0,149	0,164
k=5, c=0,35	0,344	0,166	0,065	0,072	0,073	0,000	0,304	0,160	0,149	0,162

One-Class SVM

Ustawienie	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
poly, ν=0,01, γ=0,1/d	0,444	0,410	0,024	0,023	0,093	0,129	0,235	0,093	0,097	0,043
poly, ν=0,05, γ=0,1/d	0,394	0,340	0,014	0,012	0,078	0,076	0,213	0,090	0,083	0,024
poly, ν=0,10, γ=0,1/d	0,369	0,276	0,013	0,009	0,071	0,078	0,169	0,080	0,102	0,031
poly, ν=0,20, γ=0,1/d	0,362	0,251	0,013	0,005	0,086	0,094	0,204	0,075	0,103	0,039
poly, ν=0,50, γ=0,1/d	0,387	0,244	0,013	0,008	0,094	0,090	0,251	0,078	0,095	0,046
rbf, ν=0,01, γ=0,1/d	0,310	0,137	0,090	0,101	0,204	0,090	0,411	0,251	0,411	0,164
rbf, ν=0,05, γ=0,1/d	0,353	0,223	0,167	0,172	0,201	0,100	0,412	0,242	0,465	0,335
rbf, ν=0,10, γ=0,1/d	0,406	0,280	0,194	0,122	0,192	0,139	0,428	0,260	0,491	0,488
rbf, ν=0,20, γ=0,1/d	0,535	0,431	0,204	0,154	0,193	0,227	0,425	0,239	0,530	0,560
rbf, ν=0,50, γ=0,1/d	0,821	0,647	0,208	0,109	0,294	0,225	0,427	0,142	0,596	0,319
sigmoid, ν=0,01, γ=0,1/d	0,229	0,030	0,040	0,072	0,113	0,093	0,203	0,118	0,112	0,068
sigmoid, ν=0,05, γ=0,1/d	0,247	0,058	0,086	0,095	0,180	0,116	0,242	0,112	0,131	0,112
sigmoid, ν=0,10, γ=0,1/d	0,278	0,093	0,113	0,121	0,162	0,101	0,127	0,065	0,162	0,155
sigmoid, ν=0,20, γ=0,1/d	0,350	0,179	0,173	0,132	0,200	0,140	0,085	0,037	0,297	0,238
sigmoid, ν=0,50, γ=0,1/d	0,591	0,386	0,215	0,095	0,485	0,217	0,107	0,036	0,561	0,252
linear, ν=0,01	0,478	0,336	0,044	0,055	0,200	0,150	0,217	0,096	0,121	0,123
linear, ν=0,05	0,480	0,384	0,083	0,042	0,141	0,125	0,206	0,112	0,125	0,094
linear, ν=0,10	0,587	0,466	0,075	0,051	0,140	0,111	0,188	0,093	0,141	0,103
linear, ν=0,20	0,494	0,418	0,125	0,088	0,172	0,150	0,125	0,067	0,132	0,097
linear, ν=0,50	0,519	0,476	0,060	0,052	0,137	0,143	0,156	0,064	0,273	0,193
poly, ν=0,01, γ=1,0/d	0,422	0,276	0,013	0,007	0,131	0,113	0,284	0,090	0,116	0,077
poly, ν=0,05, γ=1,0/d	0,463	0,346	0,013	0,004	0,134	0,117	0,289	0,091	0,120	0,074
poly, ν=0,10, γ=1,0/d	0,455	0,329	0,013	0,004	0,134	0,118	0,289	0,091	0,121	0,071
poly, ν=0,20, γ=1,0/d	0,423	0,292	0,013	0,004	0,135	0,117	0,288	0,088	0,114	0,059
poly, ν=0,50, γ=1,0/d	0,379	0,221	0,013	0,008	0,118	0,108	0,275	0,078	0,101	0,048
rbf, ν=0,01, γ=1,0/d	0,548	0,452	0,101	0,132	0,156	0,170	0,420	0,163	0,377	0,386
rbf, ν=0,05, γ=1,0/d	0,546	0,458	0,158	0,149	0,157	0,171	0,420	0,163	0,382	0,382
rbf, ν=0,10, γ=1,0/d	0,552	0,487	0,185	0,184	0,157	0,170	0,420	0,163	0,399	0,428
rbf, ν=0,20, γ=1,0/d	0,650	0,618	0,203	0,133	0,157	0,178	0,423	0,163	0,421	0,453
rbf, ν=0,50, γ=1,0/d	0,908	0,800	0,200	0,078	0,207	0,217	0,416	0,132	0,536	0,318
sigmoid, ν=0,01, γ=1,0/d	0,228	0,034	0,045	0,031	0,230	0,077	0,090	0,023	0,159	0,100
sigmoid, ν=0,05, γ=1,0/d	0,263	0,096	0,086	0,127	0,193	0,072	0,084	0,011	0,253	0,284
sigmoid, ν=0,10, γ=1,0/d	0,304	0,151	0,135	0,113	0,249	0,165	0,066	0,024	0,437	0,407
sigmoid, ν=0,20, γ=1,0/d	0,409	0,269	0,144	0,154	0,431	0,286	0,111	0,050	0,620	0,443
sigmoid, ν=0,50, γ=1,0/d	0,641	0,411	0,170	0,084	0,745	0,315	0,223	0,096	0,763	0,302
poly, ν=0,01, γ=10,0/d	0,470	0,388	0,014	0,007	0,132	0,118	0,289	0,091	0,117	0,082
poly, ν=0,05, γ=10,0/d	0,487	0,401	0,013	0,004	0,132	0,118	0,289	0,091	0,120	0,074
poly, ν=0,10, γ=10,0/d	0,456	0,354	0,013	0,004	0,132	0,118	0,289	0,091	0,122	0,071
poly, ν=0,20, γ=10,0/d	0,424	0,305	0,013	0,004	0,135	0,117	0,288	0,088	0,114	0,059
poly, ν=0,50, γ=10,0/d	0,379	0,220	0,013	0,007	0,118	0,108	0,275	0,078	0,101	0,048
rbf, ν=0,01, γ=10,0/d	0,921	0,836	0,154	0,114	0,102	0,167	0,409	0,095	0,258	0,199
rbf, ν=0,05, γ=10,0/d	0,921	0,839	0,155	0,092	0,102	0,167	0,409	0,095	0,258	0,200
rbf, ν=0,10, γ=10,0/d	0,921	0,838	0,168	0,117	0,101	0,167	0,409	0,095	0,258	0,199
rbf, ν=0,20, γ=10,0/d	0,921	0,840	0,188	0,103	0,102	0,167	0,409	0,095	0,258	0,200
rbf, ν=0,50, γ=10,0/d	0,938	0,808	0,197	0,071	0,101	0,167	0,409	0,095	0,260	0,199
sigmoid, ν=0,01, γ=10,0/d	0,255	0,013	0,053	0,056	0,339	0,151	0,123	0,039	0,172	0,028
sigmoid, ν=0,05, γ=10,0/d	0,276	0,117	0,048	0,087	0,377	0,123	0,072	0,000	0,203	0,155
sigmoid, ν=0,10, γ=10,0/d	0,322	0,184	0,056	0,111	0,447	0,173	0,114	0,039	0,299	0,337
sigmoid, ν=0,20, γ=10,0/d	0,441	0,322	0,053	0,081	0,447	0,382	0,108	0,049	0,538	0,453
sigmoid, ν=0,50, γ=10,0/d	0,653	0,539	0,042	0,059	0,891	0,357	0,166	0,104	0,646	0,299

DBSCAN

Ustawienie	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
minPts=10, q_ε=0,50	0,986	0,880	0,205	0,091	0,604	0,528	0,433	0,234	0,485	0,311
minPts=20, q_ε=0,50	0,986	0,892	0,189	0,095	0,546	0,540	0,428	0,288	0,509	0,384
minPts=3, q_ε=0,50	0,984	0,829	0,225	0,083	0,217	0,146	0,414	0,154	0,329	0,227
minPts=5, q_ε=0,50	0,985	0,860	0,229	0,086	0,390	0,267	0,407	0,185	0,422	0,261
minPts=10, q_ε=0,75	0,933	0,501	0,201	0,159	0,492	0,423	0,424	0,336	0,429	0,454
minPts=20, q_ε=0,75	0,945	0,384	0,188	0,168	0,346	0,120	0,424	0,284	0,471	0,515
minPts=3, q_ε=0,75	0,932	0,724	0,186	0,129	0,093	0,000	0,406	0,256	0,334	0,311

Ustawienie	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
minPts=5, q_ε=0,75	0,935	0,618	0,211	0,145	0,102	0,008	0,427	0,302	0,387	0,403
minPts=10, q_ε=0,90	0,924	0,212	0,176	0,199	0,180	0,011	0,482	0,267	0,330	0,318
minPts=20, q_ε=0,90	0,926	0,189	0,175	0,215	0,171	0,000	0,496	0,189	0,368	0,307
minPts=3, q_ε=0,90	0,922	0,353	0,180	0,184	0,091	0,000	0,448	0,358	0,332	0,373
minPts=5, q_ε=0,90	0,921	0,273	0,174	0,195	0,092	0,000	0,475	0,330	0,325	0,358
minPts=10, q_ε=0,95	0,918	0,070	0,165	0,232	0,124	0,000	0,491	0,189	0,308	0,266
minPts=20, q_ε=0,95	0,929	0,067	0,175	0,263	0,106	0,000	0,484	0,189	0,321	0,247
minPts=3, q_ε=0,95	0,916	0,217	0,174	0,204	0,092	0,000	0,471	0,340	0,294	0,277
minPts=5, q_ε=0,95	0,915	0,121	0,170	0,223	0,092	0,000	0,492	0,276	0,326	0,286
minPts=10, q_ε=0,99	0,926	0,003	0,162	0,207	0,092	0,000	0,410	0,172	0,274	0,101
minPts=20, q_ε=0,99	0,926	0,000	0,160	0,164	0,092	0,000	0,410	0,083	0,256	0,093
minPts=3, q_ε=0,99	0,923	0,052	0,165	0,217	0,092	0,000	0,410	0,200	0,255	0,115
minPts=5, q_ε=0,99	0,921	0,026	0,165	0,217	0,092	0,000	0,410	0,211	0,273	0,124

Literatura

[1] S. Han, X. Hu, H. Huang, M. Jiang, Y. Zhao. *ADBench: Anomaly Detection Benchmark*. Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track, 2022. Repozytorium `https://github.com/Minqi824/ADBench`, commit `3dac822`.

[2] S. Rayana. *ODDS Library*. Stony Brook University, Department of Computer Science, 2016. `https://odds.cs.stonybrook.edu`.

[3] G. O. Campos, A. Zimek, J. Sander, R. J. G. B. Campello, B. Micenková, E. Schubert, I. Assent, M. E. Houle. *On the evaluation of unsupervised outlier detection: measures, datasets, and an empirical study*. Data Mining and Knowledge Discovery 30(4), 891–927, 2016. `https://www.dbs.ifi.lmu.de/research/outlier-evaluation/`.

[4] M. Kelly, R. Longjohn, K. Nottingham. *The UCI Machine Learning Repository*. University of California, Irvine. `https://archive.ics.uci.edu`.

[5] W. H. Wolberg, O. L. Mangasarian. *Multisurface method of pattern separation for medical diagnosis applied to breast cytology*. Proceedings of the National Academy of Sciences 87(23), 9193–9196, 1990. (UCI: Breast Cancer Wisconsin (Original)).

[6] W. N. Street, W. H. Wolberg, O. L. Mangasarian. *Nuclear feature extraction for breast tumor diagnosis*. IS&T/SPIE Symposium on Electronic Imaging: Science and Technology, vol. 1905, 861–870, 1993. (UCI: Breast Cancer Wisconsin (Diagnostic)).

[7] K. S. Woods, C. C. Doss, K. W. Bowyer, J. L. Solka, C. E. Priebe, W. P. Kegelmeyer. *Comparative evaluation of pattern recognition techniques for detection of microcalcifications in mammography*. International Journal of Pattern Recognition and Artificial Intelligence 7(6), 1417–1436, 1993.

[8] S. Aeberhard, M. Forina. *Wine*. UCI Machine Learning Repository, 1991.

[9] D. Ayres-de Campos, J. Bernardes, A. Garrido, J. Marques-de-Sá, L. Pereira-Leite. *SisPorto 2.0: a program for automated analysis of cardiotocograms*. Journal of Maternal-Fetal Medicine 9(5), 311–318, 2000. (UCI: Cardiotocography).

[10] S. Moro, P. Cortez, P. Rita. *A data-driven approach to predict the success of bank telemarketing*. Decision Support Systems 62, 22–31, 2014. (UCI: Bank Marketing).

[11] H. A. Güvenir, B. Acar, G. Demiröz, A. Çekin. *A supervised machine learning algorithm for arrhythmia analysis*. Computers in Cardiology 1997, 433–436. (UCI: Arrhythmia).

[12] *Statlog (Heart)*. UCI Machine Learning Repository.