Politechnika Łódzka
Wydział Fizyki Technicznej, Informatyki i Matematyki Stosowanej

Analiza danych złożonych z detekcją wyjątków

# Zadanie 1

Porównanie klasycznych metod detekcji wyjątków

Jędrzej Kostyk
nr indeksu 264339

Rok akademicki 2026/2027

# Spis treści

**1 Cel i zakres** **2**

**2 Dane** **2**

2.1 Wybrane zbiory i definicja anomalii . . . . . 2

2.2 Wstępna analiza danych . . . . . 3

**3 Protokół eksperymentalny** **4**

**4 Metody i badane hiperparametry** **5**

**5 Wyniki** **5**

5.1 Dlaczego Accuracy prowadzi do błędnych wniosków . . . . . 5

5.2 Wpływ hiperparametrów . . . . . 6

5.3 Porównanie najlepszych konfiguracji . . . . . 9

5.4 Wyjątki lokalne i globalne . . . . . 10

5.5 Zgodność zbiorów wykrytych wyjątków . . . . . 12

5.6 Kompromis jakość – czas . . . . . 13

**6 Dyskusja** **13**

**7 Wnioski** **15**

**8 Odtworzenie wyników** **15**

**A Wyniki wszystkich eksperymentów** **15**

# 1 Cel i zakres

Celem zadania jest porównanie pięciu klasycznych metod detekcji wyjątków o różnych mechanizmach działania: Isolation Forest (izolacja przez losowe podziały), Local Outlier Factor (lokalna gęstość), Connectivity-based Outlier Factor (lokalna spójność sąsiedztwa), One-Class SVM (granica obszaru danych w przestrzeni jądrowej) oraz DBSCAN (punkty szumu w klasteryzacji gęstościowej). Szczególną uwagę poświęcono wpływowi hiperparametrów na liczbę i rodzaj wykrywanych wyjątków, problemowi silnego niezbalansowania klas, różnicy między wyjątkami globalnymi i lokalnymi oraz zgodności zbiorów obserwacji wskazywanych przez poszczególne detektory.

Eksperymenty przeprowadzono na pięciu zbiorach danych (cztery rzeczywiste i jeden syntetyczny), przy 10 niezależnych podziałach danych, łącznie dla 115 konfiguracji hiperparametrów na zbiór (7000 przebiegów detektorów). Cały kod znajduje się w katalogach `common/` i `task1_classical/` repozytorium, a wszystkie tabele i wykresy raportu są generowane skryptami (sekcja 8).

# 2 Dane

## 2.1 Wybrane zbiory i definicja anomalii

Wybrano zbiory z listy dopuszczonych w kursie, inne niż podane przykłady:

- **Breast Cancer Wisconsin (Diagnostic)** – 569 guzów opisanych 30 cechami morfologicznymi jąder komórkowych (średnia, odchylenie i wartość najgorsza dla 10 wielkości). Klasa normalna: guzy łagodne (357), anomalie: guzy złośliwe (212).
- **Ionosphere** – 351 sygnałów radarowych odbitych od jonosfery, 34 atrybuty (17 par części rzeczywistej i urojonej funkcji autokorelacji). Atrybut 2 jest stały i został usunięty (zostaje 33 cech). Normalne: odbicia „good” (225), anomalie: „bad” (126).
- **Parkinsons** – 195 nagrań głosu opisanych 22 miarami akustycznymi (jitter, shimmer, HNR, miary nieliniowe). Klasą większościową są osoby chore (147), więc zgodnie z regułą „mniejszość = anomalia” anomaliami są nagrania osób zdrowych (48).
- **Glass Identification** – 214 próbek szkła opisanych współczynnikiem załamania i zawartością 8 pierwiastków. Zgodnie z przyjętą w literaturze konwencją (ODDS) anomalią jest klasa 6 – szkło stołowe (9 próbek, 4,2 %), pozostałe klasy są normalne.
- **Syntetyczny gaussowski** (30 wymiarów) – dane normalne to trzy klastry gaussowskie na losowej 4-wymiarowej podprzestrzeni liniowej (jeden gęsty, $\sigma = 0{,}35$, i dwa szerokie, $\sigma = 1{,}2$) z szumem izotropowym $\sigma = 0{,}15$. Dodano 100 anomalii trzech znanych typów: *globalne* (40, daleko od wszystkich danych), *lokalne* (30, w odległości 4–6 $\sigma$ od gęstego klastra – globalnie leżą w obszarze o typowej gęstości, ale są odstające względem swojego sąsiedztwa) i *podprzestrzenne* (30, typowe położenie w podprzestrzeni, ale przesunięte poza nią). Zbiór pozwala bezpośrednio mierzyć skuteczność wykrywania wyjątków lokalnych i globalnych.

Jeśli klasa mniejszościowa stanowi więcej niż 10 % danych, jest ona losowo podpróbkowana tak, aby anomalie stanowiły 10 % zbioru (stosowana w benchmarkach ADBench/ODDS praktyka tworzenia scenariusza detekcji wyjątków z danych klasyfikacyjnych). Podpróbkowanie wykonywane jest osobno dla każdego ziarna losowego, więc 10 powtórzeń eksperymentu obejmuje różne podzbiory anomalii, co zwiększa wiarygodność uśrednionych wyników.

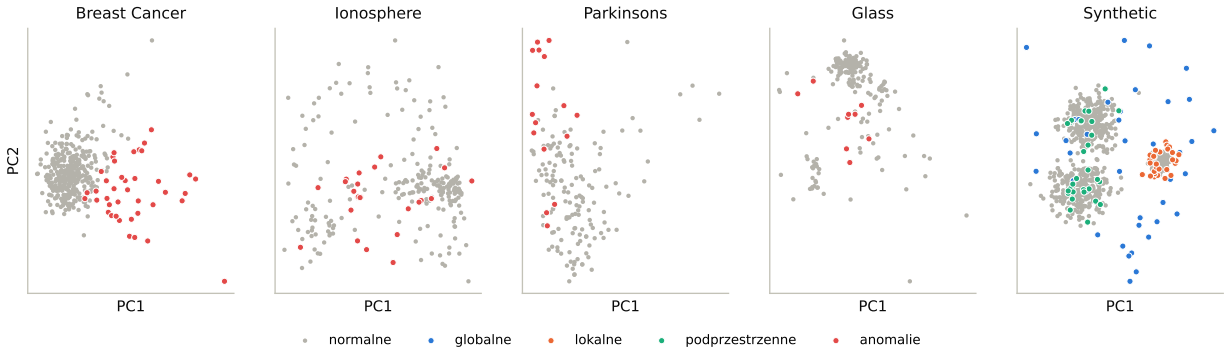
## 2.2 Wstępna analiza danych

Tabela 1 podsumowuje zbiory po przygotowaniu. Żaden zbiór nie zawiera braków danych, wszystkie cechy są ciągłe (jedyna cecha całkowitoliczbowa w Ionosphere jest binarna). Zbiory rzeczywiste mają silnie skośne rozkłady cech (średnia $|\gamma_1|$ do 2,4 w Breast Cancer – rys. 3) oraz bardzo silnie skorelowane cechy (maksymalna $|r|$ od 0,81 do 1,00; w Breast Cancer promień, obwód i pole są niemal liniowo zależne). Konsekwencją jest niska efektywna wymiarowość: 90 % wariancji wyjaśnia 6–10 składowych głównych. Odsetek wartości $|z| > 3$ (jednowymiarowe wartości odstające) wynosi 0,5–1,7 % – są one obecne także w klasie normalnej, więc jednowymiarowe reguły typu „3 sigma" nie wystarczą do identyfikacji anomalii.

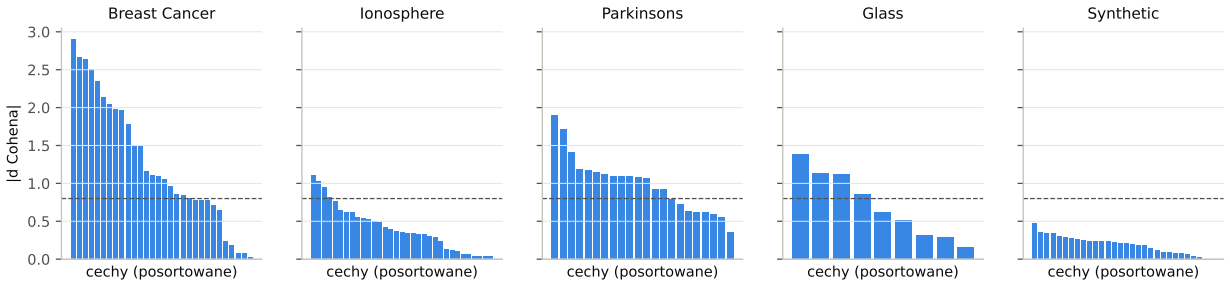
**Tabela 1:** Charakterystyka zbiorów (po podpróbkowaniu anomalii, ziarno 0). Oryg. klasy – liczności klasy normalnej i anomalnej przed podpróbkowaniem; $\overline{|\gamma_1|}$ – średnia bezwzględna skośność cech; $|z| > 3$ – odsetek wartości odstających jednowymiarowo; max $|r|$ – największa bezwzględna korelacja dwóch cech; PC 90 % – liczba składowych głównych wyjaśniających 90 % wariancji.

| Zbiór | $n$ | $d$ | Oryg. klasy (N/A) | Anomalie | Udział [%] | Braki | $\overline{\lvert\gamma_1\rvert}$ | $\lvert z\rvert > 3$ [%] | max $\lvert r\rvert$ | PC 90% |
|---|---|---|---|---|---|---|---|---|---|---|
| Breast Cancer | 397 | 30 | 357/212 | 40 | 10,1 | 0 | 2,39 | 1,64 | 1,00 | 7 |
| Ionosphere | 250 | 33 | 225/126 | 25 | 10,0 | 0 | 0,82 | 0,46 | 0,93 | 10 |
| Parkinsons | 163 | 22 | 147/48 | 16 | 9,8 | 0 | 1,60 | 1,37 | 1,00 | 6 |
| Glass | 214 | 9 | 205/9 | 9 | 4,2 | 0 | 2,06 | 1,71 | 0,81 | 6 |
| Synthetic | 1000 | 30 | 900/100 | 100 | 10,0 | 0 | 0,28 | 0,82 | 0,93 | 5 |

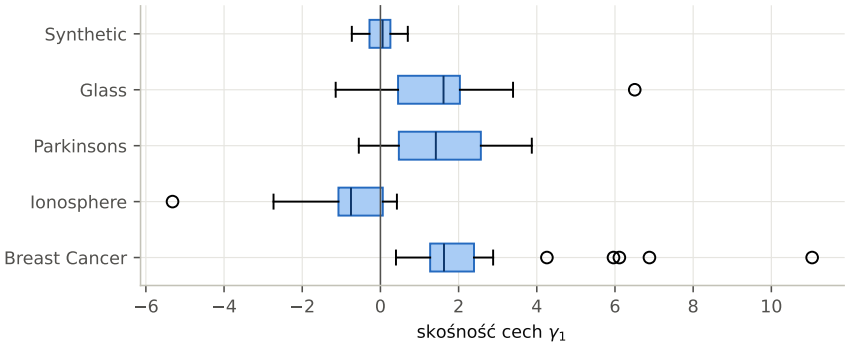
Rysunek 1 przedstawia rzut danych na dwie pierwsze składowe główne. W Breast Cancer i Ionosphere anomalie tworzą obszar przesunięty względem danych normalnych (choć w Ionosphere dane normalne same są rozproszone). W Parkinsons i Glass anomalie leżą wewnątrz chmury danych normalnych, co zapowiada trudność zadania. Potwierdza to rys. 2: w Breast Cancer kilkanaście cech ma duży efekt ($|d| > 0{,}8$), w Parkinsons i Glass jest ich tylko kilka, a w zbiorze syntetycznym żadna cecha osobno nie różnicuje klas – anomalie lokalne i podprzestrzenne są wykrywalne tylko wielowymiarowo.




**Rysunek 1:** Rzut zbiorów na dwie pierwsze składowe główne (dane standaryzowane). W zbiorze syntetycznym kolor oznacza typ anomalii.




**Rysunek 2:** Bezwzględna wartość $d$ Cohena (standaryzowana różnica średnich anomalii i obserwacji normalnych) dla kolejnych cech; linia przerywana – umowna granica dużego efektu (0,8).




**Rysunek 3:** Rozkład skośności cech w poszczególnych zbiorach.

# 3 Protokół eksperymentalny

1. **Podział danych.** Dla każdego zbioru i ziarna $s \in \{0, \ldots, 9\}$ dane dzielone są warstwowo na część uczącą, walidacyjną i testową w proporcji 50/25/25 %. Te same ziarna dają te same podziały we wszystkich trzech zadaniach.
2. **Przygotowanie.** Standaryzacja (`StandardScaler`) jest dopasowywana wyłącznie do części uczącej i stosowana do pozostałych części.
3. **Uczenie.** Detektory uczone są *bez etykiet* na części uczącej, która zawiera anomalie w naturalnej proporcji (scenariusz nienadzorowany). Każdy detektor zwraca wynik anomalii (wyższy = bardziej anomalny) dla nowych obserwacji.
4. **Strojenie.** Etykiety części walidacyjnej służą do wyboru konfiguracji (najwyższa średnia PR-AUC na walidacji, uśredniona po 10 podziałach) i progu decyzyjnego (maksymalizacja F1 na walidacji). Część testowa służy wyłącznie do końcowej oceny.
5. **Metryki.** Precision, Recall, F1 (dla klasy „anomalia”), ROC-AUC, PR-AUC (*average precision*), Accuracy (tylko do ilustracji jej wad) oraz czas uczenia i czas oceny części testowej. Raportowane są średnie (i odchylenia standardowe) z 10 podziałów.

Dla metod z parametrem `contamination` (IForest, LOF, COF) parametr ten nie zmienia wyniku anomalii, a jedynie próg: oznaczane jest $c{\cdot}100\,\%$ obserwacji uczących o najwyższym wyniku. Dlatego wszystkie wartości $c$ oceniane są na jednym wytrenowanym modelu. W przypadku OCSVM decyzja wynika z granicy SVM (sterowanej przez $\nu$), a w DBSCAN – z promienia $\varepsilon$. W tabelach siatki (dodatek A) Precision, Recall i F1 dotyczą tych „wbudowanych” reguł decyzyjnych, a w porównaniu najlepszych konfiguracji (sekcja 5.3) – progu wybranego na walidacji.

# 4 Metody i badane hiperparametry

**Isolation Forest.** Las $T$ drzew dzielących dane losowymi cięciami losowych cech; wynik anomalii zależy od średniej głębokości, na której obserwacja zostaje odizolowana. Punkty odległe od masy danych izolowane są po niewielu cięciach. Metoda patrzy na dane *globalnie* – cięcia osiowe nie „widzą" lokalnych różnic gęstości. Badano $T \in \{50, 100, 200, 500\}$ i $c \in \{0{,}02;\ 0{,}05;\ 0{,}1;\ 0{,}15;\ 0{,}2\}$.

**LOF.** Stosunek lokalnej gęstości osiągalności sąsiadów punktu do jego własnej gęstości. Wartości $\gg 1$ oznaczają punkt rzadszy niż jego otoczenie – miara jest *względna*, więc wykrywa wyjątki lokalne przy gęstych skupiskach. Badano $k \in \{5, 10, 20, 35, 50\}$ i te same wartości $c$. Użyto trybu `novelty=True`, który pozwala oceniać nowe dane.

**COF.** Wariant LOF, w którym gęstość zastąpiono *spójnością*: średnia odległość łańcuchowa (*average chaining distance*) wzdłuż ścieżki najbliższych połączeń (kolejność algorytmu Prima) w zbiorze $k$ sąsiadów. COF lepiej niż LOF radzi sobie z wzorcami o niskiej gęstości, ale regularnej strukturze (np. punkty ułożone wzdłuż linii). Implementacja została napisana od podstaw (`common/cof.py`), bo dostępne implementacje nie oceniają nowych danych; zgodność z definicją sprawdzono na naiwnej implementacji referencyjnej (różnica 0). Siatka jak dla LOF.

**One-Class SVM.** Wyznacza w przestrzeni cech jądra hiperpłaszczyznę oddzielającą dane od początku układu z maksymalnym marginesem; $\nu$ jest górnym ograniczeniem odsetka punktów uczących poza granicą (i dolnym ograniczeniem odsetka wektorów nośnych). Badano jądra RBF, wielomianowe (stopnia 3), sigmoidalne i liniowe, $\nu \in \{0{,}01;\ 0{,}05;\ 0{,}1;\ 0{,}2;\ 0{,}5\}$ oraz $\gamma \in \{0{,}1/d,\ 1/d,\ 10/d\}$ (50 konfiguracji).

**DBSCAN.** Punkty rdzeniowe mają co najmniej minPts sąsiadów w promieniu $\varepsilon$; punkty nieosiągalne z żadnego rdzenia są szumem (anomalią). Aby oceniać nowe dane, wynikiem anomalii jest odległość do najbliższego punktu rdzeniowego z części uczącej, a anomalią – punkt, dla którego odległość ta przekracza $\varepsilon$. Ponieważ skala odległości zależy od wymiaru i zbioru, $\varepsilon$ ustalano jako kwantyl $q_\varepsilon \in \{0{,}5;\ 0{,}75;\ 0{,}9;\ 0{,}95;\ 0{,}99\}$ rozkładu odległości do minPts-tego sąsiada (heurystyka wykresu $k$-odległości), minPts $\in \{3, 5, 10, 20\}$.

# 5 Wyniki

## 5.1 Dlaczego Accuracy prowadzi do błędnych wniosków

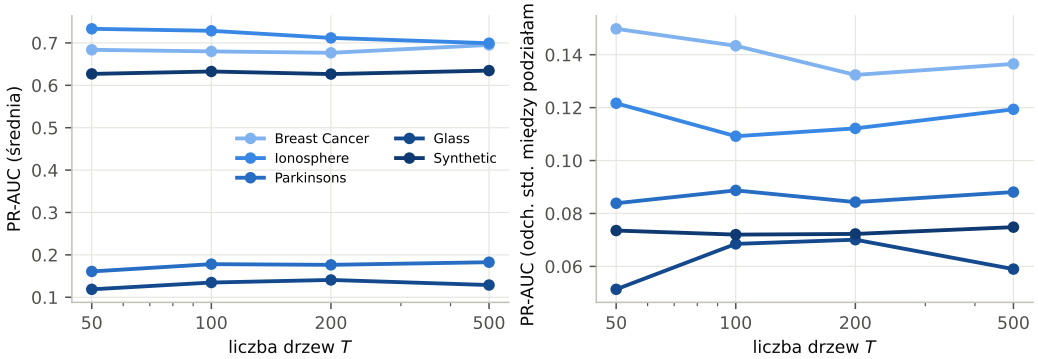
Tabela 2 zestawia trywialny klasyfikator „zawsze normalny" z najlepszym i najsłabszym (wg F1) detektorem. Klasyfikator trywialny osiąga Accuracy 0,90–0,96, nie wykrywając *żadnej* anomalii (Recall = F1 = 0). Na Glass jego Accuracy (0,956) jest *wyższa* niż najlepszego detektora (0,813), a na Breast Cancer różnica między najlepszym a najsłabszym detektorem to 0,05 w Accuracy, ale 0,16 w F1. Przy udziale anomalii $\pi$ Accuracy jest zdominowana przez klasę normalną: wykrycie wszystkich anomalii zmienia ją o co najwyżej $\pi$. Dlatego w dalszej analizie podstawą są PR-AUC (której wartość dla losowego rankingu wynosi $\pi$, a nie 0,5 jak dla ROC-AUC) oraz F1.

**Tabela 2:** Accuracy a jakość wykrywania anomalii (część testowa, średnie z 10 podziałów). „Losowy" – PR-AUC rankingu losowego (= udział anomalii).

| Zbiór | Udział anomalii | Acc. "zawsze normalny" | F1 / Recall | PR-AUC losowy | Acc. najlepszy (F1) | F1 najlepszy | Acc. najsłabszy (F1) | F1 najsłabszy |
|---|---|---|---|---|---|---|---|---|
| Breast Cancer | 0,100 | 0,900 | 0,000 / 0,000 | 0,100 | 0,938 (OCSVM) | 0,677 | 0,889 (COF) | 0,513 |
| Ionosphere | 0,102 | 0,898 | 0,000 / 0,000 | 0,102 | 0,962 (COF) | 0,799 | 0,924 (IForest) | 0,584 |
| Parkinsons | 0,098 | 0,902 | 0,000 / 0,000 | 0,098 | 0,715 (LOF) | 0,257 | 0,598 (DBSCAN) | 0,166 |
| Glass | 0,044 | 0,956 | 0,000 / 0,000 | 0,044 | 0,813 (COF) | 0,138 | 0,631 (IForest) | 0,083 |
| Synthetic | 0,100 | 0,900 | 0,000 / 0,000 | 0,100 | 0,965 (LOF) | 0,831 | 0,919 (IForest) | 0,521 |

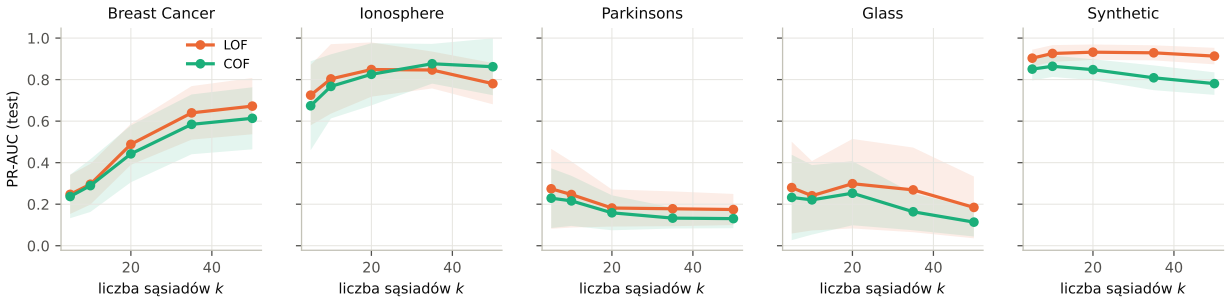
## 5.2 Wpływ hiperparametrów

**Isolation Forest – liczba drzew.** Liczba drzew praktycznie nie wpływa na średnią jakość (rys. 4; zmiany PR-AUC $\leq 0{,}035$), natomiast nieznacznie zmniejsza wariancję między podziałami (np. Breast Cancer: odchylenie 0,150 dla 50 drzew i 0,137 dla 500). Ponieważ czas uczenia rośnie liniowo z $T$, 100–200 drzew jest rozsądnym kompromisem. Różnice między zbiorami są o rząd wielkości większe niż różnice wynikające z $T$, co pokazuje, że ograniczeniem IForest jest jego mechanizm, a nie liczba drzew.




**Rysunek 4:** Isolation Forest: średnia i rozrzut PR-AUC w zależności od liczby drzew.

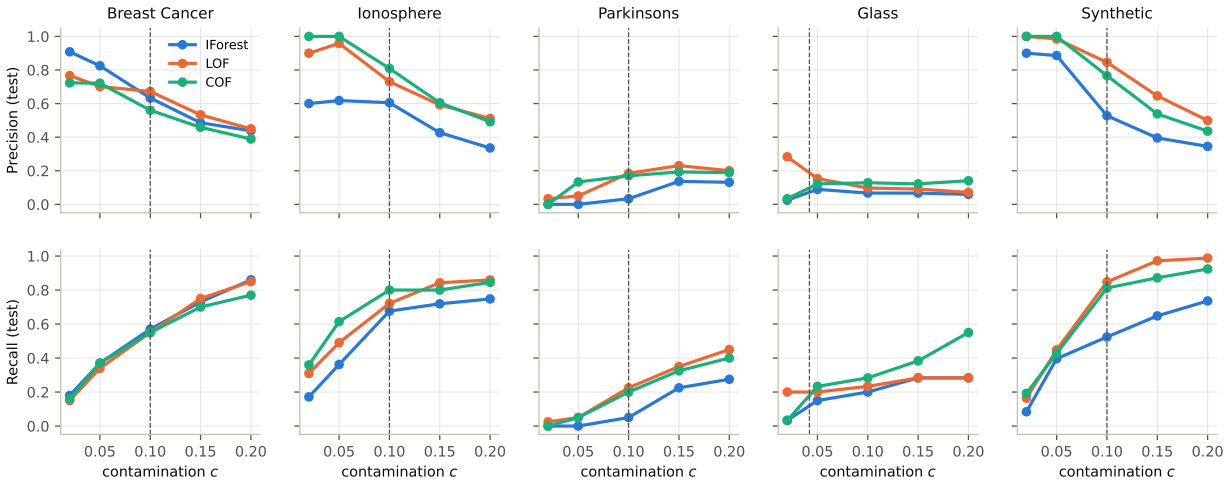
**LOF i COF – liczba sąsiadów.** Wpływ $k$ jest silny i zależy od struktury danych (rys. 5). W Breast Cancer PR-AUC LOF rośnie z 0,25 ($k = 5$) do 0,67 ($k = 50$): anomalie (guzy złośliwe) tworzą zwarte skupisko kilkunastu punktów, więc przy małym $k$ sąsiadami anomalii są inne anomalie i jej gęstość względna wydaje się normalna (efekt maskowania). Dopiero $k$ większe niż rozmiar skupiska anomalii pozwala je wykryć. W Parkinsons jest odwrotnie – najlepsze jest $k = 5$ (0,27), co sugeruje pojedyncze, lokalnie odstające nagrania. W zbiorze syntetycznym LOF jest stabilny w szerokim zakresie $k$ (0,90–0,93). COF zachowuje się podobnie, ale jest bardziej wrażliwy na zbyt duże $k$ (syntetyczny: spadek z 0,86 do 0,78), bo ścieżka łańcuchowa przy dużym $k$ „przechodzi" przez sąsiednie skupiska i zaciera lokalną strukturę.




**Rysunek 5:** LOF i COF: PR-AUC (część testowa) w funkcji liczby sąsiadów; pasy – ±1 odchylenie standardowe między podziałami.

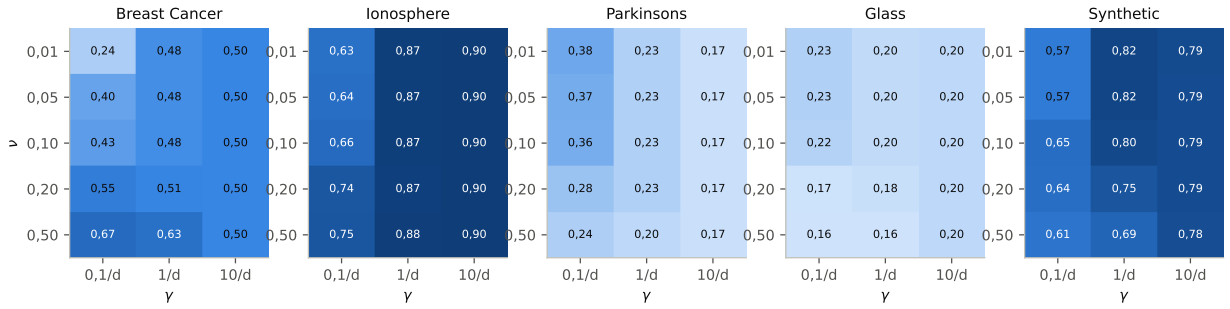
**Parametr `contamination`.** Parametr ten ustala odsetek oznaczanych obserwacji, a więc bezpośrednio steruje kompromisem Precision–Recall (rys. 6). Uśredniając po zbiorach, dla LOF wzrost $c$ z 0,02 do 0,20 podnosi Recall z 0,13 do 0,64, a Precision spada z 0,48 do 0,30; F1 jest największe w pobliżu rzeczywistego udziału anomalii ($c = 0{,}1$: F1 = 0,44 dla LOF, 0,42 dla COF, 0,38 dla IForest). Ważna obserwacja: contamination *nie zmienia* rankingu obserwacji (ROC-AUC i PR-AUC są stałe) – zmienia tylko, ile najwyżej ocenionych punktów nazywamy anomaliami. Przyjęcie $c$ mniejszego od rzeczywistego udziału daje wysoką precyzję i niski Recall

(detektor wskazuje tylko najbardziej oczywiste, zwykle globalne wyjątki), a większego – odwrotnie. W praktyce $c$ jest nieznane, dlatego w porównaniu metod próg wyznaczano na walidacji.

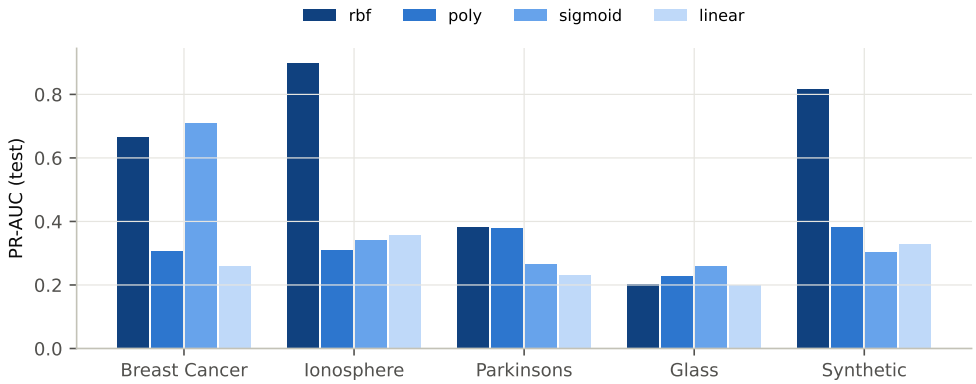



**Rysunek 6:** Precision i Recall (część testowa) w zależności od contamination dla najlepszych (wg walidacji) wartości $T$ i $k$; linia przerywana – rzeczywisty udział anomalii.

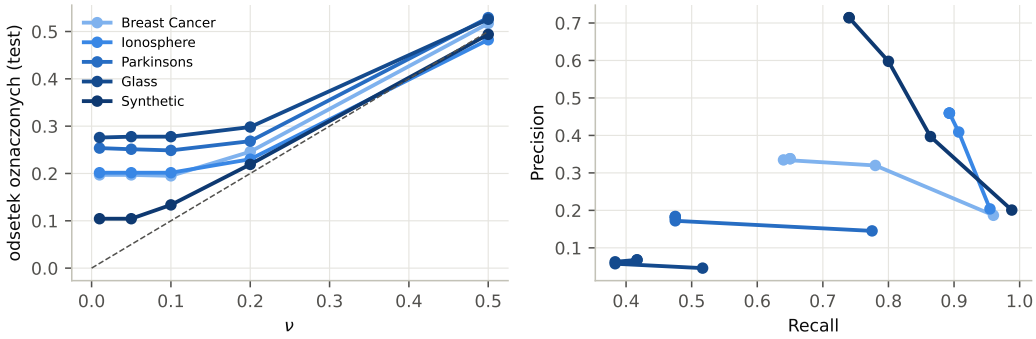
**One-Class SVM.** Kluczowe okazało się jądro i $\gamma$ (rys. 7 i 8). Jądro RBF jest najlepsze lub bliskie najlepszego na wszystkich zbiorach (Ionosphere: PR-AUC 0,90; syntetyczny: 0,82), natomiast jądro liniowe radzi sobie najsłabiej (0,20–0,36) – liniowa granica oddzielająca dane od początku układu nie może opisać skupisk ani obszarów niewypukłych. Jądro wielomianowe i sigmoidalne są niestabilne: sigmoidalne nie jest dodatnio określone, a wielomianowe mocno zależy od skali danych. Dla RBF $\gamma$ steruje „lokalnością" granicy: $\gamma = 10/d$ daje granicę ciasno opinającą dane (dobrą dla Ionosphere, w którym anomalie mieszają się z rozproszonymi danymi normalnymi), a $\gamma = 0{,}1/d$ – gładką, niemal eliptyczną granicę, dobrą dla Breast Cancer i Parkinsons. Parametr $\nu$ wpływa przede wszystkim na odsetek oznaczonych punktów (rys. 9): na danych testowych odsetek ten jest bliski $\nu$, zgodnie z interpretacją $\nu$ jako ograniczenia na odsetek punktów poza granicą. Przy małym $\gamma$ $\nu$ zmienia jednak także ranking: w Breast Cancer PR-AUC rośnie z 0,24 ($\nu = 0{,}01$) do 0,67 ($\nu = 0{,}5$), bo dopiero przy wielu wektorach nośnych granica „odcina" całe skupisko guzów złośliwych, a w zbiorze syntetycznym ($\gamma = 1/d$) maleje z 0,82 do 0,69. Przy $\gamma = 10/d$ wynik w ogóle nie zależy od $\nu$: jądro jest tak wąskie, że niemal każdy punkt staje się wektorem nośnym, a funkcja decyzyjna OCSVM sprowadza się do jądrowego estymatora gęstości (Parzena).




**Rysunek 7:** OCSVM z jądrem RBF: PR-AUC (część testowa) w zależności od $\nu$ i $\gamma$.

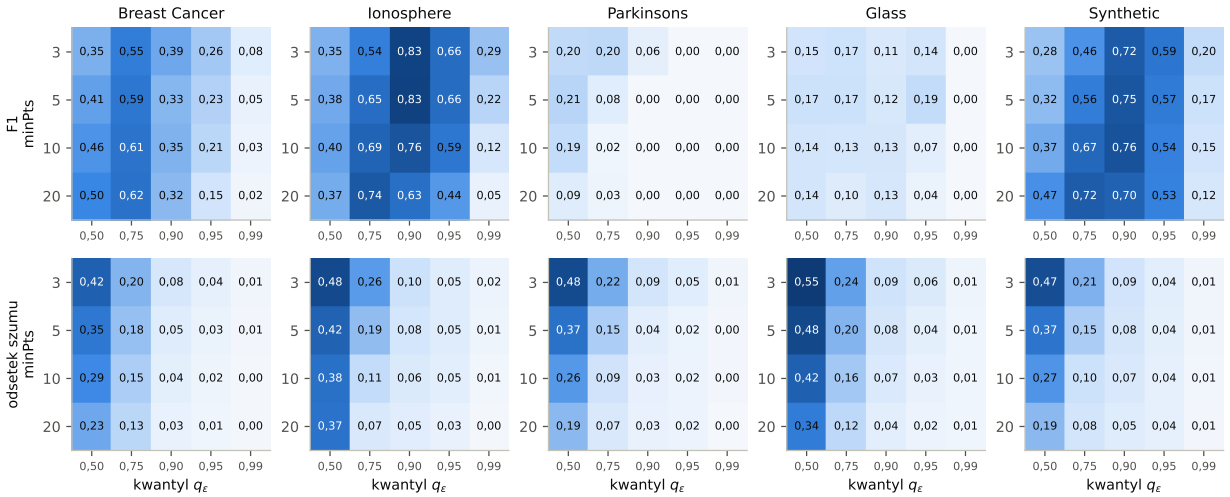



**Rysunek 8:** OCSVM: PR-AUC (część testowa) dla każdego jądra przy $\nu$ i $\gamma$ wybranych na walidacji.




**Rysunek 9:** OCSVM (RBF, $\gamma = 1/d$): odsetek oznaczonych punktów testowych w funkcji $\nu$ (linia przerywana – $y = \nu$) oraz kompromis Precision–Recall przy zmianie $\nu$.

**DBSCAN.** Rysunek 10 pokazuje, że w DBSCAN o wynikach decyduje przede wszystkim $\varepsilon$: odsetek punktów szumu maleje od 19–55 % dla $q_\varepsilon = 0{,}5$ do 0–2 % dla $q_\varepsilon = 0{,}99$, a F1 osiąga maksimum, gdy odsetek szumu zbliża się do udziału anomalii ($q_\varepsilon = 0{,}75$–$0{,}9$; Ionosphere F1 = 0,83, syntetyczny 0,76). Zależność od minPts jest słabsza, bo $\varepsilon$ jest wyznaczane jako kwantyl odległości do minPts-tego sąsiada – obie wielkości są ze sobą sprzężone. Większe minPts wymaga gęstszych rdzeni: pomaga, gdy anomalie tworzą małe skupiska (Breast Cancer: F1 rośnie z 0,55 dla minPts = 3 do 0,62 dla minPts = 20 przy $q_\varepsilon = 0{,}75$, bo skupisko guzów złośliwych przestaje tworzyć własny klaster), ale przy wysokich kwantylach $\varepsilon$ szkodzi. Wadą DBSCAN jest jeden globalny promień $\varepsilon$ – nie da się dobrać go jednocześnie do gęstego i rzadkiego skupiska.



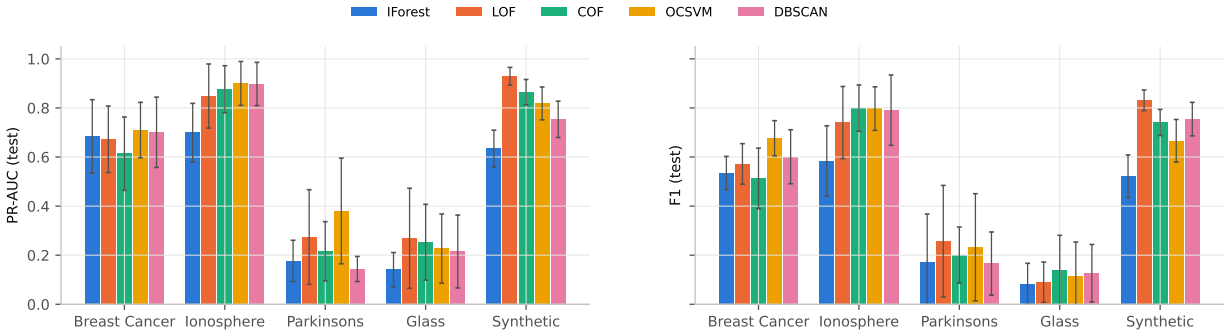

**Rysunek 10:** DBSCAN: F1 (górny wiersz) i odsetek punktów testowych uznanych za szum (dolny wiersz) w zależności od minPts i kwantyla $q_\varepsilon$ wyznaczającego $\varepsilon$.

## 5.3 Porównanie najlepszych konfiguracji

Tabela 3 i rys. 11 przedstawiają wyniki konfiguracji wybranych na walidacji, z progiem maksymalizującym F1 na walidacji.

**Tabela 3:** Najlepsze konfiguracje (wybór na walidacji wg PR-AUC, próg z walidacji wg F1); część testowa, średnia (± odchylenie std.) z 10 podziałów. Czas = uczenie + ocena części testowej. Pogrubienie – najlepsza metoda na zbiorze.

| Zbiór | Metoda | Konfiguracja | Prec. | Rec. | F1 | ROC-AUC | PR-AUC | Czas [ms] |
|---|---|---|---|---|---|---|---|---|
| Breast Cancer | IForest | $T$=50 | 0,538 | 0,610 | 0,535 ± 0,068 | 0,911 | 0,684 ± 0,150 | 54,5 |
| | LOF | $k$=50 | 0,548 | 0,650 | 0,572 ± 0,083 | 0,916 | 0,672 ± 0,136 | 7,9 |
| | COF | $k$=50 | 0,529 | 0,610 | 0,513 ± 0,123 | 0,890 | 0,614 ± 0,149 | 162,1 |
| | OCSVM | sigmoid, $\nu$=0,50, $\gamma$=1,0/$d$ | 0,776 | 0,630 | **0,677 ± 0,072** | 0,823 | **0,710 ± 0,113** | 4,0 |
| | DBSCAN | minPts=20, $q_\varepsilon$=0,75 | 0,594 | 0,650 | 0,601 ± 0,110 | 0,917 | 0,701 ± 0,143 | 5,2 |
| Ionosphere | IForest | $T$=500 | 0,684 | 0,576 | 0,584 ± 0,143 | 0,906 | 0,699 ± 0,119 | 455,8 |
| | LOF | $k$=20 | 0,786 | 0,748 | 0,741 ± 0,147 | 0,965 | 0,848 ± 0,131 | 7,0 |
| | COF | $k$=35 | 0,874 | 0,757 | **0,799 ± 0,094** | 0,964 | 0,876 ± 0,096 | 63,6 |
| | OCSVM | rbf, $\nu$=0,05, $\gamma$=10,0/$d$ | 0,842 | 0,781 | 0,797 ± 0,089 | 0,954 | **0,900 ± 0,089** | 2,0 |
| | DBSCAN | minPts=3, $q_\varepsilon$=0,90 | 0,931 | 0,729 | 0,791 ± 0,143 | 0,949 | 0,898 ± 0,088 | 6,5 |
| Parkinsons | IForest | $T$=200 | 0,123 | 0,325 | 0,172 ± 0,196 | 0,566 | 0,176 ± 0,084 | 187,6 |
| | LOF | $k$=5 | 0,198 | 0,475 | **0,257 ± 0,227** | 0,635 | 0,274 ± 0,193 | 2,7 |
| | COF | $k$=10 | 0,126 | 0,550 | 0,201 ± 0,114 | 0,609 | 0,216 ± 0,121 | 3,4 |
| | OCSVM | poly, $\nu$=0,01, $\gamma$=0,1/$d$ | 0,379 | 0,400 | 0,232 ± 0,218 | 0,642 | **0,380 ± 0,215** | 0,8 |
| | DBSCAN | minPts=3, $q_\varepsilon$=0,50 | 0,106 | 0,425 | 0,166 ± 0,129 | 0,519 | 0,144 ± 0,051 | 5,4 |
| Glass | IForest | $T$=200 | 0,046 | 0,500 | 0,083 ± 0,084 | 0,674 | 0,141 ± 0,070 | 175,8 |
| | LOF | $k$=35 | 0,049 | 0,567 | 0,090 ± 0,082 | 0,706 | **0,269 ± 0,204** | 2,0 |
| | COF | $k$=20 | 0,084 | 0,433 | **0,138 ± 0,143** | 0,809 | 0,253 ± 0,154 | 5,6 |
| | OCSVM | poly, $\nu$=0,05, $\gamma$=0,1/$d$ | 0,077 | 0,283 | 0,114 ± 0,140 | 0,784 | 0,227 ± 0,141 | 0,8 |
| | DBSCAN | minPts=3, $q_\varepsilon$=0,75 | 0,074 | 0,467 | 0,126 ± 0,117 | 0,735 | 0,215 ± 0,148 | 2,7 |
| Synthetic | IForest | $T$=500 | 0,722 | 0,440 | 0,521 ± 0,087 | 0,895 | 0,635 ± 0,075 | 460,9 |
| | LOF | $k$=35 | 0,814 | 0,864 | **0,831 ± 0,042** | 0,991 | **0,929 ± 0,036** | 14,6 |
| | COF | $k$=10 | 0,832 | 0,688 | 0,741 ± 0,053 | 0,969 | 0,864 ± 0,052 | 23,7 |
| | OCSVM | rbf, $\nu$=0,05, $\gamma$=1,0/$d$ | 0,785 | 0,624 | 0,666 ± 0,087 | 0,959 | 0,818 ± 0,067 | 3,7 |
| | DBSCAN | minPts=10, $q_\varepsilon$=0,95 | 0,911 | 0,648 | 0,755 ± 0,068 | 0,877 | 0,754 ± 0,074 | 12,1 |




**Rysunek 11:** PR-AUC i F1 najlepszych konfiguracji; słupki błędów – odchylenie standardowe między 10 podziałami.

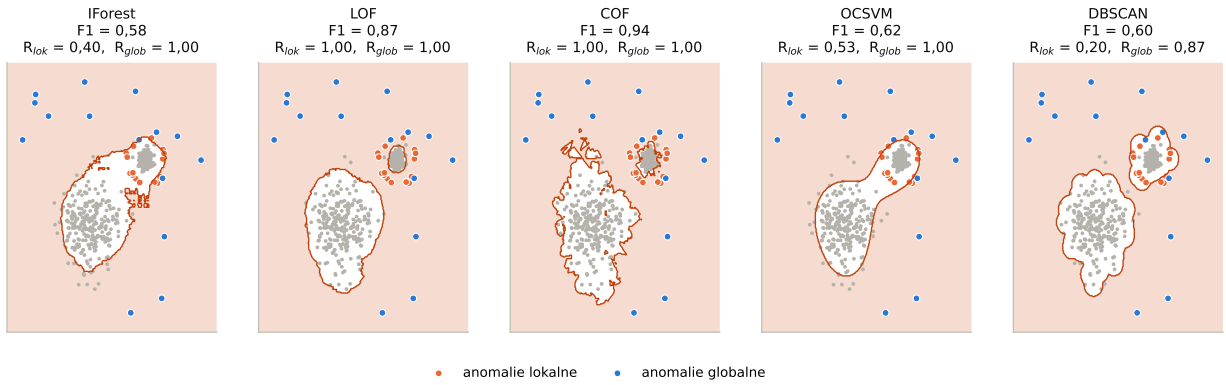
Nie ma metody najlepszej na wszystkich zbiorach. LOF wygrywa na zbiorze syntetycznym (PR-AUC 0,93, F1 0,83) i Parkinsons (F1 0,26), OCSVM na Breast Cancer (F1 0,68) i Ionosphere (PR-AUC 0,90), COF na Glass (F1 0,14) i Ionosphere (F1 0,80). Isolation Forest – mimo popularności – jest najsłabszy lub bliski najsłabszego wszędzie poza Breast Cancer. Odchylenia standardowe są duże (często 0,1–0,2), szczególnie na małych zbiorach Parkinsons i Glass, gdzie część testowa zawiera odpowiednio 4 i 2 anomalie – część różnic między metodami mieści się w rozrzucie między podziałami i nie należy ich nadinterpretować.

Na tle wysokich ROC-AUC (0,82–0,99 na Breast Cancer, Ionosphere i zbiorze syntetycznym) widać, dlaczego ROC-AUC jest metryką optymistyczną przy niezbalansowaniu: ROC-AUC = 0,91 dla IForest na Breast Cancer odpowiada PR-AUC = 0,68 i F1 = 0,54. Oś FPR na krzywej ROC jest normalizowana liczbą obserwacji normalnych (9 razy większą od liczby anomalii), więc kilkanaście fałszywych alarmów prawie nie obniża ROC-AUC, choć realnie oznacza, że co druga zgłoszona anomalia jest fałszywa. PR-AUC i Precision bezpośrednio pokazują ten koszt. Na Parkinsons ROC-AUC 0,52–0,64 jest bliskie losowemu, a PR-AUC 0,14–0,38 przy bazowym 0,10 – anomalie tego zbioru są praktycznie nieodróżnialne nienadzorowanymi metodami. Wynika to z definicji: „anomaliami” są tu osoby zdrowe, które nie są nietypowe w sensie rozkładu cech – reguła „mniejszość = anomalia” nie gwarantuje, że klasa mniejszościowa leży w obszarach niskiej gęstości. Podobnie w Glass szkło stołowe jest bliskie składem innym szkłom niebudowlanym.

Warto też zauważyć różnicę między siatką a wyborem na walidacji. Najlepsza na *teście* konfiguracja OCSVM na Breast Cancer osiąga PR-AUC 0,92 (sigmoidalne), a wybrana na walidacji – 0,71; dla RBF różnica wynosi 0,85 wobec 0,67. Część walidacyjna zawiera 10 anomalii (Breast Cancer) lub nawet 2–4 (Glass, Parkinsons), więc wybór hiperparametrów jest obarczony dużym szumem. Raportowanie maksimum z siatki na zbiorze testowym zawyżałoby wyniki – dlatego wszystkie porównania metod opierają się na wyborze walidacyjnym.

## 5.4 Wyjątki lokalne i globalne

Rysunek 12 pokazuje obszary decyzyjne na dwuwymiarowym przykładzie z gęstym i szerokim skupiskiem, pierścieniem anomalii lokalnych wokół gęstego skupiska i rozproszonymi anomaliami globalnymi (wszystkie metody oznaczają 10 % danych). Isolation Forest, OCSVM i DBSCAN wyznaczają *jeden* globalny obszar normalności, który obejmuje gęste skupisko razem z pierścieniem anomalii lokalnych (Recall lokalnych 0,40; 0,53; 0,20), bo w skali całego zbioru pierścień nie jest rzadszy niż szerokie skupisko. LOF i COF porównują gęstość punktu z gęstością jego sąsiadów, dzięki czemu wykrywają wszystkie anomalie lokalne (Recall 1,00), zachowując pełne wykrywanie globalnych.



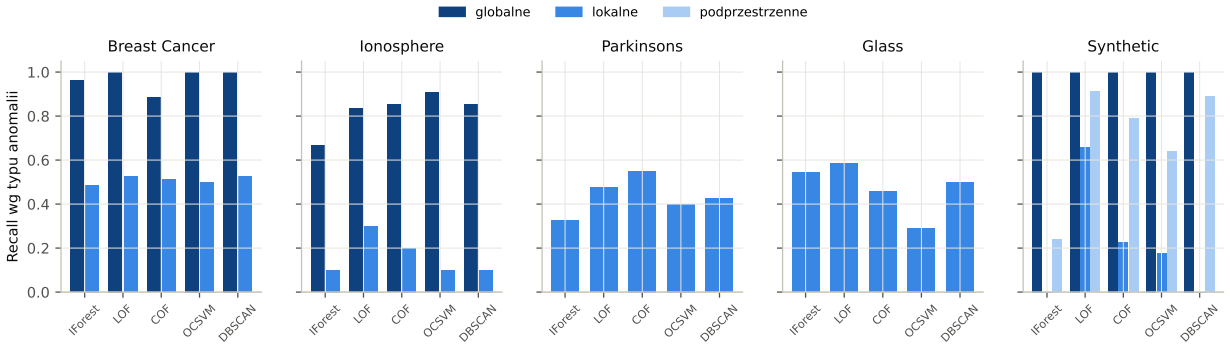

**Rysunek 12:** Obszary uznane za anomalne (kolor jasnopomarańczowy) na dwuwymiarowym przykładzie syntetycznym; $R_{lok}$, $R_{glob}$ – Recall anomalii lokalnych i globalnych.

W 30-wymiarowym zbiorze syntetycznym (tabela 4, rys. 13) wszystkie metody wykrywają 100 % anomalii globalnych. Anomalie lokalne wykrywa jedynie LOF (Recall 0,66); IForest i DBSCAN nie wykrywają ich wcale (0,00), COF i OCSVM w niewielkim stopniu (0,23 i 0,18). Anomalie podprzestrzenne (odchylenie poza 4-wymiarową podprzestrzeń danych) dobrze wykrywają metody odległościowe – LOF (0,91), DBSCAN (0,89), COF (0,79) – a słabo Isolation Forest (0,24): przesunięcie rozkłada się na 26 kierunków, a każde losowe cięcie osiowe widzi tylko jedną cechę, w której przesunięcie jest małe. To konkretna słabość IForest w danych o skorelowanych cechach.

Dla zbiorów rzeczywistych typ anomalii nie jest znany, więc przyjęto definicję operacyjną: anomalia jest *globalna*, jeśli jej odporna odległość Mahalanobisa od klasy normalnej (estymator MCD) przekracza 99. percentyl odległości obserwacji normalnych, a w przeciwnym razie *lokalna* (leży wewnątrz globalnej „otoczki” danych normalnych). W Breast Cancer i Ionosphere anomalie globalne są wykrywane niemal w całości (0,67–1,00), a lokalne w dużo mniejszym stopniu (0,10–0,53). W Parkinsons i Glass *wszystkie* anomalie są w tym sensie lokalne, co wyjaśnia słabe wyniki wszystkich metod na tych zbiorach. Najlepsze wyniki dla anomalii lokalnych osiągają LOF i COF, co jest zgodne z ich konstrukcją.

**Tabela 4:** Recall według typu anomalii (część testowa, suma po 10 podziałach; $n$ – liczba anomalii danego typu w częściach testowych).

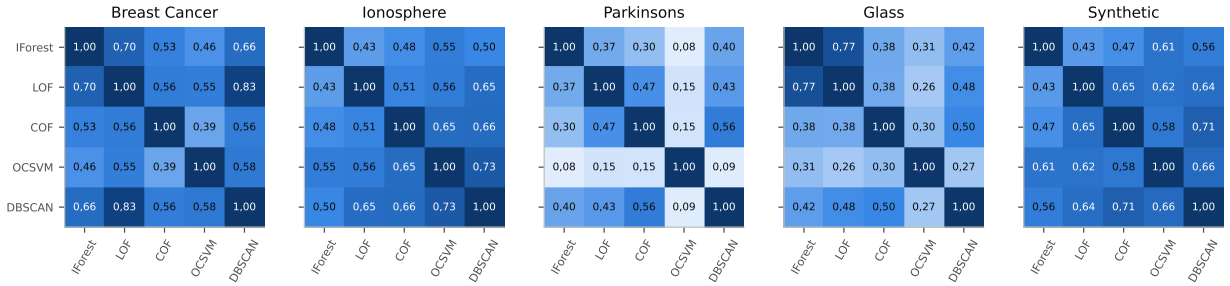
| Zbiór | Typ | $n$ (10 pow.) | IForest | LOF | COF | OCSVM | DBSCAN |
|---|---|---|---|---|---|---|---|
| Breast Cancer | globalne | 26 | 0,962 | **1,000** | 0,885 | **1,000** | **1,000** |
| | lokalne | 74 | 0,486 | **0,527** | 0,514 | 0,500 | **0,527** |
| Ionosphere | globalne | 54 | 0,667 | 0,833 | 0,852 | **0,907** | 0,852 |
| | lokalne | 10 | 0,100 | **0,300** | 0,200 | 0,100 | 0,100 |
| Parkinsons | lokalne | 40 | 0,325 | 0,475 | **0,550** | 0,400 | 0,425 |
| Glass | lokalne | 24 | 0,542 | **0,583** | 0,458 | 0,292 | 0,500 |
| Synthetic | globalne | 91 | **1,000** | **1,000** | **1,000** | **1,000** | **1,000** |
| | lokalne | 79 | 0,000 | **0,658** | 0,228 | 0,177 | 0,000 |
| | podprzestrzenne | 80 | 0,237 | **0,912** | 0,787 | 0,637 | 0,887 |




**Rysunek 13:** Recall według typu anomalii dla najlepszych konfiguracji.

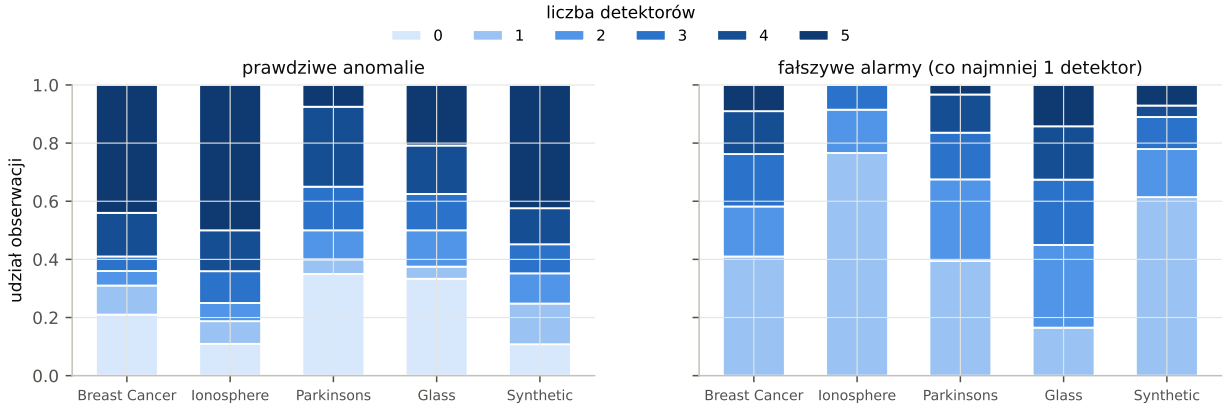
## 5.5 Zgodność zbiorów wykrytych wyjątków

Zgodność zbiorów obserwacji oznaczonych przez detektory zmierzono indeksem Jaccarda $J(A, B) = |A \cap B|/|A \cup B|$ (rys. 14, średnia z 10 podziałów). Średnia zgodność par wynosi 0,57–0,59 w Breast Cancer, Ionosphere i zbiorze syntetycznym, ale tylko 0,30 w Parkinsons i 0,41 w Glass – gdy problem jest trudny, detektory „zgadują" różnie. Najbardziej zgodne są metody o podobnym mechanizmie: LOF–DBSCAN w Breast Cancer (0,83), OCSVM–DBSCAN w Ionosphere (0,73) i COF–DBSCAN w zbiorze syntetycznym (0,71) – wszystkie trzy opierają się na odległościach do sąsiadów. Najmniej zgodny z resztą jest zwykle Isolation Forest (np. IForest–LOF 0,43 w Ionosphere i w zbiorze syntetycznym), co wynika z jego odmiennego, osiowego mechanizmu.




**Rysunek 14:** Indeks Jaccarda zbiorów obserwacji testowych oznaczonych jako anomalie przez pary detektorów (średnia z 10 podziałów).

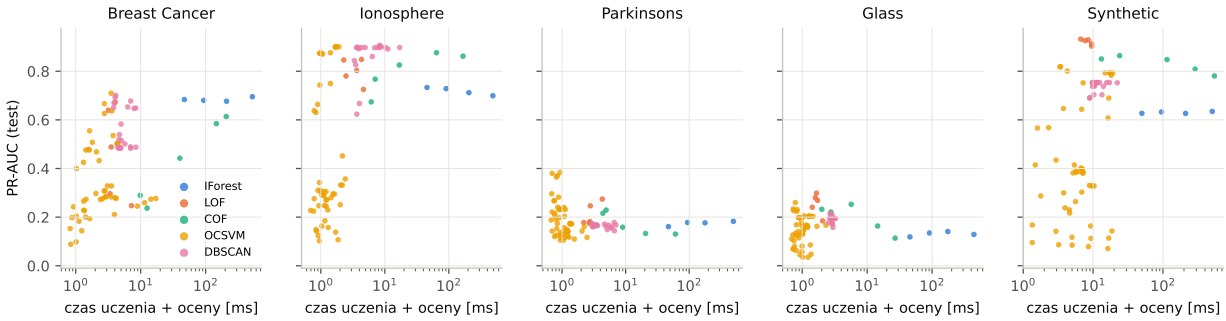
Rysunek 15 pokazuje, iloma detektorami wskazywana jest każda prawdziwa anomalia i każdy fałszywy alarm. Prawdziwe anomalie są zwykle wskazywane wspólnie: 42–50 % anomalii w Breast Cancer, Ionosphere i zbiorze syntetycznym wskazuje wszystkie pięć metod. Jednocześnie 11–21 % anomalii nie wykrywa żaden detektor (33–35 % w Glass i Parkinsons) – tych obserwacji nie uratuje żadna kombinacja detektorów. Fałszywe alarmy są natomiast w większości *indywidualne*: 77 % fałszywych alarmów w Ionosphere i 61 % w zbiorze syntetycznym zgłasza tylko jeden detektor. Obserwacje wykrywane wyłącznie przez jedną metodę to głównie anomalie lokalne wskazywane przez LOF (29 takich przypadków w zbiorze syntetycznym) i COF. Ta asymetria – błędy indywidualne, trafienia wspólne – jest przesłanką, że głosowanie detektorów może poprawić precyzję; zostanie to zbadane w zadaniu 3.




**Rysunek 15:** Rozkład liczby detektorów (spośród 5) wskazujących prawdziwe anomalie (lewo) oraz fałszywe alarmy wskazane przez co najmniej jeden detektor (prawo); część testowa, 10 podziałów.

### 5.6 Kompromis jakość – czas

Rysunek 16 zestawia czas (uczenie + ocena części testowej) z PR-AUC dla wszystkich konfiguracji. Najszybsze są OCSVM (mediana 1–6 ms) i LOF (2–8 ms) – przy kilkuset obserwacjach koszt $O(n^2)$ jest pomijalny. DBSCAN kosztuje 3–10 ms. COF jest wyraźnie wolniejszy (6–110 ms), bo dla każdego punktu buduje ścieżkę łańcuchową w czasie $O(k^2)$; jego koszt rośnie szybko z $k$ i $n$. Isolation Forest jest najwolniejszy (ok. 140 ms) – jego koszt zależy głównie od liczby drzew, a nie od $n$, więc ma przewagę dopiero przy dużych zbiorach (złożoność liniowa względem $n$, podczas gdy LOF/COF/DBSCAN wymagają wyszukiwania sąsiadów, a OCSVM – rozwiązania problemu kwadratowego o złożoności $O(n^2)$–$O(n^3)$). W badanym zakresie (do 1000 obserwacji) najkorzystniejszy stosunek jakości do czasu mają LOF i OCSVM z jądrem RBF.




**Rysunek 16:** Czas uczenia i oceny a PR-AUC (część testowa) dla wszystkich konfiguracji siatki (średnie z 10 podziałów).

## 6 Dyskusja

**Dlaczego algorytmy zachowują się inaczej?** Różnice wynikają z tego, *co* każda metoda uznaje za nietypowe.

- **Isolation Forest** mierzy łatwość izolacji osiowymi cięciami w skali całego zbioru. Jest skuteczny dla wyjątków globalnych i ekstremalnych wartości pojedynczych cech, ale ślepy na wyjątki lokalne (Recall 0,00 w zbiorze syntetycznym) i słaby dla odchyleń rozłożonych na wiele skorelowanych cech (anomalie podprzestrzenne: 0,24).
- **LOF** porównuje gęstość punktu z gęstością sąsiadów, więc wykrywa wyjątki lokalne przy gęstych skupiskach. Ceną jest wrażliwość na $k$: za małe $k$ prowadzi do maskowania skupisk

anomalii (Breast Cancer), za duże zaciera lokalność.

- **COF** zastępuje gęstość spójnością ścieżki; w danych bez wyraźnych struktur liniowych daje wyniki zbliżone do LOF, ale jest wolniejszy i bardziej czuły na duże $k$.
- **OCSVM** wyznacza jedną granicę dla całego zbioru; z jądrem RBF i odpowiednim $\gamma$ może być bardzo skuteczny (Ionosphere), ale wynik silnie zależy od $\gamma$ i jądra, a granica jest globalna – wyjątki lokalne przy gęstym skupisku pozostają wewnątrz niej.
- **DBSCAN** daje wysoką precyzję na zbiorach z wyraźnie odseparowanymi anomaliami (0,59–0,93), bo za szum uznaje tylko punkty rzeczywiście odizolowane, ale jeden globalny promień nie pasuje jednocześnie do skupisk o różnej gęstości (Recall lokalnych 0,00).

**Wpływ parametrów na rodzaj wykrywanych wyjątków.** Parametry progowe (contamination, $\nu$, $\varepsilon$) decydują o *liczbie* wykrywanych wyjątków i przesuwają kompromis Precision–Recall. Ich zmniejszanie sprawia, że detektor zgłasza tylko najbardziej oczywiste, zwykle globalne wyjątki. Parametry kształtujące wynik ($k$ w LOF/COF, $\gamma$ i jądro w OCSVM, minPts w DBSCAN) decydują o *rodzaju* wykrywanych wyjątków – o skali, na której definiowana jest „normalność". Małe $k$ lub duże $\gamma$ czynią detektor lokalnym (wykrywa odchylenia od najbliższego otoczenia, ale też maskuje małe skupiska anomalii), a duże $k$ lub małe $\gamma$ – globalnym.

**Interpretacja metryk przy niezbalansowaniu.** Przy 4–10 % anomalii Accuracy jest bezużyteczna (tabela 2), a ROC-AUC optymistyczna, bo fałszywe alarmy są normalizowane dużą liczbą obserwacji normalnych. PR-AUC odnosi się do bazowego poziomu $\pi$ i bezpośrednio uwzględnia koszt fałszywych alarmów, dlatego użyto jej do wyboru konfiguracji. Precision i Recall zależą od progu, więc porównując metody trzeba ustalić wspólną regułę wyboru progu (tu: maksymalizacja F1 na walidacji). F1 traktuje oba rodzaje błędów symetrycznie; w zastosowaniach (np. diagnostyka) należałoby dobrać próg do kosztu pominięcia anomalii.

**Ograniczenia.**

- Małe zbiory: części testowe Glass i Parkinsons zawierają 2 i 4 anomalie, części walidacyjne – tyle samo, więc wybór hiperparametrów i progu jest obarczony dużą wariancją (por. różnica 0,92 a 0,71 PR-AUC dla OCSVM). Uśrednianie po 10 podziałach łagodzi, ale nie usuwa tego problemu.
- Anomalie zdefiniowane jako klasa mniejszościowa nie muszą być „wyjątkami" w sensie rozkładu (Parkinsons, Glass) – ocena mierzy wtedy zgodność anomalii statystycznych z klasą, a nie jakość detektora w ogóle.
- Podział anomalii rzeczywistych na globalne i lokalne opiera się na przyjętej definicji (MCD, 99. percentyl); inna definicja zmieniłaby proporcje typów.
- Siatki hiperparametrów są skończone; DBSCAN był parametryzowany kwantylem $\varepsilon$, a OCSVM – względnym $\gamma$.
- Pomiary czasu dotyczą małych zbiorów (do 1000 obserwacji), na których stałe narzuty implementacji dominują nad złożonością asymptotyczną.

**Kierunki dalszych badań.** Ocena na większych zbiorach (skalowanie czasu), analiza wpływu reprezentacji danych (zadanie 2), łączenie detektorów, które – jak pokazała analiza zgodności – popełniają w dużej mierze różne błędy (zadanie 3), oraz metody półnadzorowane wykorzystujące niewielką liczbę etykiet z walidacji.

# 7 Wnioski

1. Żadna metoda nie dominuje: LOF jest najlepszy, gdy występują wyjątki lokalne (syntetyczny: PR-AUC 0,93), OCSVM z jądrem RBF i DBSCAN – gdy anomalie są globalnie odseparowane (Ionosphere: 0,90). Isolation Forest był najsłabszy na większości zbiorów.
2. O tym, *jakie* wyjątki są wykrywane, decyduje mechanizm metody: metody globalne (IForest, OCSVM, DBSCAN) nie wykrywają wyjątków lokalnych przy gęstych skupiskach (Recall 0,00–0,18), a metody lokalne (LOF, COF) tak.
3. Najważniejsze hiperparametry to $k$ (LOF/COF), $\gamma$ i jądro (OCSVM) oraz $\varepsilon$ (DBSCAN); liczba drzew w IForest ma znikomy wpływ. Contamination, $\nu$ i $\varepsilon$ sterują kompromisem Precision–Recall.
4. Przy niezbalansowaniu Accuracy jest myląca (trywialny klasyfikator osiąga 0,90–0,96), a ROC-AUC optymistyczna; podstawą oceny powinny być PR-AUC i F1.
5. Trafienia detektorów są w większości wspólne, a fałszywe alarmy indywidualne – to przesłanka do budowy zespołu detektorów (zadanie 3).
6. Jakość detekcji bardziej zależy od zbioru (tego, czy anomalie są wyjątkami w sensie rozkładu) niż od wyboru algorytmu: rozrzut PR-AUC między zbiorami (0,14–0,93) jest kilkukrotnie większy niż między metodami na tym samym zbiorze.

# 8 Odtworzenie wyników

```
python -m task1_classical.eda                # tabela 1, rys. 1-3
python -m task1_classical.run_grid           # siatka -> results/task1/grid.csv
python -m task1_classical.run_best           # najlepsze konfiguracje
python -m task1_classical.decision_regions   # rys. obszarów decyzyjnych
python -m task1_classical.analyze            # pozostałe tabele i rysunki
```

# A Wyniki wszystkich eksperymentów

Tabele zawierają średnie z 10 podziałów (część testowa) dla każdej konfiguracji. F1 dotyczy wbudowanej reguły decyzyjnej metody (contamination $c$, granica OCSVM lub promień $\varepsilon$ DBSCAN).

### Isolation Forest

| Konfiguracja | Breast Cancer | | Ionosphere | | Parkinsons | | Glass | | Synthetic | |
|---|---|---|---|---|---|---|---|---|---|---|
| | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 |
| $T$=100, $c$=0,02 | 0,680 | 0,292 | 0,729 | 0,268 | 0,178 | 0,000 | 0,135 | 0,029 | 0,633 | 0,136 |
| $T$=100, $c$=0,05 | 0,680 | 0,459 | 0,729 | 0,503 | 0,178 | 0,000 | 0,135 | 0,113 | 0,633 | 0,522 |
| $T$=100, $c$=0,10 | 0,680 | 0,604 | 0,729 | 0,591 | 0,178 | 0,085 | 0,135 | 0,094 | 0,633 | 0,534 |
| $T$=100, $c$=0,15 | 0,680 | 0,605 | 0,729 | 0,521 | 0,178 | 0,155 | 0,135 | 0,079 | 0,633 | 0,486 |
| $T$=100, $c$=0,20 | 0,680 | 0,579 | 0,729 | 0,464 | 0,178 | 0,158 | 0,135 | 0,096 | 0,633 | 0,462 |
| $T$=200, $c$=0,02 | 0,677 | 0,305 | 0,712 | 0,286 | 0,176 | 0,000 | 0,141 | 0,029 | 0,626 | 0,142 |
| $T$=200, $c$=0,05 | 0,677 | 0,436 | 0,712 | 0,474 | 0,176 | 0,000 | 0,141 | 0,110 | 0,626 | 0,535 |
| $T$=200, $c$=0,10 | 0,677 | 0,559 | 0,712 | 0,582 | 0,176 | 0,040 | 0,141 | 0,098 | 0,626 | 0,530 |
| $T$=200, $c$=0,15 | 0,677 | 0,602 | 0,712 | 0,499 | 0,176 | 0,168 | 0,141 | 0,107 | 0,626 | 0,490 |
| $T$=200, $c$=0,20 | 0,677 | 0,589 | 0,712 | 0,473 | 0,176 | 0,177 | 0,141 | 0,097 | 0,626 | 0,456 |
| $T$=500, $c$=0,02 | 0,695 | 0,305 | 0,699 | 0,264 | 0,183 | 0,000 | 0,129 | 0,029 | 0,635 | 0,150 |
| $T$=500, $c$=0,05 | 0,695 | 0,459 | 0,699 | 0,419 | 0,183 | 0,000 | 0,129 | 0,113 | 0,635 | 0,538 |
| $T$=500, $c$=0,10 | 0,695 | 0,613 | 0,699 | 0,595 | 0,183 | 0,093 | 0,129 | 0,100 | 0,635 | 0,523 |
| $T$=500, $c$=0,15 | 0,695 | 0,606 | 0,699 | 0,522 | 0,183 | 0,154 | 0,129 | 0,089 | 0,635 | 0,490 |

| Konfiguracja | Breast Cancer | | Ionosphere | | Parkinsons | | Glass | | Synthetic | |
|---|---|---|---|---|---|---|---|---|---|---|
| | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 |
| $T$=500, $c$=0,20 | 0,695 | 0,584 | 0,699 | 0,459 | 0,183 | 0,175 | 0,129 | 0,102 | 0,635 | 0,468 |
| $T$=50, $c$=0,02 | 0,684 | 0,292 | 0,733 | 0,272 | 0,161 | 0,000 | 0,119 | 0,000 | 0,627 | 0,173 |
| $T$=50, $c$=0,05 | 0,684 | 0,505 | 0,733 | 0,520 | 0,161 | 0,000 | 0,119 | 0,084 | 0,627 | 0,529 |
| $T$=50, $c$=0,10 | 0,684 | 0,593 | 0,733 | 0,616 | 0,161 | 0,069 | 0,119 | 0,104 | 0,627 | 0,502 |
| $T$=50, $c$=0,15 | 0,684 | 0,578 | 0,733 | 0,558 | 0,161 | 0,142 | 0,119 | 0,089 | 0,627 | 0,493 |
| $T$=50, $c$=0,20 | 0,684 | 0,575 | 0,733 | 0,495 | 0,161 | 0,181 | 0,119 | 0,083 | 0,627 | 0,463 |

## LOF

| Konfiguracja | Breast Cancer | | Ionosphere | | Parkinsons | | Glass | | Synthetic | |
|---|---|---|---|---|---|---|---|---|---|---|
| | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 |
| $k$=10, $c$=0,02 | 0,296 | 0,099 | 0,803 | 0,369 | 0,247 | 0,000 | 0,241 | 0,000 | 0,926 | 0,292 |
| $k$=10, $c$=0,05 | 0,296 | 0,204 | 0,803 | 0,619 | 0,247 | 0,022 | 0,241 | 0,107 | 0,926 | 0,609 |
| $k$=10, $c$=0,10 | 0,296 | 0,244 | 0,803 | 0,675 | 0,247 | 0,130 | 0,241 | 0,180 | 0,926 | 0,823 |
| $k$=10, $c$=0,15 | 0,296 | 0,280 | 0,803 | 0,657 | 0,247 | 0,211 | 0,241 | 0,196 | 0,926 | 0,730 |
| $k$=10, $c$=0,20 | 0,296 | 0,299 | 0,803 | 0,613 | 0,247 | 0,257 | 0,241 | 0,205 | 0,926 | 0,601 |
| $k$=20, $c$=0,02 | 0,488 | 0,158 | 0,848 | 0,438 | 0,182 | 0,000 | 0,299 | 0,145 | 0,932 | 0,280 |
| $k$=20, $c$=0,05 | 0,488 | 0,228 | 0,848 | 0,623 | 0,182 | 0,036 | 0,299 | 0,182 | 0,932 | 0,600 |
| $k$=20, $c$=0,10 | 0,488 | 0,353 | 0,848 | 0,711 | 0,182 | 0,101 | 0,299 | 0,205 | 0,932 | 0,846 |
| $k$=20, $c$=0,15 | 0,488 | 0,503 | 0,848 | 0,686 | 0,182 | 0,157 | 0,299 | 0,149 | 0,932 | 0,753 |
| $k$=20, $c$=0,20 | 0,488 | 0,522 | 0,848 | 0,634 | 0,182 | 0,191 | 0,299 | 0,131 | 0,932 | 0,638 |
| $k$=35, $c$=0,02 | 0,640 | 0,224 | 0,846 | 0,401 | 0,178 | 0,000 | 0,269 | 0,230 | 0,929 | 0,269 |
| $k$=35, $c$=0,05 | 0,640 | 0,359 | 0,846 | 0,653 | 0,178 | 0,000 | 0,269 | 0,172 | 0,929 | 0,606 |
| $k$=35, $c$=0,10 | 0,640 | 0,557 | 0,846 | 0,728 | 0,178 | 0,106 | 0,269 | 0,134 | 0,929 | 0,843 |
| $k$=35, $c$=0,15 | 0,640 | 0,596 | 0,846 | 0,702 | 0,178 | 0,110 | 0,269 | 0,135 | 0,929 | 0,774 |
| $k$=35, $c$=0,20 | 0,640 | 0,569 | 0,846 | 0,598 | 0,178 | 0,176 | 0,269 | 0,113 | 0,929 | 0,662 |
| $k$=50, $c$=0,02 | 0,672 | 0,244 | 0,780 | 0,392 | 0,174 | 0,000 | 0,185 | 0,107 | 0,913 | 0,258 |
| $k$=50, $c$=0,05 | 0,672 | 0,452 | 0,780 | 0,677 | 0,174 | 0,000 | 0,185 | 0,169 | 0,913 | 0,580 |
| $k$=50, $c$=0,10 | 0,672 | 0,596 | 0,780 | 0,637 | 0,174 | 0,018 | 0,185 | 0,099 | 0,913 | 0,819 |
| $k$=50, $c$=0,15 | 0,672 | 0,617 | 0,780 | 0,568 | 0,174 | 0,134 | 0,185 | 0,098 | 0,913 | 0,766 |
| $k$=50, $c$=0,20 | 0,672 | 0,584 | 0,780 | 0,505 | 0,174 | 0,172 | 0,185 | 0,090 | 0,913 | 0,658 |
| $k$=5, $c$=0,02 | 0,247 | 0,094 | 0,725 | 0,295 | 0,274 | 0,029 | 0,280 | 0,000 | 0,903 | 0,288 |
| $k$=5, $c$=0,05 | 0,247 | 0,157 | 0,725 | 0,548 | 0,274 | 0,050 | 0,280 | 0,117 | 0,903 | 0,635 |
| $k$=5, $c$=0,10 | 0,247 | 0,221 | 0,725 | 0,619 | 0,274 | 0,197 | 0,280 | 0,222 | 0,903 | 0,807 |
| $k$=5, $c$=0,15 | 0,247 | 0,225 | 0,725 | 0,606 | 0,274 | 0,270 | 0,280 | 0,144 | 0,903 | 0,701 |
| $k$=5, $c$=0,20 | 0,247 | 0,252 | 0,725 | 0,556 | 0,274 | 0,276 | 0,280 | 0,144 | 0,903 | 0,595 |

## COF

| Konfiguracja | Breast Cancer | | Ionosphere | | Parkinsons | | Glass | | Synthetic | |
|---|---|---|---|---|---|---|---|---|---|---|
| | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 |
| $k$=10, $c$=0,02 | 0,289 | 0,153 | 0,767 | 0,380 | 0,216 | 0,000 | 0,221 | 0,000 | 0,864 | 0,310 |
| $k$=10, $c$=0,05 | 0,289 | 0,211 | 0,767 | 0,459 | 0,216 | 0,069 | 0,221 | 0,194 | 0,864 | 0,591 |
| $k$=10, $c$=0,10 | 0,289 | 0,279 | 0,767 | 0,683 | 0,216 | 0,175 | 0,221 | 0,172 | 0,864 | 0,785 |
| $k$=10, $c$=0,15 | 0,289 | 0,269 | 0,767 | 0,624 | 0,216 | 0,236 | 0,221 | 0,190 | 0,864 | 0,664 |
| $k$=10, $c$=0,20 | 0,289 | 0,254 | 0,767 | 0,590 | 0,216 | 0,251 | 0,221 | 0,176 | 0,864 | 0,591 |
| $k$=20, $c$=0,02 | 0,442 | 0,210 | 0,826 | 0,407 | 0,159 | 0,000 | 0,253 | 0,033 | 0,848 | 0,311 |
| $k$=20, $c$=0,05 | 0,442 | 0,292 | 0,826 | 0,581 | 0,159 | 0,022 | 0,253 | 0,158 | 0,848 | 0,599 |
| $k$=20, $c$=0,10 | 0,442 | 0,356 | 0,826 | 0,732 | 0,159 | 0,096 | 0,253 | 0,172 | 0,848 | 0,756 |
| $k$=20, $c$=0,15 | 0,442 | 0,424 | 0,826 | 0,664 | 0,159 | 0,107 | 0,253 | 0,184 | 0,848 | 0,697 |
| $k$=20, $c$=0,20 | 0,442 | 0,443 | 0,826 | 0,592 | 0,159 | 0,115 | 0,253 | 0,219 | 0,848 | 0,622 |
| $k$=35, $c$=0,02 | 0,585 | 0,268 | 0,876 | 0,506 | 0,133 | 0,000 | 0,164 | 0,087 | 0,809 | 0,290 |
| $k$=35, $c$=0,05 | 0,585 | 0,420 | 0,876 | 0,745 | 0,133 | 0,029 | 0,164 | 0,121 | 0,809 | 0,572 |
| $k$=35, $c$=0,10 | 0,585 | 0,540 | 0,876 | 0,795 | 0,133 | 0,051 | 0,164 | 0,110 | 0,809 | 0,726 |
| $k$=35, $c$=0,15 | 0,585 | 0,539 | 0,876 | 0,684 | 0,133 | 0,088 | 0,164 | 0,165 | 0,809 | 0,662 |
| $k$=35, $c$=0,20 | 0,585 | 0,511 | 0,876 | 0,618 | 0,133 | 0,101 | 0,164 | 0,166 | 0,809 | 0,600 |
| $k$=50, $c$=0,02 | 0,614 | 0,254 | 0,862 | 0,411 | 0,130 | 0,000 | 0,114 | 0,075 | 0,781 | 0,291 |
| $k$=50, $c$=0,05 | 0,614 | 0,479 | 0,862 | 0,781 | 0,130 | 0,000 | 0,114 | 0,069 | 0,781 | 0,561 |
| $k$=50, $c$=0,10 | 0,614 | 0,541 | 0,862 | 0,783 | 0,130 | 0,033 | 0,114 | 0,067 | 0,781 | 0,666 |

| Konfiguracja | Breast Cancer | | Ionosphere | | Parkinsons | | Glass | | Synthetic | |
|---|---|---|---|---|---|---|---|---|---|---|
| | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 |
| $k$=50, $c$=0,15 | 0,614 | 0,551 | 0,862 | 0,722 | 0,130 | 0,043 | 0,114 | 0,089 | 0,781 | 0,628 |
| $k$=50, $c$=0,20 | 0,614 | 0,515 | 0,862 | 0,600 | 0,130 | 0,053 | 0,114 | 0,110 | 0,781 | 0,588 |
| $k$=5, $c$=0,02 | 0,237 | 0,140 | 0,674 | 0,386 | 0,229 | 0,040 | 0,232 | 0,050 | 0,851 | 0,313 |
| $k$=5, $c$=0,05 | 0,237 | 0,182 | 0,674 | 0,475 | 0,229 | 0,119 | 0,232 | 0,209 | 0,851 | 0,601 |
| $k$=5, $c$=0,10 | 0,237 | 0,248 | 0,674 | 0,615 | 0,229 | 0,192 | 0,232 | 0,180 | 0,851 | 0,756 |
| $k$=5, $c$=0,15 | 0,237 | 0,216 | 0,674 | 0,606 | 0,229 | 0,220 | 0,232 | 0,144 | 0,851 | 0,650 |
| $k$=5, $c$=0,20 | 0,237 | 0,220 | 0,674 | 0,544 | 0,229 | 0,224 | 0,232 | 0,105 | 0,851 | 0,580 |

## One-Class SVM

| Konfiguracja | Breast Cancer | | Ionosphere | | Parkinsons | | Glass | | Synthetic | |
|---|---|---|---|---|---|---|---|---|---|---|
| | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 |
| poly, $\nu$=0,01, $\gamma$=0,1/$d$ | 0,198 | 0,105 | 0,227 | 0,185 | 0,380 | 0,178 | 0,127 | 0,082 | 0,415 | 0,174 |
| poly, $\nu$=0,05, $\gamma$=0,1/$d$ | 0,229 | 0,110 | 0,276 | 0,171 | 0,142 | 0,147 | 0,227 | 0,086 | 0,435 | 0,175 |
| poly, $\nu$=0,10, $\gamma$=0,1/$d$ | 0,226 | 0,105 | 0,247 | 0,178 | 0,125 | 0,122 | 0,168 | 0,075 | 0,414 | 0,184 |
| poly, $\nu$=0,20, $\gamma$=0,1/$d$ | 0,194 | 0,099 | 0,310 | 0,180 | 0,120 | 0,135 | 0,134 | 0,072 | 0,402 | 0,204 |
| poly, $\nu$=0,50, $\gamma$=0,1/$d$ | 0,273 | 0,109 | 0,289 | 0,187 | 0,118 | 0,125 | 0,162 | 0,079 | 0,329 | 0,189 |
| rbf, $\nu$=0,01, $\gamma$=0,1/$d$ | 0,243 | 0,171 | 0,631 | 0,529 | 0,384 | 0,226 | 0,231 | 0,137 | 0,567 | 0,340 |
| rbf, $\nu$=0,05, $\gamma$=0,1/$d$ | 0,400 | 0,344 | 0,638 | 0,524 | 0,370 | 0,208 | 0,234 | 0,161 | 0,568 | 0,516 |
| rbf, $\nu$=0,10, $\gamma$=0,1/$d$ | 0,425 | 0,416 | 0,664 | 0,566 | 0,365 | 0,235 | 0,224 | 0,124 | 0,647 | 0,579 |
| rbf, $\nu$=0,20, $\gamma$=0,1/$d$ | 0,555 | 0,474 | 0,743 | 0,491 | 0,282 | 0,315 | 0,165 | 0,088 | 0,644 | 0,487 |
| rbf, $\nu$=0,50, $\gamma$=0,1/$d$ | 0,666 | 0,306 | 0,749 | 0,332 | 0,239 | 0,267 | 0,163 | 0,071 | 0,608 | 0,281 |
| sigmoid, $\nu$=0,01, $\gamma$=0,1/$d$ | 0,098 | 0,045 | 0,342 | 0,157 | 0,268 | 0,161 | 0,069 | 0,000 | 0,287 | 0,257 |
| sigmoid, $\nu$=0,05, $\gamma$=0,1/$d$ | 0,144 | 0,094 | 0,230 | 0,140 | 0,267 | 0,146 | 0,080 | 0,025 | 0,300 | 0,294 |
| sigmoid, $\nu$=0,10, $\gamma$=0,1/$d$ | 0,200 | 0,125 | 0,280 | 0,203 | 0,241 | 0,154 | 0,260 | 0,204 | 0,303 | 0,255 |
| sigmoid, $\nu$=0,20, $\gamma$=0,1/$d$ | 0,297 | 0,152 | 0,295 | 0,188 | 0,197 | 0,125 | 0,205 | 0,156 | 0,163 | 0,145 |
| sigmoid, $\nu$=0,50, $\gamma$=0,1/$d$ | 0,535 | 0,192 | 0,251 | 0,177 | 0,149 | 0,189 | 0,085 | 0,072 | 0,143 | 0,137 |
| linear, $\nu$=0,01 | 0,211 | 0,154 | 0,295 | 0,142 | 0,231 | 0,156 | 0,127 | 0,097 | 0,238 | 0,144 |
| linear, $\nu$=0,05 | 0,245 | 0,180 | 0,332 | 0,166 | 0,110 | 0,085 | 0,081 | 0,073 | 0,230 | 0,148 |
| linear, $\nu$=0,10 | 0,259 | 0,181 | 0,332 | 0,160 | 0,142 | 0,083 | 0,115 | 0,085 | 0,217 | 0,133 |
| linear, $\nu$=0,20 | 0,274 | 0,173 | 0,452 | 0,165 | 0,161 | 0,105 | 0,200 | 0,109 | 0,264 | 0,130 |
| linear, $\nu$=0,50 | 0,277 | 0,168 | 0,357 | 0,129 | 0,117 | 0,101 | 0,158 | 0,091 | 0,330 | 0,157 |
| poly, $\nu$=0,01, $\gamma$=1,0/$d$ | 0,276 | 0,122 | 0,310 | 0,169 | 0,106 | 0,112 | 0,141 | 0,096 | 0,382 | 0,310 |
| poly, $\nu$=0,05, $\gamma$=1,0/$d$ | 0,284 | 0,127 | 0,305 | 0,201 | 0,137 | 0,131 | 0,131 | 0,116 | 0,384 | 0,315 |
| poly, $\nu$=0,10, $\gamma$=1,0/$d$ | 0,283 | 0,130 | 0,290 | 0,168 | 0,124 | 0,113 | 0,146 | 0,135 | 0,387 | 0,310 |
| poly, $\nu$=0,20, $\gamma$=1,0/$d$ | 0,328 | 0,139 | 0,248 | 0,129 | 0,117 | 0,111 | 0,163 | 0,129 | 0,398 | 0,295 |
| poly, $\nu$=0,50, $\gamma$=1,0/$d$ | 0,308 | 0,122 | 0,271 | 0,189 | 0,126 | 0,132 | 0,167 | 0,091 | 0,328 | 0,195 |
| rbf, $\nu$=0,01, $\gamma$=1,0/$d$ | 0,476 | 0,442 | 0,873 | 0,599 | 0,233 | 0,258 | 0,198 | 0,106 | 0,818 | 0,724 |
| rbf, $\nu$=0,05, $\gamma$=1,0/$d$ | 0,476 | 0,442 | 0,874 | 0,599 | 0,232 | 0,262 | 0,198 | 0,115 | 0,818 | 0,724 |
| rbf, $\nu$=0,10, $\gamma$=1,0/$d$ | 0,479 | 0,437 | 0,874 | 0,599 | 0,233 | 0,263 | 0,198 | 0,115 | 0,801 | 0,683 |
| rbf, $\nu$=0,20, $\gamma$=1,0/$d$ | 0,508 | 0,452 | 0,871 | 0,559 | 0,231 | 0,250 | 0,178 | 0,099 | 0,752 | 0,542 |
| rbf, $\nu$=0,50, $\gamma$=1,0/$d$ | 0,626 | 0,312 | 0,876 | 0,335 | 0,203 | 0,244 | 0,163 | 0,084 | 0,690 | 0,334 |
| sigmoid, $\nu$=0,01, $\gamma$=1,0/$d$ | 0,089 | 0,029 | 0,225 | 0,160 | 0,188 | 0,058 | 0,110 | 0,000 | 0,168 | 0,071 |
| sigmoid, $\nu$=0,05, $\gamma$=1,0/$d$ | 0,204 | 0,174 | 0,142 | 0,044 | 0,205 | 0,071 | 0,103 | 0,040 | 0,142 | 0,120 |
| sigmoid, $\nu$=0,10, $\gamma$=1,0/$d$ | 0,274 | 0,228 | 0,163 | 0,121 | 0,191 | 0,069 | 0,125 | 0,062 | 0,117 | 0,114 |
| sigmoid, $\nu$=0,20, $\gamma$=1,0/$d$ | 0,468 | 0,305 | 0,185 | 0,183 | 0,153 | 0,114 | 0,058 | 0,013 | 0,112 | 0,122 |
| sigmoid, $\nu$=0,50, $\gamma$=1,0/$d$ | 0,710 | 0,280 | 0,138 | 0,125 | 0,105 | 0,085 | 0,035 | 0,000 | 0,114 | 0,131 |
| poly, $\nu$=0,01, $\gamma$=10,0/$d$ | 0,283 | 0,127 | 0,304 | 0,201 | 0,139 | 0,111 | 0,131 | 0,094 | 0,380 | 0,316 |
| poly, $\nu$=0,05, $\gamma$=10,0/$d$ | 0,277 | 0,123 | 0,304 | 0,201 | 0,142 | 0,125 | 0,131 | 0,118 | 0,384 | 0,319 |
| poly, $\nu$=0,10, $\gamma$=10,0/$d$ | 0,280 | 0,132 | 0,290 | 0,170 | 0,141 | 0,119 | 0,146 | 0,142 | 0,387 | 0,310 |
| poly, $\nu$=0,20, $\gamma$=10,0/$d$ | 0,328 | 0,139 | 0,245 | 0,129 | 0,118 | 0,111 | 0,164 | 0,132 | 0,398 | 0,296 |
| poly, $\nu$=0,50, $\gamma$=10,0/$d$ | 0,308 | 0,122 | 0,271 | 0,189 | 0,128 | 0,132 | 0,167 | 0,091 | 0,328 | 0,195 |
| rbf, $\nu$=0,01, $\gamma$=10,0/$d$ | 0,502 | 0,194 | 0,900 | 0,256 | 0,172 | 0,173 | 0,203 | 0,117 | 0,793 | 0,288 |
| rbf, $\nu$=0,05, $\gamma$=10,0/$d$ | 0,502 | 0,193 | 0,900 | 0,253 | 0,173 | 0,173 | 0,203 | 0,118 | 0,793 | 0,288 |
| rbf, $\nu$=0,10, $\gamma$=10,0/$d$ | 0,502 | 0,193 | 0,900 | 0,253 | 0,173 | 0,173 | 0,203 | 0,117 | 0,793 | 0,288 |
| rbf, $\nu$=0,20, $\gamma$=10,0/$d$ | 0,502 | 0,193 | 0,900 | 0,252 | 0,173 | 0,173 | 0,203 | 0,117 | 0,793 | 0,288 |
| rbf, $\nu$=0,50, $\gamma$=10,0/$d$ | 0,502 | 0,193 | 0,900 | 0,252 | 0,173 | 0,173 | 0,203 | 0,117 | 0,783 | 0,281 |
| sigmoid, $\nu$=0,01, $\gamma$=10,0/$d$ | 0,153 | 0,033 | 0,149 | 0,025 | 0,296 | 0,033 | 0,070 | 0,000 | 0,096 | 0,029 |
| sigmoid, $\nu$=0,05, $\gamma$=10,0/$d$ | 0,183 | 0,072 | 0,124 | 0,000 | 0,221 | 0,102 | 0,062 | 0,000 | 0,087 | 0,046 |
| sigmoid, $\nu$=0,10, $\gamma$=10,0/$d$ | 0,266 | 0,224 | 0,103 | 0,018 | 0,215 | 0,092 | 0,045 | 0,000 | 0,085 | 0,064 |
| sigmoid, $\nu$=0,20, $\gamma$=10,0/$d$ | 0,432 | 0,359 | 0,157 | 0,063 | 0,174 | 0,115 | 0,035 | 0,000 | 0,078 | 0,056 |

| Konfiguracja | Breast Cancer | | Ionosphere | | Parkinsons | | Glass | | Synthetic | |
|---|---|---|---|---|---|---|---|---|---|---|
| | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 |
| sigmoid, $\nu$=0,50, $\gamma$=10,0/$d$ | 0,637 | 0,302 | 0,107 | 0,130 | 0,157 | 0,109 | 0,048 | 0,046 | 0,071 | 0,061 |

## DBSCAN

| Konfiguracja | Breast Cancer | | Ionosphere | | Parkinsons | | Glass | | Synthetic | |
|---|---|---|---|---|---|---|---|---|---|---|
| | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 | PR-AUC | F1 |
| minPts=10, $q_\varepsilon$=0,50 | 0,651 | 0,457 | 0,667 | 0,403 | 0,159 | 0,190 | 0,194 | 0,141 | 0,690 | 0,374 |
| minPts=20, $q_\varepsilon$=0,50 | 0,670 | 0,497 | 0,624 | 0,371 | 0,165 | 0,093 | 0,158 | 0,137 | 0,692 | 0,468 |
| minPts=3, $q_\varepsilon$=0,50 | 0,647 | 0,352 | 0,906 | 0,351 | 0,144 | 0,199 | 0,209 | 0,152 | 0,703 | 0,285 |
| minPts=5, $q_\varepsilon$=0,50 | 0,653 | 0,407 | 0,860 | 0,377 | 0,149 | 0,215 | 0,197 | 0,171 | 0,704 | 0,316 |
| minPts=10, $q_\varepsilon$=0,75 | 0,692 | 0,611 | 0,843 | 0,693 | 0,165 | 0,020 | 0,194 | 0,135 | 0,739 | 0,674 |
| minPts=20, $q_\varepsilon$=0,75 | 0,701 | 0,618 | 0,827 | 0,737 | 0,168 | 0,025 | 0,194 | 0,098 | 0,737 | 0,719 |
| minPts=3, $q_\varepsilon$=0,75 | 0,648 | 0,554 | 0,904 | 0,543 | 0,167 | 0,200 | 0,215 | 0,166 | 0,738 | 0,457 |
| minPts=5, $q_\varepsilon$=0,75 | 0,678 | 0,586 | 0,897 | 0,648 | 0,163 | 0,082 | 0,178 | 0,169 | 0,740 | 0,558 |
| minPts=10, $q_\varepsilon$=0,90 | 0,540 | 0,346 | 0,893 | 0,757 | 0,171 | 0,000 | 0,172 | 0,132 | 0,752 | 0,764 |
| minPts=20, $q_\varepsilon$=0,90 | 0,583 | 0,322 | 0,892 | 0,634 | 0,173 | 0,000 | 0,172 | 0,129 | 0,753 | 0,696 |
| minPts=3, $q_\varepsilon$=0,90 | 0,488 | 0,386 | 0,898 | 0,827 | 0,178 | 0,063 | 0,205 | 0,114 | 0,752 | 0,724 |
| minPts=5, $q_\varepsilon$=0,90 | 0,501 | 0,332 | 0,898 | 0,829 | 0,171 | 0,000 | 0,197 | 0,120 | 0,752 | 0,747 |
| minPts=10, $q_\varepsilon$=0,95 | 0,515 | 0,210 | 0,898 | 0,589 | 0,162 | 0,000 | 0,194 | 0,073 | 0,754 | 0,537 |
| minPts=20, $q_\varepsilon$=0,95 | 0,519 | 0,151 | 0,898 | 0,438 | 0,161 | 0,000 | 0,195 | 0,040 | 0,754 | 0,529 |
| minPts=3, $q_\varepsilon$=0,95 | 0,489 | 0,264 | 0,898 | 0,655 | 0,156 | 0,000 | 0,189 | 0,140 | 0,754 | 0,591 |
| minPts=5, $q_\varepsilon$=0,95 | 0,488 | 0,228 | 0,898 | 0,655 | 0,162 | 0,000 | 0,189 | 0,190 | 0,754 | 0,569 |
| minPts=10, $q_\varepsilon$=0,99 | 0,483 | 0,035 | 0,898 | 0,123 | 0,167 | 0,000 | 0,195 | 0,000 | 0,754 | 0,151 |
| minPts=20, $q_\varepsilon$=0,99 | 0,483 | 0,017 | 0,898 | 0,054 | 0,167 | 0,000 | 0,195 | 0,000 | 0,754 | 0,123 |
| minPts=3, $q_\varepsilon$=0,99 | 0,483 | 0,085 | 0,898 | 0,290 | 0,167 | 0,000 | 0,195 | 0,000 | 0,754 | 0,195 |
| minPts=5, $q_\varepsilon$=0,99 | 0,485 | 0,053 | 0,898 | 0,218 | 0,167 | 0,000 | 0,195 | 0,000 | 0,754 | 0,171 |