Politechnika Łódzka
Wydział Fizyki Technicznej, Informatyki i Matematyki Stosowanej

Analiza danych złożonych z detekcją wyjątków

Zadanie 1

Porównanie klasycznych metod detekcji wyjątków

Jędrzej Kostyk
nr indeksu 264339

Rok akademicki 2026/2027

Spis treści

1 Cel i zakres **2**

2 Dane **2**

2.1 Wybrane zbiory i definicja anomalii 2

2.2 Wstępna analiza danych 3

3 Protokół eksperymentalny **4**

4 Metody i badane hiperparametry **5**

5 Wyniki **5**

5.1 Dlaczego Accuracy prowadzi do błędnych wniosków 5

5.2 Wpływ hiperparametrów 6

5.3 Porównanie najlepszych konfiguracji 9

5.4 Wyjątki lokalne i globalne 10

5.5 Zgodność zbiorów wykrytych wyjątków 12

5.6 Kompromis jakość – czas 13

6 Dyskusja **13**

7 Wnioski **15**

8 Odtworzenie wyników **15**

A Wyniki wszystkich eksperymentów **15**

1 Cel i zakres

Celem zadania jest porównanie pięciu klasycznych metod detekcji wyjątków o różnych mechanizmach działania: Isolation Forest (izolacja przez losowe podziały), Local Outlier Factor (lokalna gęstość), Connectivity-based Outlier Factor (lokalna spójność sąsiedztwa), One-Class SVM (granica obszaru danych w przestrzeni jądrowej) oraz DBSCAN (punkty szumu w klasteryzacji gęstościowej). Szczególną uwagę poświęcono wpływowi hiperparametrów na liczbę i rodzaj wykrywanych wyjątków, problemowi silnego niezbalansowania klas, różnicy między wyjątkami globalnymi i lokalnymi oraz zgodności zbiorów obserwacji wskazywanych przez poszczególne detektory.

Eksperymenty przeprowadzono na pięciu zbiorach danych (cztery rzeczywiste i jeden syntetyczny), przy 10 niezależnych podziałach danych, łącznie dla 115 konfiguracji hiperparametrów na zbiór (7000 przebiegów detektorów). Cały kod znajduje się w katalogach `common/` i `task1_classical/` repozytorium, a wszystkie tabele i wykresy raportu są generowane skryptami (sekcja 8).

2 Dane

2.1 Wybrane zbiory i definicja anomalii

Wybrano zbiory z listy dopuszczonych w kursie, inne niż podane przykłady:

- **Breast Cancer Wisconsin (Diagnostic)** – 569 guzów opisanych 30 cechami morfologicznymi jąder komórkowych (średnia, odchylenie i wartość najgorsza dla 10 wielkości). Klasa normalna: guzy łagodne (357), anomalie: guzy złośliwe (212).
- **Ionosphere** – 351 sygnałów radarowych odbitych od jonosfery, 34 atrybuty (17 par części rzeczywistej i urojonej funkcji autokorelacji). Atrybut 2 jest stały i został usunięty (zostaje 33 cech). Normalne: odbicia „good” (225), anomalie: „bad” (126).
- **Parkinsons** – 195 nagrań głosu opisanych 22 miarami akustycznymi (jitter, shimmer, HNR, miary nieliniowe). Klasą większościową są osoby chore (147), więc zgodnie z regułą „mniejszość = anomalia” anomaliami są nagrania osób zdrowych (48).
- **Glass Identification** – 214 próbek szkła opisanych współczynnikiem załamania i zawartością 8 pierwiastków. Zgodnie z przyjętą w literaturze konwencją (ODDS) anomalią jest klasa 6 – szkło stołowe (9 próbek, 4,2 %), pozostałe klasy są normalne.
- **Syntetyczny gaussowski** (30 wymiarów) – dane normalne to trzy klastry gaussowskie na losowej 4-wymiarowej podprzestrzeni liniowej (jeden gęsty, $\sigma = 0{,}35$, i dwa szerokie, $\sigma = 1{,}2$) z szumem izotropowym $\sigma = 0{,}15$. Dodano 100 anomalii trzech znanych typów: *globalne* (40, daleko od wszystkich danych), *lokalne* (30, w odległości 4–6 σ od gęstego klastra – globalnie leżą w obszarze o typowej gęstości, ale są odstające względem swojego sąsiedztwa) i *podprzestrzenne* (30, typowe położenie w podprzestrzeni, ale przesunięte poza nią). Zbiór pozwala bezpośrednio mierzyć skuteczność wykrywania wyjątków lokalnych i globalnych.

Jeśli klasa mniejszościowa stanowi więcej niż 10 % danych, jest ona losowo podpróbkowana tak, aby anomalie stanowiły 10 % zbioru (stosowana w benchmarkach ADBench/ODDS praktyka tworzenia scenariusza detekcji wyjątków z danych klasyfikacyjnych). Podpróbkowanie wykonywane jest osobno dla każdego ziarna losowego, więc 10 powtórzeń eksperymentu obejmuje różne podzbiory anomalii, co zwiększa wiarygodność uśrednionych wyników.

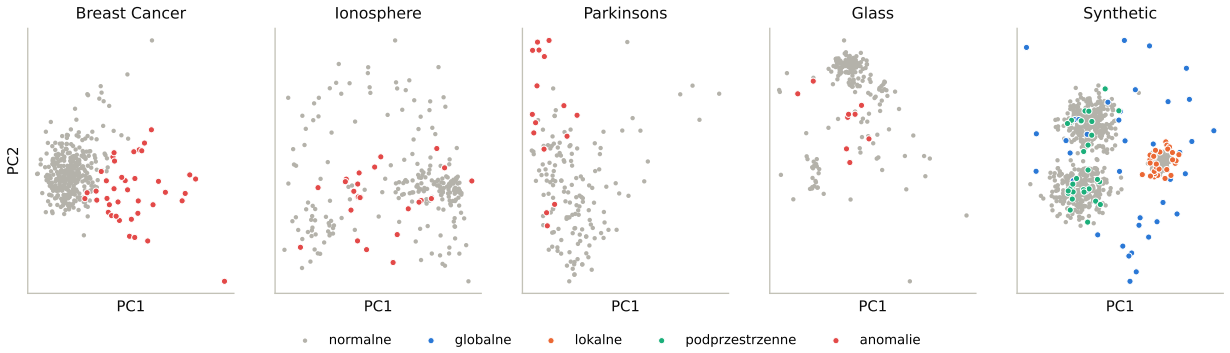
2.2 Wstępna analiza danych

Tabela 1 podsumowuje zbiory po przygotowaniu. Żaden zbiór nie zawiera braków danych, wszystkie cechy są ciągłe (jedyna cecha całkowitoliczbowa w Ionosphere jest binarna). Zbiory rzeczywiste mają silnie skośne rozkłady cech (średnia $|\gamma_1|$ do 2,4 w Breast Cancer – rys. 3) oraz bardzo silnie skorelowane cechy (maksymalna $|r|$ od 0,81 do 1,00; w Breast Cancer promień, obwód i pole są niemal liniowo zależne). Konsekwencją jest niska efektywna wymiarowość: 90 % wariancji wyjaśnia 6–10 składowych głównych. Odsetek wartości $|z| > 3$ (jednowymiarowe wartości odstające) wynosi 0,5–1,7 % – są one obecne także w klasie normalnej, więc jednowymiarowe reguły typu „3 sigma" nie wystarczą do identyfikacji anomalii.

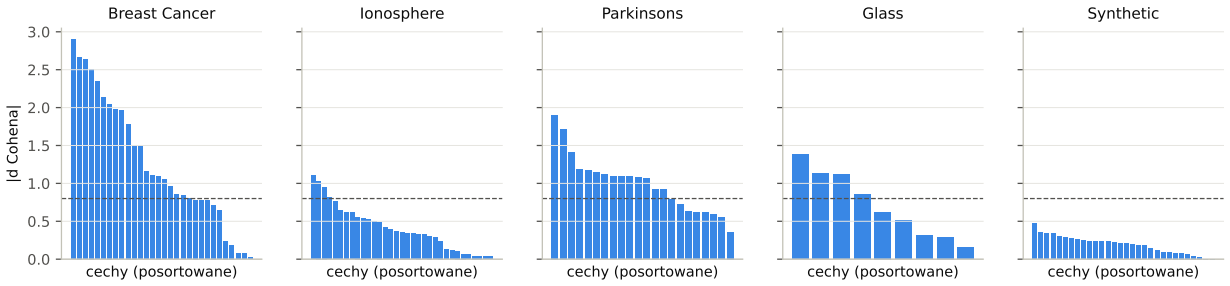
Tabela 1: Charakterystyka zbiorów (po podpróbkowaniu anomalii, ziarno 0). Oryg. klasy – liczności klasy normalnej i anomalnej przed podpróbkowaniem; $\overline{|\gamma_1|}$ – średnia bezwzględna skośność cech; $|z| > 3$ – odsetek wartości odstających jednowymiarowo; max $|r|$ – największa bezwzględna korelacja dwóch cech; PC 90 % – liczba składowych głównych wyjaśniających 90 % wariancji.

Zbiór	n	d	Oryg. klasy (N/A)	Anomalie	Udział [%]	Braki	$\overline{\lvert\gamma_1\rvert}$	$\lvert z\rvert > 3$ [%]	max $\lvert r\rvert$	PC 90%
Breast Cancer	397	30	357/212	40	10,1	0	2,39	1,64	1,00	7
Ionosphere	250	33	225/126	25	10,0	0	0,82	0,46	0,93	10
Parkinsons	163	22	147/48	16	9,8	0	1,60	1,37	1,00	6
Glass	214	9	205/9	9	4,2	0	2,06	1,71	0,81	6
Synthetic	1000	30	900/100	100	10,0	0	0,28	0,82	0,93	5

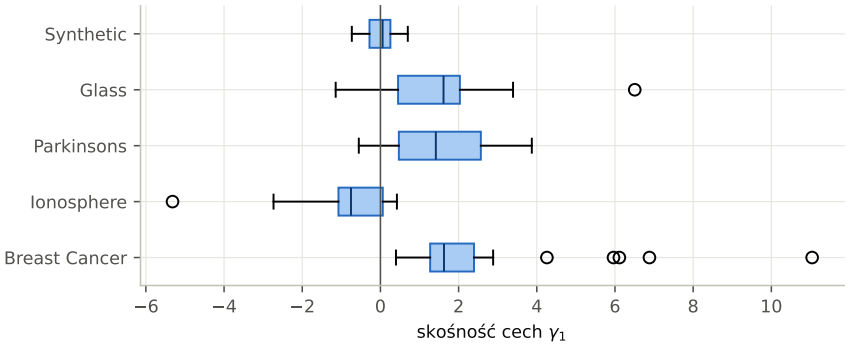
Rysunek 1 przedstawia rzut danych na dwie pierwsze składowe główne. W Breast Cancer i Ionosphere anomalie tworzą obszar przesunięty względem danych normalnych (choć w Ionosphere dane normalne same są rozproszone). W Parkinsons i Glass anomalie leżą wewnątrz chmury danych normalnych, co zapowiada trudność zadania. Potwierdza to rys. 2: w Breast Cancer kilkanaście cech ma duży efekt ($|d| > 0{,}8$), w Parkinsons i Glass jest ich tylko kilka, a w zbiorze syntetycznym żadna cecha osobno nie różnicuje klas – anomalie lokalne i podprzestrzenne są wykrywalne tylko wielowymiarowo.



Rysunek 1: Rzut zbiorów na dwie pierwsze składowe główne (dane standaryzowane). W zbiorze syntetycznym kolor oznacza typ anomalii.



Rysunek 2: Bezwzględna wartość d Cohena (standaryzowana różnica średnich anomalii i obserwacji normalnych) dla kolejnych cech; linia przerywana – umowna granica dużego efektu (0,8).



Rysunek 3: Rozkład skośności cech w poszczególnych zbiorach.

3 Protokół eksperymentalny

1. **Podział danych.** Dla każdego zbioru i ziarna $s \in \{0, \ldots, 9\}$ dane dzielone są warstwowo na część uczącą, walidacyjną i testową w proporcji 50/25/25 %. Te same ziarna dają te same podziały we wszystkich trzech zadaniach.
2. **Przygotowanie.** Standaryzacja (`StandardScaler`) jest dopasowywana wyłącznie do części uczącej i stosowana do pozostałych części.
3. **Uczenie.** Detektory uczone są *bez etykiet* na części uczącej, która zawiera anomalie w naturalnej proporcji (scenariusz nienadzorowany). Każdy detektor zwraca wynik anomalii (wyższy = bardziej anomalny) dla nowych obserwacji.
4. **Strojenie.** Etykiety części walidacyjnej służą do wyboru konfiguracji (najwyższa średnia PR-AUC na walidacji, uśredniona po 10 podziałach) i progu decyzyjnego (maksymalizacja F1 na walidacji). Część testowa służy wyłącznie do końcowej oceny.
5. **Metryki.** Precision, Recall, F1 (dla klasy „anomalia”), ROC-AUC, PR-AUC (*average precision*), Accuracy (tylko do ilustracji jej wad) oraz czas uczenia i czas oceny części testowej. Raportowane są średnie (i odchylenia standardowe) z 10 podziałów.

Dla metod z parametrem `contamination` (IForest, LOF, COF) parametr ten nie zmienia wyniku anomalii, a jedynie próg: oznaczane jest $c{\cdot}100\,\%$ obserwacji uczących o najwyższym wyniku. Dlatego wszystkie wartości c oceniane są na jednym wytrenowanym modelu. W przypadku OCSVM decyzja wynika z granicy SVM (sterowanej przez ν), a w DBSCAN – z promienia ε. W tabelach siatki (dodatek A) Precision, Recall i F1 dotyczą tych „wbudowanych” reguł decyzyjnych, a w porównaniu najlepszych konfiguracji (sekcja 5.3) – progu wybranego na walidacji.

4 Metody i badane hiperparametry

Isolation Forest. Las T drzew dzielących dane losowymi cięciami losowych cech; wynik anomalii zależy od średniej głębokości, na której obserwacja zostaje odizolowana. Punkty odległe od masy danych izolowane są po niewielu cięciach. Metoda patrzy na dane *globalnie* – cięcia osiowe nie „widzą" lokalnych różnic gęstości. Badano $T \in \{50, 100, 200, 500\}$ i $c \in \{0{,}02;\ 0{,}05;\ 0{,}1;\ 0{,}15;\ 0{,}2\}$.

LOF. Stosunek lokalnej gęstości osiągalności sąsiadów punktu do jego własnej gęstości. Wartości $\gg 1$ oznaczają punkt rzadszy niż jego otoczenie – miara jest *względna*, więc wykrywa wyjątki lokalne przy gęstych skupiskach. Badano $k \in \{5, 10, 20, 35, 50\}$ i te same wartości c. Użyto trybu `novelty=True`, który pozwala oceniać nowe dane.

COF. Wariant LOF, w którym gęstość zastąpiono *spójnością*: średnia odległość łańcuchowa (*average chaining distance*) wzdłuż ścieżki najbliższych połączeń (kolejność algorytmu Prima) w zbiorze k sąsiadów. COF lepiej niż LOF radzi sobie z wzorcami o niskiej gęstości, ale regularnej strukturze (np. punkty ułożone wzdłuż linii). Implementacja została napisana od podstaw (`common/cof.py`), bo dostępne implementacje nie oceniają nowych danych; zgodność z definicją sprawdzono na naiwnej implementacji referencyjnej (różnica 0). Siatka jak dla LOF.

One-Class SVM. Wyznacza w przestrzeni cech jądra hiperpłaszczyznę oddzielającą dane od początku układu z maksymalnym marginesem; ν jest górnym ograniczeniem odsetka punktów uczących poza granicą (i dolnym ograniczeniem odsetka wektorów nośnych). Badano jądra RBF, wielomianowe (stopnia 3), sigmoidalne i liniowe, $\nu \in \{0{,}01;\ 0{,}05;\ 0{,}1;\ 0{,}2;\ 0{,}5\}$ oraz $\gamma \in \{0{,}1/d,\ 1/d,\ 10/d\}$ (50 konfiguracji).

DBSCAN. Punkty rdzeniowe mają co najmniej minPts sąsiadów w promieniu ε; punkty nieosiągalne z żadnego rdzenia są szumem (anomalią). Aby oceniać nowe dane, wynikiem anomalii jest odległość do najbliższego punktu rdzeniowego z części uczącej, a anomalią – punkt, dla którego odległość ta przekracza ε. Ponieważ skala odległości zależy od wymiaru i zbioru, ε ustalano jako kwantyl $q_\varepsilon \in \{0{,}5;\ 0{,}75;\ 0{,}9;\ 0{,}95;\ 0{,}99\}$ rozkładu odległości do minPts-tego sąsiada (heurystyka wykresu k-odległości), minPts $\in \{3, 5, 10, 20\}$.

5 Wyniki

5.1 Dlaczego Accuracy prowadzi do błędnych wniosków

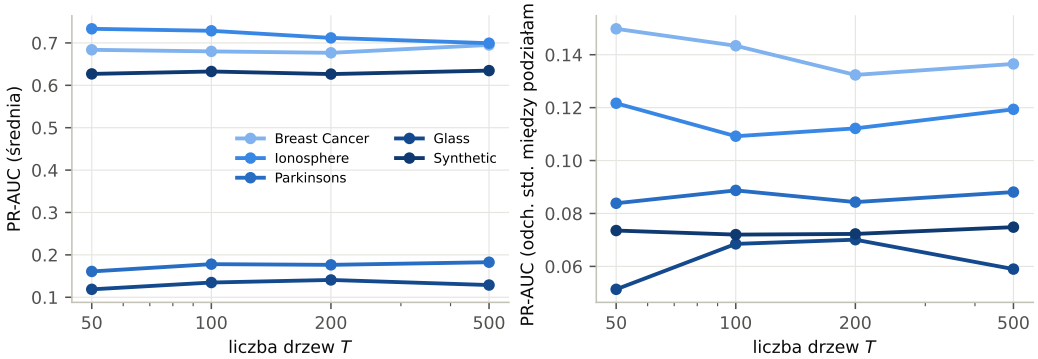
Tabela 2 zestawia trywialny klasyfikator „zawsze normalny" z najlepszym i najsłabszym (wg F1) detektorem. Klasyfikator trywialny osiąga Accuracy 0,90–0,96, nie wykrywając *żadnej* anomalii (Recall = F1 = 0). Na Glass jego Accuracy (0,956) jest *wyższa* niż najlepszego detektora (0,813), a na Breast Cancer różnica między najlepszym a najsłabszym detektorem to 0,05 w Accuracy, ale 0,16 w F1. Przy udziale anomalii π Accuracy jest zdominowana przez klasę normalną: wykrycie wszystkich anomalii zmienia ją o co najwyżej π. Dlatego w dalszej analizie podstawą są PR-AUC (której wartość dla losowego rankingu wynosi π, a nie 0,5 jak dla ROC-AUC) oraz F1.

Tabela 2: Accuracy a jakość wykrywania anomalii (część testowa, średnie z 10 podziałów). „Losowy" – PR-AUC rankingu losowego (= udział anomalii).

Zbiór	Udział anomalii	Acc. "zawsze normalny"	F1 / Recall	PR-AUC losowy	Acc. najlepszy (F1)	F1 najlepszy	Acc. najsłabszy (F1)	F1 najsłabszy
Breast Cancer	0,100	0,900	0,000 / 0,000	0,100	0,938 (OCSVM)	0,677	0,889 (COF)	0,513
Ionosphere	0,102	0,898	0,000 / 0,000	0,102	0,962 (COF)	0,799	0,924 (IForest)	0,584
Parkinsons	0,098	0,902	0,000 / 0,000	0,098	0,715 (LOF)	0,257	0,598 (DBSCAN)	0,166
Glass	0,044	0,956	0,000 / 0,000	0,044	0,813 (COF)	0,138	0,631 (IForest)	0,083
Synthetic	0,100	0,900	0,000 / 0,000	0,100	0,965 (LOF)	0,831	0,919 (IForest)	0,521

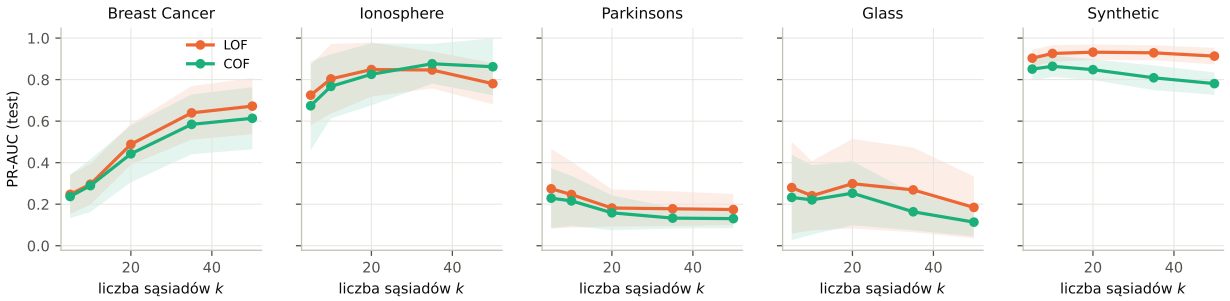
5.2 Wpływ hiperparametrów

Isolation Forest – liczba drzew. Liczba drzew praktycznie nie wpływa na średnią jakość (rys. 4; zmiany PR-AUC $\leq 0{,}035$), natomiast nieznacznie zmniejsza wariancję między podziałami (np. Breast Cancer: odchylenie 0,150 dla 50 drzew i 0,137 dla 500). Ponieważ czas uczenia rośnie liniowo z T, 100–200 drzew jest rozsądnym kompromisem. Różnice między zbiorami są o rząd wielkości większe niż różnice wynikające z T, co pokazuje, że ograniczeniem IForest jest jego mechanizm, a nie liczba drzew.



Rysunek 4: Isolation Forest: średnia i rozrzut PR-AUC w zależności od liczby drzew.

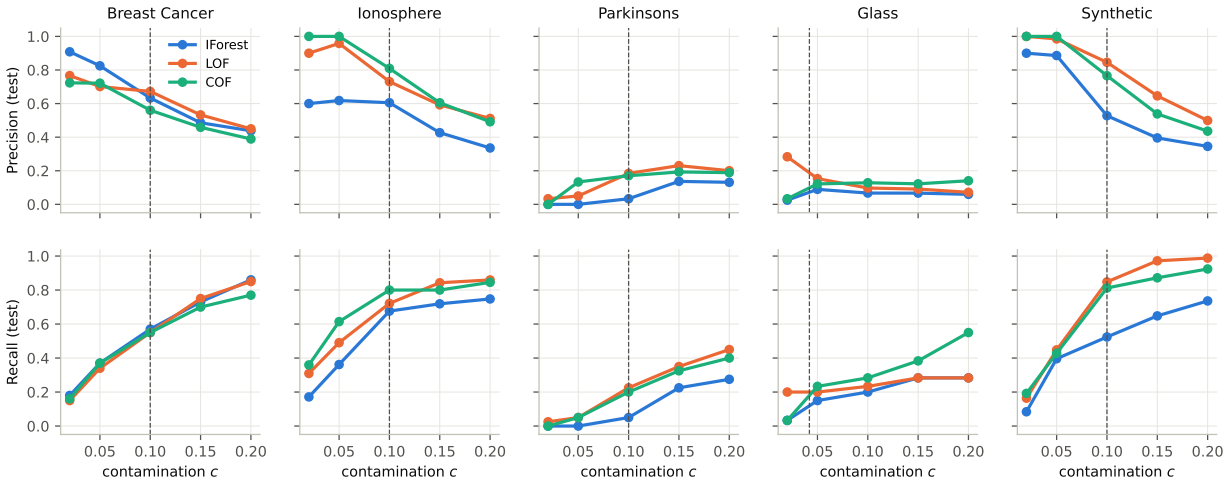
LOF i COF – liczba sąsiadów. Wpływ k jest silny i zależy od struktury danych (rys. 5). W Breast Cancer PR-AUC LOF rośnie z 0,25 ($k = 5$) do 0,67 ($k = 50$): anomalie (guzy złośliwe) tworzą zwarte skupisko kilkunastu punktów, więc przy małym k sąsiadami anomalii są inne anomalie i jej gęstość względna wydaje się normalna (efekt maskowania). Dopiero k większe niż rozmiar skupiska anomalii pozwala je wykryć. W Parkinsons jest odwrotnie – najlepsze jest $k = 5$ (0,27), co sugeruje pojedyncze, lokalnie odstające nagrania. W zbiorze syntetycznym LOF jest stabilny w szerokim zakresie k (0,90–0,93). COF zachowuje się podobnie, ale jest bardziej wrażliwy na zbyt duże k (syntetyczny: spadek z 0,86 do 0,78), bo ścieżka łańcuchowa przy dużym k „przechodzi" przez sąsiednie skupiska i zaciera lokalną strukturę.



Rysunek 5: LOF i COF: PR-AUC (część testowa) w funkcji liczby sąsiadów; pasy – ±1 odchylenie standardowe między podziałami.

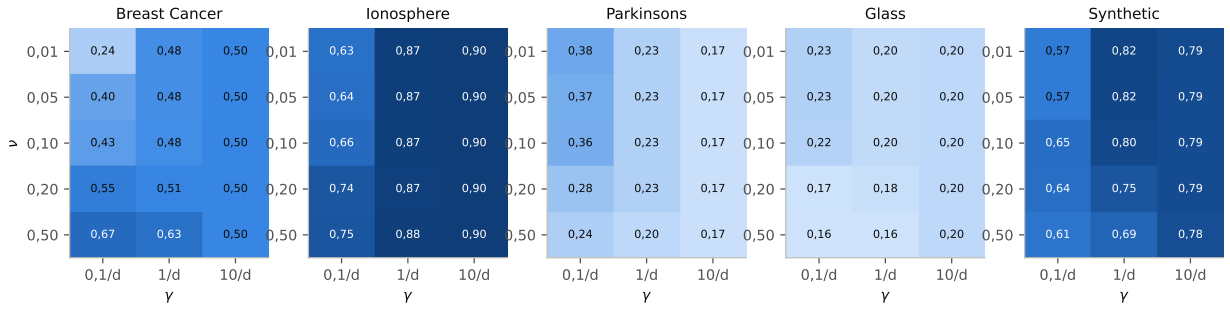
Parametr `contamination`. Parametr ten ustala odsetek oznaczanych obserwacji, a więc bezpośrednio steruje kompromisem Precision–Recall (rys. 6). Uśredniając po zbiorach, dla LOF wzrost c z 0,02 do 0,20 podnosi Recall z 0,13 do 0,64, a Precision spada z 0,48 do 0,30; F1 jest największe w pobliżu rzeczywistego udziału anomalii ($c = 0{,}1$: F1 = 0,44 dla LOF, 0,42 dla COF, 0,38 dla IForest). Ważna obserwacja: contamination *nie zmienia* rankingu obserwacji (ROC-AUC i PR-AUC są stałe) – zmienia tylko, ile najwyżej ocenionych punktów nazywamy anomaliami. Przyjęcie c mniejszego od rzeczywistego udziału daje wysoką precyzję i niski Recall

(detektor wskazuje tylko najbardziej oczywiste, zwykle globalne wyjątki), a większego – odwrotnie. W praktyce c jest nieznane, dlatego w porównaniu metod próg wyznaczano na walidacji.

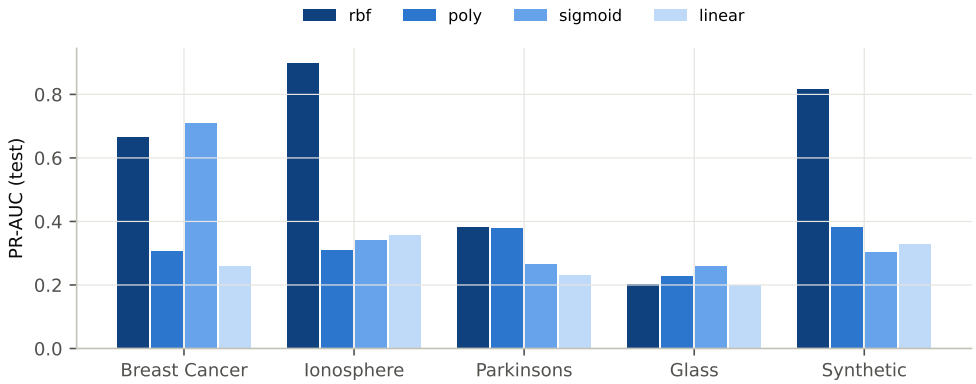


Rysunek 6: Precision i Recall (część testowa) w zależności od contamination dla najlepszych (wg walidacji) wartości T i k; linia przerywana – rzeczywisty udział anomalii.

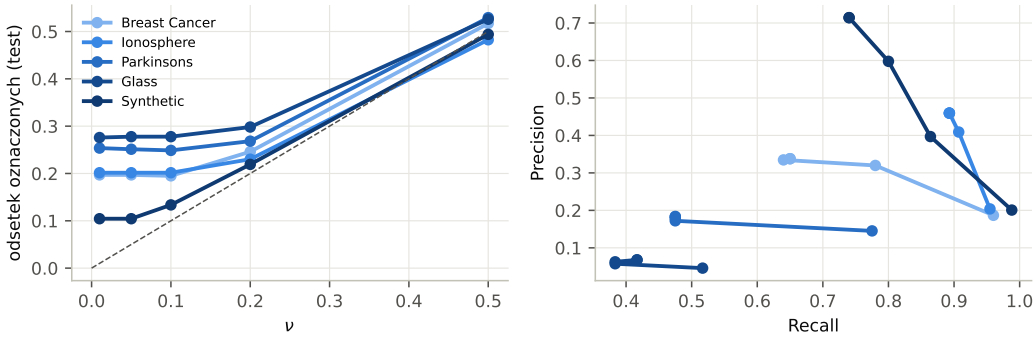
One-Class SVM. Kluczowe okazało się jądro i γ (rys. 7 i 8). Jądro RBF jest najlepsze lub bliskie najlepszego na wszystkich zbiorach (Ionosphere: PR-AUC 0,90; syntetyczny: 0,82), natomiast jądro liniowe radzi sobie najsłabiej (0,20–0,36) – liniowa granica oddzielająca dane od początku układu nie może opisać skupisk ani obszarów niewypukłych. Jądro wielomianowe i sigmoidalne są niestabilne: sigmoidalne nie jest dodatnio określone, a wielomianowe mocno zależy od skali danych. Dla RBF γ steruje „lokalnością" granicy: $\gamma = 10/d$ daje granicę ciasno opinającą dane (dobrą dla Ionosphere, w którym anomalie mieszają się z rozproszonymi danymi normalnymi), a $\gamma = 0{,}1/d$ – gładką, niemal eliptyczną granicę, dobrą dla Breast Cancer i Parkinsons. Parametr ν wpływa przede wszystkim na odsetek oznaczonych punktów (rys. 9): na danych testowych odsetek ten jest bliski ν, zgodnie z interpretacją ν jako ograniczenia na odsetek punktów poza granicą. Przy małym γ ν zmienia jednak także ranking: w Breast Cancer PR-AUC rośnie z 0,24 ($\nu = 0{,}01$) do 0,67 ($\nu = 0{,}5$), bo dopiero przy wielu wektorach nośnych granica „odcina" całe skupisko guzów złośliwych, a w zbiorze syntetycznym ($\gamma = 1/d$) maleje z 0,82 do 0,69. Przy $\gamma = 10/d$ wynik w ogóle nie zależy od ν: jądro jest tak wąskie, że niemal każdy punkt staje się wektorem nośnym, a funkcja decyzyjna OCSVM sprowadza się do jądrowego estymatora gęstości (Parzena).



Rysunek 7: OCSVM z jądrem RBF: PR-AUC (część testowa) w zależności od ν i γ.

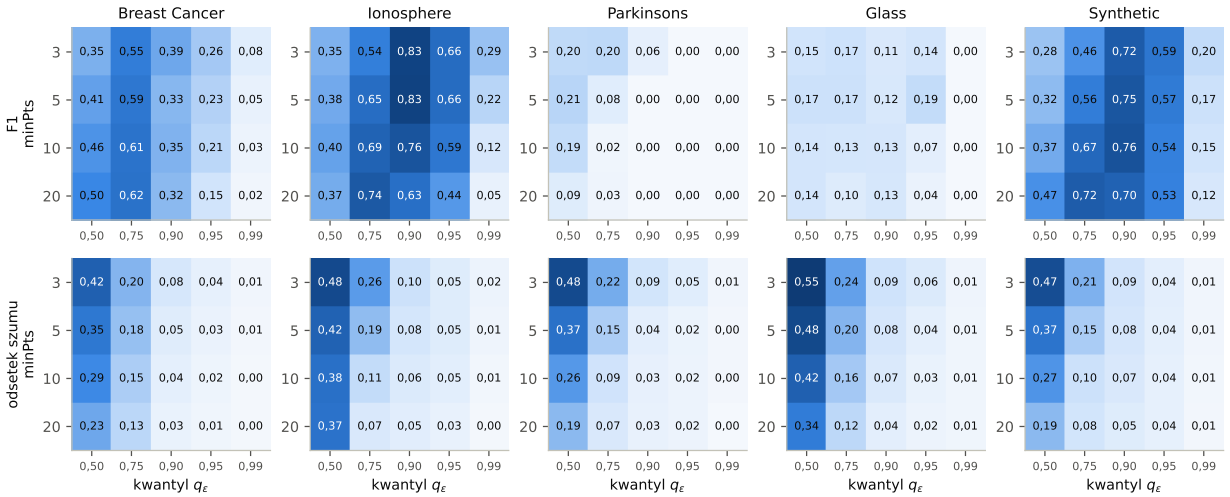


Rysunek 8: OCSVM: PR-AUC (część testowa) dla każdego jądra przy ν i γ wybranych na walidacji.



Rysunek 9: OCSVM (RBF, $\gamma = 1/d$): odsetek oznaczonych punktów testowych w funkcji ν (linia przerywana – $y = \nu$) oraz kompromis Precision–Recall przy zmianie ν.

DBSCAN. Rysunek 10 pokazuje, że w DBSCAN o wynikach decyduje przede wszystkim ε: odsetek punktów szumu maleje od 19–55 % dla $q_\varepsilon = 0{,}5$ do 0–2 % dla $q_\varepsilon = 0{,}99$, a F1 osiąga maksimum, gdy odsetek szumu zbliża się do udziału anomalii ($q_\varepsilon = 0{,}75$–$0{,}9$; Ionosphere F1 = 0,83, syntetyczny 0,76). Zależność od minPts jest słabsza, bo ε jest wyznaczane jako kwantyl odległości do minPts-tego sąsiada – obie wielkości są ze sobą sprzężone. Większe minPts wymaga gęstszych rdzeni: pomaga, gdy anomalie tworzą małe skupiska (Breast Cancer: F1 rośnie z 0,55 dla minPts = 3 do 0,62 dla minPts = 20 przy $q_\varepsilon = 0{,}75$, bo skupisko guzów złośliwych przestaje tworzyć własny klaster), ale przy wysokich kwantylach ε szkodzi. Wadą DBSCAN jest jeden globalny promień ε – nie da się dobrać go jednocześnie do gęstego i rzadkiego skupiska.



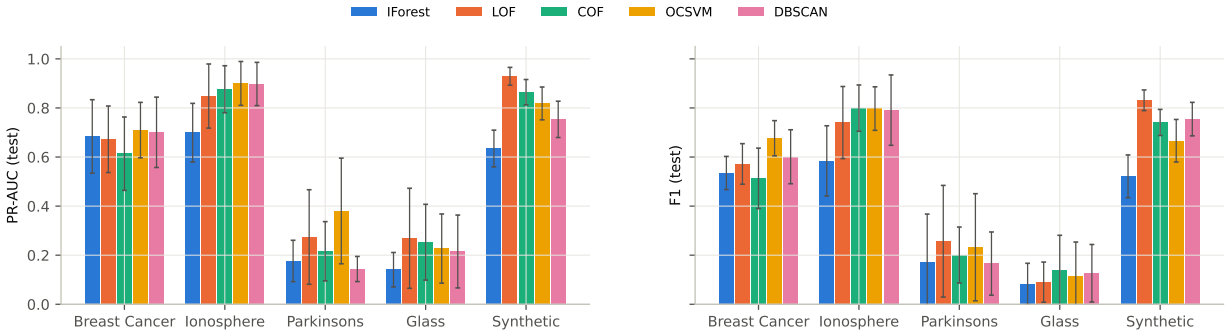
Rysunek 10: DBSCAN: F1 (górny wiersz) i odsetek punktów testowych uznanych za szum (dolny wiersz) w zależności od minPts i kwantyla q_ε wyznaczającego ε.

5.3 Porównanie najlepszych konfiguracji

Tabela 3 i rys. 11 przedstawiają wyniki konfiguracji wybranych na walidacji, z progiem maksymalizującym F1 na walidacji.

Tabela 3: Najlepsze konfiguracje (wybór na walidacji wg PR-AUC, próg z walidacji wg F1); część testowa, średnia (± odchylenie std.) z 10 podziałów. Czas = uczenie + ocena części testowej. Pogrubienie – najlepsza metoda na zbiorze.

Zbiór	Metoda	Konfiguracja	Prec.	Rec.	F1	ROC-AUC	PR-AUC	Czas [ms]
Breast Cancer	IForest	T=50	0,538	0,610	0,535 ± 0,068	0,911	0,684 ± 0,150	54,5
	LOF	k=50	0,548	0,650	0,572 ± 0,083	0,916	0,672 ± 0,136	7,9
	COF	k=50	0,529	0,610	0,513 ± 0,123	0,890	0,614 ± 0,149	162,1
	OCSVM	sigmoid, ν=0,50, γ=1,0/d	0,776	0,630	**0,677 ± 0,072**	0,823	**0,710 ± 0,113**	4,0
	DBSCAN	minPts=20, q_ε=0,75	0,594	0,650	0,601 ± 0,110	0,917	0,701 ± 0,143	5,2
Ionosphere	IForest	T=500	0,684	0,576	0,584 ± 0,143	0,906	0,699 ± 0,119	455,8
	LOF	k=20	0,786	0,748	0,741 ± 0,147	0,965	0,848 ± 0,131	7,0
	COF	k=35	0,874	0,757	**0,799 ± 0,094**	0,964	0,876 ± 0,096	63,6
	OCSVM	rbf, ν=0,05, γ=10,0/d	0,842	0,781	0,797 ± 0,089	0,954	**0,900 ± 0,089**	2,0
	DBSCAN	minPts=3, q_ε=0,90	0,931	0,729	0,791 ± 0,143	0,949	0,898 ± 0,088	6,5
Parkinsons	IForest	T=200	0,123	0,325	0,172 ± 0,196	0,566	0,176 ± 0,084	187,6
	LOF	k=5	0,198	0,475	**0,257 ± 0,227**	0,635	0,274 ± 0,193	2,7
	COF	k=10	0,126	0,550	0,201 ± 0,114	0,609	0,216 ± 0,121	3,4
	OCSVM	poly, ν=0,01, γ=0,1/d	0,379	0,400	0,232 ± 0,218	0,642	**0,380 ± 0,215**	0,8
	DBSCAN	minPts=3, q_ε=0,50	0,106	0,425	0,166 ± 0,129	0,519	0,144 ± 0,051	5,4
Glass	IForest	T=200	0,046	0,500	0,083 ± 0,084	0,674	0,141 ± 0,070	175,8
	LOF	k=35	0,049	0,567	0,090 ± 0,082	0,706	**0,269 ± 0,204**	2,0
	COF	k=20	0,084	0,433	**0,138 ± 0,143**	0,809	0,253 ± 0,154	5,6
	OCSVM	poly, ν=0,05, γ=0,1/d	0,077	0,283	0,114 ± 0,140	0,784	0,227 ± 0,141	0,8
	DBSCAN	minPts=3, q_ε=0,75	0,074	0,467	0,126 ± 0,117	0,735	0,215 ± 0,148	2,7
Synthetic	IForest	T=500	0,722	0,440	0,521 ± 0,087	0,895	0,635 ± 0,075	460,9
	LOF	k=35	0,814	0,864	**0,831 ± 0,042**	0,991	**0,929 ± 0,036**	14,6
	COF	k=10	0,832	0,688	0,741 ± 0,053	0,969	0,864 ± 0,052	23,7
	OCSVM	rbf, ν=0,05, γ=1,0/d	0,785	0,624	0,666 ± 0,087	0,959	0,818 ± 0,067	3,7
	DBSCAN	minPts=10, q_ε=0,95	0,911	0,648	0,755 ± 0,068	0,877	0,754 ± 0,074	12,1



Rysunek 11: PR-AUC i F1 najlepszych konfiguracji; słupki błędów – odchylenie standardowe między 10 podziałami.

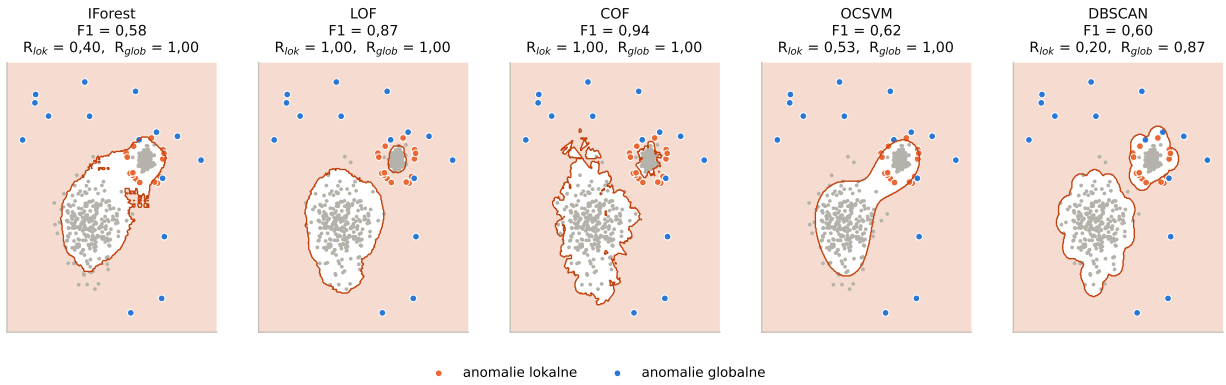
Nie ma metody najlepszej na wszystkich zbiorach. LOF wygrywa na zbiorze syntetycznym (PR-AUC 0,93, F1 0,83) i Parkinsons (F1 0,26), OCSVM na Breast Cancer (F1 0,68) i Ionosphere (PR-AUC 0,90), COF na Glass (F1 0,14) i Ionosphere (F1 0,80). Isolation Forest – mimo popularności – jest najsłabszy lub bliski najsłabszego wszędzie poza Breast Cancer. Odchylenia standardowe są duże (często 0,1–0,2), szczególnie na małych zbiorach Parkinsons i Glass, gdzie część testowa zawiera odpowiednio 4 i 2 anomalie – część różnic między metodami mieści się w rozrzucie między podziałami i nie należy ich nadinterpretować.

Na tle wysokich ROC-AUC (0,82–0,99 na Breast Cancer, Ionosphere i zbiorze syntetycznym) widać, dlaczego ROC-AUC jest metryką optymistyczną przy niezbalansowaniu: ROC-AUC = 0,91 dla IForest na Breast Cancer odpowiada PR-AUC = 0,68 i F1 = 0,54. Oś FPR na krzywej ROC jest normalizowana liczbą obserwacji normalnych (9 razy większą od liczby anomalii), więc kilkanaście fałszywych alarmów prawie nie obniża ROC-AUC, choć realnie oznacza, że co druga zgłoszona anomalia jest fałszywa. PR-AUC i Precision bezpośrednio pokazują ten koszt. Na Parkinsons ROC-AUC 0,52–0,64 jest bliskie losowemu, a PR-AUC 0,14–0,38 przy bazowym 0,10 – anomalie tego zbioru są praktycznie nieodróżnialne nienadzorowanymi metodami. Wynika to z definicji: „anomaliami” są tu osoby zdrowe, które nie są nietypowe w sensie rozkładu cech – reguła „mniejszość = anomalia” nie gwarantuje, że klasa mniejszościowa leży w obszarach niskiej gęstości. Podobnie w Glass szkło stołowe jest bliskie składem innym szkłom niebudowlanym.

Warto też zauważyć różnicę między siatką a wyborem na walidacji. Najlepsza na *teście* konfiguracja OCSVM na Breast Cancer osiąga PR-AUC 0,92 (sigmoidalne), a wybrana na walidacji – 0,71; dla RBF różnica wynosi 0,85 wobec 0,67. Część walidacyjna zawiera 10 anomalii (Breast Cancer) lub nawet 2–4 (Glass, Parkinsons), więc wybór hiperparametrów jest obarczony dużym szumem. Raportowanie maksimum z siatki na zbiorze testowym zawyżałoby wyniki – dlatego wszystkie porównania metod opierają się na wyborze walidacyjnym.

5.4 Wyjątki lokalne i globalne

Rysunek 12 pokazuje obszary decyzyjne na dwuwymiarowym przykładzie z gęstym i szerokim skupiskiem, pierścieniem anomalii lokalnych wokół gęstego skupiska i rozproszonymi anomaliami globalnymi (wszystkie metody oznaczają 10 % danych). Isolation Forest, OCSVM i DBSCAN wyznaczają *jeden* globalny obszar normalności, który obejmuje gęste skupisko razem z pierścieniem anomalii lokalnych (Recall lokalnych 0,40; 0,53; 0,20), bo w skali całego zbioru pierścień nie jest rzadszy niż szerokie skupisko. LOF i COF porównują gęstość punktu z gęstością jego sąsiadów, dzięki czemu wykrywają wszystkie anomalie lokalne (Recall 1,00), zachowując pełne wykrywanie globalnych.



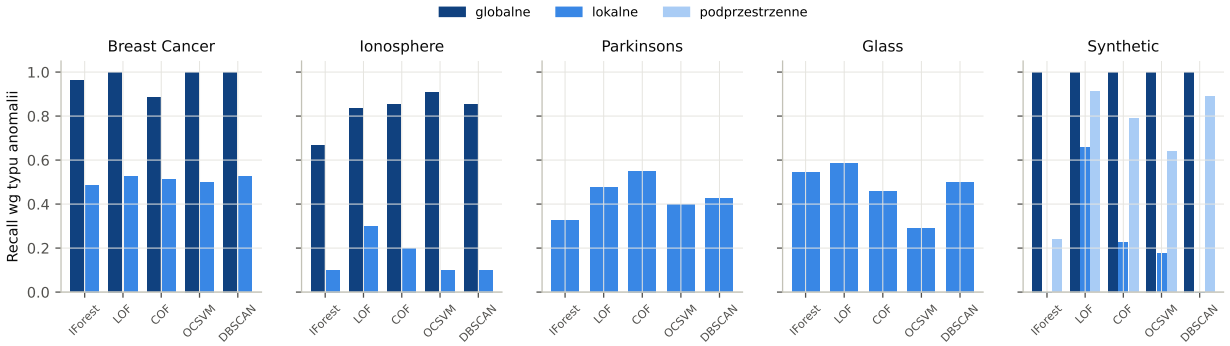
Rysunek 12: Obszary uznane za anomalne (kolor jasnopomarańczowy) na dwuwymiarowym przykładzie syntetycznym; R_{lok}, R_{glob} – Recall anomalii lokalnych i globalnych.

W 30-wymiarowym zbiorze syntetycznym (tabela 4, rys. 13) wszystkie metody wykrywają 100 % anomalii globalnych. Anomalie lokalne wykrywa jedynie LOF (Recall 0,66); IForest i DBSCAN nie wykrywają ich wcale (0,00), COF i OCSVM w niewielkim stopniu (0,23 i 0,18). Anomalie podprzestrzenne (odchylenie poza 4-wymiarową podprzestrzeń danych) dobrze wykrywają metody odległościowe – LOF (0,91), DBSCAN (0,89), COF (0,79) – a słabo Isolation Forest (0,24): przesunięcie rozkłada się na 26 kierunków, a każde losowe cięcie osiowe widzi tylko jedną cechę, w której przesunięcie jest małe. To konkretna słabość IForest w danych o skorelowanych cechach.

Dla zbiorów rzeczywistych typ anomalii nie jest znany, więc przyjęto definicję operacyjną: anomalia jest *globalna*, jeśli jej odporna odległość Mahalanobisa od klasy normalnej (estymator MCD) przekracza 99. percentyl odległości obserwacji normalnych, a w przeciwnym razie *lokalna* (leży wewnątrz globalnej „otoczki” danych normalnych). W Breast Cancer i Ionosphere anomalie globalne są wykrywane niemal w całości (0,67–1,00), a lokalne w dużo mniejszym stopniu (0,10–0,53). W Parkinsons i Glass *wszystkie* anomalie są w tym sensie lokalne, co wyjaśnia słabe wyniki wszystkich metod na tych zbiorach. Najlepsze wyniki dla anomalii lokalnych osiągają LOF i COF, co jest zgodne z ich konstrukcją.

Tabela 4: Recall według typu anomalii (część testowa, suma po 10 podziałach; n – liczba anomalii danego typu w częściach testowych).

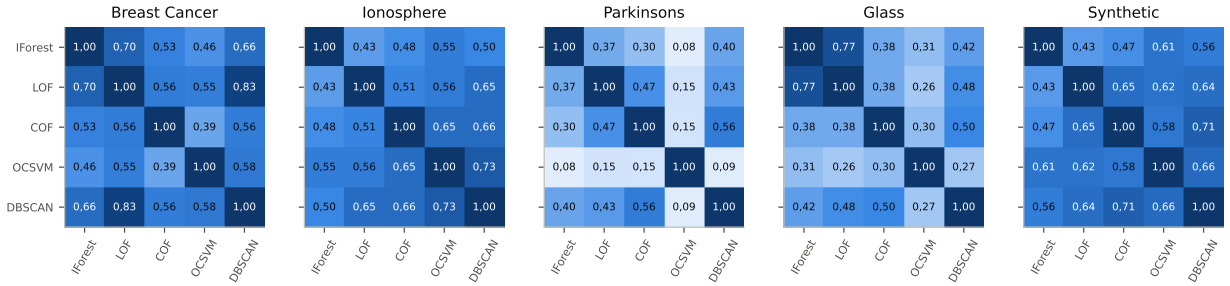
Zbiór	Typ	n (10 pow.)	IForest	LOF	COF	OCSVM	DBSCAN
Breast Cancer	globalne	26	0,962	**1,000**	0,885	**1,000**	**1,000**
	lokalne	74	0,486	**0,527**	0,514	0,500	**0,527**
Ionosphere	globalne	54	0,667	0,833	0,852	**0,907**	0,852
	lokalne	10	0,100	**0,300**	0,200	0,100	0,100
Parkinsons	lokalne	40	0,325	0,475	**0,550**	0,400	0,425
Glass	lokalne	24	0,542	**0,583**	0,458	0,292	0,500
Synthetic	globalne	91	**1,000**	**1,000**	**1,000**	**1,000**	**1,000**
	lokalne	79	0,000	**0,658**	0,228	0,177	0,000
	podprzestrzenne	80	0,237	**0,912**	0,787	0,637	0,887



Rysunek 13: Recall według typu anomalii dla najlepszych konfiguracji.

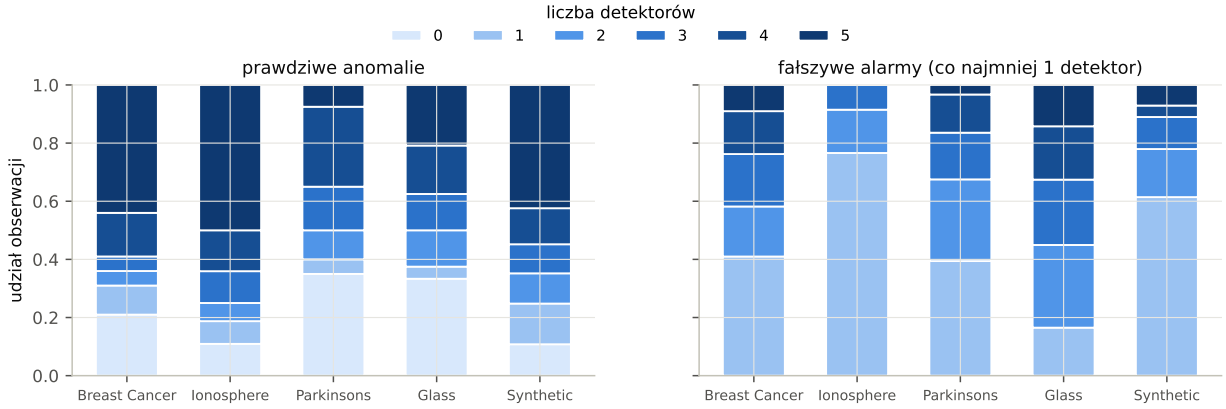
5.5 Zgodność zbiorów wykrytych wyjątków

Zgodność zbiorów obserwacji oznaczonych przez detektory zmierzono indeksem Jaccarda $J(A, B) = |A \cap B|/|A \cup B|$ (rys. 14, średnia z 10 podziałów). Średnia zgodność par wynosi 0,57–0,59 w Breast Cancer, Ionosphere i zbiorze syntetycznym, ale tylko 0,30 w Parkinsons i 0,41 w Glass – gdy problem jest trudny, detektory „zgadują" różnie. Najbardziej zgodne są metody o podobnym mechanizmie: LOF–DBSCAN w Breast Cancer (0,83), OCSVM–DBSCAN w Ionosphere (0,73) i COF–DBSCAN w zbiorze syntetycznym (0,71) – wszystkie trzy opierają się na odległościach do sąsiadów. Najmniej zgodny z resztą jest zwykle Isolation Forest (np. IForest–LOF 0,43 w Ionosphere i w zbiorze syntetycznym), co wynika z jego odmiennego, osiowego mechanizmu.



Rysunek 14: Indeks Jaccarda zbiorów obserwacji testowych oznaczonych jako anomalie przez pary detektorów (średnia z 10 podziałów).

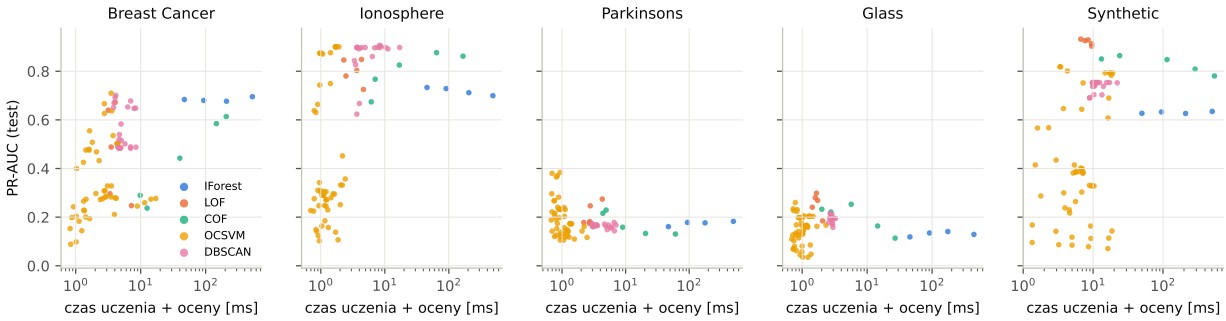
Rysunek 15 pokazuje, iloma detektorami wskazywana jest każda prawdziwa anomalia i każdy fałszywy alarm. Prawdziwe anomalie są zwykle wskazywane wspólnie: 42–50 % anomalii w Breast Cancer, Ionosphere i zbiorze syntetycznym wskazuje wszystkie pięć metod. Jednocześnie 11–21 % anomalii nie wykrywa żaden detektor (33–35 % w Glass i Parkinsons) – tych obserwacji nie uratuje żadna kombinacja detektorów. Fałszywe alarmy są natomiast w większości *indywidualne*: 77 % fałszywych alarmów w Ionosphere i 61 % w zbiorze syntetycznym zgłasza tylko jeden detektor. Obserwacje wykrywane wyłącznie przez jedną metodę to głównie anomalie lokalne wskazywane przez LOF (29 takich przypadków w zbiorze syntetycznym) i COF. Ta asymetria – błędy indywidualne, trafienia wspólne – jest przesłanką, że głosowanie detektorów może poprawić precyzję; zostanie to zbadane w zadaniu 3.



Rysunek 15: Rozkład liczby detektorów (spośród 5) wskazujących prawdziwe anomalie (lewo) oraz fałszywe alarmy wskazane przez co najmniej jeden detektor (prawo); część testowa, 10 podziałów.

5.6 Kompromis jakość – czas

Rysunek 16 zestawia czas (uczenie + ocena części testowej) z PR-AUC dla wszystkich konfiguracji. Najszybsze są OCSVM (mediana 1–6 ms) i LOF (2–8 ms) – przy kilkuset obserwacjach koszt $O(n^2)$ jest pomijalny. DBSCAN kosztuje 3–10 ms. COF jest wyraźnie wolniejszy (6–110 ms), bo dla każdego punktu buduje ścieżkę łańcuchową w czasie $O(k^2)$; jego koszt rośnie szybko z k i n. Isolation Forest jest najwolniejszy (ok. 140 ms) – jego koszt zależy głównie od liczby drzew, a nie od n, więc ma przewagę dopiero przy dużych zbiorach (złożoność liniowa względem n, podczas gdy LOF/COF/DBSCAN wymagają wyszukiwania sąsiadów, a OCSVM – rozwiązania problemu kwadratowego o złożoności $O(n^2)$–$O(n^3)$). W badanym zakresie (do 1000 obserwacji) najkorzystniejszy stosunek jakości do czasu mają LOF i OCSVM z jądrem RBF.



Rysunek 16: Czas uczenia i oceny a PR-AUC (część testowa) dla wszystkich konfiguracji siatki (średnie z 10 podziałów).

6 Dyskusja

Dlaczego algorytmy zachowują się inaczej? Różnice wynikają z tego, *co* każda metoda uznaje za nietypowe.

- **Isolation Forest** mierzy łatwość izolacji osiowymi cięciami w skali całego zbioru. Jest skuteczny dla wyjątków globalnych i ekstremalnych wartości pojedynczych cech, ale ślepy na wyjątki lokalne (Recall 0,00 w zbiorze syntetycznym) i słaby dla odchyleń rozłożonych na wiele skorelowanych cech (anomalie podprzestrzenne: 0,24).
- **LOF** porównuje gęstość punktu z gęstością sąsiadów, więc wykrywa wyjątki lokalne przy gęstych skupiskach. Ceną jest wrażliwość na k: za małe k prowadzi do maskowania skupisk

anomalii (Breast Cancer), za duże zaciera lokalność.

- **COF** zastępuje gęstość spójnością ścieżki; w danych bez wyraźnych struktur liniowych daje wyniki zbliżone do LOF, ale jest wolniejszy i bardziej czuły na duże k.
- **OCSVM** wyznacza jedną granicę dla całego zbioru; z jądrem RBF i odpowiednim γ może być bardzo skuteczny (Ionosphere), ale wynik silnie zależy od γ i jądra, a granica jest globalna – wyjątki lokalne przy gęstym skupisku pozostają wewnątrz niej.
- **DBSCAN** daje wysoką precyzję na zbiorach z wyraźnie odseparowanymi anomaliami (0,59–0,93), bo za szum uznaje tylko punkty rzeczywiście odizolowane, ale jeden globalny promień nie pasuje jednocześnie do skupisk o różnej gęstości (Recall lokalnych 0,00).

Wpływ parametrów na rodzaj wykrywanych wyjątków. Parametry progowe (contamination, ν, ε) decydują o *liczbie* wykrywanych wyjątków i przesuwają kompromis Precision–Recall. Ich zmniejszanie sprawia, że detektor zgłasza tylko najbardziej oczywiste, zwykle globalne wyjątki. Parametry kształtujące wynik (k w LOF/COF, γ i jądro w OCSVM, minPts w DBSCAN) decydują o *rodzaju* wykrywanych wyjątków – o skali, na której definiowana jest „normalność". Małe k lub duże γ czynią detektor lokalnym (wykrywa odchylenia od najbliższego otoczenia, ale też maskuje małe skupiska anomalii), a duże k lub małe γ – globalnym.

Interpretacja metryk przy niezbalansowaniu. Przy 4–10 % anomalii Accuracy jest bezużyteczna (tabela 2), a ROC-AUC optymistyczna, bo fałszywe alarmy są normalizowane dużą liczbą obserwacji normalnych. PR-AUC odnosi się do bazowego poziomu π i bezpośrednio uwzględnia koszt fałszywych alarmów, dlatego użyto jej do wyboru konfiguracji. Precision i Recall zależą od progu, więc porównując metody trzeba ustalić wspólną regułę wyboru progu (tu: maksymalizacja F1 na walidacji). F1 traktuje oba rodzaje błędów symetrycznie; w zastosowaniach (np. diagnostyka) należałoby dobrać próg do kosztu pominięcia anomalii.

Ograniczenia.

- Małe zbiory: części testowe Glass i Parkinsons zawierają 2 i 4 anomalie, części walidacyjne – tyle samo, więc wybór hiperparametrów i progu jest obarczony dużą wariancją (por. różnica 0,92 a 0,71 PR-AUC dla OCSVM). Uśrednianie po 10 podziałach łagodzi, ale nie usuwa tego problemu.
- Anomalie zdefiniowane jako klasa mniejszościowa nie muszą być „wyjątkami" w sensie rozkładu (Parkinsons, Glass) – ocena mierzy wtedy zgodność anomalii statystycznych z klasą, a nie jakość detektora w ogóle.
- Podział anomalii rzeczywistych na globalne i lokalne opiera się na przyjętej definicji (MCD, 99. percentyl); inna definicja zmieniłaby proporcje typów.
- Siatki hiperparametrów są skończone; DBSCAN był parametryzowany kwantylem ε, a OCSVM – względnym γ.
- Pomiary czasu dotyczą małych zbiorów (do 1000 obserwacji), na których stałe narzuty implementacji dominują nad złożonością asymptotyczną.

Kierunki dalszych badań. Ocena na większych zbiorach (skalowanie czasu), analiza wpływu reprezentacji danych (zadanie 2), łączenie detektorów, które – jak pokazała analiza zgodności – popełniają w dużej mierze różne błędy (zadanie 3), oraz metody półnadzorowane wykorzystujące niewielką liczbę etykiet z walidacji.

7 Wnioski

1. Żadna metoda nie dominuje: LOF jest najlepszy, gdy występują wyjątki lokalne (syntetyczny: PR-AUC 0,93), OCSVM z jądrem RBF i DBSCAN – gdy anomalie są globalnie odseparowane (Ionosphere: 0,90). Isolation Forest był najsłabszy na większości zbiorów.
2. O tym, *jakie* wyjątki są wykrywane, decyduje mechanizm metody: metody globalne (IForest, OCSVM, DBSCAN) nie wykrywają wyjątków lokalnych przy gęstych skupiskach (Recall 0,00–0,18), a metody lokalne (LOF, COF) tak.
3. Najważniejsze hiperparametry to k (LOF/COF), γ i jądro (OCSVM) oraz ε (DBSCAN); liczba drzew w IForest ma znikomy wpływ. Contamination, ν i ε sterują kompromisem Precision–Recall.
4. Przy niezbalansowaniu Accuracy jest myląca (trywialny klasyfikator osiąga 0,90–0,96), a ROC-AUC optymistyczna; podstawą oceny powinny być PR-AUC i F1.
5. Trafienia detektorów są w większości wspólne, a fałszywe alarmy indywidualne – to przesłanka do budowy zespołu detektorów (zadanie 3).
6. Jakość detekcji bardziej zależy od zbioru (tego, czy anomalie są wyjątkami w sensie rozkładu) niż od wyboru algorytmu: rozrzut PR-AUC między zbiorami (0,14–0,93) jest kilkukrotnie większy niż między metodami na tym samym zbiorze.

8 Odtworzenie wyników

```
python -m task1_classical.eda                # tabela 1, rys. 1-3
python -m task1_classical.run_grid           # siatka -> results/task1/grid.csv
python -m task1_classical.run_best           # najlepsze konfiguracje
python -m task1_classical.decision_regions   # rys. obszarów decyzyjnych
python -m task1_classical.analyze            # pozostałe tabele i rysunki
```

A Wyniki wszystkich eksperymentów

Tabele zawierają średnie z 10 podziałów (część testowa) dla każdej konfiguracji. F1 dotyczy wbudowanej reguły decyzyjnej metody (contamination c, granica OCSVM lub promień ε DBSCAN).

Isolation Forest

Konfiguracja	Breast Cancer		Ionosphere		Parkinsons		Glass		Synthetic	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
T=100, c=0,02	0,680	0,292	0,729	0,268	0,178	0,000	0,135	0,029	0,633	0,136
T=100, c=0,05	0,680	0,459	0,729	0,503	0,178	0,000	0,135	0,113	0,633	0,522
T=100, c=0,10	0,680	0,604	0,729	0,591	0,178	0,085	0,135	0,094	0,633	0,534
T=100, c=0,15	0,680	0,605	0,729	0,521	0,178	0,155	0,135	0,079	0,633	0,486
T=100, c=0,20	0,680	0,579	0,729	0,464	0,178	0,158	0,135	0,096	0,633	0,462
T=200, c=0,02	0,677	0,305	0,712	0,286	0,176	0,000	0,141	0,029	0,626	0,142
T=200, c=0,05	0,677	0,436	0,712	0,474	0,176	0,000	0,141	0,110	0,626	0,535
T=200, c=0,10	0,677	0,559	0,712	0,582	0,176	0,040	0,141	0,098	0,626	0,530
T=200, c=0,15	0,677	0,602	0,712	0,499	0,176	0,168	0,141	0,107	0,626	0,490
T=200, c=0,20	0,677	0,589	0,712	0,473	0,176	0,177	0,141	0,097	0,626	0,456
T=500, c=0,02	0,695	0,305	0,699	0,264	0,183	0,000	0,129	0,029	0,635	0,150
T=500, c=0,05	0,695	0,459	0,699	0,419	0,183	0,000	0,129	0,113	0,635	0,538
T=500, c=0,10	0,695	0,613	0,699	0,595	0,183	0,093	0,129	0,100	0,635	0,523
T=500, c=0,15	0,695	0,606	0,699	0,522	0,183	0,154	0,129	0,089	0,635	0,490

Konfiguracja	Breast Cancer		Ionosphere		Parkinsons		Glass		Synthetic	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
T=500, c=0,20	0,695	0,584	0,699	0,459	0,183	0,175	0,129	0,102	0,635	0,468
T=50, c=0,02	0,684	0,292	0,733	0,272	0,161	0,000	0,119	0,000	0,627	0,173
T=50, c=0,05	0,684	0,505	0,733	0,520	0,161	0,000	0,119	0,084	0,627	0,529
T=50, c=0,10	0,684	0,593	0,733	0,616	0,161	0,069	0,119	0,104	0,627	0,502
T=50, c=0,15	0,684	0,578	0,733	0,558	0,161	0,142	0,119	0,089	0,627	0,493
T=50, c=0,20	0,684	0,575	0,733	0,495	0,161	0,181	0,119	0,083	0,627	0,463

LOF

Konfiguracja	Breast Cancer		Ionosphere		Parkinsons		Glass		Synthetic	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
k=10, c=0,02	0,296	0,099	0,803	0,369	0,247	0,000	0,241	0,000	0,926	0,292
k=10, c=0,05	0,296	0,204	0,803	0,619	0,247	0,022	0,241	0,107	0,926	0,609
k=10, c=0,10	0,296	0,244	0,803	0,675	0,247	0,130	0,241	0,180	0,926	0,823
k=10, c=0,15	0,296	0,280	0,803	0,657	0,247	0,211	0,241	0,196	0,926	0,730
k=10, c=0,20	0,296	0,299	0,803	0,613	0,247	0,257	0,241	0,205	0,926	0,601
k=20, c=0,02	0,488	0,158	0,848	0,438	0,182	0,000	0,299	0,145	0,932	0,280
k=20, c=0,05	0,488	0,228	0,848	0,623	0,182	0,036	0,299	0,182	0,932	0,600
k=20, c=0,10	0,488	0,353	0,848	0,711	0,182	0,101	0,299	0,205	0,932	0,846
k=20, c=0,15	0,488	0,503	0,848	0,686	0,182	0,157	0,299	0,149	0,932	0,753
k=20, c=0,20	0,488	0,522	0,848	0,634	0,182	0,191	0,299	0,131	0,932	0,638
k=35, c=0,02	0,640	0,224	0,846	0,401	0,178	0,000	0,269	0,230	0,929	0,269
k=35, c=0,05	0,640	0,359	0,846	0,653	0,178	0,000	0,269	0,172	0,929	0,606
k=35, c=0,10	0,640	0,557	0,846	0,728	0,178	0,106	0,269	0,134	0,929	0,843
k=35, c=0,15	0,640	0,596	0,846	0,702	0,178	0,110	0,269	0,135	0,929	0,774
k=35, c=0,20	0,640	0,569	0,846	0,598	0,178	0,176	0,269	0,113	0,929	0,662
k=50, c=0,02	0,672	0,244	0,780	0,392	0,174	0,000	0,185	0,107	0,913	0,258
k=50, c=0,05	0,672	0,452	0,780	0,677	0,174	0,000	0,185	0,169	0,913	0,580
k=50, c=0,10	0,672	0,596	0,780	0,637	0,174	0,018	0,185	0,099	0,913	0,819
k=50, c=0,15	0,672	0,617	0,780	0,568	0,174	0,134	0,185	0,098	0,913	0,766
k=50, c=0,20	0,672	0,584	0,780	0,505	0,174	0,172	0,185	0,090	0,913	0,658
k=5, c=0,02	0,247	0,094	0,725	0,295	0,274	0,029	0,280	0,000	0,903	0,288
k=5, c=0,05	0,247	0,157	0,725	0,548	0,274	0,050	0,280	0,117	0,903	0,635
k=5, c=0,10	0,247	0,221	0,725	0,619	0,274	0,197	0,280	0,222	0,903	0,807
k=5, c=0,15	0,247	0,225	0,725	0,606	0,274	0,270	0,280	0,144	0,903	0,701
k=5, c=0,20	0,247	0,252	0,725	0,556	0,274	0,276	0,280	0,144	0,903	0,595

COF

Konfiguracja	Breast Cancer		Ionosphere		Parkinsons		Glass		Synthetic	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
k=10, c=0,02	0,289	0,153	0,767	0,380	0,216	0,000	0,221	0,000	0,864	0,310
k=10, c=0,05	0,289	0,211	0,767	0,459	0,216	0,069	0,221	0,194	0,864	0,591
k=10, c=0,10	0,289	0,279	0,767	0,683	0,216	0,175	0,221	0,172	0,864	0,785
k=10, c=0,15	0,289	0,269	0,767	0,624	0,216	0,236	0,221	0,190	0,864	0,664
k=10, c=0,20	0,289	0,254	0,767	0,590	0,216	0,251	0,221	0,176	0,864	0,591
k=20, c=0,02	0,442	0,210	0,826	0,407	0,159	0,000	0,253	0,033	0,848	0,311
k=20, c=0,05	0,442	0,292	0,826	0,581	0,159	0,022	0,253	0,158	0,848	0,599
k=20, c=0,10	0,442	0,356	0,826	0,732	0,159	0,096	0,253	0,172	0,848	0,756
k=20, c=0,15	0,442	0,424	0,826	0,664	0,159	0,107	0,253	0,184	0,848	0,697
k=20, c=0,20	0,442	0,443	0,826	0,592	0,159	0,115	0,253	0,219	0,848	0,622
k=35, c=0,02	0,585	0,268	0,876	0,506	0,133	0,000	0,164	0,087	0,809	0,290
k=35, c=0,05	0,585	0,420	0,876	0,745	0,133	0,029	0,164	0,121	0,809	0,572
k=35, c=0,10	0,585	0,540	0,876	0,795	0,133	0,051	0,164	0,110	0,809	0,726
k=35, c=0,15	0,585	0,539	0,876	0,684	0,133	0,088	0,164	0,165	0,809	0,662
k=35, c=0,20	0,585	0,511	0,876	0,618	0,133	0,101	0,164	0,166	0,809	0,600
k=50, c=0,02	0,614	0,254	0,862	0,411	0,130	0,000	0,114	0,075	0,781	0,291
k=50, c=0,05	0,614	0,479	0,862	0,781	0,130	0,000	0,114	0,069	0,781	0,561
k=50, c=0,10	0,614	0,541	0,862	0,783	0,130	0,033	0,114	0,067	0,781	0,666

Konfiguracja	Breast Cancer		Ionosphere		Parkinsons		Glass		Synthetic	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
k=50, c=0,15	0,614	0,551	0,862	0,722	0,130	0,043	0,114	0,089	0,781	0,628
k=50, c=0,20	0,614	0,515	0,862	0,600	0,130	0,053	0,114	0,110	0,781	0,588
k=5, c=0,02	0,237	0,140	0,674	0,386	0,229	0,040	0,232	0,050	0,851	0,313
k=5, c=0,05	0,237	0,182	0,674	0,475	0,229	0,119	0,232	0,209	0,851	0,601
k=5, c=0,10	0,237	0,248	0,674	0,615	0,229	0,192	0,232	0,180	0,851	0,756
k=5, c=0,15	0,237	0,216	0,674	0,606	0,229	0,220	0,232	0,144	0,851	0,650
k=5, c=0,20	0,237	0,220	0,674	0,544	0,229	0,224	0,232	0,105	0,851	0,580

One-Class SVM

Konfiguracja	Breast Cancer		Ionosphere		Parkinsons		Glass		Synthetic	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
poly, ν=0,01, γ=0,1/d	0,198	0,105	0,227	0,185	0,380	0,178	0,127	0,082	0,415	0,174
poly, ν=0,05, γ=0,1/d	0,229	0,110	0,276	0,171	0,142	0,147	0,227	0,086	0,435	0,175
poly, ν=0,10, γ=0,1/d	0,226	0,105	0,247	0,178	0,125	0,122	0,168	0,075	0,414	0,184
poly, ν=0,20, γ=0,1/d	0,194	0,099	0,310	0,180	0,120	0,135	0,134	0,072	0,402	0,204
poly, ν=0,50, γ=0,1/d	0,273	0,109	0,289	0,187	0,118	0,125	0,162	0,079	0,329	0,189
rbf, ν=0,01, γ=0,1/d	0,243	0,171	0,631	0,529	0,384	0,226	0,231	0,137	0,567	0,340
rbf, ν=0,05, γ=0,1/d	0,400	0,344	0,638	0,524	0,370	0,208	0,234	0,161	0,568	0,516
rbf, ν=0,10, γ=0,1/d	0,425	0,416	0,664	0,566	0,365	0,235	0,224	0,124	0,647	0,579
rbf, ν=0,20, γ=0,1/d	0,555	0,474	0,743	0,491	0,282	0,315	0,165	0,088	0,644	0,487
rbf, ν=0,50, γ=0,1/d	0,666	0,306	0,749	0,332	0,239	0,267	0,163	0,071	0,608	0,281
sigmoid, ν=0,01, γ=0,1/d	0,098	0,045	0,342	0,157	0,268	0,161	0,069	0,000	0,287	0,257
sigmoid, ν=0,05, γ=0,1/d	0,144	0,094	0,230	0,140	0,267	0,146	0,080	0,025	0,300	0,294
sigmoid, ν=0,10, γ=0,1/d	0,200	0,125	0,280	0,203	0,241	0,154	0,260	0,204	0,303	0,255
sigmoid, ν=0,20, γ=0,1/d	0,297	0,152	0,295	0,188	0,197	0,125	0,205	0,156	0,163	0,145
sigmoid, ν=0,50, γ=0,1/d	0,535	0,192	0,251	0,177	0,149	0,189	0,085	0,072	0,143	0,137
linear, ν=0,01	0,211	0,154	0,295	0,142	0,231	0,156	0,127	0,097	0,238	0,144
linear, ν=0,05	0,245	0,180	0,332	0,166	0,110	0,085	0,081	0,073	0,230	0,148
linear, ν=0,10	0,259	0,181	0,332	0,160	0,142	0,083	0,115	0,085	0,217	0,133
linear, ν=0,20	0,274	0,173	0,452	0,165	0,161	0,105	0,200	0,109	0,264	0,130
linear, ν=0,50	0,277	0,168	0,357	0,129	0,117	0,101	0,158	0,091	0,330	0,157
poly, ν=0,01, γ=1,0/d	0,276	0,122	0,310	0,169	0,106	0,112	0,141	0,096	0,382	0,310
poly, ν=0,05, γ=1,0/d	0,284	0,127	0,305	0,201	0,137	0,131	0,131	0,116	0,384	0,315
poly, ν=0,10, γ=1,0/d	0,283	0,130	0,290	0,168	0,124	0,113	0,146	0,135	0,387	0,310
poly, ν=0,20, γ=1,0/d	0,328	0,139	0,248	0,129	0,117	0,111	0,163	0,129	0,398	0,295
poly, ν=0,50, γ=1,0/d	0,308	0,122	0,271	0,189	0,126	0,132	0,167	0,091	0,328	0,195
rbf, ν=0,01, γ=1,0/d	0,476	0,442	0,873	0,599	0,233	0,258	0,198	0,106	0,818	0,724
rbf, ν=0,05, γ=1,0/d	0,476	0,442	0,874	0,599	0,232	0,262	0,198	0,115	0,818	0,724
rbf, ν=0,10, γ=1,0/d	0,479	0,437	0,874	0,599	0,233	0,263	0,198	0,115	0,801	0,683
rbf, ν=0,20, γ=1,0/d	0,508	0,452	0,871	0,559	0,231	0,250	0,178	0,099	0,752	0,542
rbf, ν=0,50, γ=1,0/d	0,626	0,312	0,876	0,335	0,203	0,244	0,163	0,084	0,690	0,334
sigmoid, ν=0,01, γ=1,0/d	0,089	0,029	0,225	0,160	0,188	0,058	0,110	0,000	0,168	0,071
sigmoid, ν=0,05, γ=1,0/d	0,204	0,174	0,142	0,044	0,205	0,071	0,103	0,040	0,142	0,120
sigmoid, ν=0,10, γ=1,0/d	0,274	0,228	0,163	0,121	0,191	0,069	0,125	0,062	0,117	0,114
sigmoid, ν=0,20, γ=1,0/d	0,468	0,305	0,185	0,183	0,153	0,114	0,058	0,013	0,112	0,122
sigmoid, ν=0,50, γ=1,0/d	0,710	0,280	0,138	0,125	0,105	0,085	0,035	0,000	0,114	0,131
poly, ν=0,01, γ=10,0/d	0,283	0,127	0,304	0,201	0,139	0,111	0,131	0,094	0,380	0,316
poly, ν=0,05, γ=10,0/d	0,277	0,123	0,304	0,201	0,142	0,125	0,131	0,118	0,384	0,319
poly, ν=0,10, γ=10,0/d	0,280	0,132	0,290	0,170	0,141	0,119	0,146	0,142	0,387	0,310
poly, ν=0,20, γ=10,0/d	0,328	0,139	0,245	0,129	0,118	0,111	0,164	0,132	0,398	0,296
poly, ν=0,50, γ=10,0/d	0,308	0,122	0,271	0,189	0,128	0,132	0,167	0,091	0,328	0,195
rbf, ν=0,01, γ=10,0/d	0,502	0,194	0,900	0,256	0,172	0,173	0,203	0,117	0,793	0,288
rbf, ν=0,05, γ=10,0/d	0,502	0,193	0,900	0,253	0,173	0,173	0,203	0,118	0,793	0,288
rbf, ν=0,10, γ=10,0/d	0,502	0,193	0,900	0,253	0,173	0,173	0,203	0,117	0,793	0,288
rbf, ν=0,20, γ=10,0/d	0,502	0,193	0,900	0,252	0,173	0,173	0,203	0,117	0,793	0,288
rbf, ν=0,50, γ=10,0/d	0,502	0,193	0,900	0,252	0,173	0,173	0,203	0,117	0,783	0,281
sigmoid, ν=0,01, γ=10,0/d	0,153	0,033	0,149	0,025	0,296	0,033	0,070	0,000	0,096	0,029
sigmoid, ν=0,05, γ=10,0/d	0,183	0,072	0,124	0,000	0,221	0,102	0,062	0,000	0,087	0,046
sigmoid, ν=0,10, γ=10,0/d	0,266	0,224	0,103	0,018	0,215	0,092	0,045	0,000	0,085	0,064
sigmoid, ν=0,20, γ=10,0/d	0,432	0,359	0,157	0,063	0,174	0,115	0,035	0,000	0,078	0,056

Konfiguracja	Breast Cancer		Ionosphere		Parkinsons		Glass		Synthetic	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
sigmoid, ν=0,50, γ=10,0/d	0,637	0,302	0,107	0,130	0,157	0,109	0,048	0,046	0,071	0,061

DBSCAN

Konfiguracja	Breast Cancer		Ionosphere		Parkinsons		Glass		Synthetic	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
minPts=10, q_ε=0,50	0,651	0,457	0,667	0,403	0,159	0,190	0,194	0,141	0,690	0,374
minPts=20, q_ε=0,50	0,670	0,497	0,624	0,371	0,165	0,093	0,158	0,137	0,692	0,468
minPts=3, q_ε=0,50	0,647	0,352	0,906	0,351	0,144	0,199	0,209	0,152	0,703	0,285
minPts=5, q_ε=0,50	0,653	0,407	0,860	0,377	0,149	0,215	0,197	0,171	0,704	0,316
minPts=10, q_ε=0,75	0,692	0,611	0,843	0,693	0,165	0,020	0,194	0,135	0,739	0,674
minPts=20, q_ε=0,75	0,701	0,618	0,827	0,737	0,168	0,025	0,194	0,098	0,737	0,719
minPts=3, q_ε=0,75	0,648	0,554	0,904	0,543	0,167	0,200	0,215	0,166	0,738	0,457
minPts=5, q_ε=0,75	0,678	0,586	0,897	0,648	0,163	0,082	0,178	0,169	0,740	0,558
minPts=10, q_ε=0,90	0,540	0,346	0,893	0,757	0,171	0,000	0,172	0,132	0,752	0,764
minPts=20, q_ε=0,90	0,583	0,322	0,892	0,634	0,173	0,000	0,172	0,129	0,753	0,696
minPts=3, q_ε=0,90	0,488	0,386	0,898	0,827	0,178	0,063	0,205	0,114	0,752	0,724
minPts=5, q_ε=0,90	0,501	0,332	0,898	0,829	0,171	0,000	0,197	0,120	0,752	0,747
minPts=10, q_ε=0,95	0,515	0,210	0,898	0,589	0,162	0,000	0,194	0,073	0,754	0,537
minPts=20, q_ε=0,95	0,519	0,151	0,898	0,438	0,161	0,000	0,195	0,040	0,754	0,529
minPts=3, q_ε=0,95	0,489	0,264	0,898	0,655	0,156	0,000	0,189	0,140	0,754	0,591
minPts=5, q_ε=0,95	0,488	0,228	0,898	0,655	0,162	0,000	0,189	0,190	0,754	0,569
minPts=10, q_ε=0,99	0,483	0,035	0,898	0,123	0,167	0,000	0,195	0,000	0,754	0,151
minPts=20, q_ε=0,99	0,483	0,017	0,898	0,054	0,167	0,000	0,195	0,000	0,754	0,123
minPts=3, q_ε=0,99	0,483	0,085	0,898	0,290	0,167	0,000	0,195	0,000	0,754	0,195
minPts=5, q_ε=0,99	0,485	0,053	0,898	0,218	0,167	0,000	0,195	0,000	0,754	0,171