Politechnika Łódzka
Wydział Fizyki Technicznej, Informatyki i Matematyki Stosowanej

Analiza danych złożonych z detekcją wyjątków

Zadanie 1

Porównanie klasycznych metod detekcji wyjątków

Jędrzej Kostyk
nr indeksu 264339

Rok akademicki 2026/2027

Spis treści

1 Cel i zakres **2**

2 Dane **2**

2.1 Zbiory benchmarkowe 2

2.2 Wstępna analiza danych 3

3 Protokół eksperymentalny **4**

4 Metody i badane hiperparametry **5**

5 Wyniki **5**

5.1 Dlaczego Accuracy prowadzi do błędnych wniosków 5

5.2 Wpływ hiperparametrów 6

5.3 Porównanie najlepszych konfiguracji 9

5.4 Wyjątki lokalne i globalne 11

5.5 Zgodność zbiorów wykrytych wyjątków 12

5.6 Kompromis jakość – czas 13

6 Dyskusja **14**

7 Wnioski **15**

8 Odtworzenie wyników **16**

A Wyniki wszystkich eksperymentów **16**

1 Cel i zakres

Celem zadania jest porównanie pięciu klasycznych metod detekcji wyjątków o różnych mechanizmach działania: Isolation Forest (izolacja przez losowe podziały), Local Outlier Factor (lokalna gęstość), Connectivity-based Outlier Factor (lokalna spójność sąsiedztwa), One-Class SVM (granica obszaru danych w przestrzeni jądrowej) oraz DBSCAN (punkty szumu w klasteryzacji gęstościowej). Szczególną uwagę poświęcono wpływowi hiperparametrów na liczbę i rodzaj wykrywanych wyjątków, problemowi silnego niezbalansowania klas, różnicy między wyjątkami globalnymi i lokalnymi oraz zgodności zbiorów obserwacji wskazywanych przez poszczególne detektory.

Eksperymenty przeprowadzono na pięciu zbiorach z publicznych benchmarków detekcji anomalii, dla 84 konfiguracji wymagających uczenia modelu (154 po uwzględnieniu wariantów progu `contamination`) i łącznie 90 podziałów danych (7560 wytrenowanych modeli). Cały kod znajduje się w katalogach `common/` i `task1_classical/` repozytorium, a wszystkie tabele i wykresy raportu są generowane skryptami (sekcja 8).

2 Dane

2.1 Zbiory benchmarkowe

Użyto gotowych zbiorów z trzech benchmarków detekcji anomalii: ADBench [1], ODDS [2] i repozytorium DAMI [3]. Macierz cech X i etykiety y ($y = 1$ – anomalia) są wczytywane dokładnie w postaci opublikowanej przez autorów benchmarków. **Etykiety anomalii pochodzą z tych zbiorów, a nie z tego projektu**: w kodzie nie są generowane, usuwane ani podpróbkowywane żadne obserwacje. Jedyne operacje na danych to podział warstwowy i standaryzacja dopasowana na części uczącej (sekcja 3). Zgodność plików sprawdzana jest sumami SHA256 (`data/CHECKSUMS.txt`) oraz udokumentowanymi kształtami i liczbą anomalii.

- **Breastw** (ADBench, plik `4_breastw.npz`) – Breast Cancer Wisconsin (Original) z UCI [4, 5]: 683 biopsje opisane 9 cechami cytologicznymi w skali 1–10. Anomalie: guzy złośliwe (239, 35,0 %).
- **Mammography** (ADBench, `23_mammography.npz`) – dane z pracy Woods i in. [7] (zbiór spoza UCI, udostępniany w ODDS i ADBench): 11 183 obszary mammogramów opisane 6 cechami obrazu. Anomalie: mikrozwapnienia (260, 2,3 %).
- **Wine** (ADBench, `45_wine.npz`) – Wine z UCI [4, 8]: 13 wyników analizy chemicznej win. Autorzy ODDS przyjęli klasy 2 i 3 jako normalne (119), a klasę 1, zredukowaną przez nich do 10 obserwacji, jako anomalie (7,8 %).
- **Statlog Heart** (DAMI, plik `HeartDisease_withoutdupl_05_v02.arff`) – Statlog (Heart) z UCI [4, 12]: 13 cech klinicznych. W wersji DAMI bez duplikatów, bez normalizacji, z 5 % anomalii (wariant v02): 150 osób zdrowych i 7 osób z chorobą serca jako anomalie (4,5 %). Normalizację wykonujemy sami na części uczącej.
- **Cardio** (ADBench, `6_cardio.npz`) – Cardiotocography z UCI [4, 9]: 1831 zapisów KTG opisanych 21 cechami. Klasa normalna (1655) jest normalna, klasa patologiczna zredukowana przez autorów ODDS do 176 obserwacji jest anomalią (9,6 %), klasa „podejrzana” została przez nich pominięta.

Zbiory różnią się wielkością (od 129 do 11 183 obserwacji) i udziałem anomalii (od 2,3 do 35 %). Breastw jest nietypowy: ponad jedna trzecia obserwacji to anomalie, więc tworzą one dużą, zwartą grupę, a nie rzadkie punkty. Wine i Statlog Heart mają tylko 10 i 7 anomalii, co ma konsekwencje dla protokołu (sekcja 3).

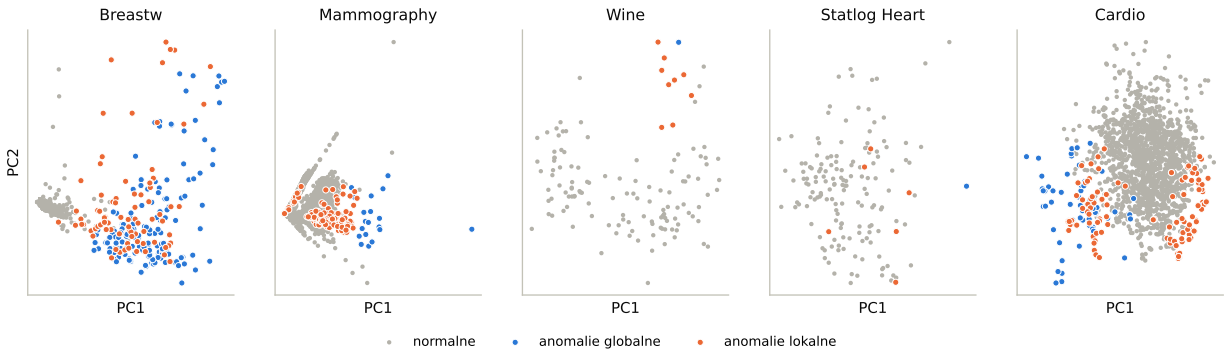
2.2 Wstępna analiza danych

Tabela 1 podsumowuje zbiory. Żaden nie zawiera braków danych. Cechy Breastw i Statlog Heart są całkowitoliczbowe (skale porządkowe, kody kategorii), a pozostałe w większości ciągłe. Mammography i Cardio mają silnie skośne rozkłady cech (średnia $|\gamma_1|$ odpowiednio 4,4 i 2,3; rys. 3). Wszystkie zbiory poza Statlog Heart zawierają silnie skorelowane pary cech (maksymalna $|r|$ od 0,81 do 0,94), więc ich efektywna wymiarowość jest mniejsza od liczby cech. Odsetek wartości $|z| > 3$ (jednowymiarowe wartości odstające) wynosi 0,5–1,3 % i występują one także w klasie normalnej, więc reguły typu „3 sigma" nie wystarczą do identyfikacji anomalii.

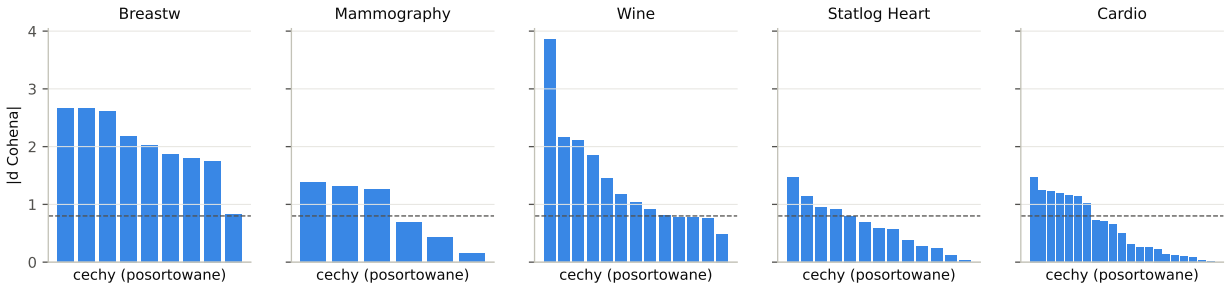
Tabela 1: Charakterystyka zbiorów. Glob./lok. – liczba anomalii globalnych i lokalnych wg definicji z sekcji 5.4; $\overline{|\gamma_1|}$ – średnia bezwzględna skośność cech; $|z| > 3$ – odsetek wartości odstających jednowymiarowo; max $|r|$ – największa bezwzględna korelacja dwóch cech; PC 90 % – liczba składowych głównych wyjaśniających 90 % wariancji.

Zbiór	Źródło	n	d	Anomalie	Udział [%]	Glob./lok.	Braki	$\overline{\lvert\gamma_1\rvert}$	$\lvert z\rvert > 3$ [%]	max $\lvert r\rvert$	PC 90%
Breastw	ADBench	683	9	239	35,0	158/81	0	1,46	1,01	0,91	6
Mammography	ADBench	11183	6	260	2,3	19/241	0	4,44	1,33	0,87	5
Wine	ADBench	129	13	10	7,8	1/9	0	0,61	0,83	0,81	8
Statlog Heart	DAMI	157	13	7	4,5	1/6	0	1,14	0,54	0,51	10
Cardio	ADBench	1831	21	176	9,6	61/115	0	2,27	1,11	0,94	12

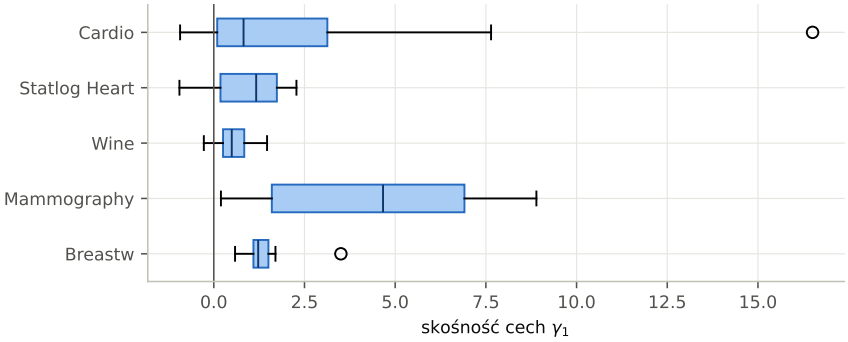
Rysunek 1 przedstawia rzut danych na dwie pierwsze składowe główne. W Breastw anomalie tworzą osobny, rozległy obszar. W Wine leżą na skraju chmury danych normalnych jako niewielkie skupisko. W Mammography i Cardio anomalie lokalne leżą na brzegu masy danych normalnych, a tylko nieliczne są wyraźnie oddalone. W Statlog Heart anomalie są wymieszane z danymi normalnymi. Potwierdza to rys. 2: w Breastw wszystkie cechy mają duży efekt ($|d| > 0{,}8$), w Wine i Cardio – kilka cech, a w Statlog Heart i Mammography tylko pojedyncze cechy przekraczają tę granicę.



Rysunek 1: Rzut zbiorów na dwie pierwsze składowe główne (dane standaryzowane); kolor anomalii oznacza typ (globalne/lokalne).



Rysunek 2: Bezwzględna wartość d Cohena (standaryzowana różnica średnich anomalii i obserwacji normalnych) dla kolejnych cech; linia przerywana – umowna granica dużego efektu (0,8).



Rysunek 3: Rozkład skośności cech w poszczególnych zbiorach.

3 Protokół eksperymentalny

1. **Podział danych.** Dla każdego zbioru i ziarna s dane dzielone są warstwowo na część uczącą, walidacyjną i testową w proporcji 50/25/25 %. Te same ziarna dają te same podziały we wszystkich trzech zadaniach.
2. **Liczba podziałów.** 10 podziałów (ziarna 0–9) dla Breastw, Mammography i Cardio oraz 30 podziałów (ziarna 0–29) dla Wine i Statlog Heart. W tych dwóch zbiorach część walidacyjna i testowa zawiera tylko 2–3 anomalie (Wine: 3 w części testowej, Statlog Heart: 2). Podział warstwowy gwarantuje co najmniej jedną anomalię w każdej części, co jest dodatkowo sprawdzane w kodzie. Pojedynczy podział jest jednak bardzo zaszumiony, więc wynik uśredniono po trzykrotnie większej liczbie podziałów.
3. **Przygotowanie.** Standaryzacja (`StandardScaler`) jest dopasowywana wyłącznie do części uczącej i stosowana do pozostałych części.
4. **Uczenie.** Detektory uczone są *bez etykiet* na części uczącej, która zawiera anomalie w naturalnej proporcji (scenariusz nienadzorowany). Każdy detektor zwraca wynik anomalii (wyższy = bardziej anomalny) dla nowych obserwacji.
5. **Strojenie.** Etykiety części walidacyjnej służą do wyboru konfiguracji (najwyższa średnia PR-AUC na walidacji, uśredniona po podziałach) i progu decyzyjnego (maksymalizacja F1 na walidacji). Część testowa służy wyłącznie do końcowej oceny.
6. **Metryki.** Precision, Recall, F1 (dla klasy „anomalia”), ROC-AUC, PR-AUC (*average precision*), Accuracy (tylko do ilustracji jej wad) oraz czas uczenia i czas oceny części testowej. Raportowane są średnie (i odchylenia standardowe) po podziałach.

Dla metod z parametrem `contamination` (IForest, LOF, COF) parametr ten nie zmienia wyniku anomalii, a jedynie próg: oznaczane jest $c{\cdot}100\,\%$ obserwacji uczących o najwyższym wyniku.

Dlatego wszystkie wartości c oceniane są na jednym wytrenowanym modelu. W przypadku OCSVM decyzja wynika z granicy SVM (sterowanej przez ν), a w DBSCAN – z promienia ε. W tabelach siatki (dodatek A) Precision, Recall i F1 dotyczą tych „wbudowanych" reguł decyzyjnych, a w porównaniu najlepszych konfiguracji (sekcja 5.3) – progu wybranego na walidacji.

4 Metody i badane hiperparametry

Isolation Forest. Las T drzew dzielących dane losowymi cięciami losowych cech; wynik anomalii zależy od średniej głębokości, na której obserwacja zostaje odizolowana. Punkty odległe od masy danych izolowane są po niewielu cięciach. Metoda patrzy na dane *globalnie* – cięcia osiowe nie „widzą" lokalnych różnic gęstości. Badano $T \in \{50, 100, 200, 500\}$ i $c \in \{0{,}02;\ 0{,}05;\ 0{,}1;\ 0{,}15;\ 0{,}2;\ 0{,}35\}$ (wartość 0,35 odpowiada udziałowi anomalii w Breastw).

LOF. Stosunek lokalnej gęstości osiągalności sąsiadów punktu do jego własnej gęstości. Wartości $\gg 1$ oznaczają punkt rzadszy niż jego otoczenie – miara jest *względna*, więc wykrywa wyjątki lokalne przy gęstych skupiskach. Badano $k \in \{5, 10, 20, 35, 50\}$ i te same wartości c. Użyto trybu `novelty=True`, który pozwala oceniać nowe dane.

COF. Wariant LOF, w którym gęstość zastąpiono *spójnością*: średnia odległość łańcuchowa (*average chaining distance*) wzdłuż ścieżki najbliższych połączeń (kolejność algorytmu Prima) w zbiorze k sąsiadów. COF lepiej niż LOF radzi sobie z wzorcami o niskiej gęstości, ale regularnej strukturze (np. punkty ułożone wzdłuż linii). Implementacja została napisana od podstaw (`common/cof.py`), bo dostępne implementacje nie oceniają nowych danych; zgodność z definicją sprawdzono na naiwnej implementacji referencyjnej (różnica 0). Siatka jak dla LOF.

One-Class SVM. Wyznacza w przestrzeni cech jądra hiperpłaszczyznę oddzielającą dane od początku układu z maksymalnym marginesem; ν jest górnym ograniczeniem odsetka punktów uczących poza granicą (i dolnym ograniczeniem odsetka wektorów nośnych). Badano jądra RBF, wielomianowe (stopnia 3), sigmoidalne i liniowe, $\nu \in \{0{,}01;\ 0{,}05;\ 0{,}1;\ 0{,}2;\ 0{,}5\}$ oraz $\gamma \in \{0{,}1/d,\ 1/d,\ 10/d\}$ (50 konfiguracji).

DBSCAN. Punkty rdzeniowe mają co najmniej minPts sąsiadów w promieniu ε; punkty nieosiągalne z żadnego rdzenia są szumem (anomalią). Aby oceniać nowe dane, wynikiem anomalii jest odległość do najbliższego punktu rdzeniowego z części uczącej, a anomalią – punkt, dla którego odległość ta przekracza ε. Ponieważ skala odległości zależy od wymiaru i zbioru, ε ustalano jako kwantyl $q_\varepsilon \in \{0{,}5;\ 0{,}75;\ 0{,}9;\ 0{,}95;\ 0{,}99\}$ rozkładu odległości do minPts-tego sąsiada (heurystyka wykresu k-odległości), minPts $\in \{3, 5, 10, 20\}$.

5 Wyniki

5.1 Dlaczego Accuracy prowadzi do błędnych wniosków

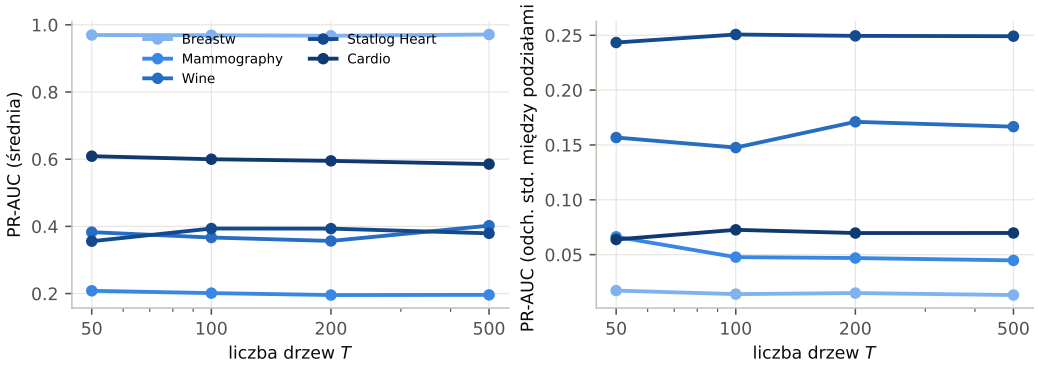
Tabela 2 zestawia trywialny klasyfikator „zawsze normalny" z najlepszym i najsłabszym (wg F1) detektorem. Poza Breastw klasyfikator trywialny osiąga Accuracy 0,90–0,98, nie wykrywając *żadnej* anomalii (Recall = F1 = 0). Na Mammography i Statlog Heart jego Accuracy (0,977 i 0,955) jest *wyższa* niż najlepszego detektora (0,974 i 0,889), choć ten wykrywa odpowiednio 23 i 48 % anomalii. Na Mammography różnica Accuracy między najlepszym a najsłabszym detektorem to 0,005, a w F1 – 0,09. Przy udziale anomalii π Accuracy jest zdominowana przez klasę normalną: wykrycie wszystkich anomalii zmienia ją o co najwyżej π. Dlatego w dalszej analizie podstawą są PR-AUC (której wartość dla losowego rankingu wynosi π, a nie 0,5 jak dla ROC-AUC) oraz F1.

Tabela 2: Accuracy a jakość wykrywania anomalii (część testowa, średnie po podziałach). „Losowy” – PR-AUC rankingu losowego (= udział anomalii).

Zbiór	Udział anomalii	Acc. “zawsze normalny”	F1 / Recall	PR-AUC losowy	Acc. najlepszy (F1)	F1 najlepszy	Acc. najsłabszy (F1)	F1 najsłabszy
Breastw	0,351	0,649	0,000 / 0,000	0,351	0,960 (DBSCAN)	0,944	0,539 (LOF)	0,582
Mammography	0,023	0,977	0,000 / 0,000	0,023	0,974 (DBSCAN)	0,290	0,969 (COF)	0,203
Wine	0,091	0,909	0,000 / 0,000	0,091	0,957 (OCSVM)	0,769	0,743 (COF)	0,241
Statlog Heart	0,050	0,950	0,000 / 0,000	0,050	0,889 (LOF)	0,282	0,867 (IForest)	0,167
Cardio	0,096	0,904	0,000 / 0,000	0,096	0,946 (OCSVM)	0,728	0,692 (COF)	0,186

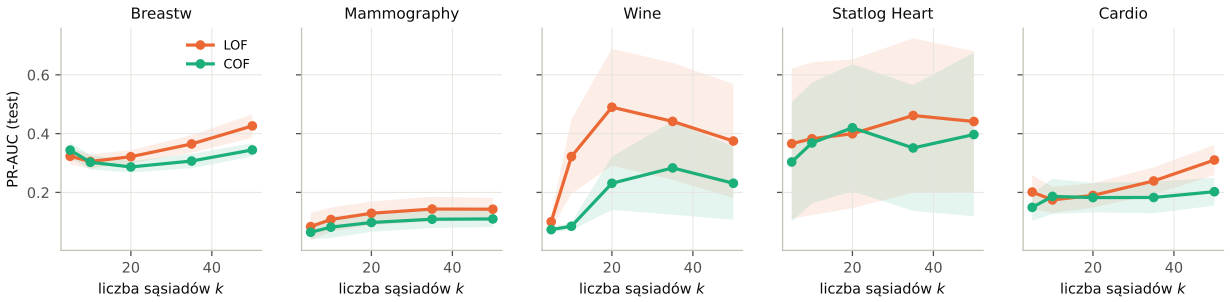
5.2 Wpływ hiperparametrów

Isolation Forest – liczba drzew. Liczba drzew praktycznie nie wpływa na średnią jakość (rys. 4; zmiany PR-AUC $\leq 0{,}045$, największe na małych Wine i Statlog Heart, gdzie odchylenie między podziałami wynosi 0,15–0,25). Na Mammography większa liczba drzew zmniejsza wariancję między podziałami (odchylenie 0,066 dla 50 drzew i 0,045 dla 500). Ponieważ czas uczenia rośnie liniowo z T, 100–200 drzew jest rozsądnym kompromisem. Różnice między zbiorami są o rząd wielkości większe niż różnice wynikające z T, co pokazuje, że ograniczeniem IForest jest jego mechanizm, a nie liczba drzew.



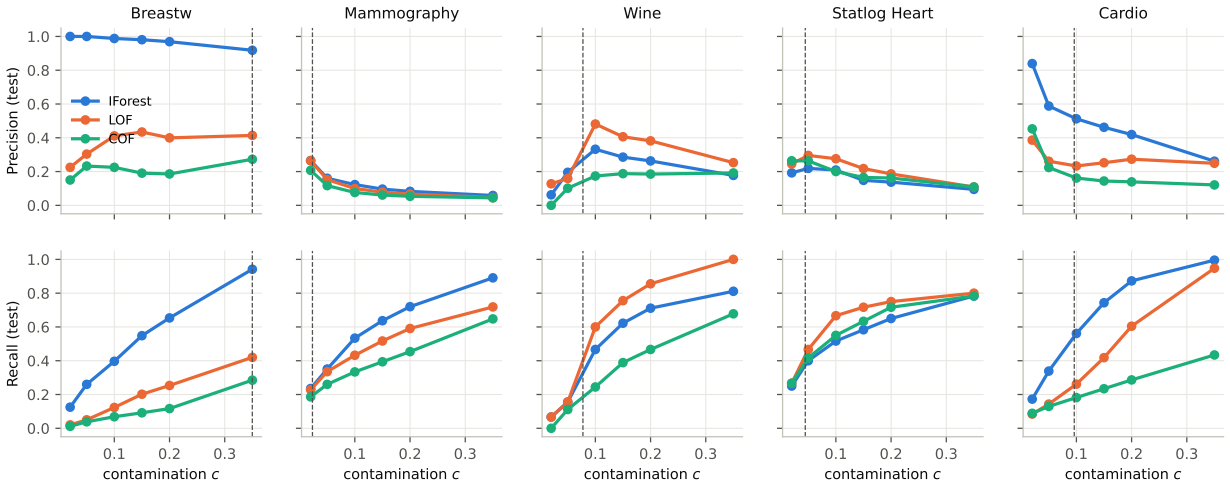
Rysunek 4: Isolation Forest: średnia i rozrzut PR-AUC w zależności od liczby drzew.

LOF i COF – liczba sąsiadów. Wpływ k jest silny i zależy od struktury anomalii (rys. 5). W Wine PR-AUC LOF rośnie z 0,10 ($k = 5$) do 0,49 ($k = 20$): anomalie tworzą małe skupisko (ok. 5 punktów w części uczącej), więc przy $k = 5$ sąsiadami anomalii są inne anomalie i jej gęstość względna wydaje się normalna (efekt maskowania). Dopiero k większe niż rozmiar skupiska pozwala je wykryć. W Cardio, Mammography i Breastw jakość rośnie monotonicznie aż do $k = 50$ (Cardio: 0,20 $\rightarrow$ 0,31), bo anomalie tworzą tam większe grupy. Skrajnym przypadkiem jest Breastw: 239 anomalii tworzy własny gęsty obszar, a LOF i COF niezależnie od k osiągają PR-AUC tylko 0,29–0,43 przy bazowym 0,35. Guz złośliwy jest „normalny” względem innych guzów złośliwych, a metody lokalne porównują punkt właśnie z jego sąsiadami. COF jest prawie wszędzie słabszy od LOF (np. Cardio: 0,20 wobec 0,31) – ścieżka łańcuchowa przy dużym k „przechodzi” przez sąsiednie skupiska i zaciera strukturę.



Rysunek 5: LOF i COF: PR-AUC (część testowa) w funkcji liczby sąsiadów; pasy – ±1 odchylenie standardowe między podziałami.

Parametr `contamination`. Parametr ten ustala odsetek oznaczanych obserwacji, a więc bezpośrednio steruje kompromisem Precision–Recall (rys. 6). Dla IForest na Cardio wzrost c z 0,02 do 0,35 podnosi Recall z 0,17 do 0,995, a Precision spada z 0,84 do 0,26. F1 jest największe w pobliżu rzeczywistego udziału anomalii: na Cardio ($\pi = 0{,}096$) przy $c = 0{,}15$ (0,57), na Breastw ($\pi = 0{,}35$) przy $c = 0{,}35$ (0,93), na Mammography ($\pi = 0{,}023$) przy $c = 0{,}02$ (0,25). Ważna obserwacja: contamination *nie zmienia* rankingu obserwacji (ROC-AUC i PR-AUC są stałe) – zmienia tylko, ile najwyżej ocenionych punktów nazywamy anomaliami. Przyjęcie c mniejszego od rzeczywistego udziału daje wysoką precyzję i niski Recall (detektor wskazuje tylko najbardziej oczywiste, zwykle globalne wyjątki), a większego – odwrotnie. W praktyce c jest nieznane, dlatego w porównaniu metod próg wyznaczano na walidacji.



Rysunek 6: Precision i Recall (część testowa) w zależności od contamination dla najlepszych (wg walidacji) wartości T i k; linia przerywana – rzeczywisty udział anomalii.

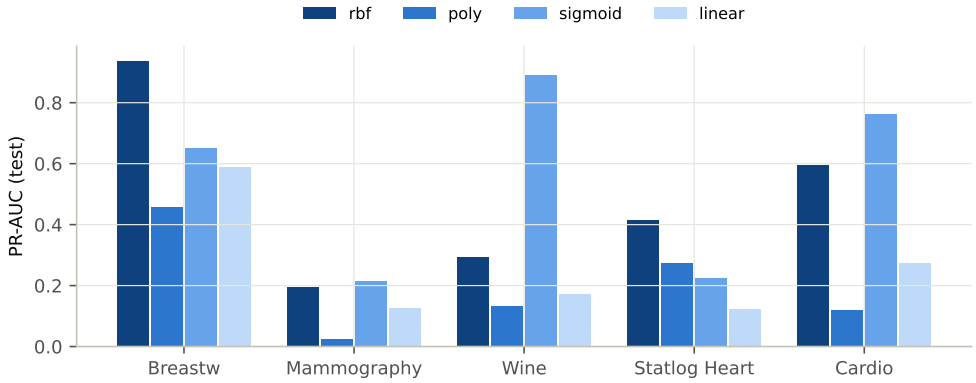
One-Class SVM. Kluczowe okazały się jądro i γ (rys. 7 i 8). Przy ν i γ wybranych na walidacji jądro RBF jest najlepsze na Breastw (PR-AUC 0,94) i Statlog Heart (0,42), a sigmoidalne – na Wine (0,89), Cardio (0,76) i Mammography (0,22). Jądro liniowe (0,13–0,59) i wielomianowe (0,02–0,46) są słabe – liniowa granica oddzielająca dane od początku układu nie może opisać skupisk ani obszarów niewypukłych, a jądro wielomianowe mocno zależy od skali danych. Sukces jądra sigmoidalnego jest empiryczny: nie jest ono dodatnio określone, więc wynik nie ma interpretacji granicy obszaru w przestrzeni Hilberta. Dla danych standaryzowanych przy $\nu = 0{,}5$ (we wszystkich trzech przypadkach) wynik zależy od iloczynów skalarnych z wieloma wektorami nośnymi i działa jak miara odchylenia od dominujących kierunków danych. Dla RBF γ steruje „lokalnością" granicy: $\gamma = 10/d$ daje granicę ciasno opinającą dane i jest najlepsze dla Breastw (0,92 niezależnie od ν), a $\gamma = 0{,}1/d$ – gładką granicę, najlepszą dla Cardio (0,60 przy $\nu = 0{,}5$,

wobec 0,26 przy $\gamma = 10/d$).

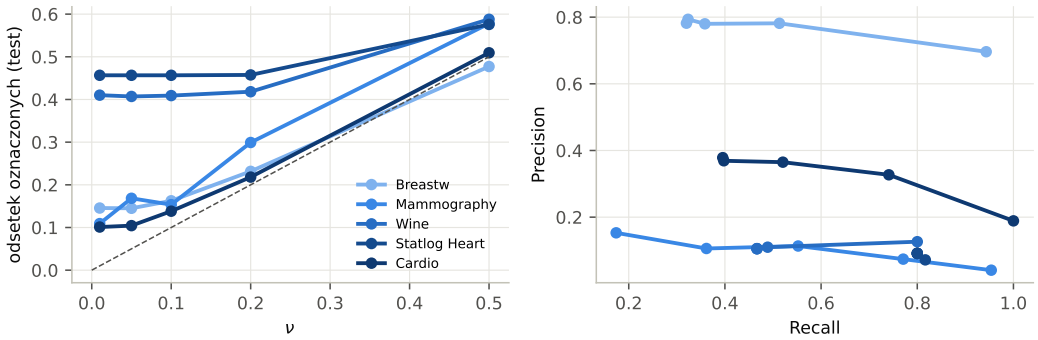
Parametr ν ogranicza odsetek *uczących* punktów poza granicą, ale na nowych danych odsetek oznaczonych punktów może być znacznie większy (rys. 9). Na małych Wine i Statlog Heart (64 i 78 punktów uczących, 13 cech) przy $\gamma = 1/d$ OCSVM oznacza 41–46 % punktów testowych nawet dla $\nu = 0{,}01$. Granica jest tak ciasno dopasowana do punktów uczących, że nowe punkty często leżą poza nią (nadmierne dopasowanie). Na większych Cardio i Mammography odsetek ten jest bliski ν dopiero od $\nu \approx 0{,}1$. Przy $\gamma = 10/d$ wynik prawie nie zależy od ν: jądro jest tak wąskie, że niemal każdy punkt staje się wektorem nośnym, a funkcja decyzyjna OCSVM sprowadza się do jądrowego estymatora gęstości (Parzena).



Rysunek 7: OCSVM z jądrem RBF: PR-AUC (część testowa) w zależności od ν i γ.



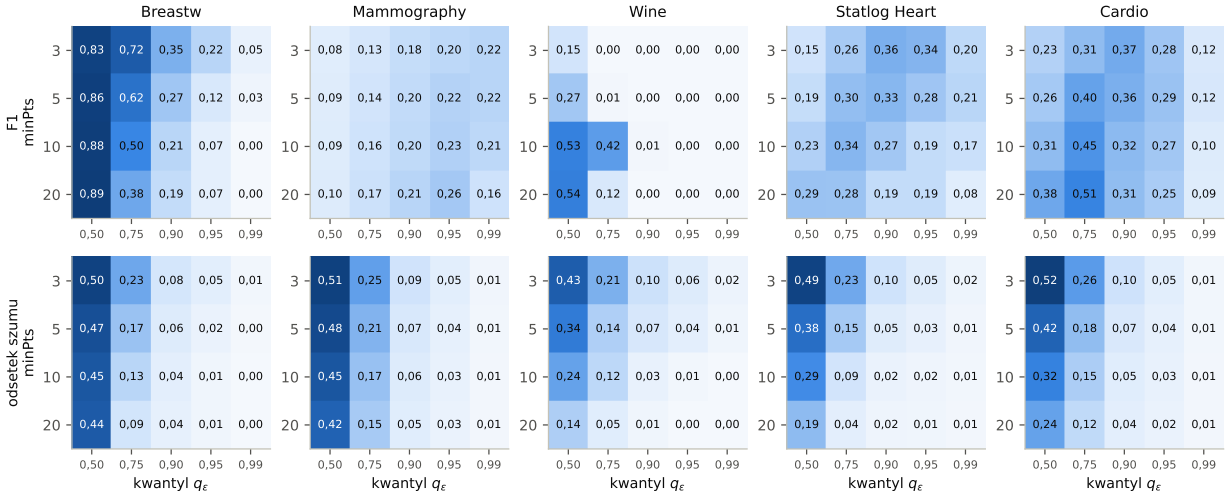
Rysunek 8: OCSVM: PR-AUC (część testowa) dla każdego jądra przy ν i γ wybranych na walidacji.



Rysunek 9: OCSVM (RBF, $\gamma = 1/d$): odsetek oznaczonych punktów testowych w funkcji ν (linia przerywana – $y = \nu$) oraz kompromis Precision–Recall przy zmianie ν.

DBSCAN. Rysunek 10 pokazuje, że w DBSCAN o wynikach decyduje przede wszystkim ε: odsetek punktów szumu maleje od 29–46 % dla $q_\varepsilon = 0{,}5$ do 0,4–1,1 % dla $q_\varepsilon = 0{,}99$. F1 osiąga

maksimum, gdy odsetek szumu jest bliski udziałowi anomalii lub nieco większy: Breastw $q_\varepsilon = 0{,}5$ (szum 46 %, F1 = 0,89), Cardio $q_\varepsilon = 0{,}75$ (18 %, 0,52), Mammography $q_\varepsilon = 0{,}95$ (3 %, 0,26). Wpływ minPts najlepiej widać na Wine. Anomalie (ok. 5 punktów w części uczącej) tworzą małe skupisko, które przy minPts ≤ 5 staje się osobnym klastrem: punkty rdzeniowe są wtedy wśród anomalii i dla $q_\varepsilon \geq 0{,}75$ F1 spada do zera. Dopiero minPts = 10 lub 20 (więcej niż rozmiar skupiska) sprawia, że anomalie nie mogą utworzyć rdzenia i stają się szumem (F1 = 0,53–0,54 przy $q_\varepsilon = 0{,}5$). Wadą DBSCAN jest jeden globalny promień ε – nie da się dobrać go jednocześnie do gęstego i rzadkiego skupiska.



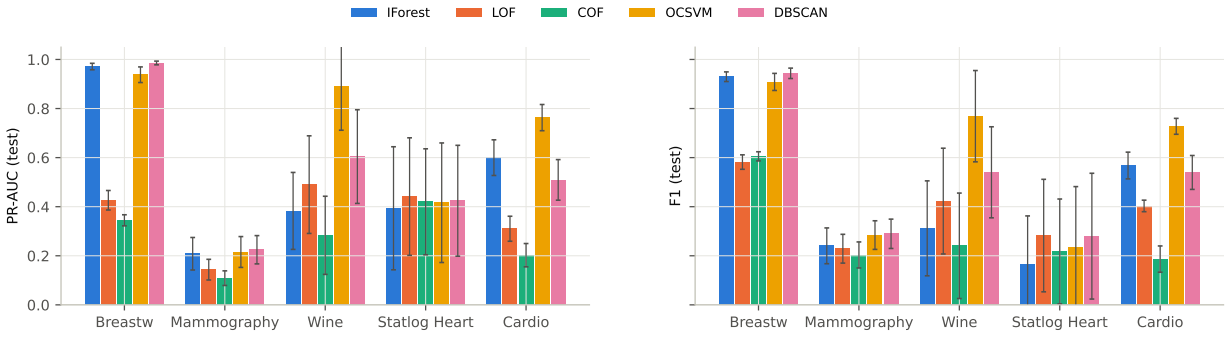
Rysunek 10: DBSCAN: F1 (górny wiersz) i odsetek punktów testowych uznanych za szum (dolny wiersz) w zależności od minPts i kwantyla q_ε wyznaczającego ε.

5.3 Porównanie najlepszych konfiguracji

Tabela 3 i rys. 11 przedstawiają wyniki konfiguracji wybranych na walidacji, z progiem maksymalizującym F1 na walidacji.

Tabela 3: Najlepsze konfiguracje (wybór na walidacji wg PR-AUC, próg z walidacji wg F1); część testowa, średnia (± odchylenie std.) po podziałach (10 lub 30). Czas = uczenie + ocena części testowej. Pogrubienie – najlepsza metoda na zbiorze.

Zbiór	Metoda	Konfiguracja	Prec.	Rec.	F1	ROC-AUC	PR-AUC	Czas [ms]
Breastw	IForest	T=500	0,899	0,965	0,930 ± 0,020	0,987	0,971 ± 0,013	624,9
	LOF	k=50	0,430	0,910	0,582 ± 0,029	0,628	0,426 ± 0,040	9,1
	COF	k=50	0,438	0,980	0,605 ± 0,019	0,527	0,345 ± 0,023	162,3
	OCSVM	rbf, ν=0,50, γ=10,0/d	0,865	0,958	0,908 ± 0,035	0,976	0,938 ± 0,032	6,1
	DBSCAN	minPts=20, q_ε=0,50	0,933	0,955	**0,944 ± 0,021**	0,992	**0,986 ± 0,008**	9,1
Mammography	IForest	T=50	0,262	0,254	0,241 ± 0,073	0,854	0,208 ± 0,066	93,1
	LOF	k=35	0,270	0,226	0,229 ± 0,059	0,774	0,143 ± 0,042	161,5
	COF	k=35	0,274	0,174	0,203 ± 0,053	0,737	0,109 ± 0,030	969,2
	OCSVM	sigmoid, ν=0,50, γ=0,1/d	0,265	0,326	0,284 ± 0,058	0,820	0,215 ± 0,063	1378,1
	DBSCAN	minPts=3, q_ε=0,50	0,404	0,232	**0,290 ± 0,060**	0,844	**0,225 ± 0,058**	265,8
Wine	IForest	T=50	0,274	0,444	0,312 ± 0,193	0,795	0,383 ± 0,157	56,9
	LOF	k=20	0,361	0,622	0,423 ± 0,215	0,907	0,490 ± 0,199	2,0
	COF	k=35	0,182	0,456	0,241 ± 0,215	0,735	0,283 ± 0,159	14,9
	OCSVM	sigmoid, ν=0,50, γ=10,0/d	0,872	0,756	**0,769 ± 0,186**	0,968	**0,891 ± 0,179**	1,3
	DBSCAN	minPts=10, q_ε=0,50	0,500	0,700	0,540 ± 0,186	0,932	0,604 ± 0,191	3,4
Statlog Heart	IForest	T=100	0,123	0,333	0,167 ± 0,196	0,795	0,394 ± 0,251	115,8
	LOF	k=50	0,242	0,483	**0,282 ± 0,229**	0,815	**0,441 ± 0,239**	3,0
	COF	k=20	0,190	0,433	0,218 ± 0,214	0,797	0,420 ± 0,216	7,1
	OCSVM	rbf, ν=0,50, γ=1,0/d	0,198	0,433	0,236 ± 0,246	0,808	0,416 ± 0,244	1,4
	DBSCAN	minPts=10, q_ε=0,75	0,265	0,433	0,280 ± 0,256	0,811	0,424 ± 0,226	4,0
Cardio	IForest	T=100	0,483	0,705	0,568 ± 0,054	0,937	0,600 ± 0,073	144,2
	LOF	k=50	0,266	0,848	0,403 ± 0,023	0,848	0,310 ± 0,051	21,7
	COF	k=50	0,235	0,398	0,186 ± 0,054	0,600	0,202 ± 0,047	788,4
	OCSVM	sigmoid, ν=0,50, γ=1,0/d	0,716	0,748	**0,728 ± 0,032**	0,920	**0,763 ± 0,053**	55,7
	DBSCAN	minPts=20, q_ε=0,50	0,548	0,536	0,540 ± 0,069	0,820	0,509 ± 0,083	22,3



Rysunek 11: PR-AUC i F1 najlepszych konfiguracji; słupki błędów – odchylenie standardowe między podziałami.

Nie ma metody najlepszej na wszystkich zbiorach. OCSVM wygrywa na Cardio (PR-AUC 0,76, F1 0,73) i Wine (0,89; 0,77). DBSCAN wygrywa na Breastw (0,99; 0,94) i ma najwyższe PR-AUC i F1 na Mammography (0,23; 0,29), ale tam różnice między DBSCAN, OCSVM i IForest (0,21–0,23) mieszczą się w odchyleniu między podziałami. Na Statlog Heart wszystkie metody osiągają PR-AUC 0,39–0,44 przy odchyleniu 0,22–0,25, więc nie da się ich uporządkować. Metody lokalne (LOF, COF) są wyraźnie najsłabsze na Breastw i Cardio. Isolation Forest jest solidny, ale nigdzie nie wygrywa.

Na tle wysokich ROC-AUC widać, dlaczego ROC-AUC jest metryką optymistyczną przy

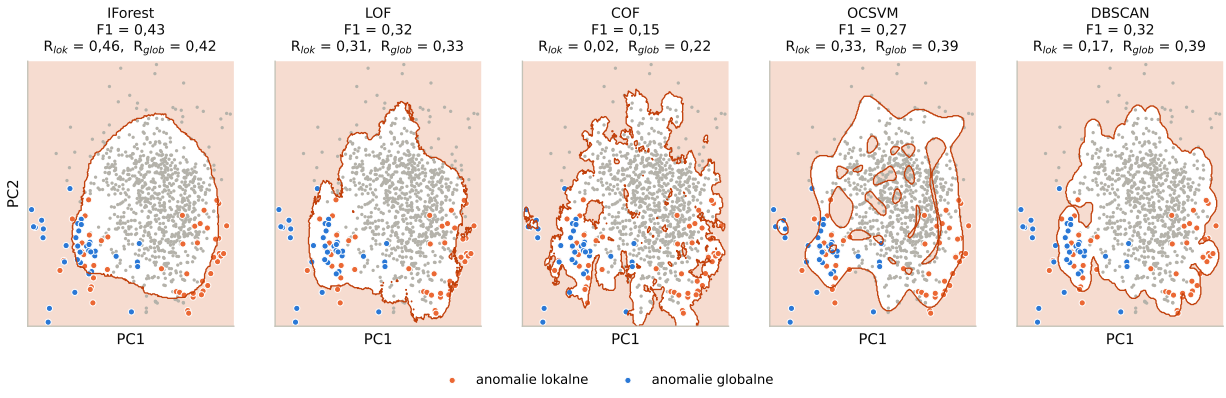
niezbalansowaniu. Na Mammography wszystkie metody mają ROC-AUC 0,74–0,85, a PR-AUC tylko 0,11–0,23: IForest z ROC-AUC 0,85 osiąga F1 = 0,24, czyli przy progu z walidacji trzy na cztery zgłoszenia są fałszywe. Oś FPR na krzywej ROC jest normalizowana liczbą obserwacji normalnych (42 razy większą od liczby anomalii), więc dziesiątki fałszywych alarmów prawie nie obniżają ROC-AUC. PR-AUC i Precision bezpośrednio pokazują ten koszt. Na Statlog Heart ROC-AUC $\approx$ 0,8 odpowiada PR-AUC $\approx$ 0,4 przy bazowym 0,045 – ranking jest znacznie lepszy od losowego, ale część testowa zawiera tylko dwie anomalie, więc F1 przyjmuje w pojedynczym podziale kilka możliwych wartości (odchylenie 0,20–0,26).

Rozbieżność między siatką a wyborem na walidacji jest niewielka: dla 18 z 25 par zbiór–metoda konfiguracja wybrana na walidacji jest też najlepsza na teście, a w pozostałych różnica PR-AUC nie przekracza 0,02 – z wyjątkiem DBSCAN na Statlog Heart (najlepsza na teście 0,50, wybrana na walidacji 0,42). Część walidacyjna zawiera tam tylko 2 anomalie, więc wybór hiperparametrów jest zaszumiony. Raportowanie maksimum z siatki na zbiorze testowym zawyżałoby wyniki – dlatego wszystkie porównania metod opierają się na wyborze walidacyjnym.

5.4 Wyjątki lokalne i globalne

Benchmarki nie określają typu anomalii, więc przyjęto definicję operacyjną: anomalia jest *globalna*, jeśli jej odporna odległość Mahalanobisa od klasy normalnej przekracza 99. percentyl odległości obserwacji normalnych, a w przeciwnym razie *lokalna* (leży wewnątrz globalnej „otoczki" danych normalnych i odróżnia ją tylko sąsiedztwo). Kowariancję klasy normalnej szacowano estymatorem MCD. W Cardio, które ma liniowo zależne cechy (macierz kowariancji źle uwarunkowana), użyto estymatora Ledoita–Wolfa. Etykiety typów służą wyłącznie analizie – nie zmieniają etykiet benchmarku. Większość anomalii jest w tym sensie lokalna (tabela 1): 93 % w Mammography, 90 % w Wine, 86 % w Statlog Heart i 65 % w Cardio. Wyjątkiem jest Breastw (34 % lokalnych).

Rysunek 12 pokazuje obszary decyzyjne w dwuwymiarowym rzucie części uczącej Cardio na dwie pierwsze składowe główne. Wszystkie metody oznaczają 10 % punktów, co odpowiada udziałowi anomalii w Cardio. IForest, OCSVM i DBSCAN wyznaczają *jeden* zwarty obszar normalności wokół masy danych. LOF i COF tworzą postrzępioną granicę, która oznacza także luki wewnątrz chmury i obrzeża mniejszych zgęszczeń. Rzut zachowuje jednak tylko część struktury 21-wymiarowych danych: wiele anomalii lokalnych leży w nim wewnątrz chmury danych normalnych, a nawet najlepszy w tym rzucie IForest osiąga F1 = 0,43. Rysunek ilustruje więc kształt granic poszczególnych metod, a nie ich skuteczność w pełnej przestrzeni.



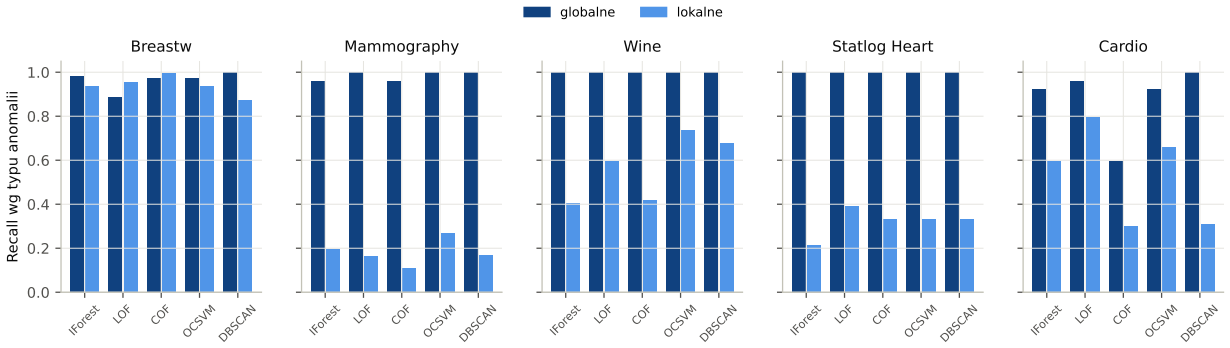
Rysunek 12: Obszary uznane za anomalne (kolor jasnopomarańczowy) w rzucie części uczącej Cardio (podział 0) na dwie pierwsze składowe główne; detektory uczone w tym rzucie. Kolor punktów – typ anomalii wyznaczony w pełnej przestrzeni cech. R_{lok}, R_{glob} – Recall anomalii lokalnych i globalnych.

W pełnej przestrzeni (tabela 4, rys. 13) anomalie globalne są wykrywane prawie w całości przez wszystkie metody (Recall 0,89–1,00; jedynym wyjątkiem jest COF na Cardio, 0,59). O

jakości decydują anomalie lokalne. Na Cardio najlepiej wykrywa je LOF (Recall 0,79), wyraźnie przed OCSVM (0,66) i IForest (0,60), a DBSCAN i COF wykrywają je słabo (0,31 i 0,30). Na Statlog Heart LOF również prowadzi (0,39). Na Wine i Mammography najwięcej anomalii lokalnych wykrywa OCSVM (0,74 i 0,27). W Mammography wszystkie metody wykrywają mniej niż 30 % anomalii lokalnych, które stanowią 93 % anomalii tego zbioru. To wyjaśnia niskie PR-AUC wszystkich metod na Mammography. Na Breastw podział na globalne i lokalne traci znaczenie: progi są tak niskie (35 % anomalii), że oba typy są wykrywane w 87–100 %. W Wine i Statlog Heart anomalii globalnych jest tylko 6 i 9 (suma po wszystkich częściach testowych), więc dla tych zbiorów Recall globalnych należy traktować orientacyjnie.

Tabela 4: Recall według typu anomalii (część testowa; n – liczba anomalii danego typu zsumowana po częściach testowych wszystkich podziałów).

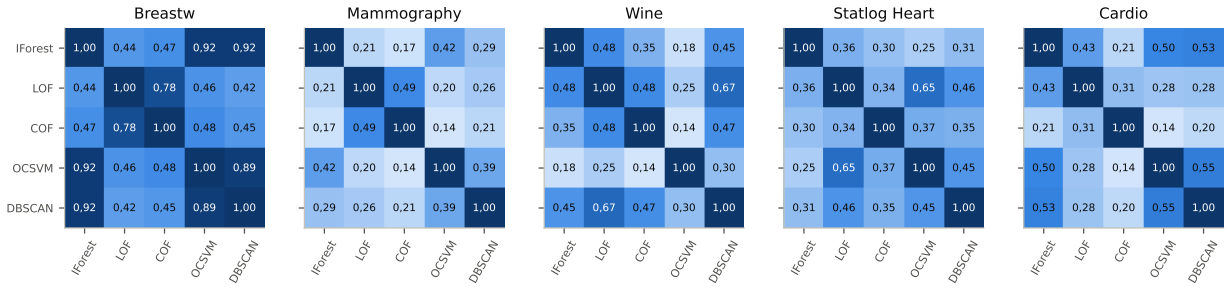
Zbiór	Typ	n (suma pow.)	IForest	LOF	COF	OCSVM	DBSCAN
Breastw	globalne	385	0,982	0,886	0,971	0,971	**1,000**
	lokalne	215	0,935	0,953	**0,995**	0,935	0,874
Mammography	globalne	50	0,960	**1,000**	0,960	**1,000**	**1,000**
	lokalne	600	0,195	0,162	0,108	**0,270**	0,168
Wine	globalne	6	**1,000**	**1,000**	**1,000**	**1,000**	**1,000**
	lokalne	84	0,405	0,595	0,417	**0,738**	0,679
Statlog Heart	globalne	9	**1,000**	**1,000**	**1,000**	**1,000**	**1,000**
	lokalne	51	0,216	**0,392**	0,333	0,333	0,333
Cardio	globalne	145	0,924	0,959	0,593	0,924	**1,000**
	lokalne	295	0,597	**0,793**	0,302	0,661	0,308



Rysunek 13: Recall według typu anomalii dla najlepszych konfiguracji.

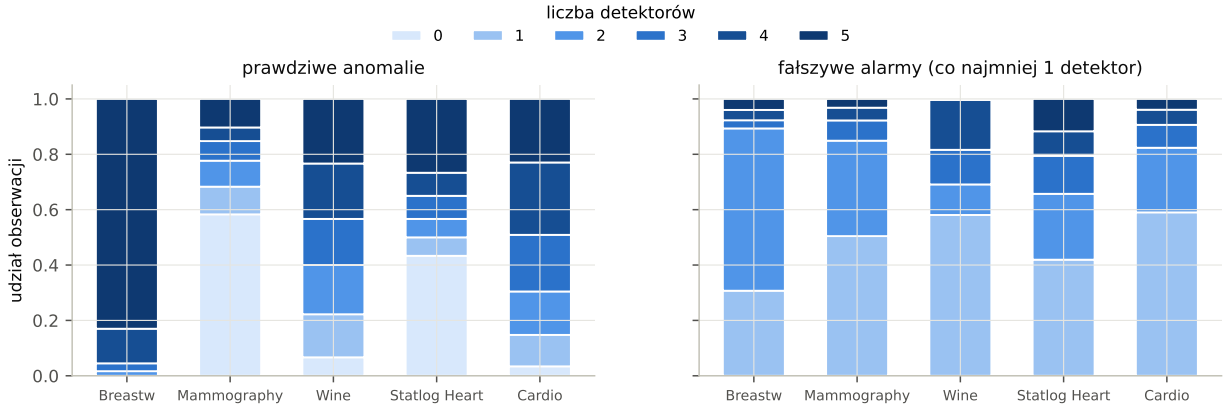
5.5 Zgodność zbiorów wykrytych wyjątków

Zgodność zbiorów obserwacji oznaczonych przez detektory zmierzono indeksem Jaccarda $J(A, B) = |A \cap B|/|A \cup B|$ (rys. 14, średnia po podziałach). Średnia zgodność par wynosi 0,62 w Breastw, ale tylko 0,28–0,38 w pozostałych zbiorach – gdy problem jest trudny, detektory wskazują różne obserwacje. Wyraźnie widać dwie rodziny metod. Metody globalne IForest, OCSVM i DBSCAN są ze sobą zgodne (Breastw 0,89–0,92, Cardio 0,50–0,55), a lokalne LOF i COF – ze sobą (Breastw 0,78, Mammography 0,49). Między rodzinami zgodność jest niska (Breastw 0,42–0,48, Cardio 0,14–0,43). Zgodność odzwierciedla więc mechanizm metody bardziej niż jej jakość.



Rysunek 14: Indeks Jaccarda zbiorów obserwacji testowych oznaczonych jako anomalie przez pary detektorów (średnia po podziałach).

Rysunek 15 pokazuje, iloma detektorami wskazywana jest każda prawdziwa anomalia i każdy fałszywy alarm. W Breastw 83 % anomalii wskazują wszystkie pięć metod i żadna nie zostaje pominięta przez wszystkie. W pozostałych zbiorach zgodnie wskazywanych jest tylko 10–27 % anomalii, a żaden detektor nie wykrywa 3 % anomalii Cardio, 7 % Wine, 43 % Statlog Heart i 58 % Mammography. Tych obserwacji nie uratuje żadna kombinacja detektorów. Fałszywe alarmy są natomiast w dużej mierze *indywidualne*: 42–59 % fałszywych alarmów zgłasza tylko jeden detektor (poza Breastw, 31 %). Anomalie wykrywane wyłącznie przez jedną metodę to głównie trafienia LOF (30 przypadków w Cardio) i OCSVM (39 w Mammography, 14 w Cardio, 11 w Wine). Ta asymetria – błędy indywidualne, część trafień unikatowa – jest przesłanką, że łączenie detektorów może poprawić jakość; zostanie to zbadane w zadaniu 3.

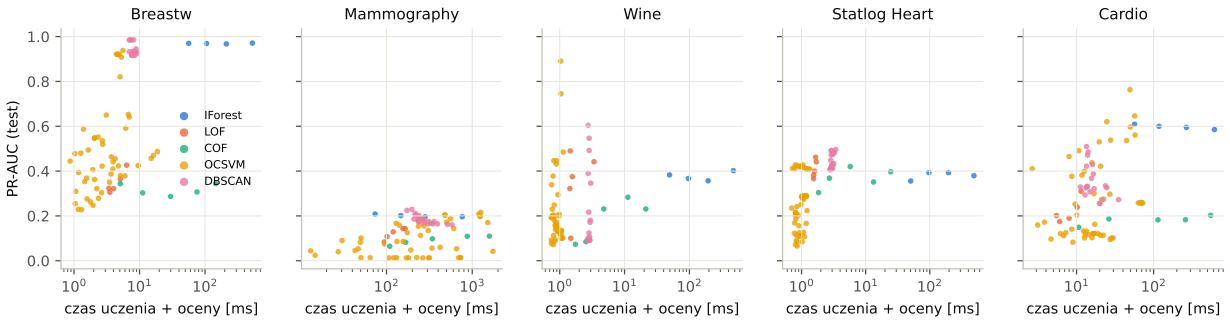


Rysunek 15: Rozkład liczby detektorów (spośród 5) wskazujących prawdziwe anomalie (lewo) oraz fałszywe alarmy wskazane przez co najmniej jeden detektor (prawo); część testowa, wszystkie podziały.

5.6 Kompromis jakość – czas

Rysunek 16 zestawia czas (uczenie + ocena części testowej) z PR-AUC dla wszystkich konfiguracji. Na małych zbiorach (Wine, Statlog Heart; ok. 70 punktów uczących) OCSVM i LOF potrzebują 1–2 ms, a Isolation Forest ok. 145 ms. Jego koszt zależy głównie od liczby drzew, a każde drzewo budowane jest na podpróbce 256 punktów, więc prawie nie zależy od n. Wraz z rozmiarem danych proporcje się odwracają. Mediana czasu OCSVM rośnie z 3 ms (Breastw, 341 punktów uczących) przez 17 ms (Cardio, 915) do 246 ms (Mammography, 5591; maksimum 1,7 s), czyli szybciej niż liniowo, zgodnie ze złożonością $O(n^2)$–$O(n^3)$ rozwiązania problemu kwadratowego. IForest w tym samym zakresie zmienia się tylko z 158 do 214 ms. COF jest najwolniejszy na większych zbiorach (mediana 343 ms na Mammography), bo dla każdego punktu buduje ścieżkę łańcuchową w czasie $O(k^2)$. LOF (120 ms) i DBSCAN (252 ms) wymagają wyszukiwania sąsiadów. W badanym zakresie najkorzystniejszy stosunek jakości do czasu ma OCSVM na zbiorach do kilku tysięcy obserwacji. Przy dziesiątkach tysięcy obserwacji przewagę zyskuje IForest (por. pomiary dla Campaign w

zadaniu 2).



Rysunek 16: Czas uczenia i oceny a PR-AUC (część testowa) dla wszystkich konfiguracji siatki (średnie po podziałach).

6 Dyskusja

Dlaczego algorytmy zachowują się inaczej? Różnice wynikają z tego, *co* każda metoda uznaje za nietypowe.

- **Isolation Forest** mierzy łatwość izolacji osiowymi cięciami w skali całego zbioru. Jest skuteczny, gdy anomalie odstają globalnie lub w pojedynczych cechach (Breastw: 0,97), i stabilny względem hiperparametrów, ale słabszy dla anomalii lokalnych (Cardio: Recall lokalnych 0,60 wobec 0,79 dla LOF).
- **LOF** porównuje gęstość punktu z gęstością sąsiadów, więc najlepiej wykrywa wyjątki lokalne (Cardio, Statlog Heart). Zawodzi, gdy anomalii jest dużo i tworzą własny gęsty obszar (Breastw: 0,43) – wtedy założenie „anomalia jest rzadsza od sąsiadów" nie jest spełnione. Za małe k prowadzi do maskowania małych skupisk anomalii (Wine).
- **COF** zastępuje gęstość spójnością ścieżki; w danych bez wyraźnych struktur liniowych daje wyniki gorsze niż LOF, a jest najwolniejszy.
- **OCSVM** wyznacza jedną granicę dla całego zbioru; przy dobrze dobranym jądrze i γ jest najlepszy na Cardio i Wine, ale wynik silnie zależy od jądra i γ, a na małych zbiorach granica nadmiernie dopasowuje się do punktów uczących.
- **DBSCAN** daje wysoką precyzję, gdy anomalie są wyraźnie oddzielone (Breastw: 0,93), bo za szum uznaje tylko punkty rzeczywiście odizolowane. Jeden globalny promień nie pasuje jednak jednocześnie do skupisk o różnej gęstości (Recall lokalnych w Cardio 0,31), a minPts musi przekraczać rozmiar skupisk anomalii.

Wpływ parametrów na rodzaj wykrywanych wyjątków. Parametry progowe (contamination, ν, ε) decydują o *liczbie* wykrywanych wyjątków i przesuwają kompromis Precision–Recall. Ich zmniejszanie sprawia, że detektor zgłasza tylko najbardziej oczywiste, zwykle globalne wyjątki. Parametry kształtujące wynik (k w LOF/COF, γ i jądro w OCSVM, minPts w DBSCAN) decydują o *rodzaju* wykrywanych wyjątków – o skali, na której definiowana jest „normalność". Małe k lub duże γ czynią detektor lokalnym (wykrywa odchylenia od najbliższego otoczenia, ale też maskuje małe skupiska anomalii), a duże k lub małe γ – globalnym.

Interpretacja metryk przy niezbalansowaniu. Przy 2–10 % anomalii Accuracy jest bezużyteczna (tabela 2), a ROC-AUC optymistyczna, bo fałszywe alarmy są normalizowane dużą liczbą obserwacji normalnych (Mammography: ROC-AUC 0,85 przy F1 0,24). PR-AUC odnosi się do bazowego poziomu π i bezpośrednio uwzględnia koszt fałszywych alarmów, dlatego użyto jej do

wyboru konfiguracji. Precision i Recall zależą od progu, więc porównując metody trzeba ustalić wspólną regułę wyboru progu (tu: maksymalizacja F1 na walidacji). F1 traktuje oba rodzaje błędów symetrycznie; w zastosowaniach (np. diagnostyka) należałoby dobrać próg do kosztu pominięcia anomalii.

Ograniczenia.

- Małe liczby anomalii: części testowe Wine i Statlog Heart zawierają 3 i 2 anomalie, części walidacyjne – 2–3. Wybór hiperparametrów i progu jest więc obarczony dużą wariancją (odchylenie F1 0,19–0,26). Trzykrotnie większa liczba podziałów (30) zmniejsza niepewność średniej, ale nie zmniejsza zmienności pojedynczego wyniku; wniosków o kolejności metod na tych zbiorach nie należy wyciągać.
- Etykiety benchmarków są przyjęte bez zmian. Klasa uznana przez autorów benchmarku za anomalię nie musi być „wyjątkiem" w sensie rozkładu (Statlog Heart, Mammography). Ocena mierzy wtedy zgodność anomalii statystycznych z tą klasą, a nie jakość detektora w ogóle. Breastw z 35 % anomalii jest raczej problemem dwóch skupisk niż detekcji rzadkich zdarzeń.
- Podział anomalii na globalne i lokalne opiera się na przyjętej definicji (MCD lub Ledoit–Wolf, 99. percentyl); inna definicja zmieniłaby proporcje typów.
- Siatki hiperparametrów są skończone; DBSCAN był parametryzowany kwantylem ε, a OCSVM – względnym γ.

Kierunki dalszych badań. Analiza wpływu reprezentacji danych (zadanie 2), łączenie detektorów, które – jak pokazała analiza zgodności – należą do dwóch rodzin i popełniają w dużej mierze różne błędy (zadanie 3), oraz metody półnadzorowane wykorzystujące niewielką liczbę etykiet z walidacji.

7 Wnioski

1. Żadna metoda nie dominuje: OCSVM jest najlepszy na Cardio (PR-AUC 0,76) i Wine (0,89), DBSCAN na Breastw (0,99) i Mammography (0,23), a na Statlog Heart metody są nierozróżnialne. LOF i COF są wyraźnie najsłabsze tam, gdzie anomalie tworzą duże skupiska (Breastw).
2. O tym, *jakie* wyjątki są wykrywane, decyduje mechanizm metody: anomalie globalne wykrywają prawie w całości wszystkie metody, a różnice dotyczą anomalii lokalnych. Tu LOF prowadzi na Cardio (Recall 0,79 wobec 0,30–0,66), a DBSCAN i COF są najsłabsze. Metody dzielą się na dwie rodziny (globalną i lokalną), co widać w zgodności ich decyzji.
3. Najważniejsze hiperparametry to k (LOF/COF), γ i jądro (OCSVM) oraz ε i minPts (DBSCAN); liczba drzew w IForest ma znikomy wpływ. Contamination, ν i ε sterują kompromisem Precision–Recall, a F1 jest największe, gdy odsetek oznaczonych punktów jest bliski udziałowi anomalii.
4. Przy niezbalansowaniu Accuracy jest myląca (trywialny klasyfikator bywa lepszy od najlepszego detektora), a ROC-AUC optymistyczna; podstawą oceny powinny być PR-AUC i F1.
5. Część trafień jest unikatowa dla jednej metody, a fałszywe alarmy są w dużej mierze indywidualne – to przesłanka do budowy zespołu detektorów (zadanie 3).
6. Jakość detekcji bardziej zależy od zbioru (tego, czy anomalie są wyjątkami w sensie rozkładu) niż od wyboru algorytmu: rozrzut PR-AUC między zbiorami (0,11–0,99) jest kilkukrotnie większy niż między najlepszymi metodami na tym samym zbiorze.

8 Odtworzenie wyników

```
python -m task1_classical.eda                # tabela 1, rys. 1-3
python -m task1_classical.run_grid           # siatka -> results/task1/grid.csv
python -m task1_classical.run_best           # najlepsze konfiguracje
python -m task1_classical.decision_regions   # rys. obszarów decyzyjnych
python -m task1_classical.analyze            # pozostałe tabele i rysunki
```

Zbiory ADBench i DAMI są pobierane automatycznie do `data/raw/`; plik `arrhythmia.mat` z ODDS (używany w zadaniach 2 i 3) trzeba pobrać ręcznie, bo serwer ODDS nie pozwala na pobieranie automatyczne.

A Wyniki wszystkich eksperymentów

Tabele zawierają średnie po podziałach (część testowa) dla każdej konfiguracji. F1 dotyczy wbudowanej reguły decyzyjnej metody (contamination c, granica OCSVM lub promień ε DBSCAN).

Isolation Forest

Konfiguracja	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
T=100, c=0,02	0,969	0,230	0,201	0,221	0,367	0,024	0,394	0,200	0,600	0,279
T=100, c=0,05	0,969	0,389	0,201	0,212	0,367	0,114	0,394	0,268	0,600	0,425
T=100, c=0,10	0,969	0,573	0,201	0,202	0,367	0,300	0,394	0,281	0,600	0,534
T=100, c=0,15	0,969	0,710	0,201	0,169	0,367	0,413	0,394	0,231	0,600	0,569
T=100, c=0,20	0,969	0,780	0,201	0,150	0,367	0,367	0,394	0,222	0,600	0,566
T=100, c=0,35	0,969	0,934	0,201	0,111	0,367	0,293	0,394	0,168	0,600	0,414
T=200, c=0,02	0,967	0,222	0,196	0,208	0,357	0,024	0,393	0,223	0,595	0,278
T=200, c=0,05	0,967	0,380	0,196	0,213	0,357	0,105	0,393	0,244	0,595	0,435
T=200, c=0,10	0,967	0,578	0,196	0,204	0,357	0,285	0,393	0,288	0,595	0,534
T=200, c=0,15	0,967	0,705	0,196	0,170	0,357	0,401	0,393	0,249	0,595	0,560
T=200, c=0,20	0,967	0,779	0,196	0,153	0,357	0,367	0,393	0,215	0,595	0,549
T=200, c=0,35	0,967	0,932	0,196	0,112	0,357	0,294	0,393	0,165	0,595	0,414
T=500, c=0,02	0,971	0,221	0,196	0,203	0,402	0,036	0,379	0,179	0,585	0,291
T=500, c=0,05	0,971	0,408	0,196	0,206	0,402	0,142	0,379	0,247	0,585	0,438
T=500, c=0,10	0,971	0,560	0,196	0,200	0,402	0,378	0,379	0,276	0,585	0,526
T=500, c=0,15	0,971	0,701	0,196	0,169	0,402	0,409	0,379	0,241	0,585	0,550
T=500, c=0,20	0,971	0,778	0,196	0,152	0,402	0,384	0,379	0,207	0,585	0,532
T=500, c=0,35	0,971	0,929	0,196	0,111	0,402	0,300	0,379	0,170	0,585	0,409
T=50, c=0,02	0,970	0,244	0,208	0,248	0,383	0,063	0,356	0,196	0,609	0,315
T=50, c=0,05	0,970	0,391	0,208	0,220	0,383	0,160	0,356	0,241	0,609	0,424
T=50, c=0,10	0,970	0,572	0,208	0,200	0,383	0,365	0,356	0,209	0,609	0,544
T=50, c=0,15	0,970	0,701	0,208	0,167	0,383	0,378	0,356	0,202	0,609	0,585
T=50, c=0,20	0,970	0,784	0,208	0,148	0,383	0,374	0,356	0,187	0,609	0,564
T=50, c=0,35	0,970	0,928	0,208	0,110	0,383	0,288	0,356	0,173	0,609	0,418

LOF

Konfiguracja	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
k=10, c=0,02	0,305	0,000	0,108	0,189	0,322	0,017	0,383	0,178	0,175	0,104
k=10, c=0,05	0,305	0,000	0,108	0,175	0,322	0,028	0,383	0,293	0,175	0,146
k=10, c=0,10	0,305	0,017	0,108	0,136	0,322	0,147	0,383	0,317	0,175	0,173
k=10, c=0,15	0,305	0,056	0,108	0,117	0,322	0,283	0,383	0,274	0,175	0,184
k=10, c=0,20	0,305	0,078	0,108	0,103	0,322	0,360	0,383	0,225	0,175	0,188
k=10, c=0,35	0,305	0,229	0,108	0,077	0,322	0,385	0,383	0,165	0,175	0,191

Konfiguracja	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
k=20, c=0,02	0,321	0,012	0,129	0,229	0,490	0,084	0,400	0,188	0,190	0,113
k=20, c=0,05	0,321	0,053	0,129	0,196	0,490	0,152	0,400	0,334	0,190	0,147
k=20, c=0,10	0,321	0,094	0,129	0,150	0,490	0,500	0,400	0,347	0,190	0,167
k=20, c=0,15	0,321	0,102	0,129	0,128	0,490	0,505	0,400	0,314	0,190	0,198
k=20, c=0,20	0,321	0,114	0,129	0,110	0,490	0,503	0,400	0,271	0,190	0,208
k=20, c=0,35	0,321	0,255	0,129	0,083	0,490	0,398	0,400	0,189	0,190	0,210
k=35, c=0,02	0,365	0,027	0,143	0,243	0,442	0,079	0,462	0,200	0,239	0,135
k=35, c=0,05	0,365	0,077	0,143	0,209	0,442	0,225	0,462	0,363	0,239	0,174
k=35, c=0,10	0,365	0,138	0,143	0,162	0,442	0,512	0,462	0,374	0,239	0,183
k=35, c=0,15	0,365	0,178	0,143	0,136	0,442	0,503	0,462	0,332	0,239	0,223
k=35, c=0,20	0,365	0,228	0,143	0,120	0,442	0,447	0,462	0,289	0,239	0,260
k=35, c=0,35	0,365	0,346	0,143	0,087	0,442	0,320	0,462	0,195	0,239	0,294
k=50, c=0,02	0,426	0,037	0,143	0,237	0,375	0,077	0,441	0,233	0,310	0,136
k=50, c=0,05	0,426	0,085	0,143	0,201	0,375	0,129	0,441	0,330	0,310	0,184
k=50, c=0,10	0,426	0,187	0,143	0,162	0,375	0,377	0,441	0,375	0,310	0,246
k=50, c=0,15	0,426	0,273	0,143	0,146	0,375	0,439	0,441	0,323	0,310	0,314
k=50, c=0,20	0,426	0,307	0,143	0,127	0,375	0,401	0,441	0,288	0,310	0,376
k=50, c=0,35	0,426	0,415	0,143	0,095	0,375	0,305	0,441	0,190	0,310	0,394
k=5, c=0,02	0,323	0,000	0,084	0,136	0,100	0,000	0,366	0,202	0,201	0,151
k=5, c=0,05	0,323	0,000	0,084	0,124	0,100	0,000	0,366	0,239	0,201	0,197
k=5, c=0,10	0,323	0,000	0,084	0,106	0,100	0,000	0,366	0,273	0,201	0,213
k=5, c=0,15	0,323	0,017	0,084	0,094	0,100	0,000	0,366	0,248	0,201	0,197
k=5, c=0,20	0,323	0,045	0,084	0,085	0,100	0,000	0,366	0,223	0,201	0,193
k=5, c=0,35	0,323	0,235	0,084	0,073	0,100	0,004	0,366	0,158	0,201	0,185

COF

Konfiguracja	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
k=10, c=0,02	0,303	0,000	0,082	0,132	0,085	0,000	0,368	0,188	0,186	0,147
k=10, c=0,05	0,303	0,000	0,082	0,124	0,085	0,000	0,368	0,292	0,186	0,167
k=10, c=0,10	0,303	0,013	0,082	0,111	0,085	0,000	0,368	0,309	0,186	0,182
k=10, c=0,15	0,303	0,032	0,082	0,094	0,085	0,000	0,368	0,265	0,186	0,187
k=10, c=0,20	0,303	0,042	0,082	0,088	0,085	0,000	0,368	0,227	0,186	0,183
k=10, c=0,35	0,303	0,102	0,082	0,080	0,085	0,024	0,368	0,164	0,186	0,180
k=20, c=0,02	0,287	0,000	0,098	0,183	0,231	0,000	0,420	0,244	0,182	0,132
k=20, c=0,05	0,287	0,008	0,098	0,152	0,231	0,024	0,420	0,293	0,182	0,159
k=20, c=0,10	0,287	0,040	0,098	0,115	0,231	0,112	0,420	0,283	0,182	0,189
k=20, c=0,15	0,287	0,057	0,098	0,100	0,231	0,190	0,420	0,259	0,182	0,192
k=20, c=0,20	0,287	0,070	0,098	0,095	0,231	0,216	0,420	0,261	0,182	0,196
k=20, c=0,35	0,287	0,104	0,098	0,082	0,231	0,274	0,420	0,190	0,182	0,172
k=35, c=0,02	0,307	0,015	0,109	0,195	0,283	0,000	0,351	0,223	0,183	0,139
k=35, c=0,05	0,307	0,036	0,109	0,161	0,283	0,102	0,351	0,244	0,183	0,159
k=35, c=0,10	0,307	0,075	0,109	0,124	0,283	0,194	0,351	0,236	0,183	0,169
k=35, c=0,15	0,307	0,078	0,109	0,106	0,283	0,247	0,351	0,232	0,183	0,169
k=35, c=0,20	0,307	0,101	0,109	0,096	0,283	0,262	0,351	0,241	0,183	0,165
k=35, c=0,35	0,307	0,195	0,109	0,083	0,283	0,294	0,351	0,198	0,183	0,153
k=50, c=0,02	0,345	0,021	0,110	0,190	0,231	0,000	0,397	0,210	0,202	0,146
k=50, c=0,05	0,345	0,063	0,110	0,157	0,231	0,010	0,397	0,235	0,202	0,163
k=50, c=0,10	0,345	0,104	0,110	0,126	0,231	0,088	0,397	0,242	0,202	0,170
k=50, c=0,15	0,345	0,123	0,110	0,105	0,231	0,147	0,397	0,242	0,202	0,178
k=50, c=0,20	0,345	0,142	0,110	0,096	0,231	0,196	0,397	0,262	0,202	0,187
k=50, c=0,35	0,345	0,278	0,110	0,082	0,231	0,245	0,397	0,196	0,202	0,189
k=5, c=0,02	0,344	0,000	0,065	0,094	0,073	0,000	0,304	0,136	0,149	0,075
k=5, c=0,05	0,344	0,000	0,065	0,092	0,073	0,000	0,304	0,208	0,149	0,143
k=5, c=0,10	0,344	0,002	0,065	0,089	0,073	0,000	0,304	0,268	0,149	0,163
k=5, c=0,15	0,344	0,017	0,065	0,080	0,073	0,000	0,304	0,228	0,149	0,165
k=5, c=0,20	0,344	0,035	0,065	0,079	0,073	0,000	0,304	0,204	0,149	0,164
k=5, c=0,35	0,344	0,166	0,065	0,072	0,073	0,000	0,304	0,160	0,149	0,162

One-Class SVM

Konfiguracja	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
poly, ν=0,01, γ=0,1/d	0,444	0,410	0,024	0,023	0,093	0,129	0,235	0,093	0,097	0,043
poly, ν=0,05, γ=0,1/d	0,394	0,340	0,014	0,012	0,078	0,076	0,213	0,090	0,083	0,024
poly, ν=0,10, γ=0,1/d	0,369	0,276	0,013	0,009	0,071	0,078	0,169	0,080	0,102	0,031
poly, ν=0,20, γ=0,1/d	0,362	0,251	0,013	0,005	0,086	0,094	0,204	0,075	0,103	0,039
poly, ν=0,50, γ=0,1/d	0,387	0,244	0,013	0,008	0,094	0,090	0,251	0,078	0,095	0,046
rbf, ν=0,01, γ=0,1/d	0,310	0,137	0,090	0,101	0,204	0,090	0,411	0,251	0,411	0,164
rbf, ν=0,05, γ=0,1/d	0,353	0,223	0,167	0,172	0,201	0,100	0,412	0,242	0,465	0,335
rbf, ν=0,10, γ=0,1/d	0,406	0,280	0,194	0,122	0,192	0,139	0,428	0,260	0,491	0,488
rbf, ν=0,20, γ=0,1/d	0,535	0,431	0,204	0,154	0,193	0,227	0,425	0,239	0,530	0,560
rbf, ν=0,50, γ=0,1/d	0,821	0,647	0,208	0,109	0,294	0,225	0,427	0,142	0,596	0,319
sigmoid, ν=0,01, γ=0,1/d	0,229	0,030	0,040	0,072	0,113	0,093	0,203	0,118	0,112	0,068
sigmoid, ν=0,05, γ=0,1/d	0,247	0,058	0,086	0,095	0,180	0,116	0,242	0,112	0,131	0,112
sigmoid, ν=0,10, γ=0,1/d	0,278	0,093	0,113	0,121	0,162	0,101	0,127	0,065	0,162	0,155
sigmoid, ν=0,20, γ=0,1/d	0,350	0,179	0,173	0,132	0,200	0,140	0,085	0,037	0,297	0,238
sigmoid, ν=0,50, γ=0,1/d	0,591	0,386	0,215	0,095	0,485	0,217	0,107	0,036	0,561	0,252
linear, ν=0,01	0,478	0,336	0,044	0,055	0,200	0,150	0,217	0,096	0,121	0,123
linear, ν=0,05	0,480	0,384	0,083	0,042	0,141	0,125	0,206	0,112	0,125	0,094
linear, ν=0,10	0,587	0,466	0,075	0,051	0,140	0,111	0,188	0,093	0,141	0,103
linear, ν=0,20	0,494	0,418	0,125	0,088	0,172	0,150	0,125	0,067	0,132	0,097
linear, ν=0,50	0,519	0,476	0,060	0,052	0,137	0,143	0,156	0,064	0,273	0,193
poly, ν=0,01, γ=1,0/d	0,422	0,276	0,013	0,007	0,131	0,113	0,284	0,090	0,116	0,077
poly, ν=0,05, γ=1,0/d	0,463	0,346	0,013	0,004	0,134	0,117	0,289	0,091	0,120	0,074
poly, ν=0,10, γ=1,0/d	0,455	0,329	0,013	0,004	0,134	0,118	0,289	0,091	0,121	0,071
poly, ν=0,20, γ=1,0/d	0,423	0,292	0,013	0,004	0,135	0,117	0,288	0,088	0,114	0,059
poly, ν=0,50, γ=1,0/d	0,379	0,221	0,013	0,008	0,118	0,108	0,275	0,078	0,101	0,048
rbf, ν=0,01, γ=1,0/d	0,548	0,452	0,101	0,132	0,156	0,170	0,420	0,163	0,377	0,386
rbf, ν=0,05, γ=1,0/d	0,546	0,458	0,158	0,149	0,157	0,171	0,420	0,163	0,382	0,382
rbf, ν=0,10, γ=1,0/d	0,552	0,487	0,185	0,184	0,157	0,170	0,420	0,163	0,399	0,428
rbf, ν=0,20, γ=1,0/d	0,650	0,618	0,203	0,133	0,157	0,178	0,423	0,163	0,421	0,453
rbf, ν=0,50, γ=1,0/d	0,908	0,800	0,200	0,078	0,207	0,217	0,416	0,132	0,536	0,318
sigmoid, ν=0,01, γ=1,0/d	0,228	0,034	0,045	0,031	0,230	0,077	0,090	0,023	0,159	0,100
sigmoid, ν=0,05, γ=1,0/d	0,263	0,096	0,086	0,127	0,193	0,072	0,084	0,011	0,253	0,284
sigmoid, ν=0,10, γ=1,0/d	0,304	0,151	0,135	0,113	0,249	0,165	0,066	0,024	0,437	0,407
sigmoid, ν=0,20, γ=1,0/d	0,409	0,269	0,144	0,154	0,431	0,286	0,111	0,050	0,620	0,443
sigmoid, ν=0,50, γ=1,0/d	0,641	0,411	0,170	0,084	0,745	0,315	0,223	0,096	0,763	0,302
poly, ν=0,01, γ=10,0/d	0,470	0,388	0,014	0,007	0,132	0,118	0,289	0,091	0,117	0,082
poly, ν=0,05, γ=10,0/d	0,487	0,401	0,013	0,004	0,132	0,118	0,289	0,091	0,120	0,074
poly, ν=0,10, γ=10,0/d	0,456	0,354	0,013	0,004	0,132	0,118	0,289	0,091	0,122	0,071
poly, ν=0,20, γ=10,0/d	0,424	0,305	0,013	0,004	0,135	0,117	0,288	0,088	0,114	0,059
poly, ν=0,50, γ=10,0/d	0,379	0,220	0,013	0,007	0,118	0,108	0,275	0,078	0,101	0,048
rbf, ν=0,01, γ=10,0/d	0,921	0,836	0,154	0,114	0,102	0,167	0,409	0,095	0,258	0,199
rbf, ν=0,05, γ=10,0/d	0,921	0,839	0,155	0,092	0,102	0,167	0,409	0,095	0,258	0,200
rbf, ν=0,10, γ=10,0/d	0,921	0,838	0,168	0,117	0,101	0,167	0,409	0,095	0,258	0,199
rbf, ν=0,20, γ=10,0/d	0,921	0,840	0,188	0,103	0,102	0,167	0,409	0,095	0,258	0,200
rbf, ν=0,50, γ=10,0/d	0,938	0,808	0,197	0,071	0,101	0,167	0,409	0,095	0,260	0,199
sigmoid, ν=0,01, γ=10,0/d	0,255	0,013	0,053	0,056	0,339	0,151	0,123	0,039	0,172	0,028
sigmoid, ν=0,05, γ=10,0/d	0,276	0,117	0,048	0,087	0,377	0,123	0,072	0,000	0,203	0,155
sigmoid, ν=0,10, γ=10,0/d	0,322	0,184	0,056	0,111	0,447	0,173	0,114	0,039	0,299	0,337
sigmoid, ν=0,20, γ=10,0/d	0,441	0,322	0,053	0,081	0,447	0,382	0,108	0,049	0,538	0,453
sigmoid, ν=0,50, γ=10,0/d	0,653	0,539	0,042	0,059	0,891	0,357	0,166	0,104	0,646	0,299

DBSCAN

Konfiguracja	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
minPts=10, q_ε=0,50	0,986	0,880	0,205	0,091	0,604	0,528	0,433	0,234	0,485	0,311
minPts=20, q_ε=0,50	0,986	0,892	0,189	0,095	0,546	0,540	0,428	0,288	0,509	0,384
minPts=3, q_ε=0,50	0,984	0,829	0,225	0,083	0,217	0,146	0,414	0,154	0,329	0,227
minPts=5, q_ε=0,50	0,985	0,860	0,229	0,086	0,390	0,267	0,407	0,185	0,422	0,261
minPts=10, q_ε=0,75	0,933	0,501	0,201	0,159	0,492	0,423	0,424	0,336	0,429	0,454
minPts=20, q_ε=0,75	0,945	0,384	0,188	0,168	0,346	0,120	0,424	0,284	0,471	0,515
minPts=3, q_ε=0,75	0,932	0,724	0,186	0,129	0,093	0,000	0,406	0,256	0,334	0,311

Konfiguracja	Breastw		Mammography		Wine		Statlog Heart		Cardio	
	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1	PR-AUC	F1
minPts=5, q_ε=0,75	0,935	0,618	0,211	0,145	0,102	0,008	0,427	0,302	0,387	0,403
minPts=10, q_ε=0,90	0,924	0,212	0,176	0,199	0,180	0,011	0,482	0,267	0,330	0,318
minPts=20, q_ε=0,90	0,926	0,189	0,175	0,215	0,171	0,000	0,496	0,189	0,368	0,307
minPts=3, q_ε=0,90	0,922	0,353	0,180	0,184	0,091	0,000	0,448	0,358	0,332	0,373
minPts=5, q_ε=0,90	0,921	0,273	0,174	0,195	0,092	0,000	0,475	0,330	0,325	0,358
minPts=10, q_ε=0,95	0,918	0,070	0,165	0,232	0,124	0,000	0,491	0,189	0,308	0,266
minPts=20, q_ε=0,95	0,929	0,067	0,175	0,263	0,106	0,000	0,484	0,189	0,321	0,247
minPts=3, q_ε=0,95	0,916	0,217	0,174	0,204	0,092	0,000	0,471	0,340	0,294	0,277
minPts=5, q_ε=0,95	0,915	0,121	0,170	0,223	0,092	0,000	0,492	0,276	0,326	0,286
minPts=10, q_ε=0,99	0,926	0,003	0,162	0,207	0,092	0,000	0,410	0,172	0,274	0,101
minPts=20, q_ε=0,99	0,926	0,000	0,160	0,164	0,092	0,000	0,410	0,083	0,256	0,093
minPts=3, q_ε=0,99	0,923	0,052	0,165	0,217	0,092	0,000	0,410	0,200	0,255	0,115
minPts=5, q_ε=0,99	0,921	0,026	0,165	0,217	0,092	0,000	0,410	0,211	0,273	0,124

Literatura

[1] S. Han, X. Hu, H. Huang, M. Jiang, Y. Zhao. *ADBench: Anomaly Detection Benchmark*. Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track, 2022. Repozytorium `https://github.com/Minqi824/ADBench`, commit `3dac822`.

[2] S. Rayana. *ODDS Library*. Stony Brook University, Department of Computer Science, 2016. `https://odds.cs.stonybrook.edu`.

[3] G. O. Campos, A. Zimek, J. Sander, R. J. G. B. Campello, B. Micenková, E. Schubert, I. Assent, M. E. Houle. *On the evaluation of unsupervised outlier detection: measures, datasets, and an empirical study*. Data Mining and Knowledge Discovery 30(4), 891–927, 2016. `https://www.dbs.ifi.lmu.de/research/outlier-evaluation/`.

[4] M. Kelly, R. Longjohn, K. Nottingham. *The UCI Machine Learning Repository*. University of California, Irvine. `https://archive.ics.uci.edu`.

[5] W. H. Wolberg, O. L. Mangasarian. *Multisurface method of pattern separation for medical diagnosis applied to breast cytology*. Proceedings of the National Academy of Sciences 87(23), 9193–9196, 1990. (UCI: Breast Cancer Wisconsin (Original)).

[6] W. N. Street, W. H. Wolberg, O. L. Mangasarian. *Nuclear feature extraction for breast tumor diagnosis*. IS&T/SPIE Symposium on Electronic Imaging: Science and Technology, vol. 1905, 861–870, 1993. (UCI: Breast Cancer Wisconsin (Diagnostic)).

[7] K. S. Woods, C. C. Doss, K. W. Bowyer, J. L. Solka, C. E. Priebe, W. P. Kegelmeyer. *Comparative evaluation of pattern recognition techniques for detection of microcalcifications in mammography*. International Journal of Pattern Recognition and Artificial Intelligence 7(6), 1417–1436, 1993.

[8] S. Aeberhard, M. Forina. *Wine*. UCI Machine Learning Repository, 1991.

[9] D. Ayres-de Campos, J. Bernardes, A. Garrido, J. Marques-de-Sá, L. Pereira-Leite. *SisPorto 2.0: a program for automated analysis of cardiotocograms*. Journal of Maternal-Fetal Medicine 9(5), 311–318, 2000. (UCI: Cardiotocography).

[10] S. Moro, P. Cortez, P. Rita. *A data-driven approach to predict the success of bank telemarketing*. Decision Support Systems 62, 22–31, 2014. (UCI: Bank Marketing).

[11] H. A. Güvenir, B. Acar, G. Demiröz, A. Çekin. *A supervised machine learning algorithm for arrhythmia analysis*. Computers in Cardiology 1997, 433–436. (UCI: Arrhythmia).

[12] *Statlog (Heart)*. UCI Machine Learning Repository.