Politechnika Łódzka
Wydział Fizyki Technicznej, Informatyki i Matematyki Stosowanej

Analiza danych złożonych z detekcją wyjątków

# Zadanie 2

Detekcja wyjątków w danych wielowymiarowych:
wpływ reprezentacji danych

Jędrzej Kostyk
nr indeksu 264339

Rok akademicki 2026/2027

# Spis treści

**1 Cel i zakres** **2**

**2 Dane i protokół** **2**

**3 Reprezentacje** **3**

**4 Wyniki** **4**

4.1 Zestawienie wszystkich konfiguracji . . . . . 4

4.2 PCA: liczba składowych, zachowana wariancja i jakość detekcji . . . . . 7

4.3 UMAP: wpływ parametrów i struktura przestrzeni . . . . . 8

4.4 Autoenkoder: wymiar latentny i architektura . . . . . 10

4.5 Wizualizacje 2D i separacja a jakość detekcji . . . . . 11

4.6 Typy anomalii w reprezentacjach . . . . . 13

4.7 Kompromis jakość – wymiar – czas . . . . . 14

4.8 Porównanie z zadaniem 1 . . . . . 15

**5 Odpowiedzi na pytania analityczne** **15**

**6 Rekomendacje i dyskusja** **16**

**7 Wnioski** **17**

**8 Odtworzenie wyników** **17**

# 1 Cel i zakres

Celem zadania jest zbadanie, jak sposób reprezentacji danych wielowymiarowych wpływa na skuteczność detekcji wyjątków. Porównano cztery reprezentacje: dane oryginalne (A), PCA (B), UMAP (C) i przestrzeń latentną autoenkodera (D). W każdej z nich uruchomiono te same trzy detektory – Isolation Forest, LOF i One-Class SVM. Dla PCA i autoenkodera oceniono dodatkowo błąd rekonstrukcji jako samodzielny wynik anomalii. Daje to 12 konfiguracji podstawowych i 2 dodatkowe na każdy zbiór, łącznie 56 porównywanych konfiguracji na czterech zbiorach. Dla każdej reprezentacji systematycznie zbadano jej parametry (liczbę składowych PCA, `n_neighbors`, `min_dist` i wymiar UMAP, wymiar latentny i architekturę autoenkodera): do 33 wariantów reprezentacji $\times$ 15 konfiguracji detektorów na każdy podział, łącznie ok. 27 tys. przebiegów detekcji.

Kod znajduje się w katalogu `task2_representations/`, a wspólne elementy (dane, podziały, detektory, metryki) w `common/`, tak jak w zadaniu 1.

# 2 Dane i protokół

Zadanie wymaga zbiorów o co najmniej 20–30 cechach, dlatego użyto czterech gotowych zbiorów benchmarkowych o 21–274 cechach. Macierz cech i etykiety wczytywane są dokładnie w postaci opublikowanej. **Etykiety anomalii pochodzą z benchmarków**, a kod nie generuje ani nie podpróbkowuje obserwacji (szczegóły i sumy kontrolne – raport z zadania 1, sekcja 2, oraz `data/CHECKSUMS.txt`).

- **Cardio** (ADBench [1], `6_cardio.npz`) – Cardiotocography z UCI [4, 9]: 1831 zapisów KTG, 21 cech, 176 anomalii (9,6 %; klasa patologiczna, zredukowana przez autorów ODDS). Ten sam zbiór występuje w zadaniu 1.
- **Arrhythmia** (ODDS [2], `arrhythmia.mat`) – Arrhythmia z UCI [4, 11]: 452 zapisy EKG, 274 cechy, 66 anomalii (14,6 %). Autorzy ODDS połączyli najmniej liczne klasy arytmii (3, 4, 5, 7, 8, 9, 14, 15) w klasę anomalii. 17 cech jest stałych; standaryzacja pozostawia je jako zera.
- **WDBC** (ADBench, `43_WDBC.npz`) – Breast Cancer Wisconsin (Diagnostic) z UCI [4, 6]: 367 guzów, 30 cech morfologicznych jąder komórkowych, 10 anomalii (2,7 %; guzy złośliwe, zredukowane przez autorów benchmarku).
- **Campaign** (ADBench, `5_campaign.npz`) – Bank Marketing z UCI [4, 10]: 41 188 kontaktów telemarketingowych, 62 cechy (w tym kodowanie one-hot zmiennych kategorycznych), 4640 anomalii (11,3 %; klienci, którzy założyli lokatę).

Protokół jest identyczny jak w zadaniu 1:

1. warstwowe podziały 50/25/25 % (train/walidacja/test), te same ziarna we wszystkich zadaniach: 10 podziałów dla Cardio i Arrhythmii, 30 dla WDBC (tylko 2–3 anomalie w części walidacyjnej i testowej; każda część zawiera co najmniej jedną anomalię) i 5 dla Campaign (koszt obliczeń, patrz niżej),
2. standaryzacja dopasowana na części uczącej,
3. **reprezentacja dopasowywana wyłącznie na części uczącej, bez etykiet** (PCA, UMAP, autoenkoder), a następnie stosowana do części walidacyjnej i testowej (`transform`),
4. detektory uczone w przestrzeni reprezentacji na części uczącej,
5. parametry reprezentacji i detektora wybierane łącznie na podstawie średniej PR-AUC na walidacji, a próg – przez maksymalizację F1 na walidacji; część testowa służy tylko do oceny.

**Ograniczenie budżetu dla Campaign.** Na 20 594 punktach uczących Campaign dopasowanie OCSVM z $\nu = 0{,}5$ trwa ok. 40 s, UMAP 25–40 s (dopasowanie i transformacja), a autoenkoder z mini-batchem 32 ponad 20 min. Pełna siatka zajęłaby kilka godzin na jeden podział. Dlatego dla tego zbioru, **bez podpróbkowania danych**:

- użyto 5 zamiast 10 podziałów,
- UMAP badano tylko z `min_dist`=0 i `n_neighbors` $\in \{15, 50\}$ (6 zamiast 18 wariantów),
- OCSVM bez $\nu = 0{,}5$ (6 zamiast 9 konfiguracji),
- autoenkoder uczono z większym mini-batchem (274 zamiast 32, co najwyżej 64 kroki na epokę).

Miary struktury (trustworthiness, silhouette) wymagają wszystkich odległości parami, więc dla Campaign liczono je na stałym, losowym podzbiorze 2000 punktów testowych. Detekcję oceniano zawsze na całej części testowej. Jeden podział Campaign liczył się mimo to ok. 26 min, a cały eksperyment (55 zadań na 3 procesach) – 54 min.

Po transformacji każda reprezentacja jest centrowana i dzielona przez *jeden wspólny* współczynnik (pierwiastek średniej wariancji współrzędnych na części uczącej). Zachowuje to geometrię przestrzeni (proporcje odległości), ale sprowadza wszystkie reprezentacje do porównywalnej skali, dzięki czemu np. $\gamma = 1/d$ w OCSVM oznacza to samo w każdej przestrzeni. Celowo nie stosowano wybielania (*whitening*) składowych PCA, które zmieniłoby geometrię i wzmocniło składowe o znikomej wariancji.

**Detektory i ich siatki.** Isolation Forest z $T = 200$ drzewami (w zadaniu 1 liczba drzew nie miała wpływu), LOF z $k \in \{5, 10, 20, 35, 50\}$, OCSVM z jądrem RBF, $\nu \in \{0{,}05;\ 0{,}1;\ 0{,}5\}$ i $\gamma \in \{0{,}1/d,\ 1/d,\ 10/d\}$, gdzie $d$ to wymiar reprezentacji. Hiperparametry detektora są wybierane osobno dla każdej reprezentacji, bo optymalne $k$ czy $\gamma$ zależą od geometrii przestrzeni. W przeciwnym razie porównanie faworyzowałoby reprezentację, do której dopasowano parametry.

**Miary jakości reprezentacji.** Oprócz metryk detekcji (Precision, Recall, F1, ROC-AUC, PR-AUC) dla każdej reprezentacji policzono na części testowej: *trustworthiness* ($k = 10$) – w jakim stopniu sąsiedztwa w przestrzeni zredukowanej istnieją także w oryginalnej (1 = brak „fałszywych sąsiadów"), oraz *silhouette* podziału normalne/anomalie – liczbową miarę widocznej separacji klas (od $-1$ do 1). Etykiety są tu użyte wyłącznie do analizy, nie do budowy reprezentacji. Mierzono czas dopasowania i transformacji reprezentacji oraz czas uczenia i oceny detektora. Recall raportowano także osobno dla anomalii globalnych i lokalnych, zdefiniowanych jak w zadaniu 1 (odporna odległość Mahalanobisa; dla Cardio, Arrhythmii i Campaign z estymatorem Ledoita–Wolfa, bo kowariancja jest tam osobliwa lub źle uwarunkowana).

## 3 Reprezentacje

**A. Dane oryginalne.** Standaryzowane cechy ($d = 21$–$274$).

**B. PCA.** Rzut na $k \in \{1, 2, 3, 5, 8, 10, 15, 20\}$ pierwszych składowych głównych. Zachowana wariancja silnie zależy od zbioru (rys. 2, dolny wiersz): dla $k = 5$ wynosi 0,84 w WDBC i 0,66 w Cardio, ale tylko 0,32 w Arrhythmii i 0,25 w Campaign. PCA zachowuje kierunki największej wariancji i odrzuca resztę, a anomalia odchylająca się w kierunkach o małej wariancji staje się niewidoczna w rzucie. Ta sama informacja jest jednak zawarta w *błędzie rekonstrukcji* $\|x - \hat{x}\|^2$ (odległość od podprzestrzeni), który oceniano jako dodatkowy detektor.

**C. UMAP.** Nieliniowe zanurzenie zachowujące lokalną strukturę grafu $k$ najbliższych sąsiadów. Badano wymiar $m \in \{2, 5, 10\}$, `n_neighbors` $\in \{5, 15, 50\}$ (skala struktury: lokalna – globalna) oraz `min_dist` $\in \{0{,}0; 0{,}5\}$ (jak ciasno upakowane mogą być punkty), łącznie 18 wariantów (6 dla Campaign). Nowe punkty są rzutowane metodą `transform`.

**D. Autoenkoder.** W pełni połączona sieć o architekturze lejka $d \to 64 \to 32 \to z \to 32 \to 64 \to d$ z aktywacją ReLU i liniowym wyjściem. Uzasadnienie wyborów:

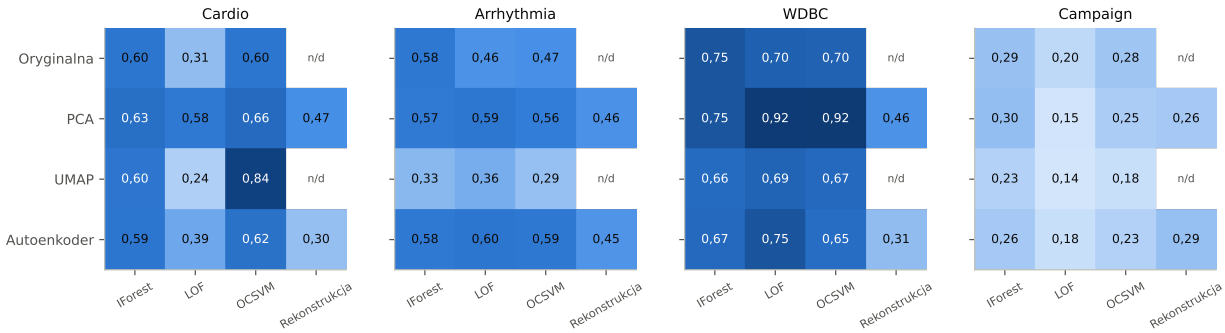
- *Niedopełniona* warstwa $z < d$ wymusza kompresję. Sieć nie może nauczyć się identyczności, więc musi odtwarzać dane z ich głównej struktury, a obserwacje do niej niepasujące mają duży błąd rekonstrukcji.
- Dwie warstwy ukryte pozwalają uchwycić zależności nieliniowe, czego PCA nie potrafi. Przy 183–915 obserwacjach uczących (poza Campaign) głębsza sieć łatwo się przeucza, dlatego zastosowano regularyzację: dropout 0,1 w koderze, *weight decay* $10^{-5}$ i wczesne zatrzymanie (patience 30 epok, maks. 400) na podstawie błędu na 15 % części uczącej odłożonych do monitorowania. Walidacja i test nie są używane do uczenia.
- Funkcja straty MSE odpowiada standaryzowanym cechom, optymalizator Adam ($\eta = 10^{-3}$). Mini-batch ma 32 obserwacje albo tyle, by epoka miała co najwyżej 64 kroki (dotyczy tylko Campaign).
- Wymiar latentny $z \in \{2, 4, 8, 16\}$ zbadano systematycznie. Wybór architektury sprawdzono porównaniem z wariantem płytszym ($d \to 32 \to 8$) i szerszym ($d \to 128 \to 64 \to 8$) – tabela 4.

Reprezentacją latentną jest wyjście kodera $z$, a wynikiem anomalii – średni kwadratowy błąd rekonstrukcji. Sieć uczy się na danych zawierających anomalie (scenariusz nienadzorowany), co ma znaczenie dla interpretacji wyników (sekcja 4.4). Autoenkoder zaimplementowano w PyTorch. Przy małych zbiorach trening na CPU jest szybszy niż na GPU (RTX 3060 Laptop), bo dominuje narzut przesyłania małych porcji danych. Dlatego obliczenia wykonywano równolegle na CPU, po jednym wątku na proces.

# 4 Wyniki

## 4.1 Zestawienie wszystkich konfiguracji

Rysunek 1 przedstawia PR-AUC na części testowej dla wszystkich par reprezentacja–detektor, a tabela 1 – pełne wyniki wszystkich 56 konfiguracji (parametry wybrane na walidacji).




**Rysunek 1:** PR-AUC (część testowa, średnia po podziałach) dla każdej pary reprezentacja–detektor; „Rekonstrukcja” – błąd rekonstrukcji PCA lub autoenkodera (n/d – nie dotyczy). Parametry reprezentacji i detektora wybrano na walidacji.

Najważniejsze obserwacje:

- **PCA najczęściej poprawia wyniki detektorów.** Na WDBC LOF rośnie z 0,71 do 0,92, a OCSVM z 0,70 do 0,93 (jedna składowa). Na Cardio poprawia wszystkie trzy detektory (LOF 0,31 → 0,58, OCSVM 0,60 → 0,66, IForest 0,60 → 0,64), a na Arrhythmii LOF i OCSVM (0,46 → 0,59 i 0,47 → 0,56).
- **UMAP pogarsza wyniki w 10 z 12 par zbiór–detektor** (Arrhythmia: IForest 0,58 → 0,33, LOF 0,46 → 0,37). Jest jednak jeden wyraźny wyjątek: na Cardio OCSVM w dwuwymiarowym UMAP osiąga najlepszy wynik całego zadania na tym zbiorze (0,84 wobec 0,60 w danych oryginalnych). Wyjaśnienie w sekcji 4.3.
- **Przestrzeń latentna autoenkodera** pomaga na Arrhythmii (LOF 0,60, OCSVM 0,59 – najlepsze wyniki na tym zbiorze), na pozostałych zbiorach daje wyniki zbliżone do danych oryginalnych lub gorsze.
- **Błąd rekonstrukcji** (PCA lub autoenkodera) nie jest najlepszym detektorem na żadnym zbiorze (0,26–0,47).
- **Na Campaign żadna reprezentacja nie zmienia obrazu**: wszystkie konfiguracje mają PR-AUC 0,14–0,30 przy bazowym 0,11. Anomalie tego zbioru (klienci, którzy założyli lokatę) nie są wyjątkami w sensie rozkładu cech, więc zmiana reprezentacji tego nie naprawi.

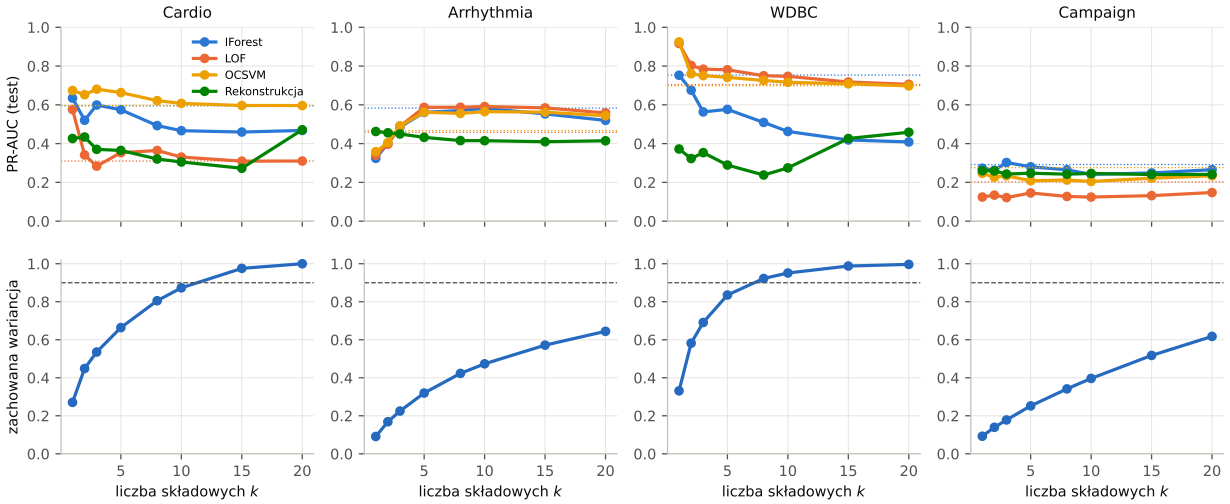
**Tabela 1:** Wszystkie konfiguracje (część testowa, średnie po podziałach, ± odchylenie std. dla PR-AUC). Konfiguracja – parametry wybrane na walidacji: $k$ – liczba składowych PCA; $m$, nn, md – wymiar, `n_neighbors` i `min_dist` UMAP; $z$ – wymiar latentny AE; $k_{LOF}$ – liczba sąsiadów LOF; Oryg. – dane oryginalne; AE – autoenkoder. $t_r$ – dopasowanie i transformacja reprezentacji, $t_d$ – uczenie i ocena detektora. Pogrubienie – najlepsza PR-AUC na zbiorze.

| Zbiór | Repr. | Detektor | Konfiguracja | Prec. | Rec. | F1 | ROC | PR-AUC | $t_r$ [ms] | $t_d$ [ms] |
|---|---|---|---|---|---|---|---|---|---|---|
| Cardio | Oryg. | IForest | – | 0,489 | 0,657 | 0,554 | 0,935 | 0,595 ± 0,070 | 0,0 | 231,7 |
| | Oryg. | LOF | $k_{LOF}$=50 | 0,266 | 0,848 | 0,403 | 0,848 | 0,310 ± 0,051 | 0,0 | 19,0 |
| | Oryg. | OCSVM | $\nu$=0,50, $\gamma$=0,1/$d$ | 0,535 | 0,734 | 0,616 | 0,947 | 0,596 ± 0,078 | 0,0 | 40,0 |
| | PCA | IForest | $k$=1 | 0,578 | 0,695 | 0,627 | 0,910 | 0,635 ± 0,061 | 1,0 | 229,2 |
| | PCA | LOF | $k$=1; $k_{LOF}$=50 | 0,544 | 0,675 | 0,595 | 0,871 | 0,576 ± 0,064 | 1,0 | 6,2 |
| | PCA | OCSVM | $k$=5; $\nu$=0,50, $\gamma$=0,1/$d$ | 0,608 | 0,727 | 0,652 | 0,944 | 0,663 ± 0,072 | 1,1 | 30,6 |
| | PCA | Rekonstr. | $k$=20 | 0,430 | 0,607 | 0,499 | 0,886 | 0,471 ± 0,123 | 1,0 | 0,3 |
| | UMAP | IForest | $m$=5, nn=50, md=0,5 | 0,570 | 0,555 | 0,547 | 0,889 | 0,601 ± 0,122 | 2767,6 | 242,4 |
| | UMAP | LOF | $m$=2, nn=5, md=0,0; $k_{LOF}$=50 | 0,403 | 0,341 | 0,326 | 0,658 | 0,238 ± 0,066 | 2047,5 | 8,3 |
| | UMAP | OCSVM | $m$=2, nn=50, md=0,0; $\nu$=0,50, $\gamma$=0,1/$d$ | 0,805 | 0,780 | 0,787 | 0,956 | **0,836 ± 0,047** | 2521,8 | 29,3 |
| | AE | IForest | $z$=16 | 0,517 | 0,716 | 0,588 | 0,936 | 0,593 ± 0,098 | 11118,9 | 210,4 |
| | AE | LOF | $z$=2; $k_{LOF}$=50 | 0,363 | 0,716 | 0,468 | 0,880 | 0,385 ± 0,098 | 8625,8 | 9,2 |
| | AE | OCSVM | $z$=16; $\nu$=0,50, $\gamma$=0,1/$d$ | 0,559 | 0,730 | 0,625 | 0,946 | 0,624 ± 0,080 | 11118,9 | 37,3 |
| | AE | Rekonstr. | $z$=16 | 0,253 | 0,430 | 0,310 | 0,700 | 0,300 ± 0,066 | 11118,9 | 0,6 |
| Arrhythmia | Oryg. | IForest | – | 0,553 | 0,541 | 0,532 | 0,844 | 0,583 ± 0,113 | 0,0 | 226,9 |
| | Oryg. | LOF | $k_{LOF}$=50 | 0,383 | 0,621 | 0,453 | 0,813 | 0,458 ± 0,118 | 0,0 | 4,2 |
| | Oryg. | OCSVM | $\nu$=0,50, $\gamma$=1,0/$d$ | 0,383 | 0,627 | 0,454 | 0,811 | 0,467 ± 0,114 | 0,0 | 7,3 |
| | PCA | IForest | $k$=8 | 0,546 | 0,560 | 0,533 | 0,829 | 0,571 ± 0,115 | 8,3 | 220,5 |
| | PCA | LOF | $k$=8; $k_{LOF}$=50 | 0,584 | 0,566 | 0,563 | 0,832 | 0,588 ± 0,114 | 8,3 | 3,9 |
| | PCA | OCSVM | $k$=8; $\nu$=0,50, $\gamma$=0,1/$d$ | 0,568 | 0,510 | 0,518 | 0,799 | 0,556 ± 0,119 | 8,3 | 3,0 |
| | PCA | Rekonstr. | $k$=1 | 0,402 | 0,609 | 0,463 | 0,813 | 0,462 ± 0,115 | 9,9 | 0,3 |

| Zbiór | Repr. | Detektor | Konfiguracja | Prec. | Rec. | F1 | ROC | PR-AUC | $t_r$ [ms] | $t_d$ [ms] |
|---|---|---|---|---|---|---|---|---|---|---|
| | UMAP | IForest | $m$=10, nn=5, md=0,5 | 0,295 | 0,480 | 0,322 | 0,695 | 0,327 ± 0,140 | 270,7 | 209,8 |
| | UMAP | LOF | $m$=5, nn=15, md=0,5; $k_{LOF}$=50 | 0,366 | 0,467 | 0,400 | 0,743 | 0,365 ± 0,124 | 405,0 | 3,3 |
| | UMAP | OCSVM | $m$=5, nn=5, md=0,5; $\nu$=0,50, $\gamma$=0,1/$d$ | 0,281 | 0,379 | 0,288 | 0,678 | 0,294 ± 0,114 | 275,2 | 2,9 |
| | AE | IForest | $z$=4 | 0,528 | 0,546 | 0,515 | 0,816 | 0,580 ± 0,129 | 1674,2 | 205,7 |
| | AE | LOF | $z$=4; $k_{LOF}$=50 | 0,489 | 0,597 | 0,522 | 0,822 | **0,597 ± 0,129** | 1674,2 | 3,3 |
| | AE | OCSVM | $z$=4; $\nu$=0,50, $\gamma$=0,1/$d$ | 0,523 | 0,566 | 0,516 | 0,810 | 0,585 ± 0,134 | 1674,2 | 2,7 |
| | AE | Rekonstr. | $z$=2 | 0,398 | 0,631 | 0,468 | 0,807 | 0,449 ± 0,117 | 889,4 | 0,4 |
| WDBC | Oryg. | IForest | – | 0,495 | 0,794 | 0,580 | 0,987 | 0,754 ± 0,186 | 0,0 | 203,9 |
| | Oryg. | LOF | $k_{LOF}$=50 | 0,472 | 0,722 | 0,541 | 0,985 | 0,705 ± 0,213 | 0,0 | 2,6 |
| | Oryg. | OCSVM | $\nu$=0,50, $\gamma$=0,1/$d$ | 0,465 | 0,683 | 0,511 | 0,985 | 0,699 ± 0,215 | 0,0 | 2,7 |
| | PCA | IForest | $k$=1 | 0,496 | 0,678 | 0,535 | 0,986 | 0,753 ± 0,191 | 1,0 | 206,6 |
| | PCA | LOF | $k$=1; $k_{LOF}$=35 | 0,777 | 0,867 | 0,789 | 0,996 | 0,916 ± 0,132 | 1,0 | 1,8 |
| | PCA | OCSVM | $k$=1; $\nu$=0,50, $\gamma$=0,1/$d$ | 0,796 | 0,900 | 0,815 | 0,997 | **0,925 ± 0,131** | 1,0 | 1,8 |
| | PCA | Rekonstr. | $k$=20 | 0,245 | 0,500 | 0,287 | 0,947 | 0,459 ± 0,242 | 1,0 | 0,2 |
| | UMAP | IForest | $m$=10, nn=5, md=0,0 | 0,545 | 0,739 | 0,568 | 0,934 | 0,658 ± 0,387 | 194,8 | 208,1 |
| | UMAP | LOF | $m$=10, nn=5, md=0,5; $k_{LOF}$=50 | 0,589 | 0,739 | 0,593 | 0,960 | 0,692 ± 0,329 | 194,9 | 3,0 |
| | UMAP | OCSVM | $m$=10, nn=5, md=0,0; $\nu$=0,50, $\gamma$=0,1/$d$ | 0,608 | 0,783 | 0,638 | 0,954 | 0,668 ± 0,364 | 194,8 | 2,1 |
| | AE | IForest | $z$=2 | 0,475 | 0,706 | 0,494 | 0,979 | 0,670 ± 0,221 | 733,6 | 198,3 |
| | AE | LOF | $z$=4; $k_{LOF}$=35 | 0,496 | 0,733 | 0,557 | 0,987 | 0,754 ± 0,228 | 1156,2 | 2,4 |
| | AE | OCSVM | $z$=8; $\nu$=0,50, $\gamma$=0,1/$d$ | 0,393 | 0,694 | 0,472 | 0,977 | 0,646 ± 0,234 | 1706,9 | 2,0 |
| | AE | Rekonstr. | $z$=16 | 0,157 | 0,622 | 0,233 | 0,913 | 0,310 ± 0,155 | 1693,0 | 0,3 |
| Campaign | Oryg. | IForest | – | 0,321 | 0,322 | 0,321 | 0,716 | 0,292 ± 0,008 | 0,0 | 848,4 |
| | Oryg. | LOF | $k_{LOF}$=35 | 0,199 | 0,381 | 0,260 | 0,634 | 0,202 ± 0,006 | 0,0 | 3778,2 |
| | Oryg. | OCSVM | $\nu$=0,10, $\gamma$=10,0/$d$ | 0,272 | 0,469 | 0,341 | 0,742 | 0,276 ± 0,009 | 0,0 | 94724,2 |
| | PCA | IForest | $k$=3 | 0,377 | 0,280 | 0,318 | 0,672 | **0,303 ± 0,008** | 9,6 | 522,9 |
| | PCA | LOF | $k$=20; $k_{LOF}$=50 | 0,125 | 0,716 | 0,213 | 0,569 | 0,148 ± 0,006 | 13,1 | 2527,9 |
| | PCA | OCSVM | $k$=1; $\nu$=0,10, $\gamma$=1,0/$d$ | 0,194 | 0,618 | 0,294 | 0,696 | 0,247 ± 0,014 | 15,9 | 3448,4 |
| | PCA | Rekonstr. | $k$=1 | 0,315 | 0,428 | 0,363 | 0,730 | 0,260 ± 0,010 | 15,9 | 4,1 |
| | UMAP | IForest | $m$=10, nn=50, md=0,0 | 0,329 | 0,351 | 0,337 | 0,637 | 0,229 ± 0,013 | 27191,9 | 504,7 |
| | UMAP | LOF | $m$=10, nn=15, md=0,0; $k_{LOF}$=50 | 0,133 | 0,597 | 0,205 | 0,542 | 0,140 ± 0,006 | 21134,4 | 448,0 |
| | UMAP | OCSVM | $m$=10, nn=15, md=0,0; $\nu$=0,10, $\gamma$=0,1/$d$ | 0,223 | 0,411 | 0,287 | 0,581 | 0,176 ± 0,010 | 21134,4 | 4415,5 |
| | AE | IForest | $z$=4 | 0,318 | 0,397 | 0,344 | 0,662 | 0,260 ± 0,029 | 49966,3 | 449,0 |
| | AE | LOF | $z$=16; $k_{LOF}$=50 | 0,177 | 0,520 | 0,254 | 0,622 | 0,177 ± 0,029 | 49183,9 | 2498,1 |
| | AE | OCSVM | $z$=16; $\nu$=0,10, $\gamma$=1,0/$d$ | 0,240 | 0,410 | 0,289 | 0,640 | 0,228 ± 0,039 | 49183,9 | 4678,2 |
| | AE | Rekonstr. | $z$=16 | 0,299 | 0,560 | 0,385 | 0,769 | 0,294 ± 0,024 | 49183,9 | 7,9 |

## 4.2 PCA: liczba składowych, zachowana wariancja i jakość detekcji

Rysunek 2 pokazuje PR-AUC w funkcji liczby składowych $k$ (parametry detektora wybierane na walidacji osobno dla każdego $k$) oraz zachowaną wariancję. Linie kropkowane to wyniki w danych oryginalnych.




**Rysunek 2:** PCA: PR-AUC (test) w zależności od liczby składowych (górny wiersz; linie kropkowane – ten sam detektor w danych oryginalnych) oraz zachowana wariancja (dolny wiersz; linia przerywana – 90 %).

Zależność między zachowaną wariancją a jakością detekcji *nie jest monotoniczna* i różni się między zbiorami:

- **WDBC:** najlepsza jest jedna składowa ($k = 1$, 33 % wariancji): OCSVM 0,93, LOF 0,92, IForest 0,75. Pierwsza składowa odpowiada ogólnej „wielkości" jądra komórkowego (promień, obwód i pole są niemal liniowo zależne), czyli właśnie temu, czym guzy złośliwe różnią się od łagodnych. Każda kolejna składowa obniża wynik (LOF przy $k = 20$: 0,71, czyli tyle co w danych oryginalnych), bo dodaje zmienność wewnątrz klasy normalnej, która rozmywa sąsiedztwa.
- **Cardio:** LOF jest najlepszy przy $k = 1$ (0,58 wobec 0,31 w danych oryginalnych), OCSVM przy $k = 1$–5 (0,65–0,68). Także tu wystarcza kierunek o największej wariancji, a dalsze składowe szkodzą.
- **Arrhythmia:** 274 cechy przy 226 punktach uczących. LOF i OCSVM osiągają maksimum przy $k = 5$–10 (0,59 i 0,57), mimo że zachowana wariancja to tylko 32–47 %. W pełnej przestrzeni odległości są zdominowane przez setki słabo informatywnych cech („przekleństwo wymiarowości"), a redukcja usuwa ten szum. Przy $k \leq 2$ wynik spada (0,34–0,41), bo ginie już także informacja o anomaliach.
- **Campaign:** wynik prawie nie zależy od $k$ (IForest 0,24–0,30, LOF 0,12–0,15).

Tabela 3 pokazuje, jak redukcja wpływa na anomalie globalne i lokalne na Arrhythmii – zbiorze, w którym redukcja jest najsilniejsza. Przy $k = 2$ (17 % wariancji) Recall anomalii globalnych LOF spada z 0,87 do 0,54: odchylenie globalnej anomalii rozkłada się na wiele cech, z których większość rzut usuwa. Przy $k = 5$–20 anomalie globalne są wykrywane prawie tak dobrze jak w pełnej przestrzeni (0,81–0,86), a PR-AUC jest wyższa. Lokalne są wykrywane słabo w każdej przestrzeni (0,18–0,35). Błąd rekonstrukcji PCA wykrywa anomalie globalne dobrze (0,86–0,91) już przy $k = 2$ – odchylenie, które znika z rzutu, pojawia się w błędzie rekonstrukcji. Ma jednak niską precyzję, bo równie duży błąd mają liczne obserwacje normalne w tym wysokowymiarowym, zaszumionym zbiorze (PR-AUC 0,42–0,46). Kryterium zachowanej wariancji mierzy wierność odtworzenia *typowych* danych, a nie informację potrzebną do wykrycia *nietypowych*. Na Arrhythmii

47 % wariancji wystarcza, a na WDBC 33 % daje wynik lepszy niż 100 %.

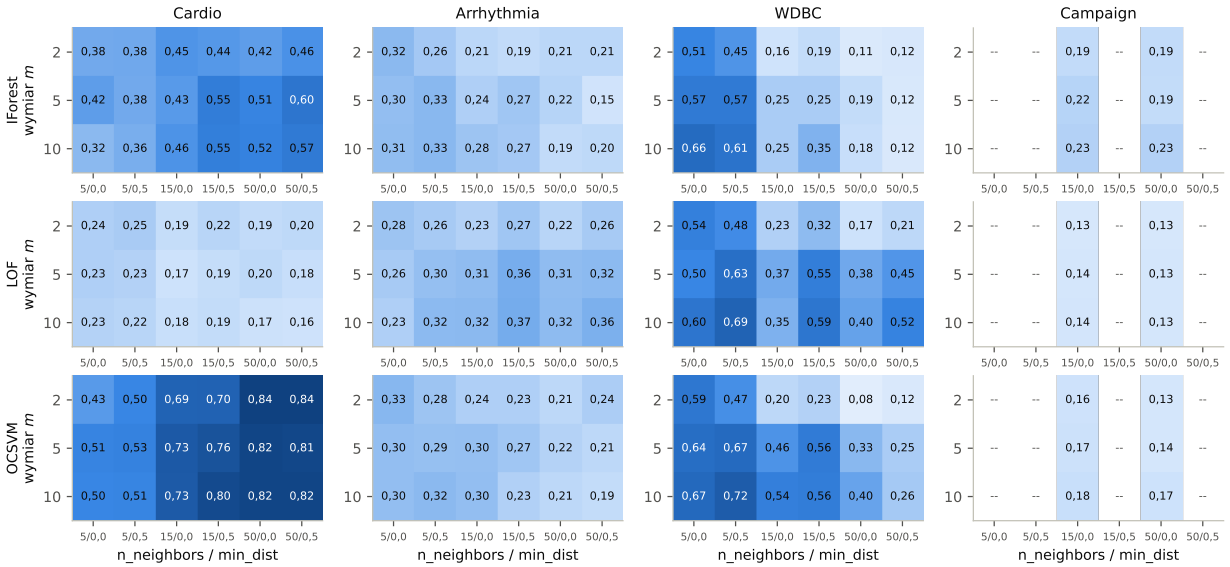
**Tabela 3:** Arrhythmia: Recall według typu anomalii i PR-AUC w zależności od liczby składowych PCA (część testowa, 10 podziałów). „Rekonstrukcja" – błąd rekonstrukcji PCA.

| Detektor | $k$ | zach. wariancja | PR-AUC | R globalne | R lokalne |
|---|---|---|---|---|---|
| LOF | oryg. (274) | 1,00 | 0,458 | 0,871 | 0,350 |
| | 2 | 0,17 | 0,397 | 0,542 | 0,179 |
| | 3 | 0,22 | 0,489 | 0,745 | 0,233 |
| | 5 | 0,32 | 0,587 | 0,809 | 0,225 |
| | 10 | 0,47 | 0,591 | 0,849 | 0,217 |
| | 20 | 0,64 | 0,558 | 0,861 | 0,322 |
| IForest | oryg. (274) | 1,00 | 0,583 | 0,838 | 0,203 |
| | 2 | 0,17 | 0,400 | 0,565 | 0,187 |
| | 3 | 0,22 | 0,485 | 0,679 | 0,222 |
| | 5 | 0,32 | 0,561 | 0,820 | 0,242 |
| | 10 | 0,47 | 0,582 | 0,833 | 0,263 |
| | 20 | 0,64 | 0,520 | 0,846 | 0,252 |
| Rekonstrukcja | 2 | 0,17 | 0,456 | 0,858 | 0,337 |
| | 3 | 0,22 | 0,450 | 0,874 | 0,363 |
| | 5 | 0,32 | 0,432 | 0,872 | 0,298 |
| | 10 | 0,47 | 0,415 | 0,896 | 0,375 |
| | 20 | 0,64 | 0,415 | 0,909 | 0,346 |

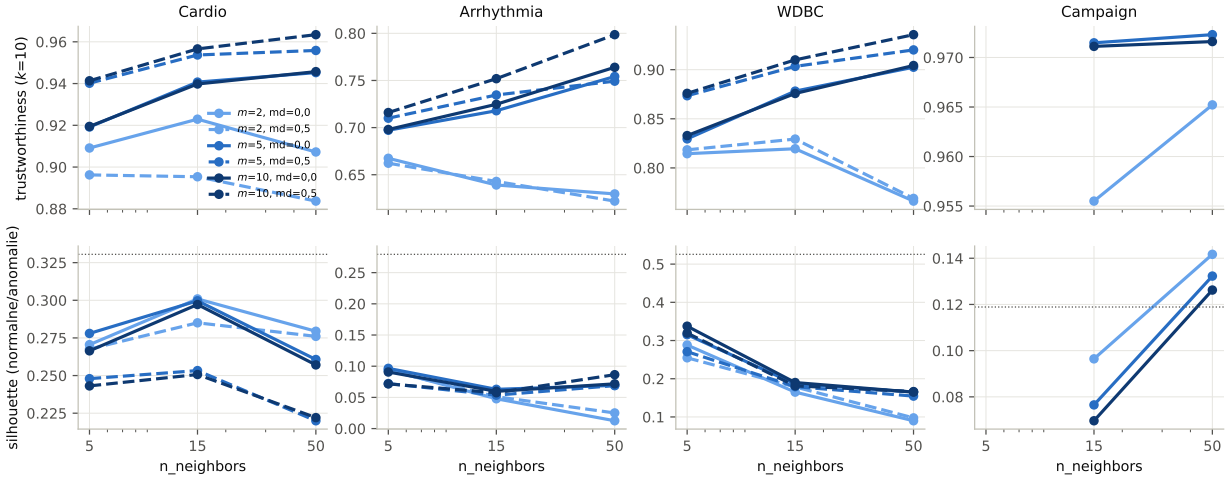
Isolation Forest korzysta z PCA w mniejszym stopniu niż w typowych przykładach z literatury. PCA obraca układ współrzędnych do osi głównych, co pomaga cięciom osiowym, gdy odchylenie anomalii rozkłada się na wiele skorelowanych cech. Tutaj jednak IForest najlepiej działa na jednej lub kilku składowych (Cardio $k = 1$: 0,64; Campaign $k = 3$: 0,30), a przy $k = 20$ na Cardio i WDBC jest wyraźnie gorszy niż w danych oryginalnych (0,47 wobec 0,60 i 0,41 wobec 0,75). Bez wybielania 20 składowych to głównie kierunki o małej wariancji, w których losowe cięcia IForest izolują przypadkowe punkty normalne.

### 4.3 UMAP: wpływ parametrów i struktura przestrzeni

Rysunek 3 przedstawia PR-AUC dla wszystkich wariantów UMAP, a rys. 4 – jakość zachowania sąsiedztw (trustworthiness) i separację klas (silhouette).




**Rysunek 3:** UMAP: PR-AUC (test) w zależności od wymiaru $m$, `n_neighbors` i `min_dist` dla trzech detektorów (parametry detektora wybrane na walidacji; „–” – wariant nie badany na Campaign).




**Rysunek 4:** UMAP: trustworthiness (górny wiersz) i silhouette podziału normalne/anomalie (dolny wiersz, linia kropkowana – dane oryginalne) w funkcji `n_neighbors`; linie ciągłe – `min_dist`=0, przerywane – 0,5; odcień – wymiar $m$.

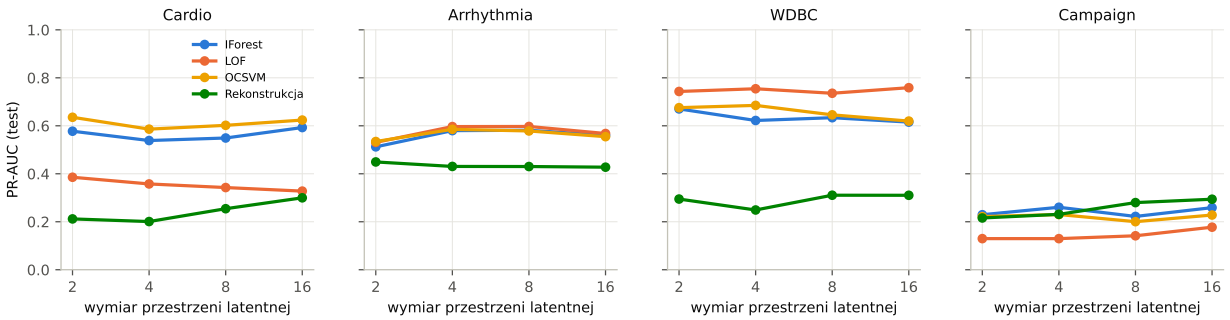
- **`n_neighbors`** ma największy wpływ, a jego kierunek zależy od struktury anomalii. Na Cardio większe wartości zdecydowanie pomagają OCSVM (0,43–0,53 dla nn=5, 0,70–0,80 dla 15, 0,81–0,84 dla 50). Klasa patologiczna tworzy tam spójną grupę, którą UMAP przy szerszym kontekście odsuwa od masy danych normalnych. Na WDBC jest odwrotnie: najlepsze jest nn=5 (OCSVM 0,47–0,72, przy nn=50 tylko 0,08–0,40). Przy ok. 5 anomaliach w części uczącej szerokie sąsiedztwo „wciąga” je w rozmaitość danych normalnych.
- **Wymiar $m$:** zwykle $m = 5$–10 jest nieco lepsze od $m = 2$ (WDBC, LOF: 0,48–0,54 dla $m = 2$ i 0,60–0,69 dla $m = 10$ przy nn=5). Wyjątkiem jest Cardio z OCSVM, gdzie $m = 2$ wystarcza. Wymiar 2 jest dobry do wizualizacji, ale zwykle za mały do detekcji.
- **`min_dist`** ma mały wpływ. Na WDBC `min_dist`=0,5 pomaga LOF (0,69 wobec 0,60 przy $m = 10$, nn=5), bo nie upakowuje punktów tak ciasno.
- Trustworthiness jest wysokie dla Cardio i Campaign (0,92–0,97), niższe dla WDBC (0,84–0,87) i najniższe dla Arrhythmii (0,69–0,72), gdzie 274 wymiary zanurzane są w co

najwyżej 10. Silhouette klas w UMAP jest niższe niż w danych oryginalnych na Cardio, WDBC i Arrhythmii (np. WDBC 0,14–0,30 wobec 0,53, Arrhythmia 0,06–0,09 wobec 0,28), a na Campaign porównywalne (0,08–0,13 wobec 0,12).

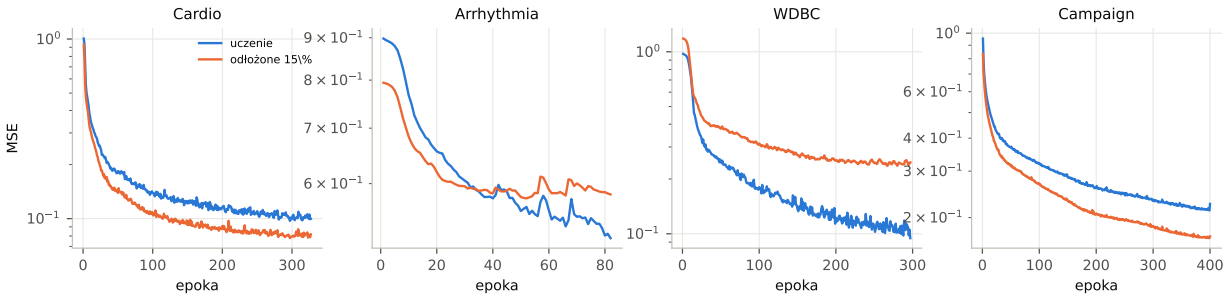
**Dlaczego UMAP zwykle szkodzi detekcji?** UMAP z konstrukcji *normalizuje lokalną gęstość*: odległości do sąsiadów każdego punktu są skalowane względem odległości do jego najbliższego sąsiada ($\rho_i$, $\sigma_i$), aby każdy punkt miał „tyle samo" połączeń. Punkt odosobniony zostaje przez to sztucznie „dociągnięty" do najbliższego skupiska, a mała grupa anomalii staje się zwartym, gęstym klastrem. Detektory gęstościowe (LOF) widzą wtedy anomalie jako normalne skupisko: na Cardio LOF spada z 0,31 do 0,24, a Recall anomalii globalnych LOF z 0,96 do 0,26 (tabela 1). Dodatkowo `transform` umieszcza nowe punkty w pobliżu ich sąsiadów z części uczącej, co dodatkowo „wciąga" anomalie do skupisk. Informacja o *skali* odchylenia, kluczowa dla wyjątków globalnych, jest tracona: Recall globalnych najlepszego detektora spada na Arrhythmii z 0,84 do 0,66, a na Campaign z 0,83 do 0,63 (tabela 5).

**Dlaczego UMAP pomaga OCSVM na Cardio?** Cardio jest jedynym zbiorem, w którym anomalie są *dużą, spójną grupą* (176 zapisów patologicznych) o odmiennej strukturze. UMAP wydziela je jako osobne skupiska na skraju zanurzenia (rys. 7, `n_neighbors`=15; przy 50 efekt jest jeszcze silniejszy). OCSVM z gładką granicą ($\gamma = 0{,}1/d$, $\nu = 0{,}5$) w dwóch wymiarach otacza główną masę danych normalnych i odcina te skupiska – nie potrzebuje, żeby były rzadkie, tylko żeby leżały poza masą. LOF w tej samej przestrzeni zawodzi, bo skupiska anomalii są lokalnie gęste. Ta sama transformacja może więc pomóc detektorowi globalnemu i zaszkodzić lokalnemu. Wynik jest stabilny: walidacyjna PR-AUC (0,85) jest zgodna z testową (0,84 ± 0,05), więc nie jest to przypadek wyboru na walidacji.

## 4.4 Autoenkoder: wymiar latentny i architektura




**Rysunek 5:** Autoenkoder: PR-AUC (test) detektorów w przestrzeni latentnej i błędu rekonstrukcji w zależności od wymiaru latentnego.




**Rysunek 6:** Krzywe uczenia autoenkodera ($z = 8$, podział 0): błąd na części uczącej i na 15 % odłożonych do wczesnego zatrzymania.

Wpływ wymiaru latentnego (rys. 5) jest umiarkowany i zależy od zbioru. Na Arrhythmii detektory w przestrzeni latentnej są najlepsze przy $z = 4$–$8$ (LOF 0,60), a przy $z = 2$ słabsze (0,53). Na Campaign błąd rekonstrukcji poprawia się z $z$ (0,22 dla $z = 2$, 0,29 dla $z = 16$), bo sieć z wąskim gardłem nie odtwarza nawet danych normalnych. Na Cardio i WDBC zmiany mieszczą się w 0,05. Detektory w przestrzeni latentnej są zwykle słabsze niż w PCA, bo koder jest uczony do rekonstrukcji, a nie do zachowania odległości. Przestrzeń latentna nie ma więc dobrze określonej metryki i sąsiedztwa mogą być w niej zniekształcone. Na Arrhythmii, gdzie problemem jest nadmiar cech, nieliniowa kompresja działa podobnie jak PCA (0,60 wobec 0,59).
Krzywe uczenia (rys. 6) pokazują, że wczesne zatrzymanie działa na małych zbiorach: błąd na danych odłożonych przestaje maleć średnio po 140 epokach (Arrhythmia) – 290 (Cardio), a różnica między błędem uczącym i odłożonym pozostaje niewielka. Na Campaign uczenie prawie zawsze dochodzi do limitu 400 epok (średnio 395), czyli sieć nie osiągnęła jeszcze minimum. Większy limit epok mógłby tam poprawić rekonstrukcję, ale kosztem dalszego wzrostu czasu (ok. 50 s na model).
Porównanie architektur (tabela 4) pokazuje, że wybór architektury ma znacznie mniejszy wpływ niż wybór zbioru i sposobu użycia autoenkodera. Na Cardio, Arrhythmii i WDBC różnice PR-AUC błędu rekonstrukcji między wariantami nie przekraczają 0,04. Na Campaign płytsza sieć $d$-32-8 jest wyraźnie słabsza (0,21 wobec 0,28), bo przy 62 cechach i 20 tys. obserwacji ma za małą pojemność. Architektura $d$-64-32-$z$ jest rozsądnym kompromisem między jakością a czasem uczenia.

**Tabela 4:** Porównanie architektur autoenkodera przy $z = 8$ (część testowa, średnie po podziałach): PR-AUC błędu rekonstrukcji, PR-AUC najlepszego (wg walidacji) detektora w przestrzeni latentnej, średnia liczba epok do wczesnego zatrzymania i czas uczenia.

| Zbiór | Architektura | PR-AUC rekonstr. | PR-AUC detektor w $z$ | Epoki | Czas uczenia [s] |
|---|---|---|---|---|---|
| Cardio | $d$-32-8 | 0,264 | 0,582 (OCSVM) | 335 | 7,91 |
| | $d$-64-32-8 | 0,254 | 0,602 (OCSVM) | 330 | 11,04 |
| | $d$-128-64-8 | 0,250 | 0,556 (OCSVM) | 198 | 7,19 |
| Arrhythmia | $d$-32-8 | 0,425 | 0,591 (LOF) | 202 | 1,44 |
| | $d$-64-32-8 | 0,430 | 0,597 (LOF) | 127 | 1,30 |
| | $d$-128-64-8 | 0,426 | 0,572 (LOF) | 119 | 1,45 |
| WDBC | $d$-32-8 | 0,272 | 0,741 (LOF) | 346 | 1,71 |
| | $d$-64-32-8 | 0,311 | 0,736 (LOF) | 252 | 1,71 |
| | $d$-128-64-8 | 0,288 | 0,749 (LOF) | 184 | 1,36 |
| Campaign | $d$-32-8 | 0,210 | 0,202 (IForest) | 400 | 31,16 |
| | $d$-64-32-8 | 0,280 | 0,222 (IForest) | 400 | 51,12 |
| | $d$-128-64-8 | 0,283 | 0,197 (OCSVM) | 400 | 72,83 |

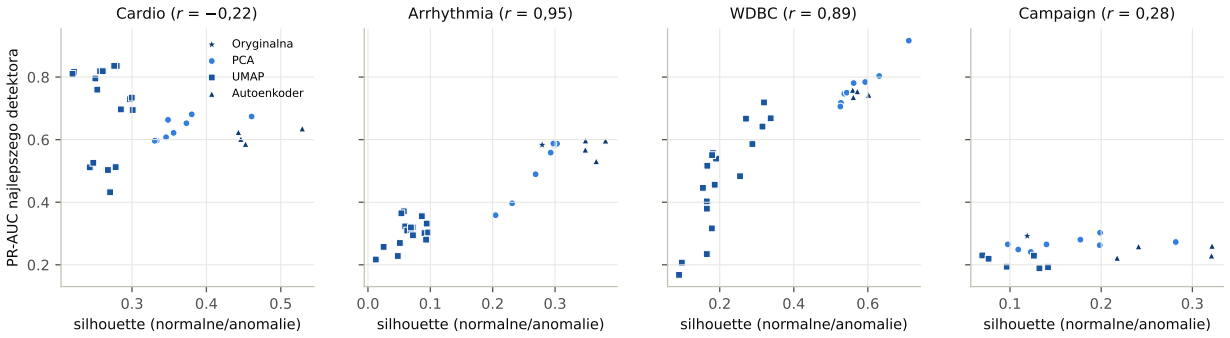
Ważnym ograniczeniem jest uczenie autoenkodera na danych zanieczyszczonych anomaliami. Na Cardio 88 zapisów patologicznych w części uczącej tworzy spójną grupę, którą sieć uczy się odtwarzać, więc błąd rekonstrukcji anomalii nie jest wyraźnie większy niż obserwacji normalnych (PR-AUC 0,25–0,30 przy bazowym 0,10). Rekonstrukcja wykrywa anomalie *niepowtarzalne*, a nie tworzące własną strukturę – dla tych drugich lepsze są detektory w przestrzeni, która tę strukturę oddziela od danych normalnych (UMAP + OCSVM na Cardio).

### 4.5 Wizualizacje 2D i separacja a jakość detekcji

Rysunek 7 przedstawia dwuwymiarowe reprezentacje części testowej, a rys. 8 – zależność między separacją klas (silhouette) a PR-AUC najlepszego detektora dla wszystkich wariantów reprezentacji.




**Rysunek 7:** Dwuwymiarowe reprezentacje części testowej (podział 0): PCA ($k = 2$), UMAP ($m = 2$, `n_neighbors`=15, `min_dist`=0) i przestrzeń latentna autoenkodera ($z = 2$); kolor anomalii – typ (globalne/lokalne).




**Rysunek 8:** Separacja klas w reprezentacji (silhouette, część testowa) a PR-AUC najlepszego detektora (wg walidacji) dla wszystkich wariantów reprezentacji; $r$ – współczynnik korelacji Pearsona.

Wizualizacje 2D mogą być mylące w obie strony. UMAP daje najbardziej „czytelne" obrazy: w Campaign rozbija dane na kilkadziesiąt skupisk (odpowiadających kombinacjom zmiennych kategorycznych), wśród których anomalie są równomiernie rozproszone, a w Arrhythmii tworzy wyraźne klastry, które nie mają związku z anomaliami. Mimo efektownego wyglądu oba zanurzenia dają słabą detekcję. Na Cardio ta sama metoda wydziela skupiska anomalii, co w tym przypadku przekłada się na najlepszą detekcję. Rzut PCA na 2 składowe dobrze oddziela anomalie WDBC (wzdłuż pierwszej składowej), ale w Arrhythmii (17 % wariancji) ukrywa większość struktury.
Liczbowa miara separacji (silhouette) koreluje z jakością detekcji silnie na Arrhythmii ($r = 0{,}95$) i WDBC ($r = 0{,}89$), słabo na Campaign ($r = 0{,}28$) i *ujemnie* na Cardio ($r = -0{,}22$). Na Cardio najwyższe silhouette mają dane oryginalne i PCA, a najlepszą detekcję – UMAP z OCSVM, który oddziela skupiska anomalii od masy danych, choć średnia odległość między klasami w nim maleje. Silhouette mierzy rozdzielenie *grup*, a nie to, czy anomalie leżą poza obszarem danych normalnych – dlatego jest lepszym, ale wciąż zawodnym wskaźnikiem jakości reprezentacji.

## 4.6 Typy anomalii w reprezentacjach

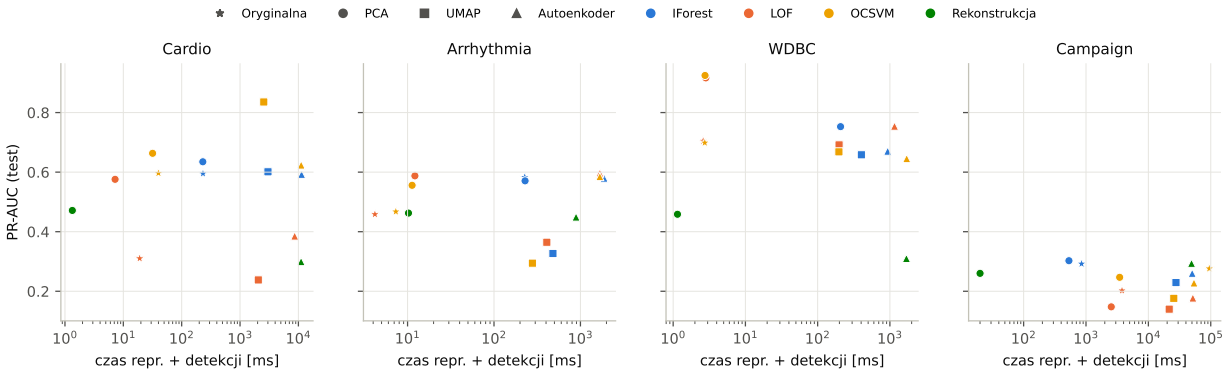
**Tabela 5:** Recall według typu anomalii dla najlepszego (wg walidacji) detektora w każdej reprezentacji (część testowa).

| Zbiór | Reprezentacja | Detektor | R globalne | R lokalne | PR-AUC |
|---|---|---|---|---|---|
| Cardio | Oryginalna | OCSVM | 0,971 | 0,620 | 0,596 |
| | PCA | OCSVM | 0,910 | 0,642 | 0,663 |
| | UMAP | OCSVM | 0,854 | 0,745 | 0,836 |
| | Autoenkoder | OCSVM | 0,988 | 0,599 | 0,624 |
| Arrhythmia | Oryginalna | IForest | 0,838 | 0,203 | 0,583 |
| | PCA | LOF | 0,874 | 0,217 | 0,588 |
| | UMAP | LOF | 0,657 | 0,238 | 0,365 |
| | Autoenkoder | LOF | 0,886 | 0,281 | 0,597 |
| WDBC | Oryginalna | LOF | 0,955 | 0,580 | 0,705 |
| | PCA | LOF | 1,000 | 0,759 | 0,916 |
| | UMAP | OCSVM | 0,955 | 0,741 | 0,668 |
| | Autoenkoder | LOF | 0,955 | 0,592 | 0,754 |
| Campaign | Oryginalna | IForest | 0,831 | 0,278 | 0,292 |
| | PCA | IForest | 0,851 | 0,231 | 0,303 |
| | UMAP | IForest | 0,628 | 0,328 | 0,229 |
| | Autoenkoder | Rekonstrukcja | 0,995 | 0,522 | 0,294 |

Tabela 5 pokazuje, która reprezentacja zachowuje jaki rodzaj informacji. Anomalie globalne są wykrywane w 83–100 % w danych oryginalnych, PCA i przestrzeni autoenkodera, ale UMAP obniża

ten odsetek na każdym zbiorze (Arrhythmia 0,66, Campaign 0,63, Cardio 0,85). Anomalie lokalne zyskują na reprezentacji, która usuwa szum: PCA na WDBC (0,58 → 0,76) i UMAP na Cardio (0,62 → 0,75). Na Arrhythmii i Campaign Recall anomalii lokalnych najlepszego detektora nie przekracza w żadnej reprezentacji 0,28 i 0,52. Żadna pojedyncza para reprezentacja–detektor nie jest najlepsza dla obu typów na wszystkich zbiorach – to przesłanka do łączenia detektorów (zadanie 3).

## 4.7 Kompromis jakość – wymiar – czas




**Rysunek 9:** Łączny czas przygotowania reprezentacji i detekcji a PR-AUC dla konfiguracji wybranych na walidacji (kształt – reprezentacja, kolor – detektor).

Koszty reprezentacji różnią się o cztery rzędy wielkości (rys. 9). PCA kosztuje 1–10 ms nawet na Campaign. UMAP kosztuje 0,3 s (WDBC) – 26 s (Campaign; 16 s dopasowania i 10 s transformacji), a autoenkoder 1,4 s (WDBC, Arrhythmia) – 50 s (Campaign). Czas detekcji zależy przede wszystkim od detektora i liczby obserwacji. Na małych zbiorach IForest z 200 drzewami kosztuje ok. 0,2 s, a LOF i OCSVM 2–34 ms. Na Campaign proporcje się odwracają: IForest 0,85 s, LOF 3,8 s, OCSVM 36 s (złożoność ponadliniowa względem $n$). Redukcja wymiaru przyspiesza tam detektory odległościowe (LOF w PCA ok. 2,5 s), ale nie poprawia ich jakości. Najkorzystniejszy kompromis dają: **PCA z LOF/OCSVM** (kilka ms, najlepsze wyniki na WDBC, poprawa na Cardio i Arrhythmii) oraz **IForest w danych oryginalnych lub PCA** na dużych zbiorach. Autoenkoder jest setki do tysięcy razy droższy od PCA przy podobnej jakości (wyjątek: Arrhythmia, gdzie jest równie dobry). UMAP jest drogi i w 10 z 12 przypadków szkodliwy.

### 4.8 Porównanie z zadaniem 1

**Tabela 6:** PR-AUC (test) detektorów w poszczególnych reprezentacjach. Zad. 1 – najlepsza konfiguracja z zadania 1 (dane oryginalne, szersza siatka; tylko Cardio jest wspólny dla obu zadań). Zysk – różnica między najlepszą reprezentacją a danymi oryginalnymi z tą samą siatką detektora.

| Zbiór | Detektor | Zad. 1 | Oryginalna | PCA | UMAP | Autoenkoder | Najlepsza repr. | Zysk |
|---|---|---|---|---|---|---|---|---|
| Cardio | IForest | 0,600 | 0,595 | 0,635 | 0,601 | 0,593 | PCA | +0,040 |
| | LOF | 0,310 | 0,310 | 0,576 | 0,238 | 0,385 | PCA | +0,266 |
| | OCSVM | 0,763 | 0,596 | 0,663 | 0,836 | 0,624 | UMAP | +0,239 |
| Arrhythmia | IForest | – | 0,583 | 0,571 | 0,327 | 0,580 | Oryginalna | +0,000 |
| | LOF | – | 0,458 | 0,588 | 0,365 | 0,597 | Autoenkoder | +0,138 |
| | OCSVM | – | 0,467 | 0,556 | 0,294 | 0,585 | Autoenkoder | +0,118 |
| WDBC | IForest | – | 0,754 | 0,753 | 0,658 | 0,670 | Oryginalna | +0,000 |
| | LOF | – | 0,705 | 0,916 | 0,692 | 0,754 | PCA | +0,212 |
| | OCSVM | – | 0,699 | 0,925 | 0,668 | 0,646 | PCA | +0,226 |
| Campaign | IForest | – | 0,292 | 0,303 | 0,229 | 0,260 | PCA | +0,010 |
| | LOF | – | 0,202 | 0,148 | 0,140 | 0,177 | Oryginalna | +0,000 |
| | OCSVM | – | 0,276 | 0,247 | 0,176 | 0,228 | Oryginalna | +0,000 |

Jedynym zbiorem wspólnym z zadaniem 1 jest Cardio (tabela 6). Dla IForest i LOF wyniki w danych oryginalnych są zgodne z zadaniem 1 (0,60 i 0,31). Dla OCSVM różnica jest duża (0,60 wobec 0,76), bo w zadaniu 1 wybrano jądro sigmoidalne, a w zadaniu 2 siatka obejmuje tylko RBF. Najlepsza reprezentacja (UMAP + OCSVM, 0,84) przewyższa jednak najlepszy wynik z zadania 1 na tym zbiorze. Zmiana reprezentacji poprawiła wynik w danych oryginalnych dla 8 z 12 par zbiór–detektor, a istotnie (o ponad 0,1 PR-AUC) w sześciu. Wszystkie istotne poprawy dają PCA lub nieliniowa redukcja (autoenkoder na Arrhythmii, UMAP + OCSVM na Cardio). Na Campaign żadna reprezentacja nie pomaga.

## 5 Odpowiedzi na pytania analityczne

**a) Czy redukcja wymiarowości zawsze poprawia skuteczność detekcji?** Nie. W porównaniu z danymi oryginalnymi PCA poprawiło wyniki w 8 z 12 par zbiór–detektor (wszystkie trzy detektory na Cardio, LOF i OCSVM na Arrhythmii i WDBC, minimalnie IForest na Campaign), UMAP – w dwóch (OCSVM na Cardio +0,24, IForest na Cardio +0,01), a przestrzeń latentna autoenkodera – w pięciu (o więcej niż 0,05 tylko LOF na Cardio oraz LOF i OCSVM na Arrhythmii). Redukcja pomaga, gdy informacja odróżniająca anomalie leży w kierunkach o dużej wariancji, a pozostałe wymiary niosą głównie szum (WDBC: $k = 1$) albo gdy cech jest więcej niż obserwacji (Arrhythmia). Szkodzi, gdy usuwa kierunki, w których anomalie się odchylają (Arrhythmia, $k = 2$: Recall globalnych 0,87 $\rightarrow$ 0,54), albo gdy zmienia geometrię (UMAP dla LOF).

**b) Czy anomalie pozostają odseparowane od normalnych w przestrzeni zredukowanej?** Zależy to od reprezentacji i struktury anomalii. W PCA z odpowiednim $k$ anomalie WDBC i Cardio pozostają odseparowane, a nawet lepiej niż w danych oryginalnych. UMAP zmniejsza separację mierzoną silhouette na trzech zbiorach (WDBC 0,53 $\rightarrow$ 0,14–0,30), choć na Cardio oddziela skupiska anomalii od masy danych. Na Campaign anomalie nie są odseparowane w żadnej przestrzeni (silhouette $\leq$ 0,14).

**c) Która reprezentacja jest najbardziej użyteczna dla poszczególnych detektorów?** LOF: **PCA** (WDBC, Cardio, Arrhythmia) – LOF jest najbardziej wrażliwy na szum wymiarów i najbardziej zyskuje na jego usunięciu. OCSVM: **PCA**, a gdy anomalie tworzą spójną grupę – **UMAP** z dużym `n_neighbors` (Cardio). Isolation Forest: **dane oryginalne** lub PCA z

małym $k$; jest najmniej wrażliwy na reprezentację. Błąd rekonstrukcji (PCA lub autoenkoder) nie był najlepszy na żadnym zbiorze (0,26–0,47); jego skuteczność zależy od tego, czy anomalie są niepowtarzalne.

**d) Czy najlepsza wizualnie separacja odpowiada najwyższej jakości detekcji?** Nie. Najbardziej efektowne wizualnie zanurzenia UMAP (Campaign, Arrhythmia) dają słabą detekcję, a liczbowa separacja (silhouette) koreluje z jakością silnie tylko na dwóch zbiorach ($r = 0{,}89$–$0{,}95$), a na Cardio ujemnie ($r = -0{,}22$).

**e) Jaki jest kompromis między jakością wyników a kosztem obliczeniowym?** Najlepszy stosunek jakości do kosztu ma PCA (milisekundy, często poprawa wyników). UMAP i autoenkoder kosztują setki do tysięcy razy więcej i tylko w pojedynczych przypadkach są lepsze od PCA (UMAP + OCSVM na Cardio). Na dużych danych (Campaign) dominującym kosztem jest detektor (OCSVM 36 s), a nie reprezentacja. Tam wybór taniego detektora (IForest 0,85 s) ma większe znaczenie niż wybór reprezentacji.

# 6 Rekomendacje i dyskusja

**Dlaczego reprezentacja poprawia lub pogarsza wyniki?** Mechanizm jest wspólny: detektor ocenia odstawanie w pewnej metryce (odległość, gęstość, łatwość izolacji). Reprezentacja zmienia tę metrykę.

- Poprawa następuje, gdy reprezentacja (1) usuwa wymiary szumu, które rozmywały odległości (PCA na WDBC, Cardio, Arrhythmii), albo (2) przenosi grupę anomalii poza obszar danych normalnych w sposób, który wykorzysta detektor globalny (UMAP + OCSVM na Cardio).
- Pogorszenie następuje, gdy reprezentacja (1) usuwa kierunki, w których anomalie się odchylają (PCA z bardzo małym $k$ na Arrhythmii), albo (2) wyrównuje gęstość, na której opiera się detektor lokalny (UMAP + LOF).

**Rekomendacje.**

1. **LOF i OCSVM** – zawsze sprawdzić PCA z kilkoma wartościami $k$, wybierając $k$ na walidacji, a nie według zachowanej wariancji. Szczególnie gdy cech jest dużo w stosunku do liczby obserwacji.
2. **Isolation Forest** – dane oryginalne; na reprezentacji zyskuje najmniej.
3. **UMAP** – głównie do wizualizacji. Jako wejście detektora tylko z detektorem globalnym (OCSVM), dużym `n_neighbors` i wyborem na walidacji. Nigdy z LOF.
4. **Autoenkoder** – przy małych zbiorach nie uzasadnia swojego kosztu, chyba że cech jest bardzo dużo (Arrhythmia). Uczony na danych zanieczyszczonych może „nauczyć się" grupy anomalii.
5. Błąd rekonstrukcji (PCA) jest tani i warto go sprawdzić jako dodatkowy detektor, ale w badanych danych nie był najlepszy.

**Ograniczenia.**

- Części walidacyjne i testowe WDBC zawierają 2–3 anomalie, więc odchylenie PR-AUC między podziałami jest tam bardzo duże (0,13–0,39), mimo 30 podziałów. Przewaga PCA na WDBC (0,92 wobec 0,71) jest jednak większa niż ten rozrzut i zgodna na walidacji (0,87 wobec 0,75).
- Dla Campaign zredukowano liczbę podziałów (5) i siatkę UMAP i OCSVM. Rozrzut między podziałami jest tam bardzo mały (odchylenie 0,01–0,04), więc 5 podziałów wystarcza do

porównania średnich. Węższa siatka mogła natomiast pominąć lepszą konfigurację UMAP, co nie zmienia wniosku, że na tym zbiorze żadna reprezentacja nie pomaga.

- Autoenkoder na Campaign nie osiągnął kryterium wczesnego zatrzymania w limicie 400 epok.
- Zbadano tylko jedną rodzinę architektur autoenkodera (MLP) i uczenie na danych zanieczyszczonych. Wariant uczenia tylko na danych normalnych (scenariusz półnadzorowany) zmieniłby wyniki rekonstrukcji.

**Kierunki dalszych badań.** Odporne PCA (np. Robust PCA) mniej wrażliwe na anomalie w części uczącej, autoenkodery uczone na danych oczyszczonych przez inny detektor, łączenie wyników detektorów z różnych reprezentacji (zadanie 3) oraz reprezentacje dopasowane do danych mieszanych (kategoryczne i ciągłe), jak w Campaign.

# 7 Wnioski

1. Reprezentacja danych ma duży wpływ na detekcję: rozrzut PR-AUC jednego detektora między reprezentacjami sięga 0,34 (LOF na Cardio: 0,24 w UMAP wobec 0,58 w PCA; OCSVM na WDBC: 0,65 w autoenkoderze wobec 0,93 w PCA).
2. PCA jest najbardziej użyteczną reprezentacją: tanią i najczęściej poprawiającą wyniki LOF i OCSVM, czasem bardzo silnie (WDBC: 0,71 → 0,92 przy jednej składowej).
3. Zachowana wariancja nie jest dobrym kryterium wyboru liczby składowych: na WDBC 33 % wariancji daje lepszy wynik niż 100 %, a na Arrhythmii optimum przypada na 32–47 %.
4. UMAP zwykle pogarsza detekcję, bo normalizuje lokalną gęstość, ale w połączeniu z detektorem globalnym może wydzielić grupę anomalii (Cardio: 0,84). Najlepsza wizualnie separacja nie oznacza najlepszej detekcji.
5. Gdy anomalie nie są wyjątkami w sensie rozkładu (Campaign), żadna reprezentacja nie pomaga. Żadna para reprezentacja–detektor nie jest najlepsza dla wszystkich typów anomalii i zbiorów, co uzasadnia łączenie detektorów w zadaniu 3.

# 8 Odtworzenie wyników

```
python -m task2_representations.run       # ok. 55 min, 3 procesy (N_JOBS)
python -m task2_representations.analyze   # tabele i rysunki
```

# Literatura


[1] S. Han, X. Hu, H. Huang, M. Jiang, Y. Zhao. *ADBench: Anomaly Detection Benchmark*. Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track, 2022. Repozytorium `https://github.com/Minqi824/ADBench`, commit `3dac822`.

[2] S. Rayana. *ODDS Library*. Stony Brook University, Department of Computer Science, 2016. `https://odds.cs.stonybrook.edu`.

[3] G. O. Campos, A. Zimek, J. Sander, R. J. G. B. Campello, B. Micenková, E. Schubert, I. Assent, M. E. Houle. *On the evaluation of unsupervised outlier detection: measures, datasets, and an empirical study*. Data Mining and Knowledge Discovery 30(4), 891–927, 2016. `https://www.dbs.ifi.lmu.de/research/outlier-evaluation/`.

[4] M. Kelly, R. Longjohn, K. Nottingham. *The UCI Machine Learning Repository*. University of California, Irvine. `https://archive.ics.uci.edu`.

[5] W. H. Wolberg, O. L. Mangasarian. *Multisurface method of pattern separation for medical diagnosis applied to breast cytology*. Proceedings of the National Academy of Sciences 87(23), 9193–9196, 1990. (UCI: Breast Cancer Wisconsin (Original)).

[6] W. N. Street, W. H. Wolberg, O. L. Mangasarian. *Nuclear feature extraction for breast tumor diagnosis*. IS&T/SPIE Symposium on Electronic Imaging: Science and Technology, vol. 1905, 861–870, 1993. (UCI: Breast Cancer Wisconsin (Diagnostic)).

[7] K. S. Woods, C. C. Doss, K. W. Bowyer, J. L. Solka, C. E. Priebe, W. P. Kegelmeyer. *Comparative evaluation of pattern recognition techniques for detection of microcalcifications in mammography*. International Journal of Pattern Recognition and Artificial Intelligence 7(6), 1417–1436, 1993.

[8] S. Aeberhard, M. Forina. *Wine*. UCI Machine Learning Repository, 1991.

[9] D. Ayres-de Campos, J. Bernardes, A. Garrido, J. Marques-de-Sá, L. Pereira-Leite. *SisPorto 2.0: a program for automated analysis of cardiotocograms*. Journal of Maternal-Fetal Medicine 9(5), 311–318, 2000. (UCI: Cardiotocography).

[10] S. Moro, P. Cortez, P. Rita. *A data-driven approach to predict the success of bank telemarketing*. Decision Support Systems 62, 22–31, 2014. (UCI: Bank Marketing).

[11] H. A. Güvenir, B. Acar, G. Demiröz, A. Çekin. *A supervised machine learning algorithm for arrhythmia analysis*. Computers in Cardiology 1997, 433–436. (UCI: Arrhythmia).

[12] *Statlog (Heart)*. UCI Machine Learning Repository.