Politechnika Łódzka
Wydział Fizyki Technicznej, Informatyki i Matematyki Stosowanej

Analiza danych złożonych z detekcją wyjątków

Zadanie 2

Detekcja wyjątków w danych wielowymiarowych:
wpływ reprezentacji danych

Jędrzej Kostyk
nr indeksu 264339

Rok akademicki 2026/2027

Spis treści

1 Cel i zakres **2**

2 Dane i protokół **2**

3 Reprezentacje **3**

4 Wyniki **4**

4.1 Zestawienie wszystkich konfiguracji 4

4.2 PCA: liczba składowych, zachowana wariancja i jakość detekcji 6

4.3 UMAP: wpływ parametrów i struktura przestrzeni 7

4.4 Autoenkoder: wymiar latentny i architektura 9

4.5 Wizualizacje 2D i separacja a jakość detekcji 10

4.6 Typy anomalii w reprezentacjach 12

4.7 Kompromis jakość – wymiar – czas 13

4.8 Porównanie z zadaniem 1 13

5 Odpowiedzi na pytania analityczne **14**

6 Rekomendacje i dyskusja **15**

7 Wnioski **15**

8 Odtworzenie wyników **16**

1 Cel i zakres

Celem zadania jest zbadanie, jak sposób reprezentacji danych wielowymiarowych wpływa na skuteczność detekcji wyjątków. Porównano cztery reprezentacje: dane oryginalne (A), PCA (B), UMAP (C) i przestrzeń latentną autoenkodera (D). W każdej z nich uruchomiono te same trzy detektory – Isolation Forest, LOF i One-Class SVM. Dla PCA i autoenkodera oceniono dodatkowo błąd rekonstrukcji jako samodzielny wynik anomalii. Daje to 12 konfiguracji podstawowych i 2 dodatkowe na każdy zbiór, łącznie 56 porównywanych konfiguracji na czterech zbiorach. Dla każdej reprezentacji systematycznie zbadano jej parametry (liczbę składowych PCA, `n_neighbors`, `min_dist` i wymiar UMAP, wymiar latentny i architekturę autoenkodera), co dało 33 warianty reprezentacji $\times$ 15 konfiguracji detektorów $\times$ 4 zbiory $\times$ 10 podziałów, czyli ok. 20 tys. przebiegów detekcji.

Kod znajduje się w katalogu `task2_representations/`, a wspólne elementy (dane, podziały, detektory, metryki) w `common/`, tak jak w zadaniu 1.

2 Dane i protokół

Zadanie wymaga zbiorów o co najmniej 20–30 cechach, dlatego wykorzystano cztery zbiory z zadania 1 spełniające ten warunek: Breast Cancer (30 cech), Ionosphere (33), Parkinsons (22) oraz 30-wymiarowy zbiór syntetyczny. Glass (9 cech) pominięto. Definicja anomalii, podpróbkowanie do 10 % i charakterystyka zbiorów są takie same jak w zadaniu 1 (tabela 1 raportu z zadania 1). Przypomnijmy, że w zbiorze syntetycznym dane normalne leżą na 4-wymiarowej podprzestrzeni liniowej, a anomalie są trzech typów: globalne, lokalne (przy gęstym skupisku) i podprzestrzenne (przesunięte poza podprzestrzeń danych). Pozwala to wskazać, jaka informacja ginie przy redukcji wymiaru.

Protokół jest identyczny jak w zadaniu 1 i we wszystkich porównaniach taki sam:

1. te same 10 warstwowych podziałów 50/25/25 % (train/walidacja/test),
2. standaryzacja dopasowana na części uczącej,
3. **reprezentacja dopasowywana wyłącznie na części uczącej, bez etykiet** (PCA, UMAP, autoenkoder), a następnie stosowana do części walidacyjnej i testowej (`transform`),
4. detektory uczone w przestrzeni reprezentacji na części uczącej,
5. parametry reprezentacji i detektora wybierane łącznie na podstawie średniej PR-AUC na walidacji, a próg – przez maksymalizację F1 na walidacji; część testowa służy tylko do oceny.

Po transformacji każda reprezentacja jest centrowana i dzielona przez *jeden wspólny* współczynnik (pierwiastek średniej wariancji współrzędnych na części uczącej). Zachowuje to geometrię przestrzeni (proporcje odległości), ale sprowadza wszystkie reprezentacje do porównywalnej skali, dzięki czemu np. $\gamma = 1/d$ w OCSVM oznacza to samo w każdej przestrzeni. Celowo nie stosowano wybielania (*whitening*) składowych PCA, które zmieniłoby geometrię i wzmocniło składowe o znikomej wariancji.

Detektory i ich siatki. Isolation Forest z $T = 200$ drzewami (w zadaniu 1 liczba drzew nie miała wpływu), LOF z $k \in \{5, 10, 20, 35, 50\}$, OCSVM z jądrem RBF (najlepszym w zadaniu 1), $\nu \in \{0{,}05;\ 0{,}1;\ 0{,}5\}$ i $\gamma \in \{0{,}1/d,\ 1/d,\ 10/d\}$, gdzie d to wymiar reprezentacji. Hiperparametry detektora są wybierane osobno dla każdej reprezentacji, bo optymalne k czy γ zależą od geometrii przestrzeni. W przeciwnym razie porównanie faworyzowałoby reprezentację, do której dopasowano parametry.

Miary jakości reprezentacji. Oprócz metryk detekcji (Precision, Recall, F1, ROC-AUC, PR-AUC) dla każdej reprezentacji policzono na części testowej: *trustworthiness* ($k = 10$) – w jakim stopniu sąsiedztwa w przestrzeni zredukowanej istnieją także w oryginalnej (1 = brak „fałszywych sąsiadów"), oraz *silhouette* podziału normalne/anomalie – liczbową miarę widocznej separacji klas (od -1 do 1). Etykiety są tu użyte wyłącznie do analizy, nie do budowy reprezentacji. Mierzono czas dopasowania i transformacji reprezentacji oraz czas uczenia i oceny detektora.

3 Reprezentacje

A. Dane oryginalne. Standaryzowane cechy ($d = 22$–33).

B. PCA. Rzut na $k \in \{1, 2, 3, 5, 8, 10, 15, 20\}$ pierwszych składowych głównych. Zachowana wariancja dla $k = 5$ wynosi 0,81–0,91, dla $k = 10$ – 0,94–0,98 (rys. 2, dolny wiersz). PCA zachowuje kierunki największej wariancji i odrzuca resztę, a anomalia odchylająca się w kierunkach o małej wariancji staje się niewidoczna w rzucie. Ta sama informacja jest jednak zawarta w *błędzie rekonstrukcji* $\|x - \hat{x}\|^2$ (odległość od podprzestrzeni), który oceniano jako dodatkowy detektor.

C. UMAP. Nieliniowe zanurzenie zachowujące lokalną strukturę grafu k najbliższych sąsiadów. Badano wymiar $m \in \{2, 5, 10\}$, `n_neighbors` $\in \{5, 15, 50\}$ (skala struktury: lokalna – globalna) oraz `min_dist` $\in \{0{,}0;\ 0{,}5\}$ (jak ciasno upakowane mogą być punkty), łącznie 18 wariantów. Nowe punkty są rzutowane metodą `transform`.

D. Autoenkoder. W pełni połączona sieć o architekturze lejka $d \to 64 \to 32 \to z \to 32 \to 64 \to d$ z aktywacją ReLU i liniowym wyjściem. Uzasadnienie wyborów:

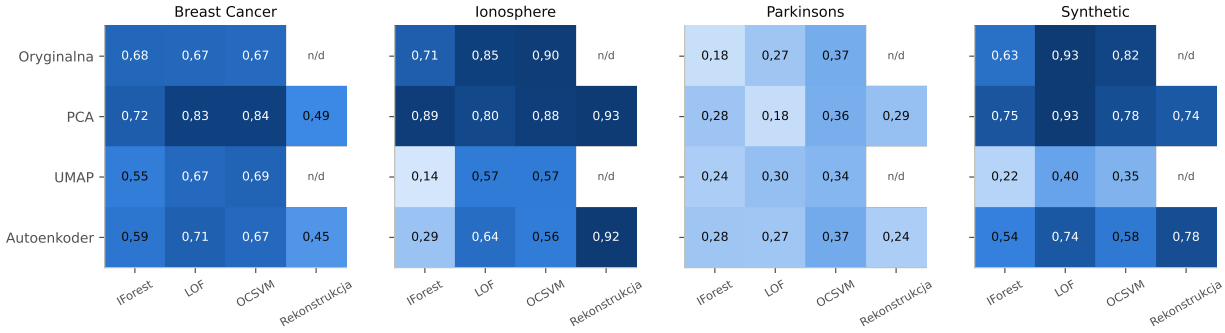
- *Niedopełniona* warstwa $z < d$ wymusza kompresję. Sieć nie może nauczyć się identyczności, więc musi odtwarzać dane z ich głównej struktury, a obserwacje do niej niepasujące mają duży błąd rekonstrukcji.
- Dwie warstwy ukryte pozwalają uchwycić zależności nieliniowe, czego PCA nie potrafi. Przy 80–500 obserwacjach uczących głębsza sieć łatwo się przeucza, dlatego zastosowano regularyzację: dropout 0,1 w koderze, *weight decay* 10^{-5} i wczesne zatrzymanie (patience 30 epok, maks. 400) na podstawie błędu na 15 % części uczącej odłożonych do monitorowania. Walidacja i test nie są używane do uczenia.
- Funkcja straty MSE odpowiada standaryzowanym, ciągłym cechom, optymalizator Adam ($\eta = 10^{-3}$, batch 32).
- Wymiar latentny $z \in \{2, 4, 8, 16\}$ zbadano systematycznie. Wybór architektury sprawdzono porównaniem z wariantem płytszym ($d \to 32 \to 8$) i szerszym ($d \to 128 \to 64 \to 8$) – tabela 4.

Reprezentacją latentną jest wyjście kodera z, a wynikiem anomalii – średni kwadratowy błąd rekonstrukcji. Sieć uczy się na danych zawierających anomalie (scenariusz nienadzorowany), co ma znaczenie dla interpretacji wyników (sekcja 4.4). Autoenkoder zaimplementowano w PyTorch. Na danych tej wielkości trening na CPU okazał się szybszy niż na GPU (RTX 3060 Laptop: ok. 0,01 s na epokę wobec ok. 0,02 s, bo dominuje narzut przesyłania małych porcji danych), dlatego obliczenia wykonywano równolegle na CPU.

4 Wyniki

4.1 Zestawienie wszystkich konfiguracji

Rysunek 1 przedstawia PR-AUC na części testowej dla wszystkich par reprezentacja–detektor, a tabela 1 – pełne wyniki wszystkich 56 konfiguracji (parametry wybrane na walidacji).



Rysunek 1: PR-AUC (część testowa, średnia z 10 podziałów) dla każdej pary reprezentacja–detektor; „Rekonstrukcja" – błąd rekonstrukcji PCA lub autoenkodera (n/d – nie dotyczy). Parametry reprezentacji i detektora wybrano na walidacji.

Najważniejsze obserwacje:

- **PCA jest jedyną reprezentacją, która często poprawia wyniki detektorów.** Na Breast Cancer LOF rośnie z 0,67 do 0,84, a OCSVM z 0,67 do 0,84. Na Ionosphere Isolation Forest rośnie z 0,71 do 0,89, a na zbiorze syntetycznym z 0,63 do 0,75.
- **Błąd rekonstrukcji jest najlepszym detektorem na Ionosphere** (PCA 0,926, autoenkoder 0,924 wobec 0,900 dla najlepszego detektora w danych oryginalnych), ale słabym na Breast Cancer (0,45–0,50).
- **UMAP pogarsza wyniki w 9 z 12 par zbiór–detektor**, często drastycznie (syntetyczny: LOF 0,93 → 0,40, Ionosphere: IForest 0,71 → 0,14).
- **Przestrzeń latentna autoenkodera** daje wyniki pośrednie: zwykle gorsze niż dane oryginalne lub PCA (wyjątek: Breast Cancer, LOF 0,71).
- Na Parkinsons żadna reprezentacja nie zmienia obrazu (PR-AUC 0,18–0,37) – jak pokazało zadanie 1, anomalie tego zbioru nie są wyjątkami statystycznymi i zmiana reprezentacji tego nie naprawi.

Tabela 1: Wszystkie konfiguracje (część testowa, średnie z 10 podziałów, ± odchylenie std. dla PR-AUC). Konfiguracja – parametry wybrane na walidacji: k – liczba składowych PCA; m, nn, md – wymiar, `n_neighbors` i `min_dist` UMAP; z – wymiar latentny AE; k_{LOF} – liczba sąsiadów LOF; Oryg. – dane oryginalne; AE – autoenkoder. t_r – dopasowanie i transformacja reprezentacji, t_d – uczenie i ocena detektora. Pogrubienie – najlepsza PR-AUC na zbiorze.

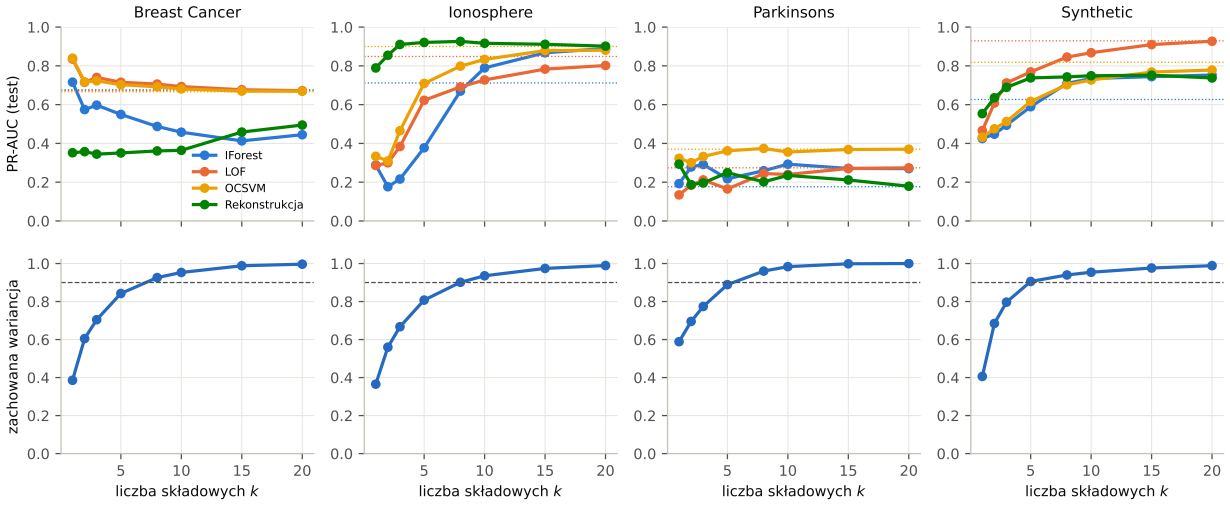
Zbiór	Repr.	Detektor	Konfiguracja	Prec.	Rec.	F1	ROC	PR-AUC	t_r [ms]	t_d [ms]
Breast Cancer	Oryg.	IForest	–	0,521	0,650	0,544	0,912	0,677 ± 0,132	0,0	257,7
	Oryg.	LOF	k_{LOF}=50	0,548	0,650	0,572	0,916	0,672 ± 0,136	0,0	3,9
	Oryg.	OCSVM	ν=0,50, γ=0,1/d	0,576	0,590	0,548	0,902	0,666 ± 0,142	0,0	3,4
	PCA	IForest	k=1	0,682	0,710	0,689	0,918	0,716 ± 0,110	1,5	273,7
	PCA	LOF	k=1; k_{LOF}=50	0,832	0,700	0,726	0,942	0,835 ± 0,093	1,5	3,0
	PCA	OCSVM	k=1; ν=0,50, γ=1,0/d	0,872	0,710	0,770	0,944	**0,840 ± 0,100**	1,5	2,3
	PCA	Rekonstr.	k=20	0,395	0,610	0,436	0,843	0,495 ± 0,123	1,4	0,2

Zbiór	Repr.	Detektor	Konfiguracja	Prec.	Rec.	F1	ROC	PR-AUC	t_r [ms]	t_d [ms]
	UMAP	IForest	m=5, nn=5, md=0,0	0,604	0,650	0,541	0,850	0,551 ± 0,227	233,8	256,2
	UMAP	LOF	m=10, nn=15, md=0,5; k_{LOF}=50	0,738	0,490	0,551	0,883	0,670 ± 0,152	396,4	3,4
	UMAP	OCSVM	m=5, nn=15, md=0,0; ν=0,50, γ=0,1/d	0,916	0,510	0,623	0,863	0,692 ± 0,107	387,3	3,0
	AE	IForest	z=2	0,492	0,690	0,559	0,896	0,590 ± 0,131	2186,2	259,4
	AE	LOF	z=2; k_{LOF}=50	0,626	0,760	0,662	0,920	0,706 ± 0,164	2186,2	3,5
	AE	OCSVM	z=2; ν=0,50, γ=0,1/d	0,645	0,590	0,580	0,901	0,671 ± 0,157	2186,2	2,6
	AE	Rekonstr.	z=8	0,334	0,600	0,405	0,815	0,446 ± 0,113	2812,9	0,5
Ionosphere	Oryg.	IForest	–	0,671	0,590	0,588	0,907	0,712 ± 0,112	0,0	227,9
	Oryg.	LOF	k_{LOF}=20	0,786	0,748	0,741	0,965	0,848 ± 0,131	0,0	1,6
	Oryg.	OCSVM	ν=0,05, γ=10,0/d	0,842	0,781	0,797	0,954	0,900 ± 0,089	0,0	2,0
	PCA	IForest	k=20	0,800	0,752	0,760	0,965	0,889 ± 0,087	1,3	209,1
	PCA	LOF	k=20; k_{LOF}=20	0,685	0,643	0,627	0,955	0,802 ± 0,123	1,3	1,6
	PCA	OCSVM	k=20; ν=0,05, γ=10,0/d	0,906	0,779	0,830	0,949	0,881 ± 0,080	1,3	2,2
	PCA	Rekonstr.	k=8	0,933	0,862	0,881	0,966	**0,926 ± 0,098**	1,1	0,2
	UMAP	IForest	m=5, nn=5, md=0,0	0,123	0,531	0,185	0,512	0,136 ± 0,046	131,8	218,8
	UMAP	LOF	m=10, nn=50, md=0,5; k_{LOF}=10	0,496	0,579	0,509	0,879	0,566 ± 0,189	276,4	1,9
	UMAP	OCSVM	m=10, nn=50, md=0,5; ν=0,50, γ=10,0/d	0,530	0,481	0,458	0,870	0,568 ± 0,197	276,4	2,3
	AE	IForest	z=8	0,268	0,338	0,230	0,715	0,289 ± 0,128	916,6	206,9
	AE	LOF	z=4; k_{LOF}=10	0,566	0,502	0,470	0,910	0,645 ± 0,216	1138,7	1,8
	AE	OCSVM	z=16; ν=0,50, γ=10,0/d	0,446	0,421	0,394	0,864	0,559 ± 0,189	927,6	1,6
	AE	Rekonstr.	z=16	0,906	0,814	0,841	0,975	0,924 ± 0,087	927,6	0,3
Parkinsons	Oryg.	IForest	–	0,123	0,325	0,172	0,566	0,176 ± 0,084	0,0	208,4
	Oryg.	LOF	k_{LOF}=5	0,198	0,475	0,257	0,635	0,274 ± 0,193	0,0	1,8
	Oryg.	OCSVM	ν=0,05, γ=0,1/d	0,248	0,350	0,272	0,740	0,370 ± 0,232	0,0	0,9
	PCA	IForest	k=2	0,234	0,350	0,254	0,673	0,278 ± 0,162	1,0	216,3
	PCA	LOF	k=2; k_{LOF}=5	0,169	0,325	0,148	0,565	0,184 ± 0,070	1,0	1,9
	PCA	OCSVM	k=5; ν=0,05, γ=0,1/d	0,208	0,350	0,250	0,730	0,362 ± 0,219	0,9	0,9
	PCA	Rekonstr.	k=1	0,292	0,300	0,222	0,609	0,293 ± 0,190	1,0	0,2
	UMAP	IForest	m=10, nn=5, md=0,5	0,211	0,325	0,200	0,655	0,244 ± 0,108	83,7	216,1
	UMAP	LOF	m=5, nn=15, md=0,0; k_{LOF}=50	0,256	0,325	0,215	0,673	0,298 ± 0,226	126,9	1,6
	UMAP	OCSVM	m=2, nn=15, md=0,5; ν=0,50, γ=0,1/d	0,481	0,300	0,303	0,609	0,335 ± 0,222	108,6	1,0
	AE	IForest	z=2	0,195	0,375	0,238	0,674	0,275 ± 0,171	692,8	210,0
	AE	LOF	z=2; k_{LOF}=50	0,175	0,375	0,228	0,620	0,272 ± 0,212	692,8	1,6
	AE	OCSVM	z=2; ν=0,05, γ=0,1/d	0,239	0,350	0,250	0,662	**0,372 ± 0,276**	692,8	1,0
	AE	Rekonstr.	z=16	0,115	0,500	0,164	0,588	0,243 ± 0,180	1305,3	0,4
Synthetic	Oryg.	IForest	–	0,735	0,436	0,507	0,889	0,626 ± 0,072	0,0	231,5
	Oryg.	LOF	k_{LOF}=35	0,814	0,864	0,831	0,991	**0,929 ± 0,036**	0,0	7,9
	Oryg.	OCSVM	ν=0,05, γ=1,0/d	0,785	0,624	0,666	0,959	0,818 ± 0,067	0,0	3,7
	PCA	IForest	k=20	1,000	0,680	0,806	0,853	0,753 ± 0,081	1,0	225,8

Zbiór	Repr.	Detektor	Konfiguracja	Prec.	Rec.	F1	ROC	PR-AUC	t_r [ms]	t_d [ms]
	PCA	LOF	k=20; k_{LOF}=20	0,839	0,840	0,832	0,990	0,927 ± 0,028	1,0	6,0
	PCA	OCSVM	k=20; ν=0,05, γ=1,0/d	0,763	0,584	0,624	0,945	0,778 ± 0,066	1,0	3,4
	PCA	Rekonstr.	k=5	1,000	0,684	0,809	0,807	0,738 ± 0,084	1,0	0,2
	UMAP	IForest	m=10, nn=15, md=0,0	0,220	0,284	0,227	0,629	0,219 ± 0,075	1015,4	224,8
	UMAP	LOF	m=2, nn=15, md=0,5; k_{LOF}=50	0,447	0,368	0,366	0,725	0,399 ± 0,085	906,9	4,6
	UMAP	OCSVM	m=2, nn=15, md=0,5; ν=0,50, γ=10,0/d	0,358	0,348	0,311	0,727	0,347 ± 0,066	906,9	9,0
	AE	IForest	z=16	0,731	0,384	0,470	0,816	0,538 ± 0,081	1772,1	216,1
	AE	LOF	z=8; k_{LOF}=35	0,867	0,624	0,722	0,845	0,739 ± 0,045	2100,3	8,5
	AE	OCSVM	z=16; ν=0,10, γ=1,0/d	0,705	0,484	0,528	0,778	0,581 ± 0,070	1772,1	3,8
	AE	Rekonstr.	z=4	0,892	0,688	0,767	0,911	0,783 ± 0,096	2067,4	0,5

4.2 PCA: liczba składowych, zachowana wariancja i jakość detekcji

Rysunek 2 pokazuje PR-AUC w funkcji liczby składowych k (parametry detektora wybierane na walidacji osobno dla każdego k) oraz zachowaną wariancję. Linie kropkowane to wyniki w danych oryginalnych.



Rysunek 2: PCA: PR-AUC (test) w zależności od liczby składowych (górny wiersz; linie kropkowane – ten sam detektor w danych oryginalnych) oraz zachowana wariancja (dolny wiersz; linia przerywana – 90 %).

Zależność między zachowaną wariancją a jakością detekcji *nie jest monotoniczna* i różni się między zbiorami:

- **Breast Cancer:** najlepsza jest jedna składowa ($k = 1$, 39 % wariancji): LOF 0,84, OCSVM 0,84, IForest 0,72. Pierwsza składowa odpowiada ogólnej „wielkości” jądra komórkowego (promień, obwód, pole są skorelowane niemal w 100 %), czyli właśnie temu, czym guzy złośliwe różnią się od łagodnych. Kolejne składowe dodają głównie zmienność wewnątrz klasy normalnej i szum, który rozmywa sąsiedztwa.
- **Ionosphere:** detektory wymagają dużego k (IForest przy $k \leq 3$: 0,18–0,29), ale błąd rekonstrukcji już przy $k = 3$ osiąga ok. 0,9 – anomalie leżą *poza* podprzestrzenią głównych składowych.
- **Zbiór syntetyczny:** LOF osiąga wynik danych oryginalnych (0,93) dopiero przy $k = 20$

(99 % wariancji), mimo że już $k = 5$ zachowuje 91 % wariancji.

Tabela 3 wyjaśnia ten ostatni przypadek, który jest modelowym przykładem **utraty informacji przy redukcji wymiaru**. Anomalie podprzestrzenne różnią się od danych normalnych wyłącznie w kierunkach o znikomej wariancji. Przy $k \leq 5$ rzut PCA usuwa dokładnie te kierunki i Recall anomalii podprzestrzennych dla LOF spada z 0,91 do 0,01 – mimo że „zachowano" 91 % wariancji. Kryterium zachowanej wariancji mierzy wierność odtworzenia *typowych* danych, a nie informację potrzebną do wykrycia *nietypowych*. Ta sama informacja nie ginie jednak, jeśli użyć błędu rekonstrukcji: przy $k = 5$ wykrywa on 100 % anomalii podprzestrzennych. Jednocześnie redukcja do $k = 5$ *poprawia* wykrywanie anomalii lokalnych przez LOF (0,66 → 0,84), bo usuwa 25 wymiarów szumu, które rozmywały różnice lokalnej gęstości. Redukcja wymiaru jest więc zawsze wymianą: usuwa szum, ale razem z nim informację o odchyleniach w kierunkach o małej wariancji.

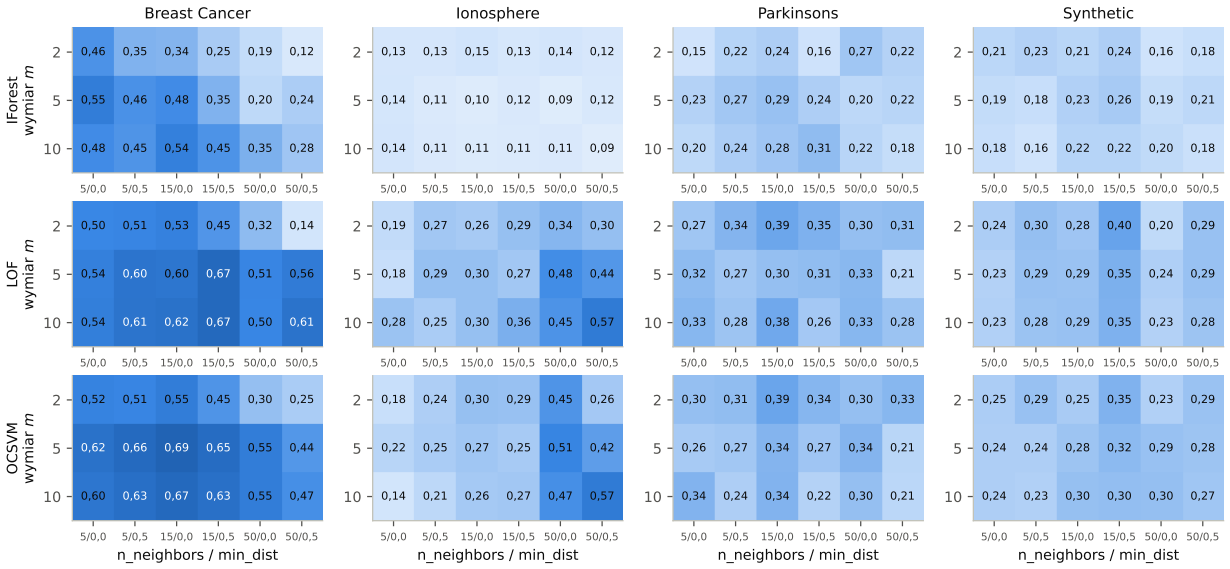
Tabela 3: Zbiór syntetyczny: Recall według typu anomalii i PR-AUC w zależności od liczby składowych PCA (część testowa, 10 podziałów). „Rekonstrukcja" – błąd rekonstrukcji PCA.

Detektor	k	zach. wariancja	PR-AUC	R globalne	R lokalne	R podprzestrzenne
LOF	oryg. (30)	1,00	0,929	1,000	0,660	0,910
	2	0,68	0,608	0,758	0,764	0,000
	3	0,80	0,712	0,881	0,766	0,013
	5	0,91	0,769	1,000	0,844	0,013
	10	0,95	0,868	1,000	0,813	0,468
	20	0,99	0,927	1,000	0,622	0,882
IForest	oryg. (30)	1,00	0,626	1,000	0,013	0,220
	2	0,68	0,448	0,773	0,306	0,151
	3	0,80	0,494	0,861	0,198	0,102
	5	0,91	0,589	0,970	0,000	0,171
	10	0,95	0,735	1,000	0,000	0,651
	20	0,99	0,753	1,000	0,000	0,986
Rekonstrukcja	2	0,68	0,635	0,960	0,000	0,387
	3	0,80	0,689	1,000	0,000	0,711
	5	0,91	0,738	1,000	0,000	1,000
	10	0,95	0,749	1,000	0,000	0,983
	20	0,99	0,738	1,000	0,000	0,958

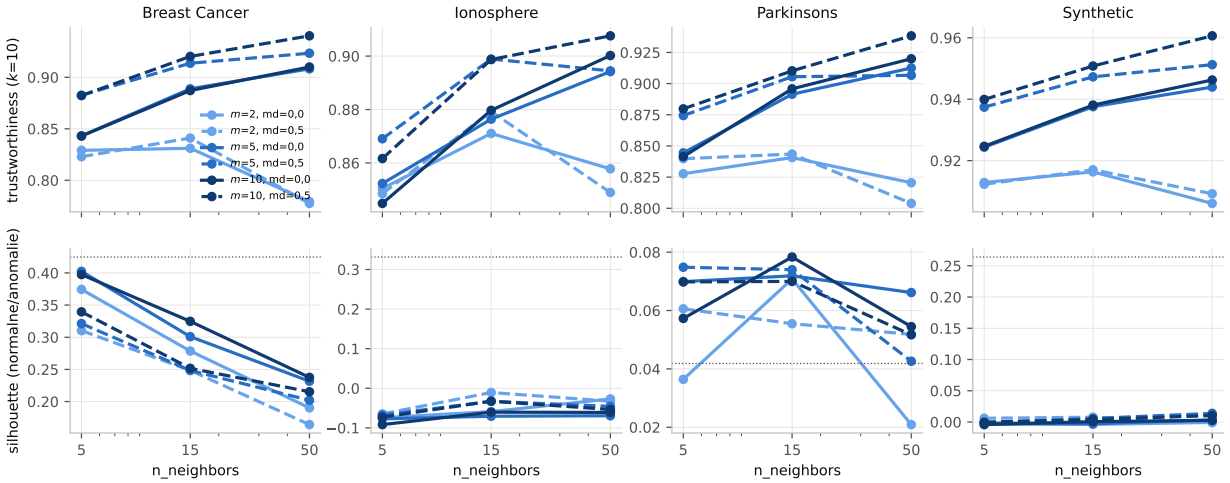
Ciekawym efektem jest poprawa Isolation Forest po PCA (syntetyczny 0,63 → 0,75, Ionosphere 0,71 → 0,89). PCA przy $k = 20$ niemal nie redukuje informacji, ale *obraca* układ współrzędnych do osi głównych. Isolation Forest wykonuje cięcia równoległe do osi. W danych oryginalnych odchylenie anomalii podprzestrzennej rozkłada się na wszystkie 30 cech i w każdej z nich ginie wśród dużej zmienności wzdłuż podprzestrzeni. Po obrocie trafia ono w składowe o małej wariancji, gdzie pojedyncze cięcie łatwo je izoluje (Recall podprzestrzennych 0,22 → 0,99). Dla LOF i OCSVM, które opierają się na odległościach euklidesowych niezmienniczych względem obrotu, ten efekt nie występuje.

4.3 UMAP: wpływ parametrów i struktura przestrzeni

Rysunek 3 przedstawia PR-AUC dla wszystkich 18 wariantów UMAP, a rys. 4 – jakość zachowania sąsiedztw (trustworthiness) i separację klas (silhouette).



Rysunek 3: UMAP: PR-AUC (test) w zależności od wymiaru m, `n_neighbors` i `min_dist` dla trzech detektorów (parametry detektora wybrane na walidacji).

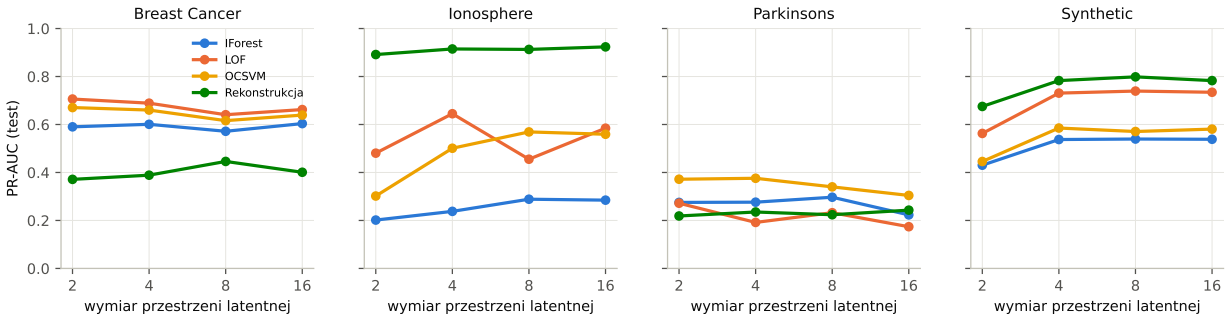


Rysunek 4: UMAP: trustworthiness (górny wiersz) i silhouette podziału normalne/anomalie (dolny wiersz, linia kropkowana – dane oryginalne) w funkcji `n_neighbors`; linie ciągłe – `min_dist`=0, przerywane – 0,5; odcień – wymiar m.

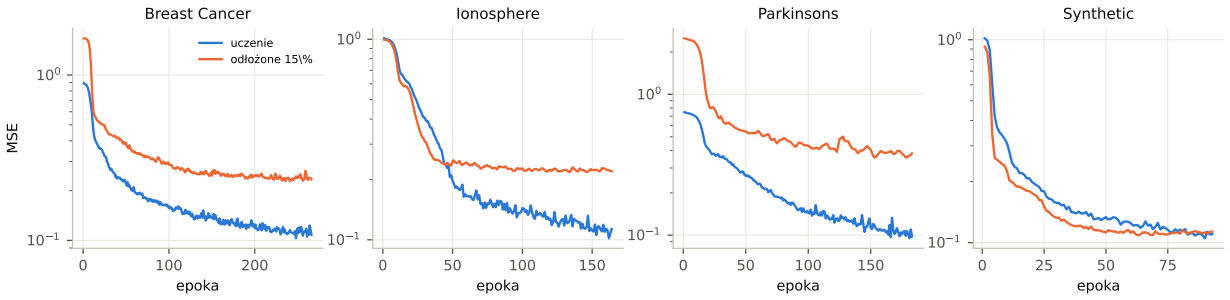
- **Wymiar m:** większy wymiar zwykle pomaga (Breast Cancer, LOF: najlepiej 0,53 dla $m = 2$ wobec 0,67 dla $m = 10$) i zwiększa trustworthiness. Wymiar 2 jest dobry do wizualizacji, ale za mały do detekcji.
- **`n_neighbors`:** większe wartości podnoszą trustworthiness (UMAP uwzględnia szerszy kontekst) i zwykle PR-AUC LOF i OCSVM (Ionosphere, LOF: 0,18–0,29 dla nn=5 wobec 0,30–0,57 dla nn=50), bo przy małym `n_neighbors` graf rozpada się na drobne, lokalne składowe. Silhouette maleje jednak ze wzrostem `n_neighbors` (Breast Cancer: 0,40 → 0,17–0,24).
- **`min_dist`:** `min_dist`=0 upakowuje punkty ciasno w skupiska i daje ładniejsze wizualnie klastry, ale nie poprawia detekcji; `min_dist`=0,5 zachowuje więcej informacji o rozproszeniu (wyższe PR-AUC LOF na Ionosphere: 0,57 wobec 0,36 przy nn=50, $m = 10$).

Dlaczego UMAP szkodzi detekcji? UMAP z konstrukcji *normalizuje lokalną gęstość*: odległości do sąsiadów każdego punktu są skalowane względem odległości do jego najbliższego sąsiada (ρ_i, σ_i), aby każdy punkt miał „tyle samo" połączeń. Punkt odosobniony zostaje przez to sztucznie „dociągnięty" do najbliższego skupiska, a mała grupa anomalii staje się zwartym, gęstym klastrem (rys. 7, Ionosphere i Breast Cancer). Detektory gęstościowe (LOF) i izolacyjne (IForest) widzą wtedy anomalie jako normalne skupisko. Dodatkowo `transform` dla nowych punktów umieszcza je w pobliżu ich sąsiadów z części uczącej, co dodatkowo „wciąga" anomalie do skupisk. Informacja o *skali* odchylenia, kluczowa dla wyjątków globalnych, jest tracona: Recall anomalii globalnych zbioru syntetycznego spada z 1,00 do 0,40–0,53 (tabela 5). UMAP jest narzędziem do wizualizacji struktury klastrowej, a nie reprezentacją zachowującą informację o odstawaniu.

4.4 Autoenkoder: wymiar latentny i architektura



Rysunek 5: Autoenkoder: PR-AUC (test) detektorów w przestrzeni latentnej i błędu rekonstrukcji w zależności od wymiaru latentnego.



Rysunek 6: Krzywe uczenia autoenkodera ($z = 8$, podział 0): błąd na części uczącej i na 15 % odłożonych do wczesnego zatrzymania.

Wpływ wymiaru latentnego (rys. 5) jest umiarkowany i zależy od zbioru. Na zbiorze syntetycznym błąd rekonstrukcji poprawia się od $z = 2$ (0,67) do $z \geq 4$ (0,78–0,80), czyli gdy wymiar latentny osiąga prawdziwy wymiar podprzestrzeni danych (4). Mniejsze z nie pozwala odtworzyć nawet danych normalnych, a większe nie szkodzi dzięki regularyzacji. Na Ionosphere błąd rekonstrukcji jest wysoki (0,89–0,92) dla każdego z. Detektory w przestrzeni latentnej są zwykle słabsze niż w danych oryginalnych, bo koder jest uczony do rekonstrukcji, a nie do zachowania odległości. Przestrzeń latentna nie ma więc dobrze określonej metryki i sąsiedztwa mogą być w niej dowolnie zniekształcone.

Krzywe uczenia (rys. 6) pokazują, że wczesne zatrzymanie działa: błąd na danych odłożonych przestaje maleć po 100–290 epokach, a różnica między błędem uczącym i odłożonym pozostaje niewielka. Porównanie architektur (tabela 4) pokazuje, że wybór architektury ma znacznie mniejszy wpływ niż wybór zbioru i sposobu użycia autoenkodera. Różnice PR-AUC błędu rekonstrukcji między wariantami nie przekraczają 0,055 i mieszczą się w rozrzucie między podziałami.

Architektura d-64-32-z jest rozsądnym kompromisem: daje najlepszy błąd rekonstrukcji na dwóch zbiorach i umiarkowany czas uczenia.

Tabela 4: Porównanie architektur autoenkodera przy $z = 8$ (część testowa, 10 podziałów): PR-AUC błędu rekonstrukcji, PR-AUC najlepszego (wg walidacji) detektora w przestrzeni latentnej, średnia liczba epok do wczesnego zatrzymania i czas uczenia.

Zbiór	Architektura	PR-AUC rekonstr.	PR-AUC detektor w z	Epoki	Czas uczenia [s]
Breast Cancer	d-32-8	0,391	0,682 (LOF)	327	2,47
	d-64-32-8	0,446	0,641 (LOF)	241	2,81
	d-128-64-8	0,407	0,640 (LOF)	164	2,02
Ionosphere	d-32-8	0,919	0,714 (OCSVM)	238	1,09
	d-64-32-8	0,913	0,569 (OCSVM)	143	0,92
	d-128-64-8	0,920	0,737 (OCSVM)	181	1,23
Parkinsons	d-32-8	0,224	0,326 (OCSVM)	377	1,34
	d-64-32-8	0,224	0,340 (OCSVM)	290	1,36
	d-128-64-8	0,239	0,330 (OCSVM)	259	1,34
Synthetic	d-32-8	0,790	0,778 (LOF)	230	3,26
	d-64-32-8	0,799	0,739 (LOF)	104	2,10
	d-128-64-8	0,780	0,746 (LOF)	73	1,60

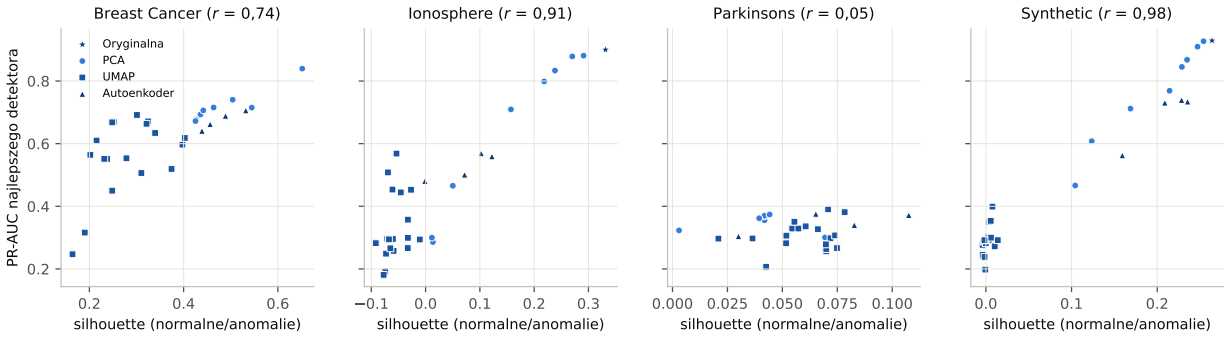
Ważnym ograniczeniem jest uczenie autoenkodera na danych zanieczyszczonych anomaliami. Na Breast Cancer guzy złośliwe tworzą spójne skupisko (ok. 20 obserwacji w części uczącej), które sieć nauczyła się odtwarzać. Błąd rekonstrukcji anomalii nie jest wtedy większy niż obserwacji normalnych (PR-AUC 0,45). Na Ionosphere anomalie są rozproszone i „niepodobne do siebie", więc sieć nie jest w stanie ich zapamiętać i błąd rekonstrukcji działa bardzo dobrze. Rekonstrukcja wykrywa więc anomalie *niepowtarzalne*, a nie skupione.

4.5 Wizualizacje 2D i separacja a jakość detekcji

Rysunek 7 przedstawia dwuwymiarowe reprezentacje części testowej, a rys. 8 – zależność między separacją klas (silhouette) a PR-AUC najlepszego detektora dla wszystkich wariantów reprezentacji.



Rysunek 7: Dwuwymiarowe reprezentacje części testowej (podział 0): PCA ($k = 2$), UMAP ($m = 2$, `n_neighbors`=15, `min_dist`=0) i przestrzeń latentna autoenkodera ($z = 2$).



Rysunek 8: Separacja klas w reprezentacji (silhouette, część testowa) a PR-AUC najlepszego detektora (wg walidacji) dla wszystkich wariantów reprezentacji; r – współczynnik korelacji Pearsona.

Wizualizacje 2D mogą być mylące. UMAP daje najbardziej „czytelne" obrazy: w Ionosphere i Breast Cancer anomalie tworzą wyraźnie oddzielone, zwarte skupisko, a w zbiorze syntetycznym trzy klastry są idealnie rozdzielone. Te same reprezentacje dają jednak najgorszą detekcję. Gdy anomalie tworzą własny gęsty klaster, nie są już *wyjątkami* w sensie żadnego detektora nienadzorowanego, który nie zna etykiet. Widoczna na wykresie „separacja" wymaga wiedzy, które punkty są anomaliami, a detektor jej nie ma. W zbiorze syntetycznym UMAP wciąga anomalie lokalne i podprzestrzenne do skupisk i obraz 2D w ogóle ich nie pokazuje. Rzut PCA na 2 składowe także je ukrywa, choć z innego powodu (utrata składowych o małej wariancji).
Liczbowa miara separacji (silhouette) koreluje z jakością detekcji silnie na zbiorze syntetycznym ($r = 0{,}98$) i Ionosphere ($r = 0{,}91$), umiarkowanie na Breast Cancer ($r = 0{,}74$) i wcale na Parkinsons ($r = 0{,}05$). Silhouette liczona w pełnej reprezentacji jest więc dużo lepszym wskaźnikiem niż wrażenie wizualne z rzutu 2D. Także ona mierzy jednak rozdzielenie *grup*, a nie odstawanie pojedynczych punktów – stąd rozbieżności na Breast Cancer, gdzie anomalie tworzą skupisko.

4.6 Typy anomalii w reprezentacjach

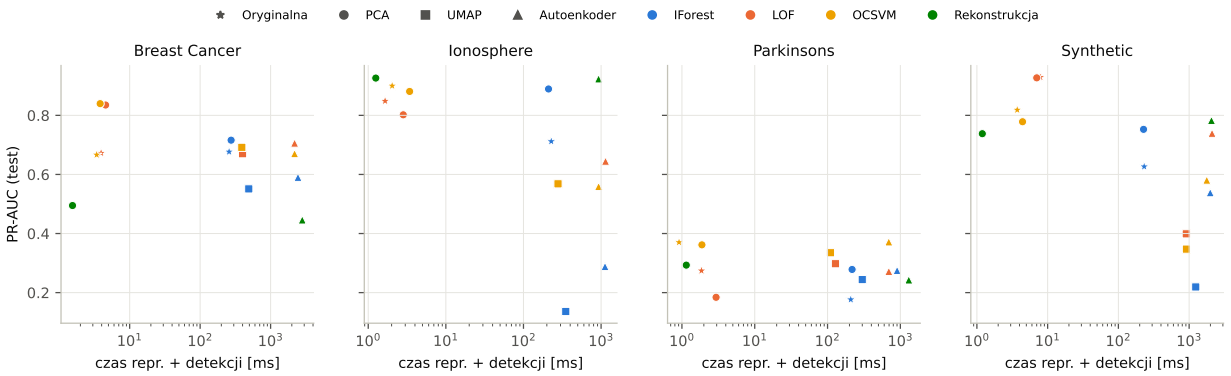
Tabela 5: Zbiór syntetyczny: Recall według typu anomalii dla konfiguracji wybranych na walidacji (część testowa, 10 podziałów).

Reprezentacja	Detektor	globalne	lokalne	podprzestrzenne	PR-AUC
Oryginalna	IForest	1,000	0,013	0,220	0,626
	LOF	1,000	0,660	0,910	0,929
	OCSVM	1,000	0,185	0,626	0,818
PCA	IForest	1,000	0,000	0,986	0,753
	LOF	1,000	0,622	0,882	0,927
	OCSVM	1,000	0,207	0,520	0,778
	Rekonstrukcja	1,000	0,000	1,000	0,738
UMAP	IForest	0,403	0,362	0,087	0,219
	LOF	0,443	0,581	0,051	0,399
	OCSVM	0,532	0,410	0,076	0,347
Autoenkoder	IForest	0,952	0,037	0,070	0,538
	LOF	0,971	0,816	0,034	0,739
	OCSVM	0,980	0,285	0,107	0,581
	Rekonstrukcja	1,000	0,050	0,953	0,783

Tabela 5 pokazuje, która reprezentacja zachowuje jaki rodzaj informacji. Anomalie globalne są wykrywane w każdej reprezentacji poza UMAP. Anomalie lokalne wykrywa przede wszystkim LOF, najlepiej w przestrzeni latentnej autoenkodera (0,82) – autoenkoder usuwa szum spoza

podprzestrzeni, co wyostrza różnice gęstości przy gęstym skupisku. Anomalie podprzestrzenne wykrywają błąd rekonstrukcji PCA (1,00) i autoenkodera (0,95), Isolation Forest po obrocie PCA (0,99) oraz LOF w danych oryginalnych (0,91), ale już nie LOF w przestrzeni latentnej (0,03), bo koder rzutuje je na podprzestrzeń danych. Żadna pojedyncza para reprezentacja–detektor nie wykrywa dobrze wszystkich trzech typów. To ważna przesłanka do łączenia detektorów (zadanie 3).

4.7 Kompromis jakość – wymiar – czas



Rysunek 9: Łączny czas przygotowania reprezentacji i detekcji a PR-AUC dla konfiguracji wybranych na walidacji (kształt – reprezentacja, kolor – detektor).

Koszty reprezentacji różnią się o trzy rzędy wielkości (rys. 9): PCA kosztuje ok. 1 ms, UMAP 0,1–1 s (dopasowanie 0,09–0,61 s i transformacja 0,04–0,40 s), a autoenkoder 1–2,4 s uczenia. Czas detekcji zależy przede wszystkim od detektora (IForest z 200 drzewami ok. 230 ms, LOF i OCSVM 2–5 ms) i tylko nieznacznie od wymiaru reprezentacji, bo przy kilkuset obserwacjach dominują narzuty stałe. Najkorzystniejszy kompromis dają: **PCA z LOF/OCSVM** (kilka ms, najlepsze wyniki na Breast Cancer) oraz **błąd rekonstrukcji PCA** (ok. 1 ms, najlepszy wynik na Ionosphere). Autoenkoder jest ok. 1000 razy droższy od PCA przy podobnej lub gorszej jakości. Jego przewaga mogłaby się ujawnić dopiero przy silnie nieliniowej strukturze danych i większej liczbie obserwacji. UMAP jest drogi i szkodliwy dla detekcji.

4.8 Porównanie z zadaniem 1

Tabela 6: PR-AUC (test) detektorów: najlepsza konfiguracja z zadania 1 (dane oryginalne, szersza siatka) oraz najlepsze konfiguracje w poszczególnych reprezentacjach (zadanie 2). Zysk – różnica między najlepszą reprezentacją a zadaniem 1.

Zbiór	Detektor	Zad. 1	Oryginalna	PCA	UMAP	Autoenkoder	Najlepsza repr.	Zysk
Breast Cancer	IForest	0,684	0,677	0,716	0,551	0,590	PCA	+0,032
	LOF	0,672	0,672	0,835	0,670	0,706	PCA	+0,163
	OCSVM	0,710	0,666	0,840	0,692	0,671	PCA	+0,130
Ionosphere	IForest	0,699	0,712	0,889	0,136	0,289	PCA	+0,190
	LOF	0,848	0,848	0,802	0,566	0,645	Oryginalna	+0,000
	OCSVM	0,900	0,900	0,881	0,568	0,559	Oryginalna	+0,000
Parkinsons	IForest	0,176	0,176	0,278	0,244	0,275	PCA	+0,102
	LOF	0,274	0,274	0,184	0,298	0,272	UMAP	+0,024
	OCSVM	0,380	0,370	0,362	0,335	0,372	Autoenkoder	-0,008
Synthetic	IForest	0,635	0,626	0,753	0,219	0,538	PCA	+0,118
	LOF	0,929	0,929	0,927	0,399	0,739	Oryginalna	+0,000
	OCSVM	0,818	0,818	0,778	0,347	0,581	Oryginalna	+0,000

Wyniki w danych oryginalnych są zgodne z zadaniem 1 (tabela 6). Dla LOF i OCSVM wybrano w większości te same konfiguracje, a niewielkie różnice wynikają z węższej siatki w zadaniu 2 (tylko jądro RBF w OCSVM – na Parkinsons w zadaniu 1 wybrano jądro wielomianowe – oraz stałe 200 drzew w IForest). Zmiana reprezentacji poprawiła najlepszy wynik z zadania 1 dla 7 z 12 par zbiór–detektor, ale istotnie (o ponad 0,1 PR-AUC) tylko w pięciu: IForest na Ionosphere (+0,19), Parkinsons (+0,10) i zbiorze syntetycznym (+0,12) oraz LOF i OCSVM na Breast Cancer (+0,16 i +0,13). We wszystkich tych przypadkach najlepszą reprezentacją było PCA. Dla najlepszych detektorów z zadania 1 (OCSVM na Ionosphere, LOF na zbiorze syntetycznym) dane oryginalne pozostają najlepsze. Najbardziej na zmianie reprezentacji zyskuje najsłabszy w zadaniu 1 detektor (Isolation Forest), bo PCA kompensuje jego słabość – cięcia równoległe do osi w danych o skorelowanych cechach. Najlepszy wynik na zbiorze uzyskano w zadaniu 2 tylko dla Breast Cancer (0,84 wobec 0,71) i Ionosphere (rekonstrukcja PCA 0,93 wobec 0,90).

5 Odpowiedzi na pytania analityczne

a) Czy redukcja wymiarowości zawsze poprawia skuteczność detekcji? Nie. W porównaniu z danymi oryginalnymi PCA poprawiło wyniki w 6 z 12 par zbiór–detektor (we wszystkich czterech dla IForest), UMAP – w trzech (IForest i LOF na Parkinsons, OCSVM na Breast Cancer; poza IForest na Parkinsons o mniej niż 0,03, czyli w granicach szumu), a przestrzeń latentna autoenkodera – w czterech, ale o więcej niż 0,03 tylko w dwóch (IForest na Parkinsons +0,10, LOF na Breast Cancer +0,03). Redukcja pomaga, gdy informacja odróżniająca anomalie leży w kierunkach o dużej wariancji, a pozostałe wymiary niosą głównie szum (Breast Cancer: $k = 1$). Szkodzi, gdy anomalie odchylają się w kierunkach o małej wariancji (anomalie podprzestrzenne: Recall 0,91 $\rightarrow$ 0,01 przy 91 % zachowanej wariancji) albo gdy metoda redukcji zmienia geometrię (UMAP).

b) Czy anomalie pozostają odseparowane od normalnych w przestrzeni zredukowanej? Zależy to od reprezentacji i typu anomalii. Anomalie globalne pozostają odseparowane w PCA i autoenkoderze. Anomalie podprzestrzenne znikają w każdej reprezentacji niskowymiarowej, choć pozostają widoczne w jej błędzie rekonstrukcji. UMAP przesuwa anomalie do skupisk (silhouette syntetyczny 0,26 $\rightarrow$ 0,00, Ionosphere 0,33 $\rightarrow -0{,}06$). Na Parkinsons anomalie nie są odseparowane w żadnej przestrzeni (silhouette $< 0{,}08$).

c) Która reprezentacja jest najbardziej użyteczna dla poszczególnych detektorów? Isolation Forest: **PCA** (najlepsze na wszystkich 4 zbiorach, obrót do osi głównych). LOF: **dane oryginalne** lub **PCA z umiarkowanym** k (Breast Cancer). LOF jest wrażliwy na szum wymiarów, ale też na utratę kierunków o małej wariancji. OCSVM: **dane oryginalne** lub **PCA**; granica jądrowa w pełnej przestrzeni działa dobrze, gdy γ jest dobrane do wymiaru. Błąd rekonstrukcji (PCA lub autoenkoder) to osobny, komplementarny detektor – najlepszy, gdy anomalie są rozproszone i leżą poza podprzestrzenią danych.

d) Czy najlepsza wizualnie separacja odpowiada najwyższej jakości detekcji? Nie. Najczytelniejsze wizualnie reprezentacje (UMAP 2D) dają najgorszą detekcję, bo zamieniają anomalie w zwarte skupiska. Liczbowa separacja w pełnej reprezentacji (silhouette) koreluje z jakością detekcji (r do 0,98), ale nie zawsze (Parkinsons $r = 0{,}05$, Breast Cancer $r = 0{,}74$).

e) Jaki jest kompromis między jakością wyników a kosztem obliczeniowym? Najlepszy stosunek jakości do kosztu ma PCA (ok. 1 ms, często poprawa wyników). UMAP i autoenkoder kosztują 100–1000 razy więcej i w badanych danych nie dają lepszych wyników niż PCA. Większy wymiar reprezentacji nie zwiększa istotnie kosztu detekcji przy tej skali danych, a często poprawia jakość (UMAP $m = 10$, PCA $k = 20$). Nie należy więc redukować wymiaru „na zapas”.

Koszt detekcji determinuje wybór detektora (IForest ok. 60 razy wolniejszy od LOF przy tych rozmiarach).

6 Rekomendacje i dyskusja

Dlaczego reprezentacja poprawia lub pogarsza wyniki? Mechanizm jest wspólny: detektor ocenia odstawanie w pewnej metryce (odległość, gęstość, łatwość izolacji). Reprezentacja zmienia tę metrykę.

- Poprawa następuje, gdy reprezentacja (1) usuwa wymiary szumu, które rozmywały odległości (PCA na Breast Cancer, LOF dla anomalii lokalnych), albo (2) dopasowuje geometrię do mechanizmu detektora (obrót PCA dla cięć osiowych IForest).
- Pogorszenie następuje, gdy reprezentacja (1) usuwa kierunki, w których anomalie się odchylają (PCA z małym k, przestrzeń latentna dla anomalii podprzestrzennych), albo (2) celowo zniekształca gęstość (UMAP).

Rekomendacje.

1. **Isolation Forest** – stosować na składowych PCA z dużym k (prawie bez redukcji, ale z obrotem do osi głównych).
2. **LOF** – dane oryginalne. Redukcja PCA tylko wtedy, gdy walidacja wskazuje, że wiele cech to szum; nie schodzić poniżej $\approx$ 95–99 % wariancji, jeśli możliwe są anomalie w kierunkach o małej wariancji.
3. **OCSVM** – dane oryginalne lub PCA z umiarkowanym k, zawsze z γ dobranym do wymiaru reprezentacji.
4. **Zawsze** sprawdzić błąd rekonstrukcji PCA jako tani, komplementarny detektor anomalii „poza strukturą danych".
5. **UMAP** – tylko do wizualizacji, nie jako wejście detektora.
6. **Autoenkoder** – przy małych zbiorach nie uzasadnia swojego kosztu. Gdy jest używany, wynikiem powinien być błąd rekonstrukcji, a nie odległości w przestrzeni latentnej. Należy pamiętać, że uczony na danych zanieczyszczonych może „nauczyć się" skupisk anomalii.

Ograniczenia. Zbiory są małe (80–500 obserwacji uczących), co sprzyja PCA, a ogranicza autoenkoder i UMAP. Wybór spośród wielu wariantów reprezentacji na małej walidacji grozi przeuczeniem wyboru (UMAP na Parkinsons: PR-AUC 0,50 na walidacji, 0,30 na teście). Zbadano tylko jedną rodzinę architektur autoenkodera (MLP) i uczenie na danych zanieczyszczonych. Wariant uczenia tylko na danych normalnych (scenariusz półnadzorowany) zmieniłby wyniki rekonstrukcji. Trustworthiness i silhouette liczono na części testowej o 40–250 obserwacjach.

Kierunki dalszych badań. Odporne PCA (np. Robust PCA) mniej wrażliwe na anomalie w części uczącej, autoenkodery uczone na danych oczyszczonych przez inny detektor, łączenie wyników detektorów z różnych reprezentacji (zadanie 3) oraz ocena na większych zbiorach, na których metody nieliniowe mają szansę się wykazać.

7 Wnioski

1. Reprezentacja danych ma duży wpływ na detekcję: rozrzut PR-AUC jednego detektora między reprezentacjami sięga 0,75 (IForest na Ionosphere: 0,14 w UMAP wobec 0,89 w PCA). Wpływ ten jest jednak przede wszystkim *negatywny* – łatwo go pogorszyć, trudno istotnie poprawić najlepszy wynik z danych oryginalnych.

2. PCA jest najbardziej użyteczną reprezentacją: tanią, często poprawiającą wyniki (szczególnie IForest), a jej błąd rekonstrukcji jest osobnym, wartościowym detektorem (najlepszy wynik na Ionosphere: 0,93).
3. Zachowana wariancja nie jest dobrym kryterium wyboru liczby składowych dla detekcji: 91 % wariancji może oznaczać utratę 99 % informacji o anomaliach podprzestrzennych.
4. UMAP pogarsza detekcję, bo normalizuje lokalną gęstość i zamienia grupy anomalii w zwarte skupiska – najlepsza wizualnie separacja nie oznacza najlepszej detekcji.
5. Żadna para reprezentacja–detektor nie wykrywa wszystkich typów anomalii, co uzasadnia łączenie komplementarnych detektorów w zadaniu 3.

8 Odtworzenie wyników

```
python -m task2_representations.run       # ok. 15 min, 3 procesy (N_JOBS)
python -m task2_representations.analyze   # tabele i rysunki
```