Politechnika Łódzka
Wydział Fizyki Technicznej, Informatyki i Matematyki Stosowanej

Analiza danych złożonych z detekcją wyjątków

Zadanie 2

Detekcja wyjątków w danych wielowymiarowych:
wpływ reprezentacji danych

Jędrzej Kostyk
nr indeksu 264339

Jędrzej Małaczyński
nr indeksu 264351

Rok akademicki 2026/2027

Spis treści

1 Cel i zakres **2**

2 Dane **2**

2.1 Zbiory danych 2

3 Protokół eksperymentalny **3**

4 Reprezentacje i detektory **4**

5 Wyniki **6**

5.1 Przegląd: wszystkie reprezentacje i detektory 6

5.2 Dane oryginalne (punkt odniesienia) 8

5.3 PCA 9

5.4 UMAP 12

5.5 Autoenkoder 14

5.6 Co wykryto: porównanie reprezentacji 17

5.7 Wizualizacje 2D i separacja klas 18

5.8 Anomalie globalne i lokalne 21

5.9 Jakość a czas działania 22

5.10 Porównanie z zadaniem 1 23

6 Odpowiedzi na pytania analityczne **23**

7 Ograniczenia i dalsze badania **24**

8 Wnioski **24**

A Wyniki wszystkich konfiguracji **25**

1 Cel i zakres

Celem zadania jest sprawdzenie, czy detektor wyjątków działa lepiej, gdy zamiast surowych cech dostanie inną *reprezentację* danych, czyli te same obserwacje opisane innym zestawem liczb. Porównano cztery reprezentacje: dane oryginalne, PCA, UMAP i przestrzeń ukrytą autoenkodera. W każdej z nich uruchomiono te same trzy detektory z zadania 1 – Isolation Forest, LOF i One-Class SVM. PCA i autoenkoder dają też własny wynik anomalii (błąd rekonstrukcji), który oceniono jako czwarty detektor.

Eksperymenty przeprowadzono na czterech zbiorach danych o 21–274 cechach. Dla każdej reprezentacji zbadano jej parametry (np. liczbę składowych PCA), co daje do 33 wariantów reprezentacji i 15 ustawień detektorów na każdy podział danych. Cały kod znajduje się w katalogach `common/` i `task2_representations/` repozytorium.

2 Dane

W tej sekcji przedstawiono cztery zbiory danych użyte w zadaniu 2 (te same zbiory wykorzystuje zadanie 3).

2.1 Zbiory danych

Zadanie wymaga danych z wieloma cechami, dlatego wybrano cztery gotowe zbiory z benchmarków ADBench i ODDS (tabela 1). Etykiety anomalii pochodzą od autorów benchmarków; zbiory nie były w żaden sposób zmieniane. Cardio występuje też w zadaniu 1, co pozwala porównać oba zadania.

Tabela 1: Zbiory danych użyte w zadaniu.

Zbiór danych	Źródło	Co zawiera	Obserwacje	Cechy	Anomalie
Cardio	ADBench	zapisy KTG płodu; anomalia = zapis patologiczny	1 831	21	176 (9,6 %)
Arrhythmia	ODDS	zapisy EKG; anomalia = rzadki typ arytmii	452	274	66 (14,6 %)
WDBC	ADBench	pomiary jąder komórkowych guzów; anomalia = guz złośliwy	367	30	10 (2,7 %)
Campaign	ADBench	kontakty banku z klientami; anomalia = klient założył lokatę	41 188	62	4 640 (11,3 %)

Zbiory różnią się tym, co utrudnia detekcję:

- **Arrhythmia** ma więcej cech (274) niż obserwacji uczących (226), a 17 cech jest stałych;
- **WDBC** ma tylko 10 anomalii, więc w części testowej są 2–3;
- **Campaign** jest duży (41 tys. obserwacji), a część cech to zakodowane kategorie (np. zawód klienta zapisany jako kilka kolumn 0/1).

Tabela 2 pokazuje po jednej obserwacji normalnej i jednej anomalii z każdego zbioru danych. Benchmarki udostępniają cechy bez nazw, dlatego oznaczono je numerami.

Tabela 2: Przykładowe obserwacje (pierwsze pięć cech; „…” – pozostałe cechy).

Cardio

cecha 1	cecha 2	cecha 3	cecha 4	cecha 5	…	Anomalia
0,00	0,69	−0,20	0,60	0,35	…	nie
0,22	−0,65	−0,20	2,03	2,39	…	tak

Arrhythmia

cecha 1	cecha 2	cecha 3	cecha 4	cecha 5	…	Anomalia
56	1	165	64	81	…	nie
75	0	190	80	91	…	tak

WDBC

cecha 1	cecha 2	cecha 3	cecha 4	cecha 5	…	Anomalia
13,54	14,36	87,46	566,30	0,10	…	nie
15,30	25,27	102,40	732,40	0,11	…	tak

Campaign

cecha 1	cecha 2	cecha 3	cecha 4	cecha 5	…	Anomalia
0,21	0	0	0	0	…	nie
0,53	0	0	0	1	…	tak

3 Protokół eksperymentalny

Ta sekcja opisuje, jak przygotowano eksperyment, żeby wyniki były uczciwe i porównywalne z zadaniem 1. Protokół jest taki sam jak w zadaniu 1; nowa jest tylko reprezentacja, która też uczy się wyłącznie na części uczącej.

Podział na trzy części. Każdy zbiór danych dzielimy losowo na część uczącą (50 %), walidacyjną (25 %) i testową (25 %), z takim samym udziałem anomalii w każdej części. Przykład: Arrhythmia ma 452 obserwacje, więc 226 trafia do uczenia, 113 do walidacji i 113 do testu.

- **uczenie** – na nim powstaje reprezentacja (np. osie PCA) i uczy się detektor, *bez* informacji, które obserwacje są anomaliami;
- **walidacja** – na niej wybieramy parametry reprezentacji, ustawienia detektora i próg decyzji;
- **test** – oceniamy na nim wynik tylko raz, na końcu.

Skalowanie i reprezentacja tylko z części uczącej. Każdą cechę standaryzujemy (odejmujemy średnią i dzielimy przez odchylenie standardowe), licząc średnią i odchylenie tylko na części uczącej. Tak samo reprezentacja: np. osie PCA wyznaczamy z 226 obserwacji uczących Arrhythmii, a potem tymi samymi osiami przekształcamy walidację i test. Na koniec każdą reprezentację mnożymy przez jedną liczbę, tak by jej współrzędne miały średnio taki sam rozrzut jak w danych oryginalnych. Nie zmienia to kształtu danych, ale sprawia, że parametr detektora (np. szerokość jądra OCSVM) znaczy to samo w każdej reprezentacji.

Ziarno losowe i wiele podziałów. *Ziarno* to liczba startowa generatora losowego: to samo ziarno daje zawsze ten sam podział. Jeden podział to loteria – WDBC ma w teście 2–3 anomalie, więc jedno trafienie zmienia wynik o kilkadziesiąt punktów procentowych. Dlatego Cardio i Arrhythmię dzielimy 10 razy, WDBC 30 razy, a Campaign 5 razy (koszt obliczeń, niżej).

Raportujemy średnią i odchylenie standardowe po podziałach. Te same ziarna dają te same podziały w zadaniach 1–3.

Wybór ustawień i progu. Detektor daje każdej obserwacji *wynik anomalii* – liczbę tym większą, im bardziej obserwacja jest podejrzana. Parametry reprezentacji i detektora wybieramy razem: to połączenie, które ma najwyższą średnią PR-AUC na walidacji. Następnie na walidacji wybieramy próg wyniku, który daje najwyższe F1.

Miary jakości. Te same co w zadaniu 1:

- **Precision** – ile zgłoszonych obserwacji to naprawdę anomalie;
- **Recall** – ile prawdziwych anomalii wykryto;
- **F1** – jedna liczba łącząca Precision i Recall, wysoka tylko wtedy, gdy obie są wysokie;
- **ROC-AUC** – szansa, że losowa anomalia dostanie wyższy wynik niż losowa obserwacja normalna (0,5 = zgadywanie);
- **PR-AUC** – jak wysoko na liście najbardziej podejrzanych obserwacji są anomalie (od 0 do 1; zgadywanie daje wynik równy udziałowi anomalii, np. 0,10 dla Cardio). To główna miara porównań.

Mierzono też czas: przygotowania reprezentacji oraz uczenia i oceny detektora.

Ograniczenie obliczeń dla Campaign. Campaign ma 20 594 obserwacje uczące, a jeden model OCSVM uczy się na nich ok. 40 s, UMAP 25–40 s, a autoenkoder kilkadziesiąt sekund. Dlatego dla tego zbioru, **bez zmniejszania danych**, użyto 5 zamiast 10 podziałów, 6 zamiast 18 wariantów UMAP i OCSVM bez $\nu = 0{,}5$. Miary struktury reprezentacji (sekcja 4) liczono na stałym losowym podzbiorze 2000 punktów testowych; detekcję oceniano zawsze na całej części testowej.

4 Reprezentacje i detektory

Tabela 3 opisuje, jak działa każda reprezentacja i jakie wartości jej parametrów sprawdzono, a tabela 4 – detektory uruchamiane w każdej z nich.

Tabela 3: Reprezentacje danych i sprawdzone wartości parametrów.

Reprezentacja	Jak działa	Parametry (sprawdzone wartości)
dane oryginalne	Wszystkie cechy po standaryzacji; punkt odniesienia.	–
PCA (analiza składowych głównych)	Zastępuje cechy ich kombinacjami (*składowymi*) uporządkowanymi od tej, wzdłuż której dane są najbardziej rozrzucone. Zostawiamy k pierwszych składowych, a resztę odrzucamy. *Zachowana wariancja* mówi, jaką część rozrzutu danych zachowuje k składowych (1 = całą).	liczba składowych k: 1, 2, 3, 5, 8, 10, 15, 20
UMAP	Nieliniowo „spłaszcza" dane do m wymiarów tak, by punkty bliskie w oryginale pozostały blisko siebie. Nowe punkty umieszcza obok ich najbliższych sąsiadów z części uczącej.	wymiar m: 2, 5, 10; liczba sąsiadów nn (lokalna albo szersza struktura): 5, 15, 50; minimalny odstęp punktów md: 0; 0,5
autoenkoder	Sieć neuronowa, która ściska dane do z liczb (*przestrzeń ukryta*) i próbuje odtworzyć z nich wszystkie cechy. Jako reprezentację bierzemy te z liczb.	wymiar przestrzeni ukrytej z: 2, 4, 8, 16; dla $z = 8$ także dwie inne architektury
błąd rekonstrukcji (PCA, autoenkoder)	Nie reprezentacja, lecz dodatkowy detektor: jak bardzo obserwacja odtworzona z k składowych lub z z liczb różni się od oryginału. Obserwacja niepasująca do typowej struktury danych odtwarza się źle.	jak dla PCA i autoenkodera

Tabela 4: Detektory uruchamiane w każdej reprezentacji (d – liczba wymiarów reprezentacji).

Detektor	Jak działa	Parametry (sprawdzone wartości)
Isolation Forest	Anomalię da się odciąć od reszty po niewielu losowych cięciach.	liczba drzew $T = 200$ (w zadaniu 1 nie miała wpływu)
LOF	Punkt wyraźnie rzadszy niż jego sąsiedzi jest podejrzany.	liczba sąsiadów k_{LOF}: 5, 10, 20, 35, 50
One-Class SVM	Granica wokół obszaru danych; punkty poza nią są anomaliami. Jądro RBF.	ν (limit odsetka punktów uczących poza granicą): 0,05; 0,1; 0,5; γ (szerokość jądra): $0{,}1/d$, $1/d$, $10/d$

Ustawienia detektora wybieramy osobno w każdej reprezentacji, bo najlepsze k_{LOF} czy γ zależą od kształtu danych. Wspólne ustawienia faworyzowałyby reprezentację, do której je dobrano.

Architektura autoenkodera. Sieć ma kształt lejka: $d \to 64 \to 32 \to z \to 32 \to 64 \to d$, gdzie d to liczba cech. Uzasadnienie:

- środek węższy niż wejście ($z < d$) zmusza sieć do kompresji, więc nie może po prostu przepisać danych, tylko uczy się ich typowej struktury;
- dwie warstwy ukryte pozwalają uchwycić zależności nieliniowe, których PCA nie widzi;
- małe zbiory (183–915 obserwacji uczących poza Campaign) łatwo się „uczą na pamięć",

dlatego uczenie zatrzymujemy, gdy błąd na 15 % części uczącej odłożonych z boku przestaje maleć (maks. 400 epok, czyli przejść przez dane).

Sieć uczy się na danych z anomaliami, tak jak w praktyce, gdy etykiet nie ma. Dwie inne architektury ($d \to 32 \to 8$ i $d \to 128 \to 64 \to 8$) porównano w sekcji 5.5.

Miary struktury reprezentacji. Dla każdej reprezentacji policzono na części testowej dwie miary, które nie zależą od detektora:

- **zaufanie sąsiedztw** (*trustworthiness*, od 0 do 1) – czy sąsiedzi punktu w nowej reprezentacji byli też jego sąsiadami w danych oryginalnych (1 = brak „fałszywych" sąsiadów);
- **separacja klas** (*silhouette*, od -1 do 1) – czy anomalie leżą bliżej siebie niż obserwacji normalnych; 0 = klasy wymieszane.

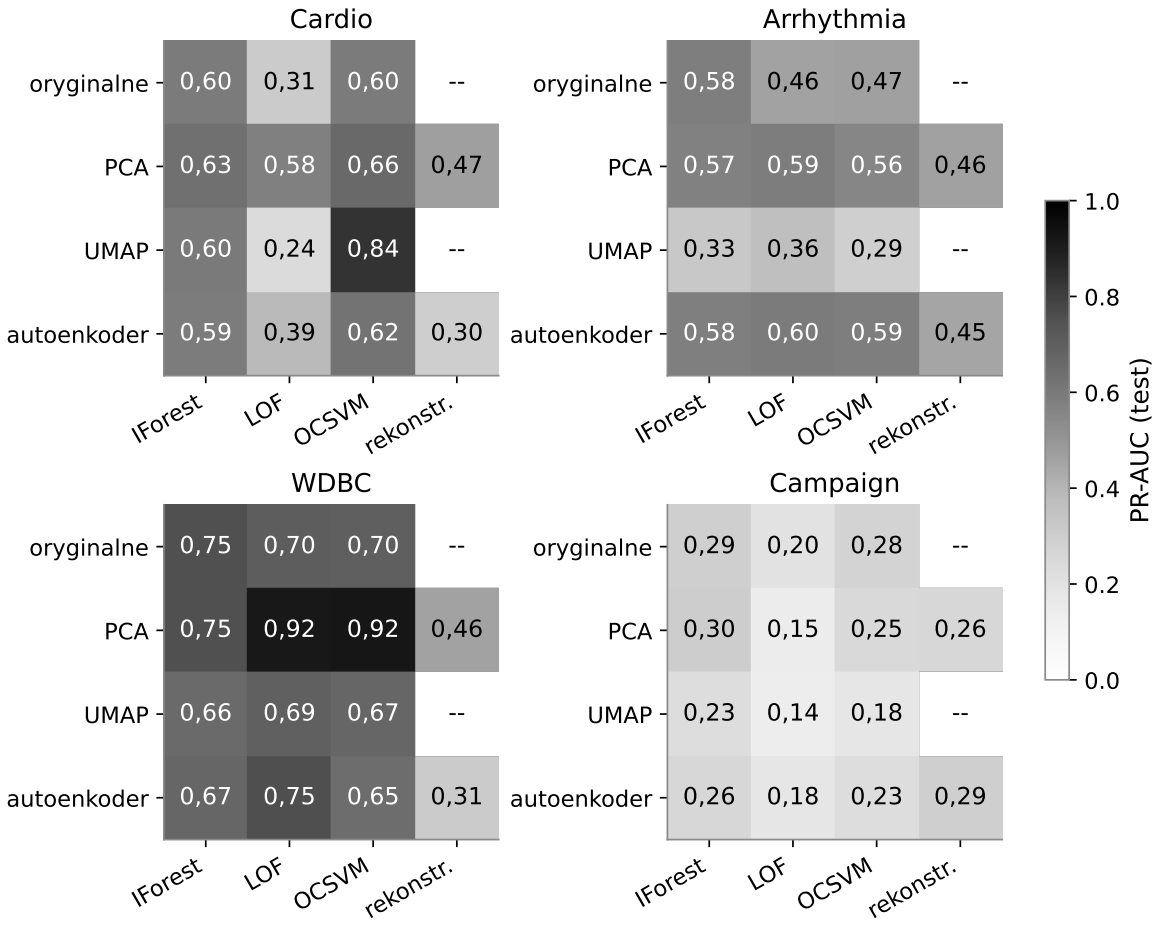
Etykiety służą tu tylko do analizy, nie do budowy reprezentacji. Recall liczono też osobno dla anomalii *globalnych* (leżących dalej od środka danych normalnych niż 99 % obserwacji normalnych) i *lokalnych* (pozostałych), tak jak w zadaniu 1.

5 Wyniki

W tej sekcji najpierw zestawiono wszystkie pary reprezentacja–detektor, potem omówiono każdą reprezentację osobno w tym samym układzie, a na końcu porównano je ze sobą i z zadaniem 1.

5.1 Przegląd: wszystkie reprezentacje i detektory

Rysunek 1 pokazuje jakość każdej pary reprezentacja–detektor na każdym zbiorze danych; pełne wyniki są w aneksie A.



Rysunek 1: PR-AUC każdej pary reprezentacja–detektor (ustawienia wybrane na walidacji); ciemniejsze pole – lepszy wynik, „–" – nie dotyczy.

Zmiana reprezentacji może zmienić wynik detektora o ponad 0,2 PR-AUC, w obie strony:

- **WDBC: PCA ⇒ LOF 0,71 → 0,92, OCSVM 0,70 → 0,93**;
- **Cardio: UMAP ⇒ OCSVM 0,60 → 0,84** (najlepszy wynik na tym zbiorze), ale LOF 0,31 → 0,24;
- **Arrhythmia: UMAP ⇒ IForest 0,58 → 0,33**, a autoenkoder i PCA poprawiają LOF i OCSVM o 0,09–0,14 – ale tylko do poziomu IForest w danych oryginalnych (0,58);
- **Campaign: żadna reprezentacja nie pomaga** – wszystkie pary mają 0,14–0,30 przy zgadywaniu 0,11.

Tabela 5 pokazuje, który parametr reprezentacji ma największy wpływ: o ile zmienia się PR-AUC, gdy zmieniamy tylko ten parametr (resztę, łącznie z detektorem, wybiera walidacja).

Tabela 5: Wpływ parametrów reprezentacji: różnica PR-AUC między najlepszą a najgorszą wartością parametru („–” – na Campaign badano jedną wartość).

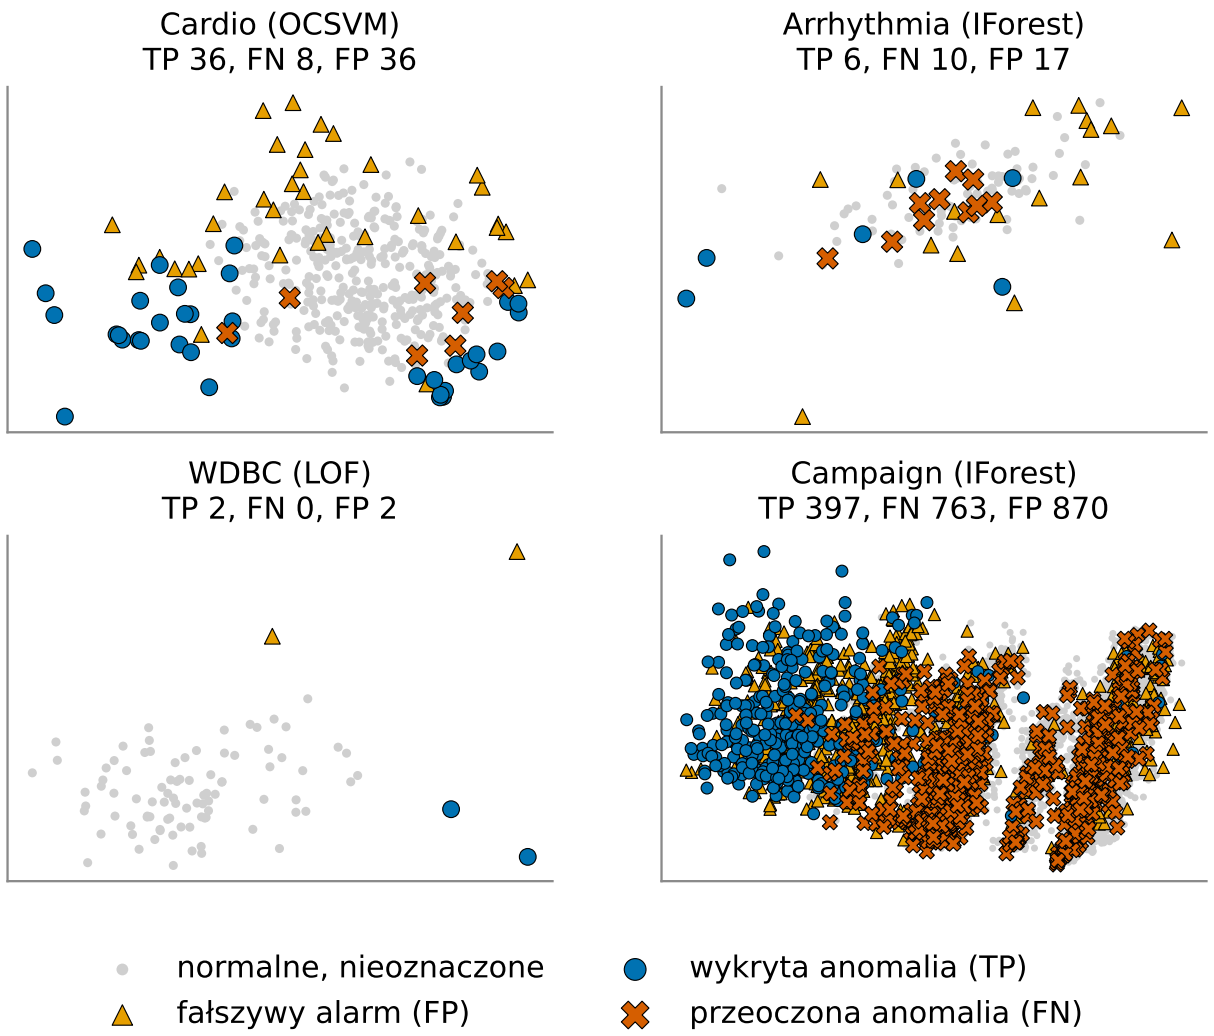
Zbiór danych	PCA: liczba składowych k	UMAP: liczba sąsiadów nn	UMAP: wymiar m	UMAP: odstęp md	Autoenkoder: wymiar z
Cardio	0,084	0,310	0,017	0,000	0,049
Arrhythmia	0,191	0,070	0,039	0,042	0,066
WDBC	0,211	0,152	0,082	0,051	0,023
Campaign	0,062	0,001	0,035	–	0,065

Największy wpływ mają liczba składowych PCA (do 0,21 na WDBC) i liczba sąsiadów UMAP (0,31 na Cardio); wymiar UMAP, odstęp md i wymiar autoenkodera zmieniają wynik najwyżej o 0,08.

Rysunki „co wykryto” w kolejnych podsekcjach pokazują, co najlepszy (według walidacji) detektor w danej reprezentacji wykrył w części testowej jednego podziału (ziarno 0). Wszystkie mapy używają tego samego rzutu – dwóch pierwszych składowych PCA danych oryginalnych – więc można je porównywać punkt po punkcie. Kolory oznaczają: **TP** – wykryta anomalia, **FN** – przeoczona anomalia, **FP** – fałszywy alarm; szare punkty to obserwacje normalne słusznie niezgłoszone. Część testowa WDBC w tym podziale ma tylko 2 anomalie.

5.2 Dane oryginalne (punkt odniesienia)

Tu pokazano, co wykrywają detektory na samych cechach, bez zmiany reprezentacji.

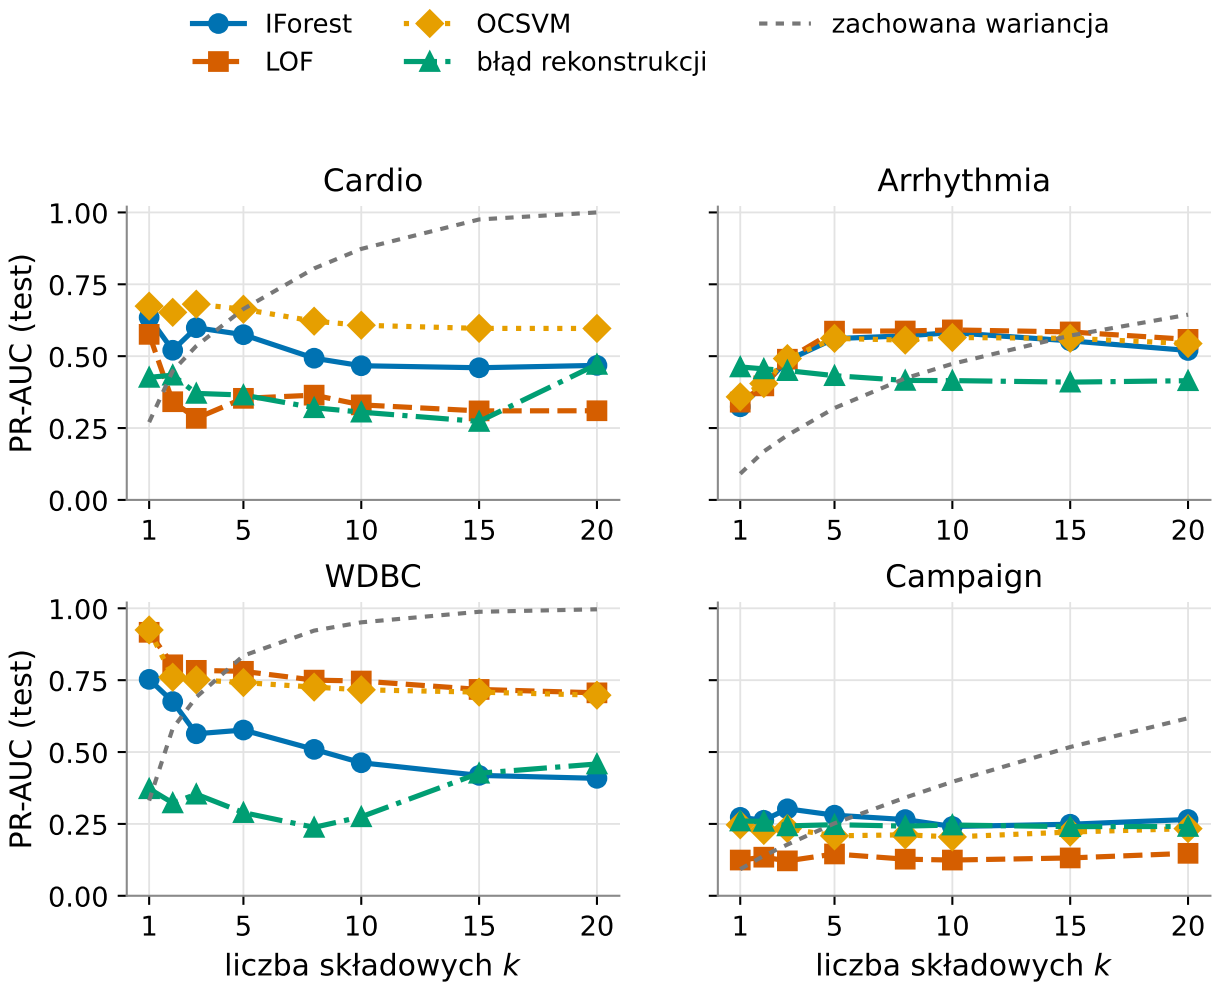


Rysunek 2: Co wykrył najlepszy detektor w danych oryginalnych na każdym zbiorze danych (w nawiasie – detektor wybrany na walidacji).

Na Cardio OCSVM wykrywa 36 z 44 anomalii, ale z 36 fałszywymi alarmami; na Campaign IForest przeocza 763 z 1160 anomalii (rys. 2). Anomalie Campaign leżą w tych samych obszarach co klienci, którzy lokaty nie założyli, więc żaden detektor nie odróżnia ich po położeniu. Na Arrhythmii IForest wykrywa 6 z 16 anomalii przy 17 fałszywych alarmach, a na WDBC LOF wykrywa obie anomalie testowe przy 2 fałszywych alarmach.

5.3 PCA

Sprawdzono, jak liczba zostawionych składowych k wpływa na wykrywanie.



Rysunek 3: PCA: PR-AUC w zależności od liczby składowych k; linia szara – zachowana wariancja (ta sama skala 0–1).

Zależność między zachowaną wariancją a jakością detekcji **nie jest monotoniczna** (rys. 3):

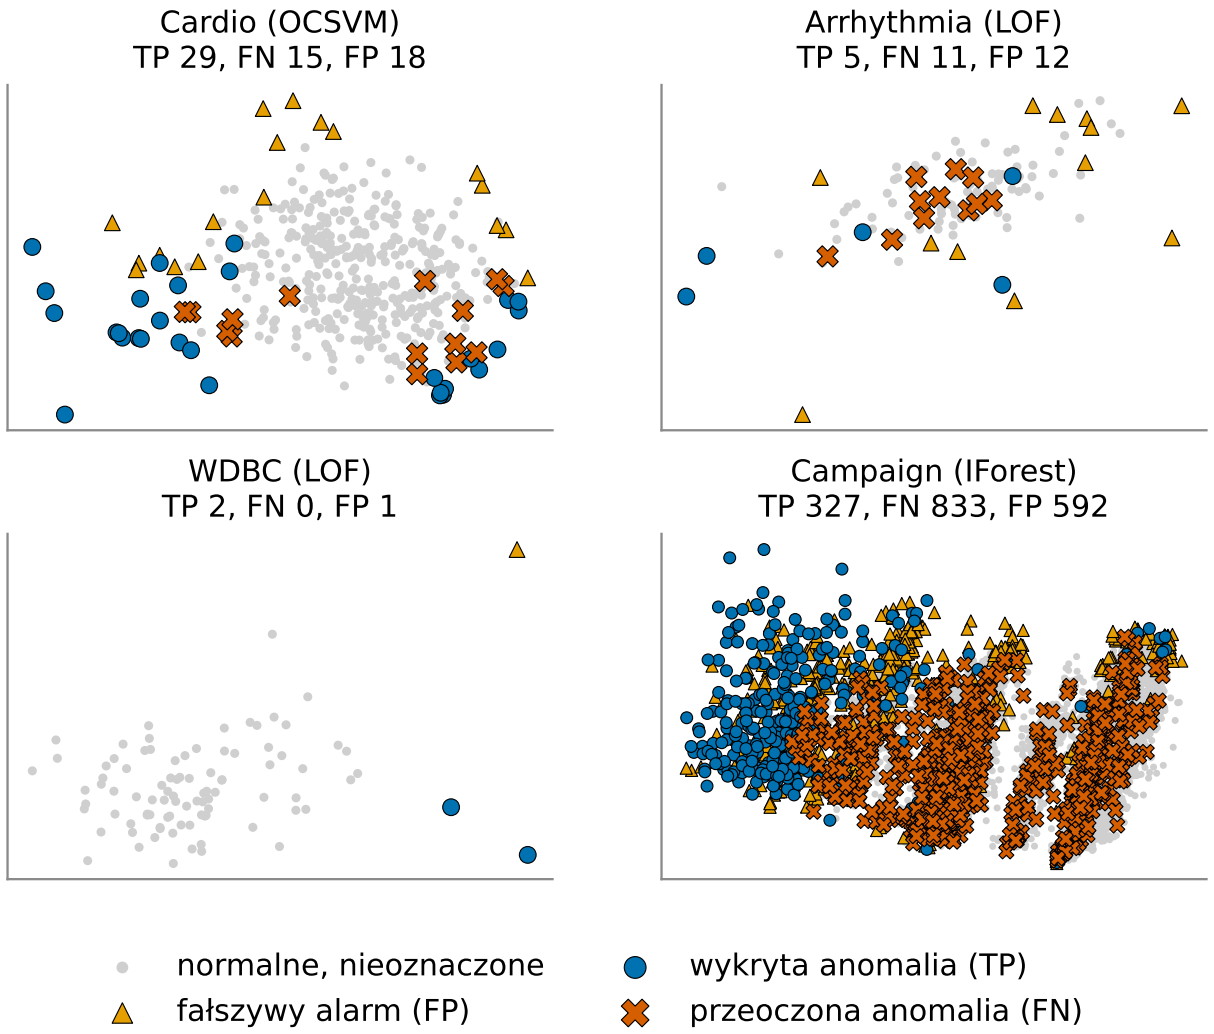
- **WDBC:** $k = 1$ **(33 % wariancji)** $\Rightarrow$ **OCSVM 0,93, LOF 0,92** – pierwsza składowa opisuje ogólną wielkość jądra komórkowego, czyli właśnie to, czym guzy złośliwe różnią się od łagodnych; każda kolejna składowa dodaje tylko zmienność wśród guzów łagodnych.
- **Cardio:** $k = 1$ $\Rightarrow$ **LOF 0,58** (w danych oryginalnych 0,31); OCSVM jest najlepszy przy $k = 1$–5.
- **Arrhythmia:** $k = 5$–**15** $\Rightarrow$ **LOF 0,58–0,59** (w danych oryginalnych 0,46), choć to tylko 32–57 % wariancji. Przy 274 cechach odległości w danych oryginalnych zagłusza szum setek słabych cech, a redukcja go usuwa. Tyle samo osiąga jednak IForest bez żadnej redukcji (0,58), więc PCA pomaga tu LOF, a nie poprawia najlepszego wyniku na zbiorze. Przy $k \leq 2$ wynik spada (0,34–0,40), bo znika też informacja o anomaliach.
- **Campaign:** k **prawie nie ma wpływu** (IForest 0,24–0,30).

Zachowana wariancja mierzy, jak wiernie odtwarzamy *typowe* dane, a nie to, czy zostaje informacja odróżniająca *nietypowe*. Dlatego k trzeba wybierać na walidacji, a nie według progu wariancji.

Tabela 6: PCA: LOF i błąd rekonstrukcji przy różnej liczbie składowych k („wszystkie” – dane oryginalne; Recall osobno dla anomalii globalnych i lokalnych).

			LOF			błąd rekonstrukcji	
Zbiór danych	k	zachowana wariancja	PR-AUC	Recall globalne	Recall lokalne	PR-AUC	Recall globalne
Cardio	wszystkie	1,00	0,310	0,963	0,787	–	–
	1	0,27	0,576	0,824	0,602	0,426	0,948
	2	0,45	0,342	0,770	0,692	0,434	0,969
	5	0,66	0,353	0,831	0,610	0,365	0,987
	20	1,00	0,310	0,963	0,787	0,471	0,879
Arrhythmia	wszystkie	1,00	0,458	0,871	0,350	–	–
	1	0,09	0,340	0,610	0,451	0,462	0,858
	2	0,17	0,397	0,542	0,179	0,456	0,858
	5	0,32	0,587	0,809	0,225	0,432	0,872
	20	0,64	0,558	0,861	0,322	0,415	0,909
WDBC	wszystkie	1,00	0,705	0,955	0,580	–	–
	1	0,33	0,916	1,000	0,759	0,372	0,909
	2	0,58	0,803	0,955	0,644	0,323	0,864
	5	0,84	0,781	0,955	0,690	0,289	0,886
	20	1,00	0,706	0,955	0,580	0,459	0,864
Campaign	wszystkie	1,00	0,202	0,408	0,379	–	–
	1	0,09	0,124	0,889	0,841	0,260	0,944
	2	0,14	0,134	0,658	0,541	0,259	0,946
	5	0,25	0,145	0,670	0,585	0,247	0,915
	20	0,62	0,148	0,860	0,704	0,241	0,917

Tabela 6 pokazuje, co redukcja robi z typami anomalii. **Arrhythmia:** $k = 2 \Rightarrow$ **Recall globalnych anomalii LOF 0,87 → 0,54**: odchylenie takiej anomalii rozkłada się na wiele cech, a rzut na dwie składowe je usuwa. To samo odchylenie widać jednak w błędzie rekonstrukcji, który wykrywa 0,86–0,99 anomalii globalnych na każdym zbiorze danych. Ma przy tym niską trafność zgłoszeń (PR-AUC 0,24–0,47), bo równie źle odtwarza się wiele obserwacji normalnych.

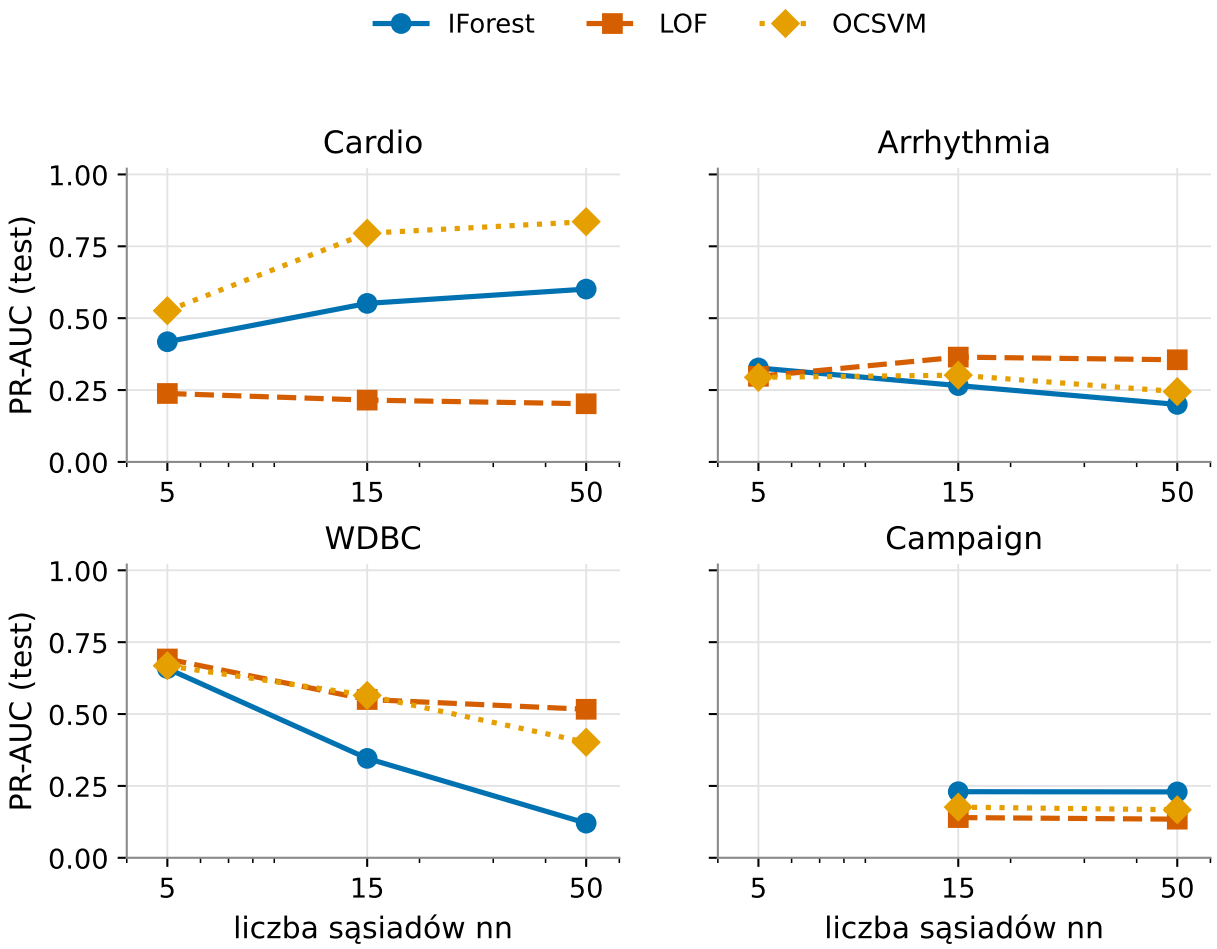


Rysunek 4: Co wykrył najlepszy detektor w reprezentacji PCA na każdym zbiorze danych.

W porównaniu z danymi oryginalnymi **PCA ogranicza fałszywe alarmy na każdym zbiorze danych**: Cardio 18 zamiast 36, Arrhythmia 12 zamiast 17, WDBC 1 zamiast 2, Campaign 592 zamiast 870 (rys. 4). Kosztem jest część wykrytych anomalii (Cardio 29 zamiast 36, Arrhythmia 5 zamiast 6, Campaign 327 zamiast 397); na WDBC obie anomalie są nadal wykryte.

5.4 UMAP

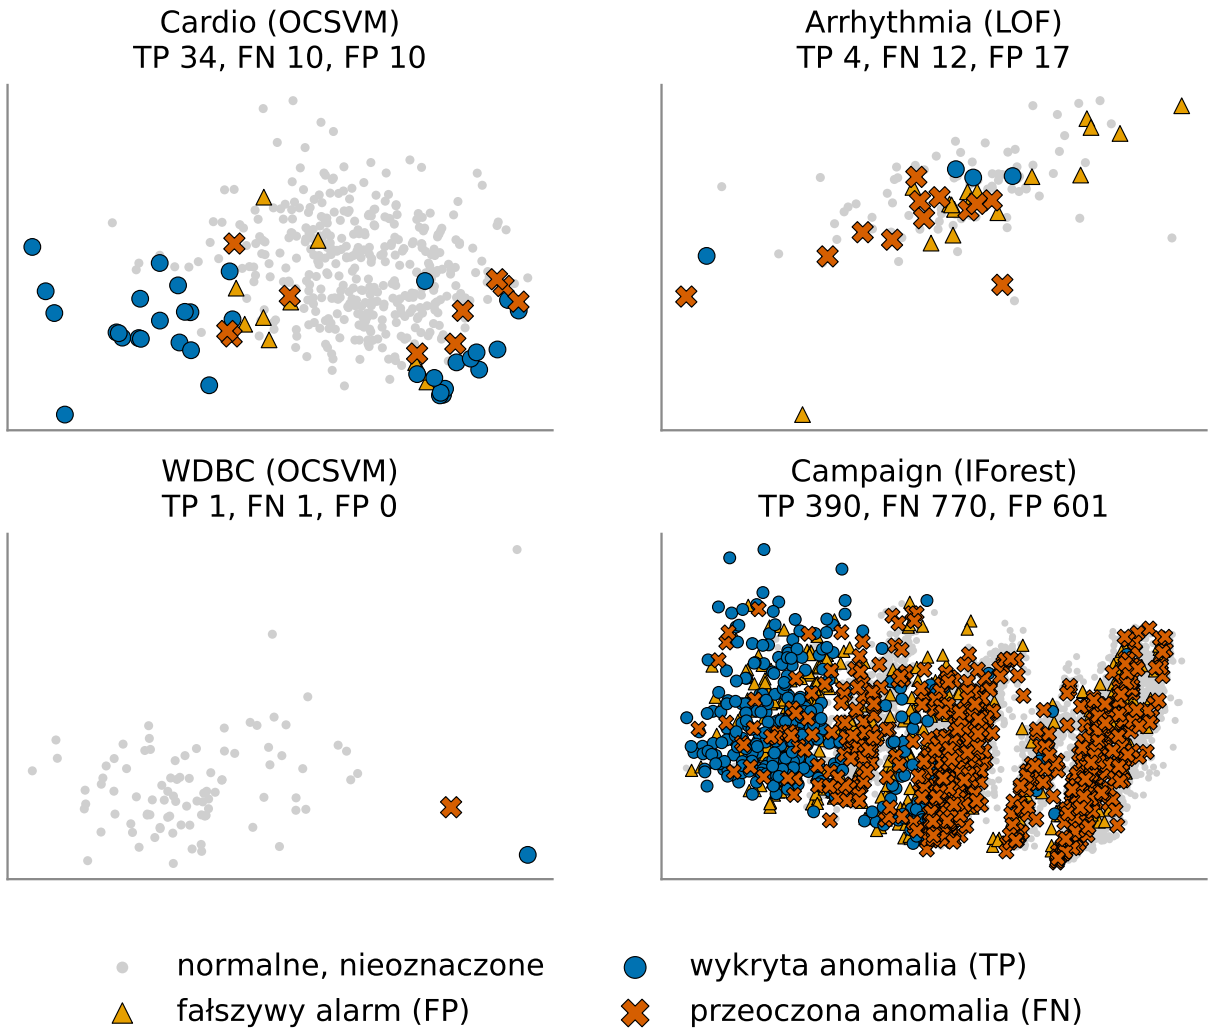
Sprawdzono wpływ liczby sąsiadów nn, wymiaru m i odstępu md na wykrywanie.



Rysunek 5: UMAP: PR-AUC w zależności od liczby sąsiadów nn (m i md wybrane na walidacji); liczba sąsiadów działa w przeciwnych kierunkach na Cardio i WDBC.

- **Liczba sąsiadów nn – Cardio: 5 → 50 ⇒ OCSVM 0,53 → 0,84; WDBC: odwrotnie, IForest 0,66 → 0,12** (rys. 5). Anomalie Cardio to duża, spójna grupa, którą UMAP przy szerszym kontekście odsuwa od reszty danych. W WDBC jest tylko 5 anomalii w części uczącej i szeroki kontekst „wciąga" je między obserwacje normalne.
- **Wymiar m i odstęp md** zmieniają wynik najwyżej o 0,08 (tabela 5); $m = 2$ wystarcza do rysunku, ale do detekcji zwykle lepsze jest 5–10.

Dlaczego UMAP zwykle szkodzi? UMAP z założenia wyrównuje gęstość: każdy punkt dostaje „tyle samo" sąsiadów, bez względu na to, jak daleko oni leżą. Odosobniona anomalia zostaje dociągnięta do najbliższej grupy, a mała grupa anomalii staje się zwartym skupiskiem. LOF, który szuka punktów rzadszych od sąsiadów, przestaje je widzieć (Cardio: 0,31 → 0,24). **Dlaczego pomaga OCSVM na Cardio?** OCSVM nie potrzebuje, żeby anomalie były rzadkie – wystarczy, że leżą poza główną masą danych, a UMAP odsuwa grupę zapisów patologicznych na brzeg.

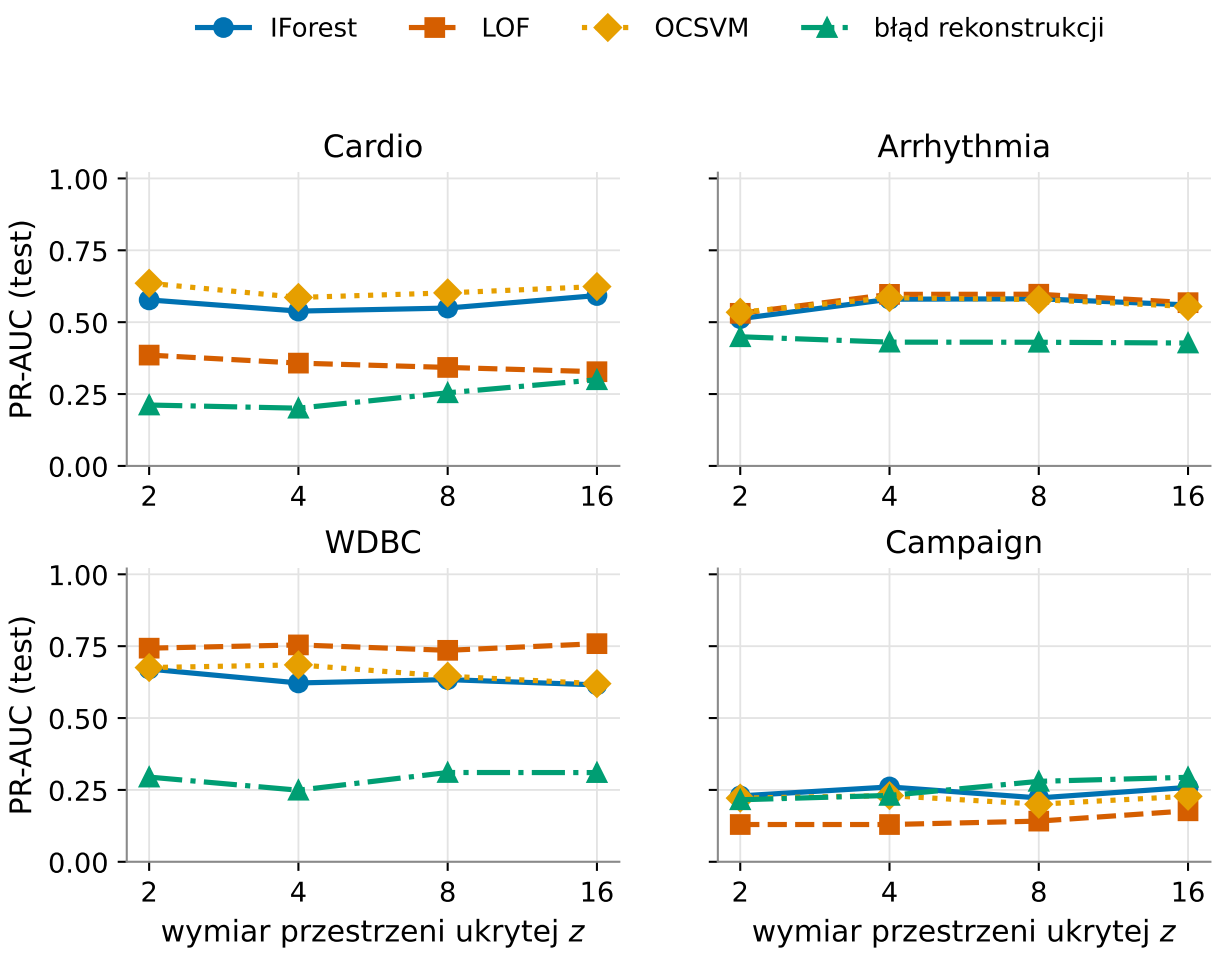


Rysunek 6: Co wykrył najlepszy detektor w reprezentacji UMAP na każdym zbiorze danych.

Na Cardio OCSVM w UMAP ma najlepszą równowagę: 34 z 44 anomalii przy 10 fałszywych alarmach (w danych oryginalnych 36 i 36). Na Arrhythmii i WDBC UMAP gubi anomalie: LOF wykrywa 4 z 16 (w danych oryginalnych 6), a OCSVM 1 z 2 (w danych oryginalnych 2). Na Campaign IForest wykrywa prawie tyle samo co w danych oryginalnych (390 wobec 397) przy mniejszej liczbie fałszywych alarmów (601 wobec 870; rys. 6).

5.5 Autoenkoder

Sprawdzono wpływ wymiaru przestrzeni ukrytej z i architektury sieci.



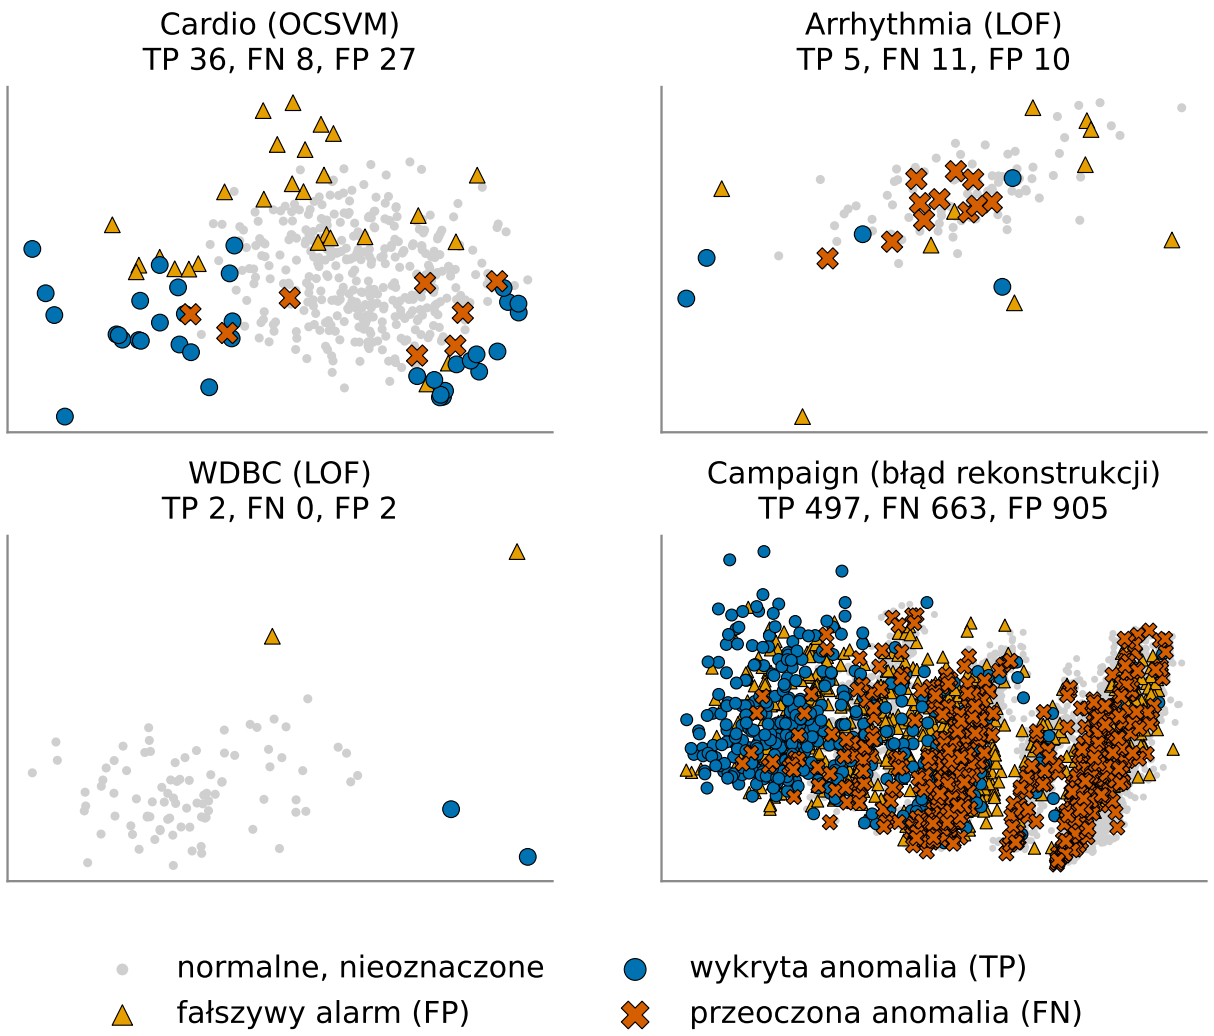
Rysunek 7: Autoenkoder: PR-AUC detektorów w przestrzeni ukrytej i błędu rekonstrukcji w zależności od wymiaru z; wymiar ma mały wpływ.

Wymiar z zmienia wynik najwyżej o 0,07 (rys. 7, tabela 5). **Autoenkoder nie daje lepszego wyniku niż PCA na żadnym zbiorze danych.** Na Arrhythmii poprawia LOF (0,46 → 0,60), ale tyle samo dają PCA (0,59) i IForest w danych oryginalnych (0,58); różnice mieszczą się w rozrzucie między podziałami (autoenkoder jest lepszy od PCA w 7 z 10 podziałów, średnio o 0,01). Na pozostałych zbiorach zyskuje mniej niż PCA (np. LOF na WDBC: 0,71 → 0,75, w PCA 0,92) albo traci: sieć uczy się odtwarzać dane, a nie zachowywać odległości, na których opierają się detektory.

Tabela 7: Porównanie architektur autoenkodera przy $z = 8$: PR-AUC błędu rekonstrukcji, PR-AUC najlepszego detektora w przestrzeni ukrytej (w nawiasie – detektor), średnia liczba epok do zatrzymania i czas uczenia.

Zbiór danych	Architektura	PR-AUC błędu rekonstrukcji	PR-AUC detektora w przestrzeni z	Epoki uczenia	Czas uczenia [s]
Cardio	d-32-8	0,264	0,582 (OCSVM)	335	7,91
	d-64-32-8	0,254	0,602 (OCSVM)	330	11,04
	d-128-64-8	0,250	0,556 (OCSVM)	198	7,19
Arrhythmia	d-32-8	0,425	0,591 (LOF)	202	1,44
	d-64-32-8	0,430	0,597 (LOF)	127	1,30
	d-128-64-8	0,426	0,572 (LOF)	119	1,45
WDBC	d-32-8	0,272	0,741 (LOF)	346	1,71
	d-64-32-8	0,311	0,736 (LOF)	252	1,71
	d-128-64-8	0,288	0,749 (LOF)	184	1,36
Campaign	d-32-8	0,210	0,202 (IForest)	400	31,16
	d-64-32-8	0,280	0,222 (IForest)	400	51,12
	d-128-64-8	0,283	0,197 (OCSVM)	400	72,83

Architektura zmienia wynik najwyżej o 0,05, z wyjątkiem Campaign, gdzie płytsza sieć d-32-8 ma za małą pojemność (0,21 wobec 0,28; tabela 7). Na Campaign uczenie zawsze dochodzi do limitu 400 epok, czyli sieć nie osiągnęła jeszcze najlepszego wyniku. Na Cardio błąd rekonstrukcji wykrywa słabo (0,25–0,26): 88 zapisów patologicznych w części uczącej tworzy własną grupę, którą sieć uczy się odtwarzać.



Rysunek 8: Co wykrył najlepszy detektor w reprezentacji autoenkodera na każdym zbiorze danych.

Na Campaign najlepszy według walidacji jest błąd rekonstrukcji autoenkodera: wykrywa 497 z 1160 anomalii (IForest w danych oryginalnych 397), ale zgłasza też 905 fałszywych alarmów (rys. 8). Na Cardio OCSVM w przestrzeni ukrytej wykrywa tyle samo anomalii co w danych oryginalnych (36), z mniejszą liczbą fałszywych alarmów (27 wobec 36). Na Arrhythmii LOF wykrywa 5 z 16 anomalii przy 10 fałszywych alarmach (IForest w danych oryginalnych: 6 i 17), a na WDBC wynik jest taki sam jak w danych oryginalnych (obie anomalie, 2 fałszywe alarmy).

5.6 Co wykryto: porównanie reprezentacji

Tabela 8 zbiera liczby z czterech map „co wykryto”.

Tabela 8: Liczby z rysunków „co wykryto” (część testowa, ziarno 0): TP / FN / FP, czyli wykryte anomalie / przeoczone anomalie / fałszywe alarmy; w nawiasie – detektor wybrany na walidacji.

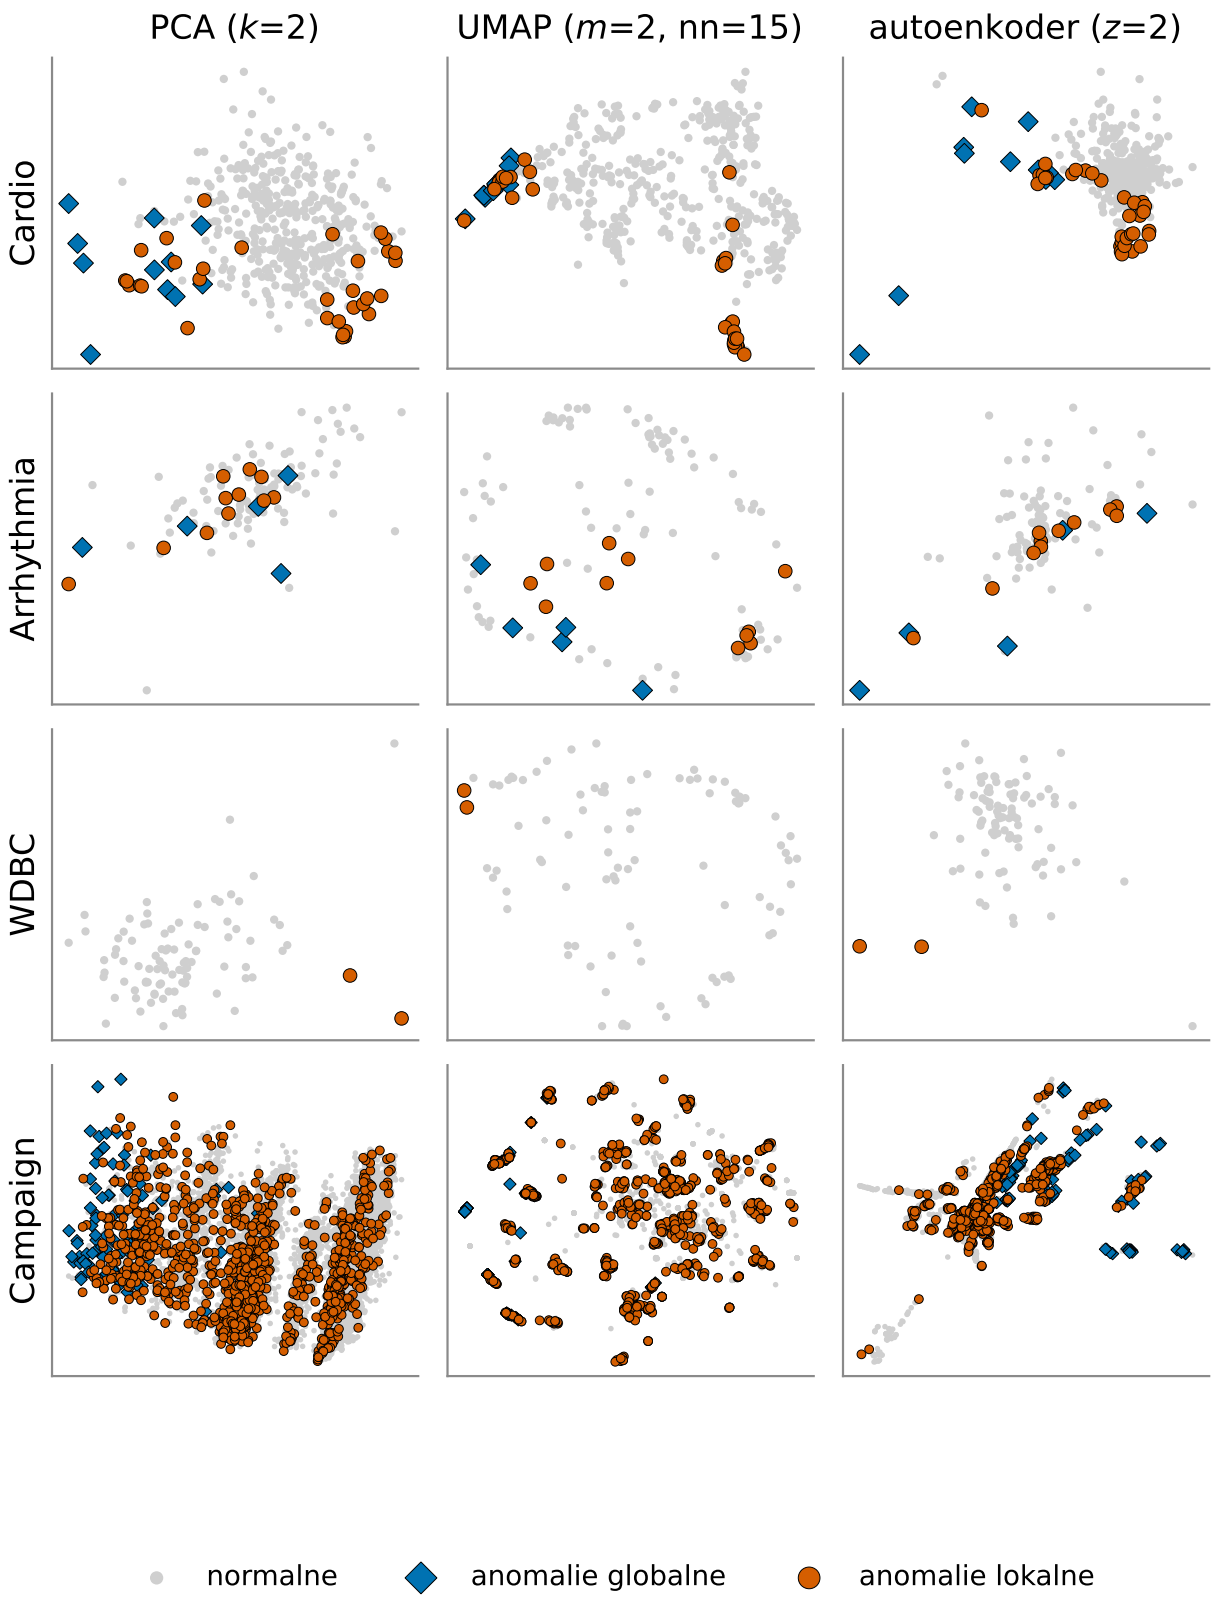
Zbiór danych	Anomalie w teście	dane oryginalne	PCA	UMAP	autoenkoder
Cardio	44	36 / 8 / 36 (OCSVM)	29 / 15 / 18 (OCSVM)	34 / 10 / 10 (OCSVM)	36 / 8 / 27 (OCSVM)
Arrhythmia	16	6 / 10 / 17 (IForest)	5 / 11 / 12 (LOF)	4 / 12 / 17 (LOF)	5 / 11 / 10 (LOF)
WDBC	2	2 / 0 / 2 (LOF)	2 / 0 / 1 (LOF)	1 / 1 / 0 (OCSVM)	2 / 0 / 2 (LOF)
Campaign	1160	397 / 763 / 870 (IForest)	327 / 833 / 592 (IForest)	390 / 770 / 601 (IForest)	497 / 663 / 905 (błąd rekonstrukcji)

Reprezentacja zmienia głównie liczbę fałszywych alarmów, a mniej liczbę wykrytych anomalii:

- Cardio: 29–36 z 44 anomalii, fałszywych alarmów od 10 (UMAP) do 36 (dane oryginalne);
- Arrhythmia: 4–6 z 16 anomalii, fałszywych alarmów od 10 (autoenkoder) do 17 (dane oryginalne i UMAP);
- Campaign: 327–497 z 1160 anomalii, fałszywych alarmów od 592 (PCA) do 905 (autoenkoder);
- WDBC ma w tym podziale tylko 2 anomalie testowe: każda reprezentacja poza UMAP wykrywa obie, przy 1–2 fałszywych alarmach.

5.7 Wizualizacje 2D i separacja klas

Ta część sprawdza, czy reprezentacja, w której anomalie *widać* najlepiej, daje też najlepszą detekcję.



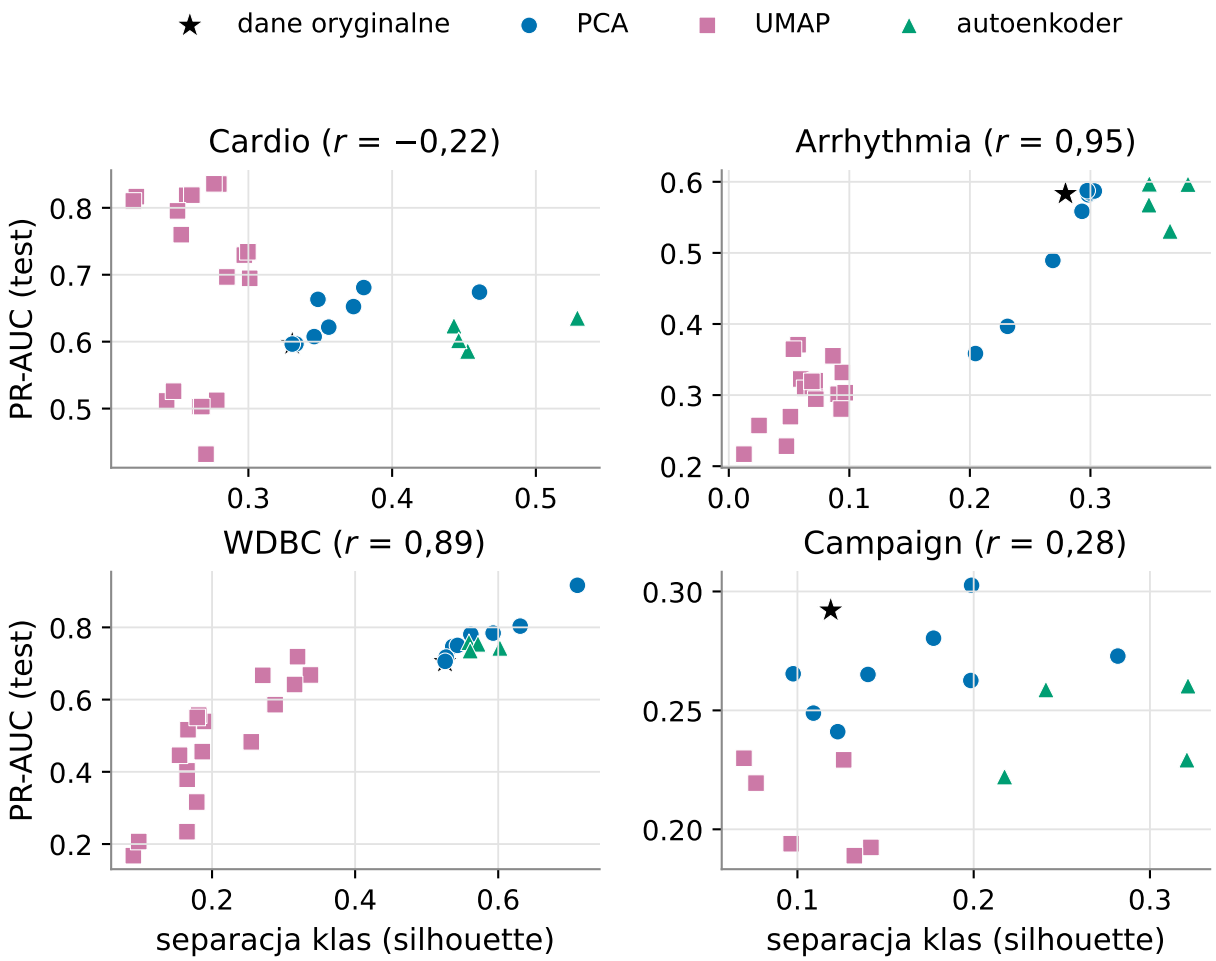
Rysunek 9: Dwuwymiarowe reprezentacje części testowej (ziarno 0): PCA, UMAP i autoenkoder; ładny obraz nie oznacza dobrej detekcji.

Obraz 2D może mylić w obie strony (rys. 9). UMAP daje najbardziej „czytelne" obrazy: Campaign rozbija na kilkadziesiąt skupisk (odpowiadających kombinacjom kategorii), a Arrhythmię na wyraźne grupy, ale anomalie są w nich rozproszone i detekcja jest słaba. Na Cardio UMAP odsuwa anomalie na brzeg i to daje najlepszy wynik. PCA na 2 składowe dobrze oddziela

anomalie WDBC, ale w Arrhythmii (17 % wariancji) ukrywa większość struktury.

Tabela 9: Zaufanie sąsiedztw w UMAP i separacja klas w każdej reprezentacji (od – do po wariantach reprezentacji).

Zbiór danych	Zaufanie sąsiedztw UMAP	Separacja: dane oryginalne	Separacja: PCA	Separacja: UMAP	Separacja: autoenkoder
Cardio	0,88 – 0,96	0,33	0,33 – 0,46	0,22 – 0,30	0,44 – 0,53
Arrhythmia	0,62 – 0,80	0,28	0,20 – 0,30	0,01 – 0,10	0,35 – 0,38
WDBC	0,77 – 0,94	0,53	0,53 – 0,71	0,09 – 0,34	0,56 – 0,60
Campaign	0,96 – 0,97	0,12	0,10 – 0,28	0,07 – 0,14	0,22 – 0,32



Rysunek 10: Separacja klas a PR-AUC dla wszystkich wariantów reprezentacji; r – współczynnik korelacji (1 = pełna zgodność, 0 = brak związku).

Separacja klas zgadza się z jakością detekcji na Arrhythmii ($r = 0{,}95$) i WDBC ($r = 0{,}89$), ale nie na Campaign ($r = 0{,}28$) i Cardio ($r = -0{,}22$) (rys. 10). Na Cardio najlepiej wykrywa UMAP, choć ma niższą separację niż dane oryginalne (0,22–0,30 wobec 0,33; tabela 9). Separacja mierzy, czy anomalie tworzą osobną grupę, a nie czy leżą poza obszarem danych normalnych. UMAP najsłabiej zachowuje sąsiedztwa na Arrhythmii (0,62–0,80), gdzie 274 cechy ściska do najwyżej 10.

5.8 Anomalie globalne i lokalne

Ta część sprawdza, który typ anomalii zyskuje, a który traci na zmianie reprezentacji.

Tabela 10: Recall anomalii globalnych i lokalnych najlepszego (według walidacji) detektora w każdej reprezentacji. Zgłoszone punkty – odsetek obserwacji testowych zgłoszonych jako anomalie; im więcej zgłoszeń, tym łatwiej o wysoki Recall.

Zbiór danych	Reprezentacja	Detektor	Recall globalne	Recall lokalne	Zgłoszone punkty [%]	PR-AUC
Cardio	dane oryginalne	OCSVM	0,971	0,620	13,3	0,596
	PCA	OCSVM	0,910	0,642	11,9	0,663
	UMAP	OCSVM	0,854	0,745	9,4	0,836
	autoenkoder	OCSVM	0,988	0,599	12,8	0,624
Arrhythmia	dane oryginalne	IForest	0,838	0,203	15,2	0,583
	PCA	LOF	0,874	0,217	14,3	0,588
	UMAP	LOF	0,657	0,238	19,6	0,365
	autoenkoder	LOF	0,886	0,281	18,3	0,597
WDBC	dane oryginalne	LOF	0,955	0,580	4,6	0,705
	PCA	LOF	1,000	0,759	3,4	0,916
	UMAP	OCSVM	0,955	0,741	5,7	0,668
	autoenkoder	LOF	0,955	0,592	4,5	0,754
Campaign	dane oryginalne	IForest	0,831	0,278	11,3	0,292
	PCA	IForest	0,851	0,231	8,5	0,303
	UMAP	IForest	0,628	0,328	12,4	0,229
	autoenkoder	błąd rekonstrukcji	0,995	0,522	21,5	0,294

UMAP obniża Recall anomalii globalnych na trzech zbiorach danych z czterech: Arrhythmia 0,84 → 0,66, Campaign 0,83 → 0,63, Cardio 0,97 → 0,85; na WDBC Recall się nie zmienia (0,955; tabela 10). Tabela 11 pokazuje, dlaczego.

Tabela 11: Anomalie globalne przed i po UMAP (dane oryginalne → UMAP, średnio po podziałach). Procenty – jak często losowa anomalia globalna leży dalej niż losowa obserwacja normalna (50 % – brak różnicy) od 10 najbliższych punktów uczących i od środka części uczącej. Detektor – wybrany na walidacji w danych oryginalnych / w UMAP.

Zbiór danych	Detektor	ROC-AUC detektora dla anomalii globalnych	Dalej od sąsiadów niż obserwacja normalna [%]	Dalej od środka danych niż obserwacja normalna [%]
Cardio	OCSVM	0,98 → 0,98	94 → 45	99 → 98
Arrhythmia	IForest / LOF	0,95 → 0,83	93 → 57	93 → 62
WDBC	LOF / OCSVM	1,00 → 0,98	100 → 71	100 → 97
Campaign	IForest	0,94 → 0,85	98 → 38	99 → 86

- **UMAP zaciera odległość od sąsiadów na każdym zbiorze danych**: w danych oryginalnych anomalia globalna ma dalej do sąsiadów niż obserwacja normalna w 93–100 % przypadków, po UMAP tylko w 38–71 %. UMAP zachowuje to, kto jest czyim sąsiadem, ale nie to, jak daleko (sekcja 5.4).
- **Arrhythmia i Campaign: anomalie globalne przestają też leżeć na skraju danych** (93 → 62 % i 99 → 86 %), więc detektor naprawdę je gubi: ROC-AUC spada z 0,95 do 0,83 i z 0,94 do 0,85, w każdym podziale. Recall spada, choć detektor w UMAP zgłasza więcej punktów (19,6 wobec 15,2 % i 12,4 wobec 11,3 %).
- **Cardio i WDBC: anomalie globalne zostają na skraju mapy** (98 i 97 %), a OCSVM szuka właśnie punktów poza główną masą danych. Ustawia je więc w rankingu prawie tak

samo wysoko jak detektor w danych oryginalnych (ROC-AUC 0,98; na WDBC wcześniej 1,00). Spadek Recall na Cardio wynika tylko z progu: OCSVM w UMAP zgłasza mniej punktów (9,4 wobec 13,3 %).

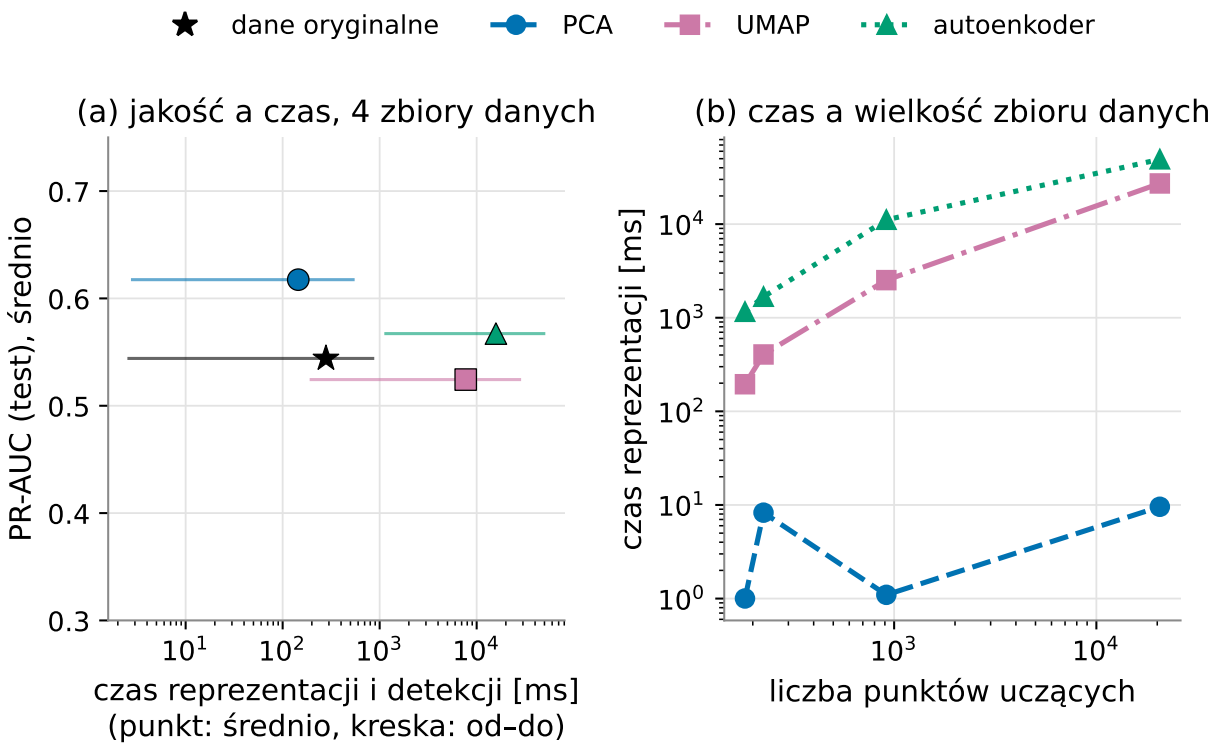
Anomalie lokalne zyskują na reprezentacji, która usuwa szum: PCA na WDBC (0,58 → 0,76) i UMAP na Cardio (0,62 → 0,75), choć obie zgłaszają mniej punktów niż dane oryginalne (3,4 wobec 4,6 % i 9,4 wobec 13,3 %). Żadna para reprezentacja–detektor nie jest najlepsza dla obu typów na wszystkich zbiorach danych.

5.9 Jakość a czas działania

Ta część zestawia jakość i czas na wszystkich czterech zbiorach danych; dla każdej reprezentacji użyto detektora wybranego na walidacji.

Tabela 12: Jakość i czas reprezentacji na czterech zbiorach danych. Miejsce – pozycja reprezentacji według PR-AUC na danym zbiorze danych (1 = najlepsza), uśredniona po zbiorach.

Reprezentacja	PR-AUC (średnio)	Miejsce (średnio)	Czas reprezentacji: średnio [ms]	Czas reprezentacji: od – do [ms]	Czas detektora: średnio [ms]
dane oryginalne	0,544	3,2	–	–	279
PCA	0,617	1,5	5	1 – 10	140
UMAP	0,524	3,2	7578	195 – 27192	135
autoenkoder	0,567	2,0	15783	1156 – 49184	13



Rysunek 11: (a) Średnia jakość a łączny czas (kreska – od najkrótszego do najdłuższego czasu na czterech zbiorach danych); (b) czas przygotowania reprezentacji a liczba punktów uczących (obie osie logarytmiczne).

PCA jest jednocześnie najlepsza i najtańsza: średnio PR-AUC 0,617 i 1,5 miejsce, przy 5 ms na przygotowanie reprezentacji (tabela 12). UMAP i autoenkoder kosztują tysiące razy więcej (średnio 7,6 s i 15,8 s, na Campaign do 27 s i 49 s; rys. 11b), a średnio są gorsze od

PCA (0,524 i 0,567). Na dużym zbiorze najwięcej kosztuje jednak detektor: OCSVM w danych oryginalnych Campaign uczy się i ocenia średnio 95 s, IForest 0,85 s (aneks A).

5.10 Porównanie z zadaniem 1

Tu zestawiono wyniki zadań 1 i 2 na wspólnym zbiorze danych i sprawdzono, ile daje zmiana reprezentacji.

Tabela 13: PR-AUC detektorów w każdej reprezentacji. Zad. 1 – najlepsze ustawienie z zadania 1 (tylko Cardio jest wspólny). Zysk – najlepsza reprezentacja minus dane oryginalne.

Zbiór danych	Detektor	Zad. 1	dane oryginalne	PCA	UMAP	autoenkoder	Najlepsza	Zysk
Cardio	IForest	0,600	0,595	0,635	0,601	0,593	PCA	+0,040
	LOF	0,310	0,310	0,576	0,238	0,385	PCA	+0,266
	OCSVM	0,763	0,596	0,663	0,836	0,624	UMAP	+0,239
Arrhythmia	IForest	–	0,583	0,571	0,327	0,580	dane oryginalne	+0,000
	LOF	–	0,458	0,588	0,365	0,597	autoenkoder	+0,138
	OCSVM	–	0,467	0,556	0,294	0,585	autoenkoder	+0,118
WDBC	IForest	–	0,754	0,753	0,658	0,670	dane oryginalne	+0,000
	LOF	–	0,705	0,916	0,692	0,754	PCA	+0,212
	OCSVM	–	0,699	0,925	0,668	0,646	PCA	+0,226
Campaign	IForest	–	0,292	0,303	0,229	0,260	PCA	+0,010
	LOF	–	0,202	0,148	0,140	0,177	dane oryginalne	+0,000
	OCSVM	–	0,276	0,247	0,176	0,228	dane oryginalne	+0,000

Cardio: IForest i LOF mają w danych oryginalnych te same wyniki co w zadaniu 1 (0,60 i 0,31) (tabela 13). OCSVM jest słabszy (0,60 wobec 0,76), bo w zadaniu 1 walidacja wybrała jądro sigmoidalne, a tu siatka obejmuje tylko RBF. UMAP z OCSVM (0,84) przewyższa jednak najlepszy wynik zadania 1 na tym zbiorze. Zmiana reprezentacji poprawiła wynik w 8 z 12 par zbiór–detektor, a o ponad 0,1 PR-AUC w sześciu.

6 Odpowiedzi na pytania analityczne

W tej sekcji krótko odpowiedziano na pięć pytań postawionych w zadaniu, na podstawie wyników z sekcji 5.

a) **Czy redukcja wymiarowości zawsze poprawia detekcję?** Nie. PCA poprawiło wynik w 8 z 12 par zbiór–detektor, autoenkoder w 5, UMAP w 2. Redukcja pomaga, gdy pozostałe wymiary to głównie szum (WDBC, $k = 1$) albo cech jest więcej niż obserwacji (Arrhythmia). Szkodzi, gdy usuwa kierunki, w których anomalie się odchylają (Arrhythmia, $k = 2$), albo wyrównuje gęstość (UMAP z LOF).

b) **Czy anomalie pozostają oddzielone od danych normalnych?** W PCA z dobrym k – tak, na WDBC i Cardio nawet lepiej niż w danych oryginalnych (separacja do 0,71 i 0,46). UMAP zmniejsza separację na trzech zbiorach (WDBC: 0,53 → 0,09–0,34). Na Campaign separacja jest niska w danych oryginalnych, PCA i UMAP (0,07–0,28), a w autoenkoderze nieco wyższa (0,22–0,32), co jednak nie poprawia detekcji.

c) **Która reprezentacja jest najlepsza dla którego detektora?** LOF – PCA (największy zysk, bo najbardziej cierpi na szum wymiarów). OCSVM – PCA, a gdy anomalie tworzą spójną grupę – UMAP z dużym nn (Cardio). Isolation Forest – dane oryginalne lub PCA z małym k; zmiana reprezentacji dała mu najwyżej +0,04.

d) **Czy najlepsza wizualnie separacja oznacza najlepszą detekcję?** Nie. Najbardziej efektowne obrazy UMAP (Campaign, Arrhythmia) dają słabą detekcję, a liczbowa separacja zgadza się z jakością tylko na dwóch zbiorach na czterech.

e) **Jaki jest kompromis jakości i kosztu?** Najlepszy ma PCA (milisekundy, najczęściej poprawa). UMAP i autoenkoder są tysiące razy droższe i rzadko lepsze. Na dużych danych więcej kosztuje detektor niż reprezentacja (OCSVM na Campaign: 95 s).

7 Ograniczenia i dalsze badania

W tej sekcji wymieniono, co ogranicza pewność wniosków i co warto zbadać dalej.

- WDBC ma w walidacji i teście po 2–3 anomalie, więc wyniki między podziałami różnią się bardzo (odchylenie 0,13–0,39), mimo 30 podziałów. Przewaga PCA na WDBC (0,92 wobec 0,71) jest jednak większa od tego rozrzutu i widać ją też na walidacji.
- Dla Campaign użyto 5 podziałów i węższej siatki UMAP i OCSVM. Rozrzut między podziałami jest tam mały (0,01–0,04), ale węższa siatka mogła pominąć lepszy wariant UMAP.
- Autoenkoder na Campaign nie skończył uczenia w limicie 400 epok. Zbadano tylko jeden typ sieci i uczenie na danych z anomaliami.
- Dalsze badania: odporne PCA, mniej wrażliwe na anomalie w części uczącej; autoenkoder uczony na danych oczyszczonych przez inny detektor; łączenie detektorów z różnych reprezentacji (zadanie 3).

8 Wnioski

Najważniejsze wnioski z zadania, każdy poparty liczbami z sekcji 5.

1. **Reprezentacja ma duży wpływ, w obie strony.** Ten sam detektor zmienia PR-AUC o ponad 0,2 zależnie od reprezentacji (OCSVM na WDBC: 0,65 w autoenkoderze, 0,93 w PCA; LOF na Cardio: 0,24 w UMAP, 0,58 w PCA).
2. **PCA jest najlepszą reprezentacją**: średnio PR-AUC 0,617 wobec 0,544 w danych oryginalnych, przy koszcie kilku milisekund. Zysk pochodzi głównie z WDBC (LOF i OCSVM: 0,71 → 0,92, lepiej w 23 z 30 podziałów) i Cardio (0,60 → 0,66); na Arrhythmii i Campaign zmiana mieści się w 0,01.
3. **Liczby składowych nie wybierać według zachowanej wariancji**: na WDBC 33 % wariancji daje lepszy wynik niż 100 %, a na Arrhythmii wynik przestaje rosnąć już przy 32 % (5 składowych).
4. **UMAP zwykle szkodzi**, bo wyrównuje gęstość (pogorszenie w 10 z 12 par), ale z OCSVM może oddzielić spójną grupę anomalii (Cardio: 0,84 – najlepszy wynik na tym zbiorze). Używać go głównie do rysunków, a do detekcji tylko z OCSVM i wyborem na walidacji.
5. **Autoenkoder nie uzasadnia swojego kosztu**: jest tysiące razy wolniejszy od PCA i na żadnym zbiorze danych nie daje lepszego wyniku. Nawet na Arrhythmii, gdzie cech jest więcej niż obserwacji, osiąga tyle samo co PCA i IForest w danych oryginalnych (0,58–0,60).
6. **Ładny obraz 2D nie oznacza dobrej detekcji**: UMAP daje najczytelniejsze obrazy Campaign i Arrhythmii, a na obu jest najsłabszą reprezentacją (PR-AUC 0,23 i 0,36). Separacja klas zgadza się z jakością tylko na dwóch zbiorach z czterech ($r = 0{,}95$ na Arrhythmii i 0,89 na WDBC, ale 0,28 na Campaign i $-0{,}22$ na Cardio).

7. **Gdy anomalie nie odstają od danych (Campaign), żadna reprezentacja nie pomaga** (PR-AUC najwyżej 0,30). Żadna para reprezentacja–detektor nie jest najlepsza wszędzie – to przesłanka do łączenia detektorów w zadaniu 3.

A Wyniki wszystkich konfiguracji

Tabela podaje wyniki najlepszych ustawień (według walidacji) każdej pary reprezentacja–detektor: średnie z części testowych, ± odchylenie standardowe dla PR-AUC. Skróty: oryg. – dane oryginalne, AE – autoenkoder, rekonstr. – błąd rekonstrukcji, Prec. i Rec. – Precision i Recall; t_r – czas przygotowania reprezentacji, t_d – czas uczenia i oceny detektora.

Zbiór	Repr.	Detektor	Ustawienie	Prec.	Rec.	F1	ROC-AUC	PR-AUC	t_r [ms]	t_d [ms]
Cardio	oryg.	IForest	–	0,489	0,657	0,554	0,935	0,595 ± 0,070	0,0	231,7
	oryg.	LOF	k_{LOF}=50	0,266	0,848	0,403	0,848	0,310 ± 0,051	0,0	19,0
	oryg.	OCSVM	ν=0,50, γ=0,1/d	0,535	0,734	0,616	0,947	0,596 ± 0,078	0,0	40,0
	PCA	IForest	k=1	0,578	0,695	0,627	0,910	0,635 ± 0,061	1,0	229,2
	PCA	LOF	k=1; k_{LOF}=50	0,544	0,675	0,595	0,871	0,576 ± 0,064	1,0	6,2
	PCA	OCSVM	k=5; ν=0,50, γ=0,1/d	0,608	0,727	0,652	0,944	0,663 ± 0,072	1,1	30,6
	PCA	rekonstr.	k=20	0,430	0,607	0,499	0,886	0,471 ± 0,123	1,0	0,3
	UMAP	IForest	m=5, nn=50, md=0,5	0,570	0,555	0,547	0,889	0,601 ± 0,122	2767,6	242,4
	UMAP	LOF	m=2, nn=5, md=0,0; k_{LOF}=50	0,403	0,341	0,326	0,658	0,238 ± 0,066	2047,5	8,3
	UMAP	OCSVM	m=2, nn=50, md=0,0; ν=0,50, γ=0,1/d	0,805	0,780	0,787	0,956	**0,836 ± 0,047**	2521,8	29,3
	AE	IForest	z=16	0,517	0,716	0,588	0,936	0,593 ± 0,098	11118,9	210,4
	AE	LOF	z=2; k_{LOF}=50	0,363	0,716	0,468	0,880	0,385 ± 0,098	8625,8	9,2
	AE	OCSVM	z=16; ν=0,50, γ=0,1/d	0,559	0,730	0,625	0,946	0,624 ± 0,080	11118,9	37,3
	AE	rekonstr.	z=16	0,253	0,430	0,310	0,700	0,300 ± 0,066	11118,9	0,6
Arrhythmia	oryg.	IForest	–	0,553	0,541	0,532	0,844	0,583 ± 0,113	0,0	226,9
	oryg.	LOF	k_{LOF}=50	0,383	0,621	0,453	0,813	0,458 ± 0,118	0,0	4,2
	oryg.	OCSVM	ν=0,50, γ=1,0/d	0,383	0,627	0,454	0,811	0,467 ± 0,114	0,0	7,3
	PCA	IForest	k=8	0,546	0,560	0,533	0,829	0,571 ± 0,115	8,3	220,5
	PCA	LOF	k=8; k_{LOF}=50	0,584	0,566	0,563	0,832	0,588 ± 0,114	8,3	3,9
	PCA	OCSVM	k=8; ν=0,50, γ=0,1/d	0,568	0,510	0,518	0,799	0,556 ± 0,119	8,3	3,0
	PCA	rekonstr.	k=1	0,402	0,609	0,463	0,813	0,462 ± 0,115	9,9	0,3
	UMAP	IForest	m=10, nn=5, md=0,5	0,295	0,480	0,322	0,695	0,327 ± 0,140	270,7	209,8
	UMAP	LOF	m=5, nn=15, md=0,5; k_{LOF}=50	0,366	0,467	0,400	0,743	0,365 ± 0,124	405,0	3,3
	UMAP	OCSVM	m=5, nn=5, md=0,5; ν=0,50, γ=0,1/d	0,281	0,379	0,288	0,678	0,294 ± 0,114	275,2	2,9
	AE	IForest	z=4	0,528	0,546	0,515	0,816	0,580 ± 0,129	1674,2	205,7
	AE	LOF	z=4; k_{LOF}=50	0,489	0,597	0,522	0,822	**0,597 ± 0,129**	1674,2	3,3
	AE	OCSVM	z=4; ν=0,50, γ=0,1/d	0,523	0,566	0,516	0,810	0,585 ± 0,134	1674,2	2,7
	AE	rekonstr.	z=2	0,398	0,631	0,468	0,807	0,449 ± 0,117	889,4	0,4
WDBC	oryg.	IForest	–	0,495	0,794	0,580	0,987	0,754 ± 0,186	0,0	203,9
	oryg.	LOF	k_{LOF}=50	0,472	0,722	0,541	0,985	0,705 ± 0,213	0,0	2,6
	oryg.	OCSVM	ν=0,50, γ=0,1/d	0,465	0,683	0,511	0,985	0,699 ± 0,215	0,0	2,7

Zbiór	Repr.	Detektor	Ustawienie	Prec.	Rec.	F1	ROC-AUC	PR-AUC	t_r [ms]	t_d [ms]
	PCA	IForest	k=1	0,496	0,678	0,535	0,986	0,753 ± 0,191	1,0	206,6
	PCA	LOF	k=1; k_{LOF}=35	0,777	0,867	0,789	0,996	0,916 ± 0,132	1,0	1,8
	PCA	OCSVM	k=1; ν=0,50, γ=0,1/d	0,796	0,900	0,815	0,997	**0,925 ± 0,131**	1,0	1,8
	PCA	rekonstr.	k=20	0,245	0,500	0,287	0,947	0,459 ± 0,242	1,0	0,2
	UMAP	IForest	m=10, nn=5, md=0,0	0,545	0,739	0,568	0,934	0,658 ± 0,387	194,8	208,1
	UMAP	LOF	m=10, nn=5, md=0,5; k_{LOF}=50	0,589	0,739	0,593	0,960	0,692 ± 0,329	194,9	3,0
	UMAP	OCSVM	m=10, nn=5, md=0,0; ν=0,50, γ=0,1/d	0,608	0,783	0,638	0,954	0,668 ± 0,364	194,8	2,1
	AE	IForest	z=2	0,475	0,706	0,494	0,979	0,670 ± 0,221	733,6	198,3
	AE	LOF	z=4; k_{LOF}=35	0,496	0,733	0,557	0,987	0,754 ± 0,228	1156,2	2,4
	AE	OCSVM	z=8; ν=0,50, γ=0,1/d	0,393	0,694	0,472	0,977	0,646 ± 0,234	1706,9	2,0
	AE	rekonstr.	z=16	0,157	0,622	0,233	0,913	0,310 ± 0,155	1693,0	0,3
Campaign	oryg.	IForest	–	0,321	0,322	0,321	0,716	0,292 ± 0,008	0,0	848,4
	oryg.	LOF	k_{LOF}=35	0,199	0,381	0,260	0,634	0,202 ± 0,006	0,0	3778,2
	oryg.	OCSVM	ν=0,10, γ=10,0/d	0,272	0,469	0,341	0,742	0,276 ± 0,009	0,0	94724,2
	PCA	IForest	k=3	0,377	0,280	0,318	0,672	**0,303 ± 0,008**	9,6	522,9
	PCA	LOF	k=20; k_{LOF}=50	0,125	0,716	0,213	0,569	0,148 ± 0,006	13,1	2527,9
	PCA	OCSVM	k=1; ν=0,10, γ=1,0/d	0,194	0,618	0,294	0,696	0,247 ± 0,014	15,9	3448,4
	PCA	rekonstr.	k=1	0,315	0,428	0,363	0,730	0,260 ± 0,010	15,9	4,1
	UMAP	IForest	m=10, nn=50, md=0,0	0,329	0,351	0,337	0,637	0,229 ± 0,013	27191,9	504,7
	UMAP	LOF	m=10, nn=15, md=0,0; k_{LOF}=50	0,133	0,597	0,205	0,542	0,140 ± 0,006	21134,4	448,0
	UMAP	OCSVM	m=10, nn=15, md=0,0; ν=0,10, γ=0,1/d	0,223	0,411	0,287	0,581	0,176 ± 0,010	21134,4	4415,5
	AE	IForest	z=4	0,318	0,397	0,344	0,662	0,260 ± 0,029	49966,3	449,0
	AE	LOF	z=16; k_{LOF}=50	0,177	0,520	0,254	0,622	0,177 ± 0,029	49183,9	2498,1
	AE	OCSVM	z=16; ν=0,10, γ=1,0/d	0,240	0,410	0,289	0,640	0,228 ± 0,039	49183,9	4678,2
	AE	rekonstr.	z=16	0,299	0,560	0,385	0,769	0,294 ± 0,024	49183,9	7,9