Politechnika Łódzka
Wydział Fizyki Technicznej, Informatyki i Matematyki Stosowanej

Analiza danych złożonych z detekcją wyjątków

Zadanie 3

Zespołowa detekcja wyjątków:
projekt własnego rozwiązania

Jędrzej Kostyk
nr indeksu 264339

Rok akademicki 2026/2027

Spis treści

1 Cel i zakres **2**

2 Dane i protokół **2**

3 Detektory bazowe **2**

4 Metody agregacji **3**

4.1 Ujednolicenie wyników anomalii 3

4.2 Majority Voting 4

4.3 Weighted Score Fusion 4

4.4 Warianty własne 5

5 Wyniki **5**

5.1 Pełna tabela wyników 5

5.2 Majority Voting: wpływ progu 7

5.3 Zgodność i komplementarność detektorów 8

5.4 Wpływ normalizacji, wag, wyboru detektorów i progu 9

5.5 Wagi i wybór detektorów w wariantach własnych 10

5.6 Przypadki poprawy i pogorszenia 10

5.7 Test potwierdzający na nowych podziałach 12

5.8 Porównanie z zadaniami 1 i 2 12

6 Synteza: co miało największy wpływ na jakość detekcji? **13**

7 Rekomendacje: kiedy zespół, a kiedy pojedynczy detektor **14**

8 Ograniczenia **14**

9 Wnioski **14**

10 Odtworzenie wyników **15**

1 Cel i zakres

Celem zadania jest zaprojektowanie i ocena zespołowego systemu detekcji wyjątków, który łączy wyniki kilku detektorów o różnych zasadach działania. Sprawdzamy, czy agregacja przewyższa najlepszy pojedynczy detektor. Porównano trzy grupy rozwiązań:

1. **modele pojedyncze** – cztery detektory bazowe oceniane niezależnie (punkt odniesienia),
2. **głosowanie większościowe** (*Majority Voting*) z progami od 1/4 do 4/4 głosów,
3. **fuzja wyników** $S(x) = \sum_k w_k \, \hat{s}_k(x)$ z różnymi sposobami normalizacji, wag i wyboru detektorów, w tym dwa własne warianty: DSF i CBF.

Ostatnia część raportu (sekcja 6) zbiera wyniki wszystkich trzech zadań i odpowiada na pytanie przewodnie projektu: co miało największy wpływ na jakość detekcji – wybór algorytmu, reprezentacja danych czy połączenie detektorów.

Kod znajduje się w katalogu `task3_ensemble/`: normalizacja, wagi i agregacja w `ensemble.py`, detektory bazowe w `run_base.py`, warianty zespołów w `run_ensembles.py`, a tabele i rysunki w `analyze.py`.

2 Dane i protokół

Wykorzystano te same cztery zbiory co w zadaniu 2 (Breast Cancer, Ionosphere, Parkinsons, syntetyczny), aby porównanie z zadaniami 1 i 2 było bezpośrednie. Protokół jest taki sam we wszystkich zadaniach: te same 10 podziałów 50/25/25 % (ziarna 0–9), standaryzacja i reprezentacje dopasowywane na części uczącej, detektory uczone bez etykiet. **Część walidacyjna** służy do doboru progów poszczególnych detektorów, wag, podzbioru detektorów i progu decyzji zespołu. **Część testowa** nie jest używana do żadnej decyzji.

Dodatkowo, ponieważ jeden z wariantów (CBF) zaprojektowano po analizie niepowodzeń pierwszego (sekcja 4.4), wszystkie warianty oceniono ponownie na **10 nowych podziałach** (ziarna 10–19, inne podpróbki anomalii i inne podziały). Nie były one używane w żadnym etapie projektowania i stanowią test potwierdzający (sekcja 5.7).

3 Detektory bazowe

Wybrano cztery detektory o różnych zasadach działania:

- **Isolation Forest** – izolacja losowymi cięciami,
- **LOF** – lokalna gęstość względem sąsiadów,
- **One-Class SVM** – granica obszaru danych w przestrzeni jądra RBF,
- **błąd rekonstrukcji PCA** – odległość od podprzestrzeni głównych składowych (wykrywa odchylenia w kierunkach o małej wariancji).

Zgodnie z zaleceniem, konfiguracje wybrano na podstawie wcześniejszych eksperymentów. Dla każdego zbioru i detektora przyjęto reprezentację i hiperparametry o najwyższej średniej PR-AUC na walidacji w zadaniu 2 (tabela 1). Detektor bazowy to więc para *reprezentacja + algorytm*. Na Breast Cancer trzy detektory działają na jednej składowej PCA, a na Parkinsons trzy na UMAP. Ten drugi wybór jest skutkiem przeuczenia wyboru na małej walidacji, opisanego w zadaniu 2, i przyjęto go świadomie, bez korekty na podstawie testu.

Tabela 1: Konfiguracje detektorów bazowych (wybór na walidacji w zadaniu 2).

Zbiór	Detektor	Reprezentacja	Parametry	PR-AUC wal. (Zad. 2)
Breast Cancer	IForest	PCA (k=1)	T=200	0,706
	LOF	PCA (k=1)	k=50	0,842
	OCSVM	PCA (k=1)	ν=0,50, γ=1,0/d	0,844
	PCA (rekonstr.)	PCA (k=20)	błąd rekonstrukcji	0,404
Ionosphere	IForest	PCA (k=20)	T=200	0,900
	LOF	oryginalna	k=20	0,866
	OCSVM	oryginalna	ν=0,05, γ=10,0/d	0,956
	PCA (rekonstr.)	PCA (k=8)	błąd rekonstrukcji	0,964
Parkinsons	IForest	UMAP (m=10, nn=5, md=0,5)	T=200	0,382
	LOF	UMAP (m=5, nn=15, md=0,0)	k=50	0,498
	OCSVM	UMAP (m=2, nn=15, md=0,5)	ν=0,50, γ=0,1/d	0,471
	PCA (rekonstr.)	PCA (k=1)	błąd rekonstrukcji	0,316
Synthetic	IForest	PCA (k=20)	T=200	0,749
	LOF	oryginalna	k=35	0,951
	OCSVM	oryginalna	ν=0,05, γ=1,0/d	0,827
	PCA (rekonstr.)	PCA (k=5)	błąd rekonstrukcji	0,746

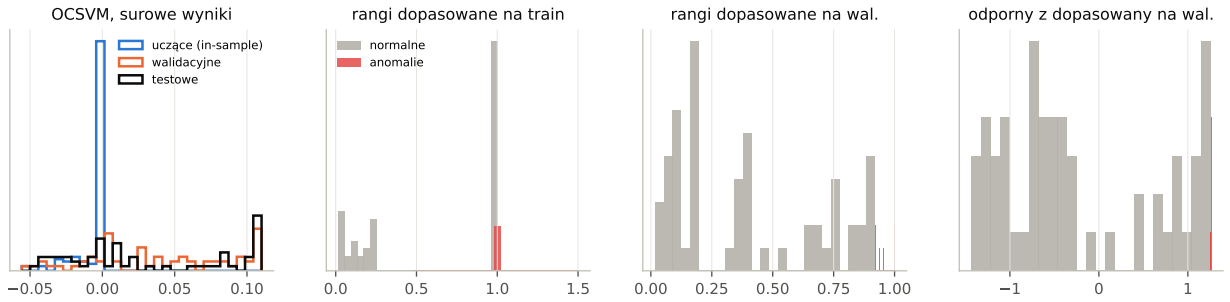
4 Metody agregacji

4.1 Ujednolicenie wyników anomalii

Wszystkie detektory zwracają wynik, w którym wyższa wartość oznacza większą anomalność: IForest $-$`score_samples`, LOF i OCSVM $-$`score_samples`/$-$`decision_function`, PCA – kwadrat błędu rekonstrukcji. Skale są jednak zupełnie różne (np. LOF $\approx$ 1–3, błąd rekonstrukcji od 0 do kilkuset), więc przed agregacją każdy wynik jest normalizowany. Zbadano cztery normalizacje, każdą dopasowywaną osobno dla każdego detektora:

- **min-max**: $(s - \min)/(\max - \min)$,
- **z-score**: $(s - \mu)/\sigma$,
- **odporny z-score**: $(s - \text{med})/(1{,}4826 \cdot \text{MAD})$ – mediana i MAD nie zależą od kilku skrajnych wartości, czyli od samych anomalii,
- **rangi (dystrybuanta empiryczna)**: odsetek wyników referencyjnych mniejszych od s.

Kluczowe okazało się **na czym** dopasować normalizację. Naturalnym wyborem są wyniki części uczącej, ale są to wyniki *in-sample*: detektor ocenia punkty, na których był uczony. Rysunek 1 pokazuje skutek dla OCSVM z wąskim jądrem ($\gamma = 10/d$) na Ionosphere. Punkty uczące są wektorami nośnymi lub leżą tuż przy nich i dostają niskie wyniki, a niemal wszystkie punkty testowe – wyższe niż *każdy* punkt uczący. Normalizacja rangowa dopasowana na części uczącej przypisuje im wszystkim wartość 1 i cała informacja o kolejności ginie. Dlatego normalizacje dopasowywano na **wynikach części walidacyjnej** (*out-of-sample*, bez użycia etykiet). Tabela 2 pokazuje, że dla fuzji przez maksimum z rangami zmiana ta podnosi średnią PR-AUC z 0,415 do 0,645.



Rysunek 1: OCSVM ($\gamma = 10/d$) na Ionosphere, podział 0: rozkład surowych wyników części uczącej (in-sample), walidacyjnej i testowej oraz wyniki testowe po normalizacji rangowej dopasowanej na części uczącej (nasycenie w 1), rangowej dopasowanej na walidacji i odpornym z-score dopasowanym na walidacji.

Tabela 2: Wpływ normalizacji i danych, na których ją dopasowano (średnia PR-AUC z 4 zbiorów, część testowa): fuzja przez średnią, fuzja przez maksimum oraz wariant CBF (PR-AUC i F1).

Normalizacja	Średnia: dopas. train	Średnia: dopas. wal.	Maksimum: train	Maksimum: wal.	CBF: PR-AUC	CBF: F1
min-max	0,710	0,724	0,656	0,690	0,739	0,659
z-score	0,710	0,721	0,650	0,686	0,735	0,658
odporny z	0,726	0,722	0,716	0,722	0,741	0,679
rangi (ECDF)	0,713	0,710	0,415	0,645	0,732	0,638

4.2 Majority Voting

Każdy detektor podejmuje decyzję binarną na podstawie własnego progu, wybranego jako maksymalizujący F1 na walidacji (wariant główny) albo jako kwantyl $1-c$ wyników walidacyjnych przy $c = 0{,}1$ (wariant „c", bez etykiet). Obserwacja jest anomalią, gdy wskaże ją co najmniej m z 4 detektorów, $m \in \{1, 2, 3, 4\}$. Próg $m = 1$ to suma (OR), a $m = 4$ – iloczyn (AND) decyzji. Ranking potrzebny do ROC-AUC i PR-AUC tworzy liczba głosów. Jest on taki sam dla każdego m, więc te metryki nie zależą od progu.

4.3 Weighted Score Fusion

$S(x) = \sum_k w_k\, \hat{s}_k(x)$, $\sum_k w_k = 1$, gdzie $\hat{s}_k$ jest znormalizowanym wynikiem. Zbadano schematy wag wyznaczanych na walidacji:

- **równe** – zwykła średnia,
- **PR-AUC** – $w_k \propto \mathrm{AP}_k^{wal}$,
- **skill** – $w_k \propto \max(0,\ \mathrm{AP}_k^{wal} - \pi)$, gdzie π to udział anomalii: wagę dostaje tylko przewaga nad losowym rankingiem, a detektor nie lepszy od losowego dostaje 0,
- **skill** $\times$ **różnorodność** – skill pomnożony przez $1 - \bar{\rho}_k$, gdzie $\bar{\rho}_k$ to średnia korelacja Spearmana wyników detektora k z pozostałymi (na walidacji),

oraz **maksimum** znormalizowanych wyników (klasyczna alternatywa dla średniej). Każdy schemat zbadano dla wszystkich detektorów i dla podzbioru wybranego zachłannie na walidacji. Próg decyzji wyznaczano dwoma kryteriami: (1) maksymalizacja F1 na walidacji (używa etykiet walidacji; F1 równoważy Precision i Recall, a próg wybrany wprost pod raportowaną metrykę jest najprostszy do uzasadnienia), (2) kwantyl $1 - c$ zfuzjowanych wyników walidacyjnych przy $c = 0{,}1$ (nie używa etykiet, wymaga jedynie znajomości oczekiwanego udziału anomalii).

4.4 Warianty własne

DSF – *diversity-weighted skill fusion* (wersja 1). Pierwotna propozycja opierała się na założeniu, że zespół zyskuje na detektorach, które są dobre *i* wnoszą informację niedostępną dla innych. Składa się z rangowej normalizacji (dopasowanej na walidacji), wag $w_k \propto \max(0, \mathrm{AP}_k - \pi) \cdot (1 - \bar{\rho}_k)$ oraz zachłannego wyboru detektorów. Wybór zaczyna od detektora o najlepszej walidacyjnej PR-AUC i dodaje kolejne, dopóki poprawiają walidacyjną PR-AUC fuzji o więcej niż 10^{-3}. Próg wybierany jest przez maksymalizację F1 na walidacji.

CBF – *competence-based fusion* (wersja 2). Analiza niepowodzeń DSF (sekcja 5.6) pokazała trzy problemy: (a) na walidacji zawierającej 4–16 anomalii zachłanny wybór i ciągłe wagi dopasowują się do szumu, (b) człon różnorodności nagradza detektory *słabe*, bo słaby detektor jest z definicji mało skorelowany z dobrymi, (c) normalizacja rangowa nasyca się powyżej zakresu próby, na której ją dopasowano. CBF odpowiada wprost na te problemy:

1. Dla każdego detektora szacuje *niepewność* jego walidacyjnej PR-AUC metodą bootstrap (500 prób losowanych ze zwracaniem osobno z anomalii i obserwacji normalnych części walidacyjnej).
2. Za *kompetentne* uznaje detektory, które w co najmniej 10 % prób bootstrapowych są nie gorsze od detektora najlepszego na walidacji, czyli te, o których dane nie pozwalają powiedzieć, że są gorsze.
3. Detektory kompetentne uśrednia z *równymi* wagami. Równe wagi nie wymagają estymacji, a różnic w jakości i tak nie da się wiarygodnie zmierzyć. Detektory wyraźnie gorsze odrzuca.
4. Normalizuje odpornym z-score dopasowanym na wynikach walidacyjnych, który nie nasyca się i nie zależy od skrajnych wartości.
5. Próg decyzyjny wybiera przez maksymalizację F1 na walidacji.

Gdy jeden detektor wyraźnie dominuje, CBF sprowadza się do niego. Gdy kilka jest nieodróżnialnych, uśrednia je i zmniejsza wariancję. Jest to zasada „uśredniaj tylko to, czego nie umiesz rozróżnić”.

5 Wyniki

5.1 Pełna tabela wyników

Tabela 3: Wyniki wszystkich wariantów (część testowa, ziarna 0–9, średnia ± odchylenie std.). Czas – łączny czas przygotowania reprezentacji, uczenia i oceny wykorzystanych detektorów oraz agregacji. Pogrubienie – najlepsza wartość na zbiorze.

Zbiór	Wariant	Prec.	Rec.	F1	ROC-AUC	PR-AUC	Czas [ms]
Breast Cancer	IForest	0,682	0,710	0,689 ± 0,106	0,918	0,716 ± 0,110	199
	LOF	0,832	0,700	0,726 ± 0,150	0,942	0,835 ± 0,093	4
	OCSVM	0,872	0,710	0,770 ± 0,069	0,944	**0,840 ± 0,100**	3
	PCA (rekonstr.)	0,395	0,610	0,436 ± 0,076	0,843	0,495 ± 0,123	1
	Najlepszy pojedynczy (wal.)	0,832	0,750	0,775 ± 0,062	0,944	0,836 ± 0,097	4
	MV 1/4	0,426	0,800	0,533 ± 0,111	0,877	0,691 ± 0,121	208
	MV 2/4	0,750	0,760	0,739 ± 0,059	0,877	0,691 ± 0,121	208
	MV 3/4	0,855	0,670	0,735 ± 0,110	0,877	0,691 ± 0,121	208
	MV 4/4	0,888	0,500	0,605 ± 0,209	0,877	0,691 ± 0,121	208

Zbiór	Wariant	Prec.	Rec.	F1	ROC-AUC	PR-AUC	Czas [ms]
	Fuzja: maksimum	0,653	0,770	0,696 ± 0,081	0,916	0,629 ± 0,122	208
	Fuzja: średnia	0,720	0,700	0,679 ± 0,112	0,934	0,772 ± 0,130	209
	Fuzja: wagi PR-AUC	0,800	0,630	0,690 ± 0,102	0,936	0,790 ± 0,128	211
	Fuzja: wagi skill	0,808	0,620	0,687 ± 0,101	0,937	0,795 ± 0,126	211
	DSF (własna, wersja 1)	0,838	0,720	0,760 ± 0,070	0,944	0,815 ± 0,101	34
	CBF (własna)	0,846	0,750	**0,778 ± 0,071**	0,944	0,834 ± 0,094	87
Ionosphere	IForest	0,800	0,752	0,760 ± 0,105	0,965	0,889 ± 0,087	191
	LOF	0,786	0,748	0,741 ± 0,147	0,965	0,848 ± 0,131	10
	OCSVM	0,842	0,781	0,797 ± 0,089	0,954	0,900 ± 0,089	3
	PCA (rekonstr.)	0,933	0,862	**0,881 ± 0,096**	0,966	**0,926 ± 0,098**	2
	Najlepszy pojedynczy (wal.)	0,848	0,769	0,790 ± 0,134	0,963	0,898 ± 0,094	78
	MV 1/4	0,655	0,890	0,750 ± 0,115	0,937	0,858 ± 0,112	206
	MV 2/4	0,878	0,876	0,866 ± 0,096	0,937	0,858 ± 0,112	206
	MV 3/4	0,928	0,736	0,808 ± 0,120	0,937	0,858 ± 0,112	206
	MV 4/4	0,988	0,640	0,761 ± 0,130	0,937	0,858 ± 0,112	206
	Fuzja: maksimum	0,788	0,738	0,747 ± 0,127	0,960	0,838 ± 0,121	206
	Fuzja: średnia	0,929	0,829	0,864 ± 0,127	0,968	0,908 ± 0,106	207
	Fuzja: wagi PR-AUC	0,929	0,829	0,864 ± 0,127	0,969	0,915 ± 0,111	209
	Fuzja: wagi skill	0,929	0,829	0,864 ± 0,127	0,969	0,915 ± 0,111	209
	DSF (własna, wersja 1)	0,893	0,736	0,778 ± 0,137	0,961	0,859 ± 0,111	108
	CBF (własna)	0,948	0,829	0,869 ± 0,078	0,969	0,922 ± 0,097	168
Parkinsons	IForest	0,211	0,325	0,200 ± 0,126	0,655	0,244 ± 0,108	607
	LOF	0,256	0,325	0,215 ± 0,177	0,673	0,298 ± 0,226	118
	OCSVM	0,481	0,300	0,303 ± 0,292	0,609	0,335 ± 0,222	102
	PCA (rekonstr.)	0,292	0,300	0,222 ± 0,180	0,609	0,293 ± 0,190	1
	Najlepszy pojedynczy (wal.)	0,421	0,250	0,239 ± 0,192	0,652	0,338 ± 0,236	106
	MV 1/4	0,167	0,625	0,236 ± 0,183	0,604	0,293 ± 0,186	829
	MV 2/4	0,363	0,400	**0,326 ± 0,220**	0,604	0,293 ± 0,186	829
	MV 3/4	0,483	0,175	0,233 ± 0,202	0,604	0,293 ± 0,186	829
	MV 4/4	0,125	0,050	0,065 ± 0,142	0,604	0,293 ± 0,186	829
	Fuzja: maksimum	0,234	0,275	0,232 ± 0,241	0,611	0,246 ± 0,225	829
	Fuzja: średnia	0,506	0,300	0,316 ± 0,269	0,653	**0,352 ± 0,237**	829
	Fuzja: wagi PR-AUC	0,438	0,225	0,256 ± 0,300	0,637	0,343 ± 0,236	831
	Fuzja: wagi skill	0,399	0,275	0,269 ± 0,303	0,640	0,349 ± 0,236	831
	DSF (własna, wersja 1)	0,235	0,200	0,175 ± 0,221	0,640	0,290 ± 0,190	208
	CBF (własna)	0,294	0,300	0,236 ± 0,233	0,618	0,277 ± 0,204	310
Synthetic	IForest	1,000	0,680	0,806 ± 0,067	0,853	0,753 ± 0,081	205
	LOF	0,814	0,864	**0,831 ± 0,042**	0,991	**0,929 ± 0,036**	58
	OCSVM	0,785	0,624	0,666 ± 0,087	0,959	0,818 ± 0,067	6
	PCA (rekonstr.)	1,000	0,684	0,809 ± 0,067	0,807	0,738 ± 0,084	2
	Najlepszy pojedynczy (wal.)	0,814	0,864	**0,831 ± 0,042**	0,991	**0,929 ± 0,036**	58
	MV 1/4	0,757	0,896	0,813 ± 0,067	0,942	0,860 ± 0,061	271
	MV 2/4	0,876	0,732	0,789 ± 0,059	0,942	0,860 ± 0,061	271
	MV 3/4	1,000	0,660	0,792 ± 0,069	0,942	0,860 ± 0,061	271
	MV 4/4	1,000	0,564	0,712 ± 0,120	0,942	0,860 ± 0,061	271
	Fuzja: maksimum	0,898	0,708	0,786 ± 0,077	0,974	0,867 ± 0,054	271
	Fuzja: średnia	0,893	0,656	0,749 ± 0,055	0,930	0,808 ± 0,068	272
	Fuzja: wagi PR-AUC	0,870	0,656	0,737 ± 0,057	0,938	0,816 ± 0,069	274
	Fuzja: wagi skill	0,873	0,656	0,739 ± 0,059	0,939	0,817 ± 0,069	274
	DSF (własna, wersja 1)	0,813	0,852	0,823 ± 0,052	0,991	0,920 ± 0,038	67

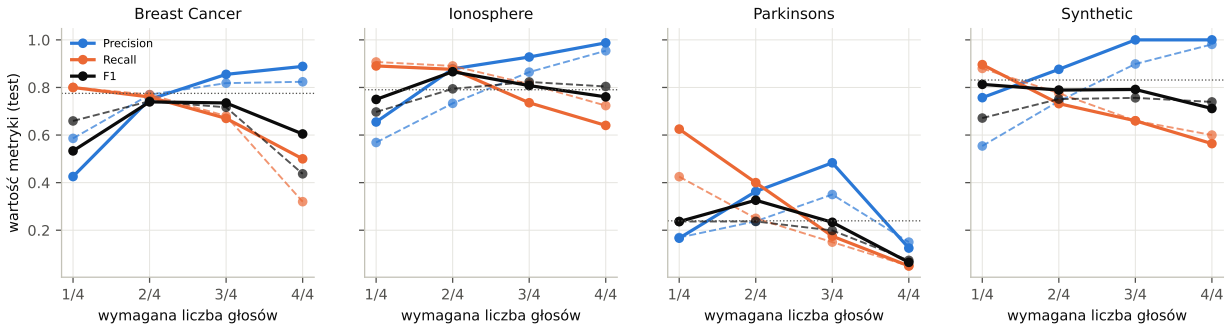
Zbiór	Wariant	Prec.	Rec.	F1	ROC-AUC	PR-AUC	Czas [ms]
	CBF (własna)	0,814	0,864	**0,831 ± 0,042**	0,991	**0,929 ± 0,036**	59

Najważniejsze obserwacje z tabeli 3:

- **Żaden wariant zespołowy nie przewyższa wyraźnie najlepszego pojedynczego detektora na wszystkich zbiorach.** Na Ionosphere zespoły wygrywają: CBF ma PR-AUC 0,922 i F1 0,869, MV 2/4 F1 0,866, a najlepszy pojedynczy detektor PR-AUC 0,898 i F1 0,790. Na Breast Cancer i zbiorze syntetycznym zwykłe uśrednianie przegrywa (fuzja średnia na zbiorze syntetycznym 0,808 wobec 0,929). Na Parkinsons wyniki wszystkich wariantów mieszczą się w szumie.
- **CBF dorównuje najlepszemu pojedynczemu detektorowi lub go przewyższa na trzech zbiorach** (Breast Cancer 0,834 wobec 0,836, Ionosphere 0,922 wobec 0,898, syntetyczny 0,929 wobec 0,929) i ma najwyższe średnie F1 spośród fuzji (0,679 wobec 0,659 najlepszego pojedynczego). Przegrywa na Parkinsons (0,277 wobec 0,338).
- **Majority Voting** poprawia F1 tam, gdzie detektory są porównywalnie dobre (Ionosphere +0,08, Parkinsons +0,09), ale traci na Breast Cancer i zbiorze syntetycznym, a jego ranking (liczba głosów, tylko 5 poziomów) daje niską PR-AUC.
- Fuzja przez **maksimum** (z rangami) jest najgorszym schematem (średnio 0,645): wzmacnia fałszywe alarmy każdego detektora.

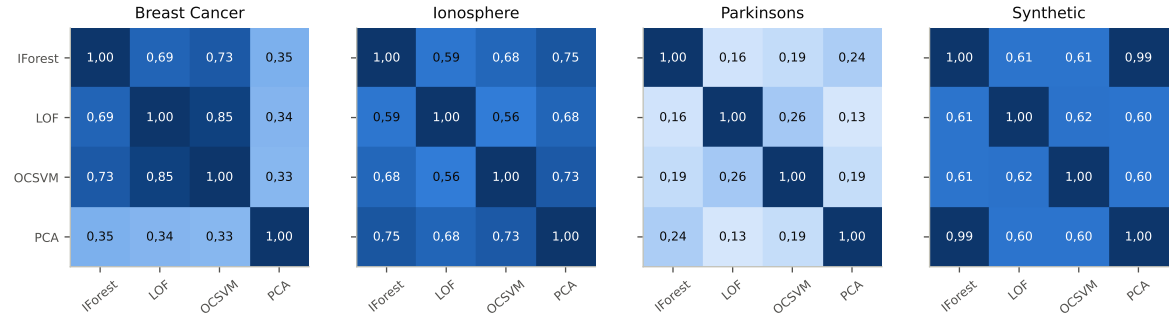
5.2 Majority Voting: wpływ progu

Rysunek 2 pokazuje klasyczny kompromis. Zwiększanie liczby wymaganych głosów podnosi Precision (Ionosphere: 0,66 przy 1/4, 0,88 przy 2/4, 0,93 przy 3/4, 0,99 przy 4/4) i obniża Recall (0,89 → 0,88 → 0,74 → 0,64). F1 jest najwyższe przy $m = 2$ na trzech zbiorach. Reguła AND ($m = 4$) jest zbyt restrykcyjna: na Parkinsons, gdzie detektory rzadko się zgadzają (Jaccard 0,13–0,26), Recall spada do 0,05. Reguła OR ($m = 1$) daje najwyższy Recall, ale sumuje fałszywe alarmy wszystkich detektorów. Na zbiorze syntetycznym próg $m \geq 2$ przekreśla wykrywanie anomalii lokalnych: wykrywa je tylko LOF, więc nie zbierają drugiego głosu (Recall lokalnych 0,66 dla LOF, 0,18 dla MV 2/4, 0 dla MV 3/4). Progi wyznaczane z contamination (linie przerywane) są nieco gorsze od progów z walidacyjnego F1, ale nie wymagają etykiet.



Rysunek 2: Majority Voting: Precision, Recall i F1 w zależności od wymaganej liczby głosów (linie ciągłe – progi detektorów z walidacyjnego F1, przerywane – z contamination 0,1); linia kropkowana – F1 najlepszego pojedynczego detektora.

5.3 Zgodność i komplementarność detektorów

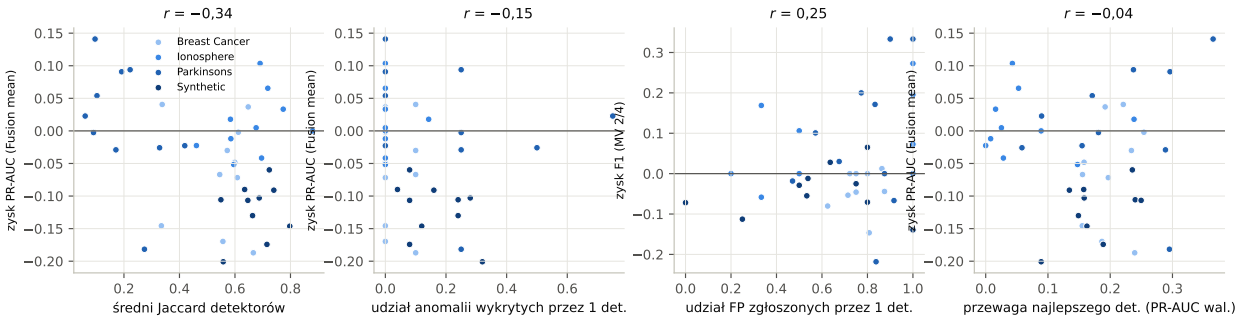


Rysunek 3: Indeks Jaccarda zbiorów obserwacji testowych oznaczonych przez pary detektorów bazowych (średnia z 10 podziałów).

Rysunek 3 pokazuje bardzo różną strukturę zgodności na poszczególnych zbiorach:

- **Breast Cancer**: LOF, OCSVM i IForest działają na tej samej, jednej składowej PCA i są silnie zgodne (Jaccard 0,69–0,85), więc nie są komplementarne. Błąd rekonstrukcji PCA jest od nich niezależny (0,33–0,35), ale słaby (PR-AUC 0,50). Zespół nie ma tu z czego zyskać – dodanie słabego, niezależnego detektora tylko szkodzi.
- **Ionosphere**: wszystkie detektory są dobre (PR-AUC 0,85–0,93) i umiarkowanie zgodne (0,56–0,75). To jedyny zbiór, na którym wszystkie warianty fuzji poprawiają wynik najlepszego detektora: wspólne trafienia się sumują, a indywidualne błędy wzajemnie znoszą.
- **Parkinsons**: detektory niemal się nie zgadzają (0,13–0,26), bo każdy z nich jest słaby (PR-AUC 0,24–0,34). Niska zgodność nie oznacza tu komplementarności, tylko losowość błędów.
- **Zbiór syntetyczny**: IForest i błąd rekonstrukcji PCA są niemal identyczne (Jaccard 0,99 – oba wykrywają anomalie globalne i podprzestrzenne), a LOF jako jedyny wykrywa anomalie lokalne. Detektory *są* komplementarne, ale tak, że głos LOF w sprawie anomalii lokalnych zostaje przegłosowany przez trzy pozostałe.

Rysunek 4 zestawia miary komplementarności z zyskiem zespołu na poziomie pojedynczych podziałów. Korelacje są słabe ($|r| \leq 0{,}34$): przy 4–16 anomaliach w części testowej zysk w pojedynczym podziale jest silnie zaszumiony. Jedyny wyraźny wzorzec widać na poziomie zbiorów. Ionosphere ma najmniejszą przewagę najlepszego detektora na walidacji (0,065 PR-AUC wobec 0,18–0,21 na pozostałych zbiorach) i jako jedyny zyskuje na fuzji.



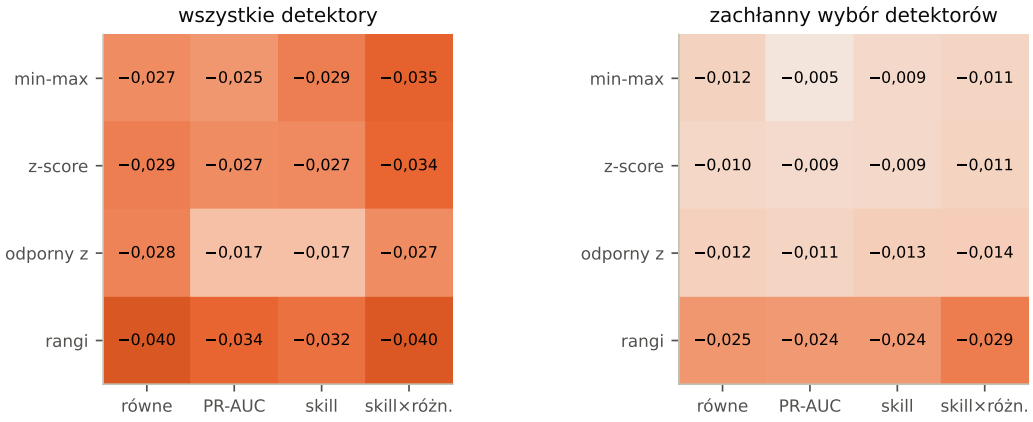
Rysunek 4: Zysk zespołu względem najlepszego pojedynczego detektora (wybranego na walidacji) w poszczególnych podziałach a miary komplementarności: średni Jaccard decyzji, udział anomalii wykrytych przez dokładnie jeden detektor, udział fałszywych alarmów zgłoszonych przez jeden detektor oraz przewaga najlepszego detektora na walidacji.

5.4 Wpływ normalizacji, wag, wyboru detektorów i progu

Tabela 5 i rys. 5 przedstawiają pełną ablację fuzji: 4 normalizacje × 4 schematy wag × 2 sposoby wyboru detektorów × 2 kryteria progu.

Tabela 5: Ablacja fuzji wyników (normalizacja dopasowana na walidacji): średnia PR-AUC i F1 z 4 zbiorów (test) oraz różnica względem najlepszego pojedynczego detektora (Δ); F1 dla progu z walidacyjnego F1 i dla progu z contamination; „Wygrane" – liczba zbiorów, na których fuzja ma wyższą PR-AUC niż najlepszy pojedynczy detektor.

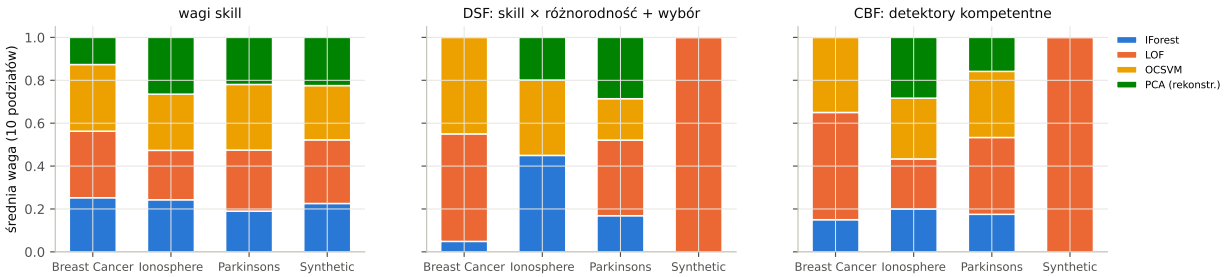
Normalizacja	Wagi	Detektory	PR-AUC	ΔPR-AUC	F1 (próg wal.)	ΔF1	F1 (próg c)	Wygrane (z 4)
min-max	równe	wszystkie	0,724	−0,027	0,645	−0,014	0,647	2
min-max	równe	zachłanny wybór	0,739	−0,012	0,637	−0,022	0,651	2
min-max	PR-AUC	wszystkie	0,725	−0,025	0,638	−0,021	0,643	2
min-max	PR-AUC	zachłanny wybór	0,746	−0,005	0,639	−0,020	0,651	2
min-max	skill	wszystkie	0,721	−0,029	0,642	−0,017	0,639	1
min-max	skill	zachłanny wybór	0,741	−0,009	0,639	−0,020	0,652	2
min-max	skill×różn.	wszystkie	0,715	−0,035	0,640	−0,019	0,636	1
min-max	skill×różn.	zachłanny wybór	0,740	−0,011	0,639	−0,020	0,652	2
z-score	równe	wszystkie	0,721	−0,029	0,659	−0,000	0,642	2
z-score	równe	zachłanny wybór	0,741	−0,010	0,637	−0,022	0,651	1
z-score	PR-AUC	wszystkie	0,723	−0,027	0,639	−0,020	0,645	1
z-score	PR-AUC	zachłanny wybór	0,742	−0,009	0,638	−0,021	0,653	1
z-score	skill	wszystkie	0,723	−0,027	0,639	−0,020	0,644	1
z-score	skill	zachłanny wybór	0,741	−0,009	0,638	−0,021	0,653	1
z-score	skill×różn.	wszystkie	0,717	−0,034	0,633	−0,026	0,635	1
z-score	skill×różn.	zachłanny wybór	0,739	−0,011	0,638	−0,021	0,653	1
odporny z	równe	wszystkie	0,722	−0,028	0,661	+0,002	0,648	1
odporny z	równe	zachłanny wybór	0,738	−0,012	0,648	−0,011	0,655	1
odporny z	PR-AUC	wszystkie	0,733	−0,017	0,656	−0,003	0,644	1
odporny z	PR-AUC	zachłanny wybór	0,740	−0,011	0,639	−0,020	0,644	1
odporny z	skill	wszystkie	0,733	−0,017	0,657	−0,002	0,642	1
odporny z	skill	zachłanny wybór	0,737	−0,013	0,638	−0,021	0,645	1
odporny z	skill×różn.	wszystkie	0,724	−0,027	0,672	+0,013	0,636	1
odporny z	skill×różn.	zachłanny wybór	0,737	−0,014	0,639	−0,021	0,644	1
rangi	równe	wszystkie	0,710	−0,040	0,652	−0,007	0,626	2
rangi	równe	zachłanny wybór	0,725	−0,025	0,639	−0,020	0,655	0
rangi	PR-AUC	wszystkie	0,716	−0,034	0,637	−0,022	0,614	2
rangi	PR-AUC	zachłanny wybór	0,726	−0,024	0,634	−0,025	0,645	0
rangi	skill	wszystkie	0,719	−0,032	0,640	−0,019	0,615	2
rangi	skill	zachłanny wybór	0,726	−0,024	0,634	−0,025	0,646	0
rangi	skill×różn.	wszystkie	0,711	−0,040	0,624	−0,035	0,606	2
rangi	skill×różn.	zachłanny wybór	0,721	−0,029	0,634	−0,025	0,645	0



Rysunek 5: Zmiana średniej PR-AUC fuzji względem najlepszego pojedynczego detektora w zależności od normalizacji i wag (lewo – wszystkie detektory, prawo – zachłanny wybór).

- **Normalizacja**: min-max, z-score i odporny z-score dają zbliżoną PR-AUC (różnice do 0,01), a rangi są we wszystkich schematach najgorsze (o ok. 0,01–0,02). W F1 przy fuzji wszystkich detektorów najlepszy jest odporny z-score (0,656–0,672 wobec 0,633–0,659 dla pozostałych). Wyjaśnienie słabości rang: przy 40–125 punktach walidacyjnych dystrybuanta empiryczna jest schodkowa i nasyca się w 1 dla najbardziej skrajnych obserwacji testowych – dokładnie tam, gdzie PR-AUC jest najbardziej czuła. Min-max i z-score są wrażliwe na pojedyncze skrajne wartości w próbie, do której są dopasowywane.
- **Wagi**: różnice między schematami są małe (do 0,02), mniejsze niż wpływ normalizacji i wyboru detektorów. Wagi „skill × różnorodność" są najgorsze, bo premiują słabe detektory.
- **Wybór detektorów**: zachłanny wybór poprawia średnią PR-AUC (np. rangi, równe wagi: 0,710 → 0,725), bo usuwa słabe detektory (błąd rekonstrukcji na Breast Cancer). Jednocześnie obniża F1 i nigdy nie wygrywa z najlepszym detektorem na więcej niż 2 zbiorach – dopasowuje się do szumu małej walidacji.
- **Próg**: próg z walidacyjnego F1 i z contamination dają podobne średnie F1 (0,61–0,67). Próg z contamination jest stabilniejszy, gdy walidacja ma bardzo mało anomalii, a próg z F1 lepiej dopasowuje się do zbioru, gdy anomalii jest więcej.

5.5 Wagi i wybór detektorów w wariantach własnych



Rysunek 6: Średnie wagi detektorów (10 podziałów) w fuzji z wagami skill, w DSF i w CBF.

Rysunek 6 pokazuje różnicę między wariantami. Wagi skill rozkładają się na wszystkie detektory, także słabe (rekonstrukcja PCA na Breast Cancer). DSF dzięki zachłannemu wyborowi często zostawia jeden lub dwa detektory, ale ich wybór zmienia się między podziałami. CBF na zbiorze syntetycznym we wszystkich 10 podziałach wybiera wyłącznie LOF (jego przewaga jest istotna), na Breast Cancer – LOF i OCSVM (w 5 podziałach) lub te dwa z IForest, na Ionosphere – najczęściej wszystkie cztery (8 z 10 podziałów). Wybory CBF są zgodne z intuicją: odrzuca dokładnie te detektory, które w tabeli 3 są wyraźnie słabsze.

5.6 Przypadki poprawy i pogorszenia

Tabela 6 porównuje decyzje zespołów z decyzjami najlepszego pojedynczego detektora dla każdej obserwacji testowej.

Tabela 6: Analiza przypadków (część testowa, suma po 10 podziałach): anomalie wykryte przez zespół, a pominięte przez najlepszy pojedynczy detektor („uratowane"), i odwrotnie („utracone"), oraz fałszywe alarmy usunięte i dodane przez zespół.

Zbiór	Zespół	Anomalie	Uratowane	Utracone	FP najl. pojed.	FP usunięte	FP dodane
Breast Cancer	MV 2/4	100	1	0	19	0	11
	MV 3/4	100	0	8	19	5	0
	Fuzja: średnia	100	4	9	19	4	22
	DSF (własna, wersja 1)	100	0	3	19	2	0
	CBF (własna)	100	1	1	19	1	0
Ionosphere	MV 2/4	64	7	0	10	2	2
	MV 3/4	64	3	5	10	5	0
	Fuzja: średnia	64	6	2	10	6	1
	DSF (własna, wersja 1)	64	1	3	10	2	0
	CBF (własna)	64	6	2	10	5	0
Parkinsons	MV 2/4	40	6	0	32	9	28
	MV 3/4	40	2	5	32	18	8
	Fuzja: średnia	40	5	3	32	21	13
	DSF (własna, wersja 1)	40	0	2	32	9	1
	CBF (własna)	40	4	2	32	8	24
Synthetic	MV 2/4	250	6	39	54	25	0
	MV 3/4	250	1	52	54	54	0
	Fuzja: średnia	250	5	57	54	44	12
	DSF (własna, wersja 1)	250	0	3	54	0	0
	CBF (własna)	250	0	0	54	0	0

Kiedy zespół pomaga. Na Ionosphere fuzja średnia i CBF „ratują" 6 anomalii, tracąc tylko 2, i usuwają 5–6 z 10 fałszywych alarmów. Detektory są tam porównywalnie dobre i ich błędy są w dużej mierze indywidualne. Uśrednienie zmniejsza wariancję wyniku, co jest klasycznym mechanizmem działania zespołów. MV 2/4 ratuje 7 anomalii bez żadnej straty.

Kiedy zespół szkodzi. Na zbiorze syntetycznym fuzja średnia traci 57 anomalii (Recall anomalii lokalnych spada z 0,66 do 0,02), a MV 3/4 – 52. Mechanizm to *rozmycie unikalnej informacji*: anomalie lokalne wykrywa wyłącznie LOF, a trzy pozostałe detektory oceniają je jako normalne. W średniej wysoki wynik LOF zostaje rozcieńczony do poziomu obserwacji normalnych, a w głosowaniu – przegłosowany. Komplementarność, która miała być zaletą zespołu, staje się jego wadą, gdy agregacja traktuje odosobniony głos jako błąd. Na Breast Cancer fuzja średnia dodaje 22 fałszywe alarmy, bo do trzech zgodnych, dobrych detektorów dochodzi słaby, niezależny (rekonstrukcja PCA), którego błędy przesuwają wyniki obserwacji normalnych.

Dlaczego DSF zawiodło. DSF traci mało anomalii, ale też prawie nic nie zyskuje. Na Ionosphere jego PR-AUC (0,859) jest niższa od fuzji średniej (0,908): zachłanny wybór dopasowany do walidacji z 6 anomaliami zostawia jeden lub dwa detektory i traci korzyść z uśredniania. Człon różnorodności $1 - \bar{\rho}_k$ zwiększa wagi detektorów słabych, bo słaby detektor jest mało skorelowany z dobrymi. Normalizacja rangowa nasyca się dla skrajnych punktów testowych. Te trzy obserwacje doprowadziły do CBF.

Dlaczego CBF zawodzi na Parkinsons. Część walidacyjna zawiera 4 anomalie, więc bootstrap PR-AUC ma ogromną wariancję i zbiór „kompetentnych" detektorów zmienia się między podziałami (7 różnych kombinacji w 10 podziałach). Co więcej, detektory bazowe na Parkinsons działają na UMAP wybranym przez przeuczenie w zadaniu 2. Przy tak małej walidacji żadna metoda doboru wag nie ma wystarczającej informacji i najbezpieczniejsza jest zwykła średnia (0,352, jedna z najwyższych PR-AUC na tym zbiorze).

5.7 Test potwierdzający na nowych podziałach

Tabela 7: Średnie PR-AUC i F1 (4 zbiory, część testowa) na podziałach użytych przy projektowaniu (ziarna 0–9) i na nowych podziałach (ziarna 10–19); „Lepszy niż najl." – liczba zbiorów, na których PR-AUC wariantu jest wyższa niż najlepszego pojedynczego detektora.

Wariant	PR-AUC (0–9)	F1 (0–9)	Lepszy niż najl. (0–9)	PR-AUC (10–19)	F1 (10–19)	Lepszy niż najl. (10–19)
Najlepszy pojedynczy (wal.)	0,750	0,659	0	0,794	0,678	0
MV 2/4	0,675	0,680	0	0,658	0,629	0
Fuzja: średnia	0,710	0,652	2	0,716	0,626	1
Fuzja: wagi skill	0,719	0,640	2	0,736	0,646	1
DSF (własna, wersja 1)	0,721	0,634	0	0,773	0,650	0
CBF (własna)	0,741	0,679	1	0,772	0,671	2

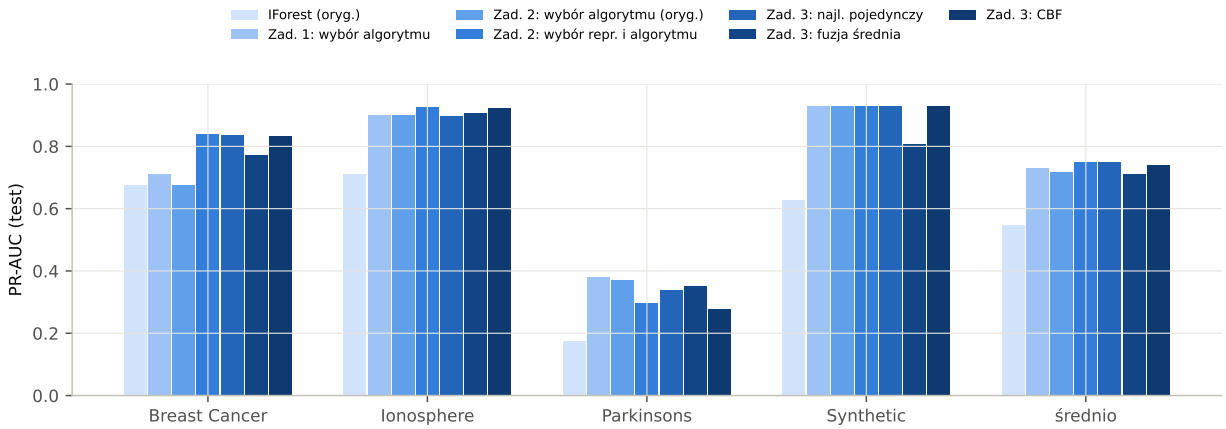
Na nowych podziałach (tabela 7) potwierdza się, że CBF jest najlepszym wariantem zespołowym: PR-AUC 0,772, F1 0,671. Wyprzedza fuzję średnią (0,716; 0,626), wagi skill (0,736; 0,646) i MV 2/4 (0,658; 0,629), a w PR-AUC jest wyższy od najlepszego pojedynczego detektora na 2 z 4 zbiorów. Średnio jednak **nadal nie przewyższa najlepszego pojedynczego detektora** (0,794; 0,678), głównie z powodu Parkinsons (0,358 wobec 0,473). Przewaga MV 2/4 w F1 z ziaren 0–9 (0,680 wobec 0,659) **nie potwierdziła się** (0,629 wobec 0,678). Był to efekt konkretnych podziałów, a nie stała właściwość metody. DSF na nowych podziałach wypada lepiej (0,773), ale wciąż przegrywa z najlepszym detektorem na wszystkich zbiorach. Test potwierdzający pokazuje, jak łatwo przy 10 podziałach małych zbiorów uznać przypadkową różnicę za efekt metody.

5.8 Porównanie z zadaniami 1 i 2

Tabela 8 przedstawia PR-AUC uzyskaną na kolejnych etapach projektu na tych samych podziałach (ziarna 0–9). Każdy wybór dokonywany jest na walidacji.

Tabela 8: PR-AUC (test) na kolejnych etapach projektu: domyślny Isolation Forest w danych oryginalnych, wybór algorytmu (zad. 1 i 2), wybór reprezentacji i algorytmu (zad. 2), najlepszy pojedynczy detektor bazowy oraz zespoły (zad. 3).

Etap	Breast Cancer	Ionosphere	Parkinsons	Synthetic	Średnio
IForest (oryg.)	0,677	0,712	0,176	0,626	0,548
Zad. 1: wybór algorytmu	0,710	0,900	0,380	0,929	0,730
Zad. 2: wybór algorytmu (oryg.)	0,677	0,900	0,370	0,929	0,719
Zad. 2: wybór repr. i algorytmu	0,840	0,926	0,298	0,929	0,748
Zad. 3: najl. pojedynczy	0,836	0,898	0,338	0,929	0,750
Zad. 3: fuzja średnia	0,772	0,908	0,352	0,808	0,710
Zad. 3: CBF	0,834	0,922	0,277	0,929	0,741



Rysunek 7: PR-AUC (test) na kolejnych etapach trzech zadań.

Największy skok jakości daje **wybór algorytmu** w zadaniu 1: średnia PR-AUC rośnie z 0,548 (domyślny Isolation Forest) do 0,730. Wybór reprezentacji w zadaniu 2 dodaje średnio ok. 0,03 (0,719 → 0,748), ale nierówno. Duży zysk daje na Breast Cancer (0,68 → 0,84, PCA z jedną składową), a na Parkinsons strata (0,37 → 0,30), bo walidacja wybrała przeuczony UMAP. Zespół (zadanie 3) nie poprawia średniej (CBF 0,741, fuzja średnia 0,710 wobec 0,750). Poprawia tylko Ionosphere (0,922 wobec 0,898).

6 Synteza: co miało największy wpływ na jakość detekcji?

Tabela 9 przedstawia dwa rodzaje miar wpływu na PR-AUC. Pierwszy to *rozrzut* (maksimum − minimum), który mówi, ile można zyskać lub stracić danym wyborem. Drugi to *zrealizowany zysk* z zespołu przy wyborze na walidacji.

Tabela 9: Wpływ czynników na PR-AUC (test): rozrzut między algorytmami (5 metod z zad. 1; 3 detektory w danych oryginalnych z zad. 2), średni rozrzut jednego detektora między reprezentacjami (zad. 2) oraz zysk zespołu względem najlepszego pojedynczego detektora wybranego na walidacji (zad. 3).

Zbiór	Algorytm (Zad. 1, 5 metod)	Algorytm (Zad. 2, oryg.)	Reprezentacja	Zespół: średnia	Zespół: CBF
Breast Cancer	0,096	0,010	0,168	−0,064	−0,002
Ionosphere	0,201	0,188	0,459	+0,010	+0,024
Parkinsons	0,236	0,194	0,084	+0,014	−0,061
Synthetic	0,294	0,303	0,512	−0,121	+0,000
średnio	0,207	0,174	0,305	−0,040	−0,010

Odpowiedź. Na podstawie wyników trzech zadań:

1. **Największy zrealizowany wpływ ma wybór algorytmu.** Dopasowanie mechanizmu detektora do typu wyjątków podnosi średnią PR-AUC o 0,18 (0,548 → 0,730). Rozrzut między algorytmami na tym samym zbiorze wynosi średnio 0,21 (do 0,29 na zbiorze syntetycznym, gdzie występują wyjątki lokalne widoczne tylko dla LOF). Kluczowa jest zgodność mechanizmu metody z naturą anomalii: lokalne – LOF, globalne i rozproszone – OCSVM, rekonstrukcja, IForest.
2. **Reprezentacja ma największy rozrzut (średnio 0,31), ale głównie w dół.** Zła reprezentacja (UMAP) potrafi zniszczyć detekcję (Ionosphere: IForest 0,89 → 0,14), a dobra (PCA) daje istotną poprawę tylko na części zbiorów (Breast Cancer +0,16, Isolation Forest wszędzie). Zrealizowany zysk przy wyborze na walidacji to średnio ok. 0,03, a wybór spośród wielu wariantów reprezentacji na małej walidacji łatwo się przeucza (Parkinsons).

3. **Połączenie detektorów ma najmniejszy wpływ.** Najlepszy wariant (CBF) zmienia średnią PR-AUC o $-0{,}01$ (na nowych podziałach $-0{,}02$), a zwykła średnia o $-0{,}04$. Zespół pomaga tylko wtedy, gdy detektory są porównywalnie dobre i popełniają różne błędy (Ionosphere). Zespół źle zaprojektowany potrafi zaszkodzić bardziej, niż dobrze zaprojektowany pomaga (fuzja średnia na zbiorze syntetycznym: $-0{,}12$).
4. Ponad wszystkimi trzema czynnikami stoi **natura danych**: rozrzut PR-AUC między zbiorami (0,38–0,93 dla najlepszej metody) jest większy niż efekt któregokolwiek wyboru. Na Parkinsons, gdzie „anomalie" nie są wyjątkami statystycznymi, nie pomógł ani algorytm, ani reprezentacja, ani zespół.

7 Rekomendacje: kiedy zespół, a kiedy pojedynczy detektor

- **Pojedynczy detektor**, gdy walidacja wyraźnie wskazuje zwycięzcę (przewaga istotna w bootstrapie, jak LOF na zbiorze syntetycznym) lub gdy jeden detektor jako jedyny wykrywa pewien typ anomalii. Uśrednianie rozmyje wtedy jego unikalny sygnał.
- **Zespół (średnia lub CBF)**, gdy kilka detektorów o różnych mechanizmach ma porównywalną jakość, a ich błędy są w dużej mierze indywidualne (Ionosphere). Uśrednianie obniża wtedy wariancję i liczbę fałszywych alarmów.
- **Majority Voting z progiem 2/4**, gdy priorytetem jest stabilna decyzja binarna, a nie ranking. Wyższe progi tylko przy bardzo wysokim koszcie fałszywego alarmu.
- **Nie stosować** fuzji przez maksimum ani wag nagradzających różnorodność bez kontroli jakości. Normalizację dopasowywać na wynikach *out-of-sample* (walidacja), a nie na wynikach części uczącej.
- **Bardzo mała walidacja** (kilka anomalii): unikać ciągłych wag i zachłannego wyboru. Najbezpieczniejsza jest prosta średnia lub pojedynczy, sprawdzony detektor.
- **CBF** jest rozsądnym wyborem domyślnym, gdy nie wiadomo, czy zespół pomoże. Z konstrukcji sprowadza się do najlepszego detektora, gdy ten wyraźnie dominuje, i do średniej, gdy detektory są nieodróżnialne. W teście potwierdzającym był najlepszym wariantem zespołowym.

8 Ograniczenia

- Małe zbiory (4–16 anomalii w części walidacyjnej) ograniczają wiarygodność każdej metody doboru wag i progów. Pokazał to test potwierdzający (różnica wyników MV 2/4 między ziarnami 0–9 i 10–19).
- CBF zaprojektowano po obejrzeniu wyników testowych dla ziaren 0–9. Test na ziarnach 10–19 częściowo usuwa ten problem, ale zbiory danych i detektory bazowe pozostały te same.
- Detektory bazowe przejęto z zadania 2 razem z jego błędami wyboru (UMAP na Parkinsons).
- Zbadano zespoły heterogeniczne złożone z 4 detektorów. Nie badano zespołów jednorodnych (np. wielu LOF o różnych k) ani uczenia meta-modelu (stacking) na walidacji, który przy tak małych zbiorach byłby silnie przeuczony.

9 Wnioski

1. Zespół detektorów nie jest automatycznie lepszy od najlepszego detektora. W tym projekcie żaden wariant zespołowy nie przewyższył go średnio, choć na Ionosphere zespoły wygrywały

wyraźnie (CBF: PR-AUC 0,922 wobec 0,898, F1 0,869 wobec 0,790).

2. O efekcie zespołu decyduje relacja między jakością a komplementarnością detektorów. Komplementarność pomaga, gdy błędy są indywidualne, a szkodzi, gdy unikalną wiedzę ma jeden detektor (anomalie lokalne – LOF) i agregacja ją przegłosowuje.
3. Normalizacja wyników jest ważniejsza niż schemat wag. Wyniki in-sample są przesunięte względem wyników nowych danych, a normalizacja rangowa dopasowana na nich niszczy ranking (maksimum: 0,415 $\rightarrow$ 0,645 po dopasowaniu na walidacji).
4. Własny wariant CBF (bootstrapowy wybór detektorów kompetentnych i równe wagi) okazał się najlepszym i najbardziej stabilnym wariantem zespołowym w obu seriach podziałów. Zawodzi tylko tam, gdzie walidacja jest zbyt mała, by ocenić kompetencję detektorów.
5. W skali całego projektu o jakości detekcji decydowały kolejno: natura danych, wybór algorytmu, reprezentacja i dopiero na końcu połączenie detektorów.

10 Odtworzenie wyników

```
python -m task3_ensemble.run_base                    # wymaga wyników zad. 2
python -m task3_ensemble.run_ensembles
python -m task3_ensemble.run_base --confirm          # ziarna 10-19
python -m task3_ensemble.run_ensembles --confirm
python -m task3_ensemble.analyze
```