Politechnika Łódzka
Wydział Fizyki Technicznej, Informatyki i Matematyki Stosowanej

Analiza danych złożonych z detekcją wyjątków

Zadanie 3

Zespołowa detekcja wyjątków:
projekt własnego rozwiązania

Jędrzej Kostyk
nr indeksu 264339

Rok akademicki 2026/2027

Spis treści

1 Cel i zakres **2**

2 Dane i protokół **2**

3 Detektory bazowe **2**

4 Metody agregacji **3**

4.1 Ujednolicenie wyników anomalii 3

4.2 Majority Voting 4

4.3 Weighted Score Fusion 4

4.4 Warianty własne 5

5 Wyniki **5**

5.1 Pełna tabela wyników 5

5.2 Majority Voting: wpływ progu 7

5.3 Zgodność i komplementarność detektorów 8

5.4 Wpływ normalizacji, wag, wyboru detektorów i progu 9

5.5 Wagi i wybór detektorów w wariantach własnych 10

5.6 Przypadki poprawy i pogorszenia 11

5.7 Test potwierdzający na nowych podziałach 12

5.8 Porównanie z zadaniami 1 i 2 12

6 Synteza: co miało największy wpływ na jakość detekcji? **13**

7 Rekomendacje: kiedy zespół, a kiedy pojedynczy detektor **14**

8 Ograniczenia **14**

9 Wnioski **15**

10 Odtworzenie wyników **15**

1 Cel i zakres

Celem zadania jest zaprojektowanie i ocena zespołowego systemu detekcji wyjątków, który łączy wyniki kilku detektorów o różnych zasadach działania. Sprawdzamy, czy agregacja przewyższa najlepszy pojedynczy detektor. Porównano trzy grupy rozwiązań:

1. **modele pojedyncze** – cztery detektory bazowe oceniane niezależnie (punkt odniesienia),
2. **głosowanie większościowe** (*Majority Voting*) z progami od 1/4 do 4/4 głosów,
3. **fuzja wyników** $S(x) = \sum_k w_k \, \hat{s}_k(x)$ z różnymi sposobami normalizacji, wag i wyboru detektorów, w tym dwa własne warianty: DSF i CBF.

Ostatnia część raportu (sekcja 6) zbiera wyniki wszystkich trzech zadań i odpowiada na pytanie przewodnie projektu: co miało największy wpływ na jakość detekcji – wybór algorytmu, reprezentacja danych czy połączenie detektorów.

Kod znajduje się w katalogu `task3_ensemble/`: normalizacja, wagi i agregacja w `ensemble.py`, detektory bazowe w `run_base.py`, warianty zespołów w `run_ensembles.py`, a tabele i rysunki w `analyze.py`.

2 Dane i protokół

Wykorzystano te same cztery zbiory benchmarkowe co w zadaniu 2: Cardio (ADBench [1]; UCI Cardiotocography [9]), Arrhythmia (ODDS [2]; UCI Arrhythmia [11]), WDBC (ADBench; UCI Breast Cancer Wisconsin (Diagnostic) [6]) i Campaign (ADBench; UCI Bank Marketing [10]). Dzięki temu porównanie z zadaniem 2 jest bezpośrednie. Dane i **etykiety anomalii pochodzą z benchmarków** bez żadnych modyfikacji (opis – raporty z zadań 1 i 2).

Protokół jest taki sam we wszystkich zadaniach: te same warstwowe podziały 50/25/25 % (10 podziałów dla Cardio i Arrhythmii, 30 dla WDBC, 5 dla Campaign), standaryzacja i reprezentacje dopasowywane na części uczącej, detektory uczone bez etykiet. **Część walidacyjna** służy do doboru progów poszczególnych detektorów, wag, podzbioru detektorów i progu decyzji zespołu. **Część testowa** nie jest używana do żadnej decyzji. Liczba anomalii w części walidacyjnej bardzo się różni między zbiorami: 2–3 w WDBC, ok. 17 w Arrhythmii, 44 w Cardio i 1160 w Campaign. Jak pokażą wyniki, ma to kluczowe znaczenie dla zespołów.

Wszystkie warianty zespołów, w tym oba warianty własne, zostały zdefiniowane z ustalonymi parametrami przed uruchomieniem ich na tych danych. Dodatkowo oceniono je na **nowych podziałach** (kolejny blok ziaren: 10–19 dla Cardio i Arrhythmii, 30–59 dla WDBC, 5–9 dla Campaign), nieużywanych w żadnym etapie wyboru konfiguracji. Stanowią one test potwierdzający (sekcja 5.7).

3 Detektory bazowe

Wybrano cztery detektory o różnych zasadach działania:

- **Isolation Forest** – izolacja losowymi cięciami,
- **LOF** – lokalna gęstość względem sąsiadów,
- **One-Class SVM** – granica obszaru danych w przestrzeni jądra RBF,
- **błąd rekonstrukcji PCA** – odległość od podprzestrzeni głównych składowych (wykrywa odchylenia w kierunkach o małej wariancji).

Zgodnie z zaleceniem, konfiguracje wybrano na podstawie wcześniejszych eksperymentów. Dla każdego zbioru i detektora przyjęto reprezentację i hiperparametry o najwyższej średniej PR-AUC

na walidacji w zadaniu 2 (tabela 1). Detektor bazowy to więc para *reprezentacja + algorytm*, np. OCSVM na dwuwymiarowym UMAP dla Cardio, LOF i OCSVM na jednej składowej PCA dla WDBC, LOF i OCSVM w przestrzeni latentnej autoenkodera dla Arrhythmii.

Tabela 1: Konfiguracje detektorów bazowych (wybór na walidacji w zadaniu 2).

Zbiór	Detektor	Reprezentacja	Parametry	PR-AUC wal. (Zad. 2)
Cardio	IForest	autoenkoder (z=16)	T=200	0,619
	LOF	PCA (k=1)	k=50	0,537
	OCSVM	UMAP (m=2, nn=50, md=0,0)	ν=0,50, γ=0,1/d	0,848
	PCA (rekonstr.)	PCA (k=20)	błąd rekonstrukcji	0,480
Arrhythmia	IForest	PCA (k=8)	T=200	0,530
	LOF	autoenkoder (z=4)	k=50	0,545
	OCSVM	autoenkoder (z=4)	ν=0,50, γ=0,1/d	0,534
	PCA (rekonstr.)	PCA (k=1)	błąd rekonstrukcji	0,400
WDBC	IForest	oryginalna	T=200	0,737
	LOF	PCA (k=1)	k=35	0,871
	OCSVM	PCA (k=1)	ν=0,50, γ=0,1/d	0,871
	PCA (rekonstr.)	PCA (k=20)	błąd rekonstrukcji	0,421
Campaign	IForest	PCA (k=3)	T=200	0,295
	LOF	oryginalna	k=35	0,196
	OCSVM	oryginalna	ν=0,10, γ=10,0/d	0,271
	PCA (rekonstr.)	PCA (k=1)	błąd rekonstrukcji	0,259

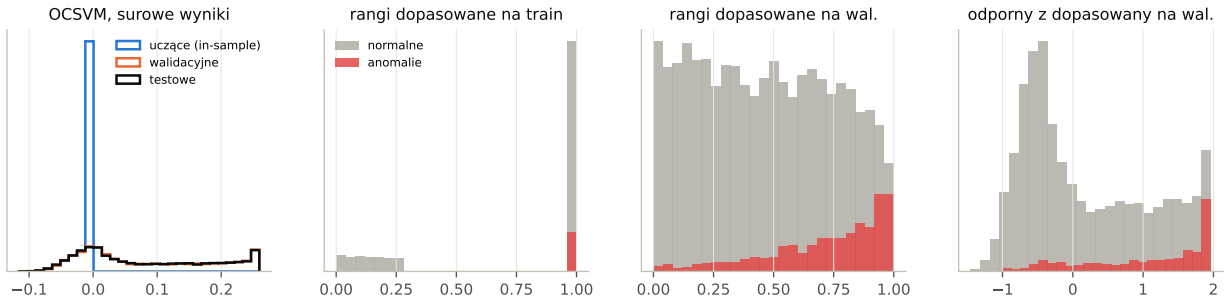
4 Metody agregacji

4.1 Ujednolicenie wyników anomalii

Wszystkie detektory zwracają wynik, w którym wyższa wartość oznacza większą anomalność: IForest −`score_samples`, LOF i OCSVM −`score_samples`/−`decision_function`, PCA – kwadrat błędu rekonstrukcji. Skale są jednak zupełnie różne (np. LOF ≈ 1–3, błąd rekonstrukcji od 0 do kilkuset), więc przed agregacją każdy wynik jest normalizowany. Zbadano cztery normalizacje, każdą dopasowywaną osobno dla każdego detektora:

- **min-max**: $(s - \min)/(\max - \min)$,
- **z-score**: $(s - \mu)/\sigma$,
- **odporny z-score**: $(s - \text{med})/(1{,}4826 \cdot \text{MAD})$ – mediana i MAD nie zależą od kilku skrajnych wartości, czyli od samych anomalii,
- **rangi (dystrybuanta empiryczna)**: odsetek wyników referencyjnych mniejszych od s.

Ważne jest, **na czym** dopasować normalizację. Naturalnym wyborem są wyniki części uczącej, ale są to wyniki *in-sample*: detektor ocenia punkty, na których był uczony. Rysunek 1 pokazuje skutek dla OCSVM z wąskim jądrem ($\gamma = 10/d$) na Campaign. Punkty uczące są wektorami nośnymi lub leżą tuż przy nich i dostają niemal identyczne, niskie wyniki, a 71 % punktów testowych ma wynik wyższy niż *każdy* punkt uczący. Normalizacja rangowa dopasowana na części uczącej przypisuje im wszystkim wartość 1 i informacja o ich kolejności ginie. Dlatego normalizacje dopasowywano na **wynikach części walidacyjnej** (*out-of-sample*, bez użycia etykiet). Tabela 2 pokazuje, że dla fuzji przez maksimum zmiana ta podnosi średnią PR-AUC przy rangach z 0,412 do 0,524, a przy z-score z 0,483 do 0,576.



Rysunek 1: OCSVM ($\gamma = 10/d$) na Campaign, podział 0: rozkład surowych wyników części uczącej (in-sample), walidacyjnej i testowej oraz wyniki testowe po normalizacji rangowej dopasowanej na części uczącej (nasycenie w 1), rangowej dopasowanej na walidacji i odpornym z-score dopasowanym na walidacji.

Tabela 2: Wpływ normalizacji i danych, na których ją dopasowano (średnia PR-AUC z 4 zbiorów, część testowa): fuzja przez średnią, fuzja przez maksimum oraz wariant CBF (PR-AUC i F1).

Normalizacja	Średnia: dopas. train	Średnia: dopas. wal.	Maksimum: train	Maksimum: wal.	CBF: PR-AUC	CBF: F1
min-max	0,589	0,635	0,523	0,585	0,657	0,598
z-score	0,574	0,618	0,483	0,576	0,654	0,597
odporny z	0,573	0,586	0,524	0,537	0,652	0,597
rangi (ECDF)	0,637	0,622	0,412	0,524	0,639	0,583

4.2 Majority Voting

Każdy detektor podejmuje decyzję binarną na podstawie własnego progu, wybranego jako maksymalizujący F1 na walidacji (wariant główny) albo jako kwantyl $1-c$ wyników walidacyjnych, gdzie c to udział anomalii w części walidacyjnej (wariant „c"; z etykiet wykorzystywana jest tylko ta jedna liczba). Obserwacja jest anomalią, gdy wskaże ją co najmniej m z 4 detektorów, $m \in \{1, 2, 3, 4\}$. Próg $m = 1$ to suma (OR), a $m = 4$ – iloczyn (AND) decyzji. Ranking potrzebny do ROC-AUC i PR-AUC tworzy liczba głosów. Jest on taki sam dla każdego m, więc te metryki nie zależą od progu.

4.3 Weighted Score Fusion

$S(x) = \sum_k w_k\, \hat{s}_k(x)$, $\sum_k w_k = 1$, gdzie $\hat{s}_k$ jest znormalizowanym wynikiem. Zbadano schematy wag wyznaczanych na walidacji:

- **równe** – zwykła średnia,
- **PR-AUC** – $w_k \propto \mathrm{AP}_k^{wal}$,
- **skill** – $w_k \propto \max(0,\ \mathrm{AP}_k^{wal} - \pi)$, gdzie π to udział anomalii: wagę dostaje tylko przewaga nad losowym rankingiem, a detektor nie lepszy od losowego dostaje 0,
- **skill** $\times$ **różnorodność** – skill pomnożony przez $1 - \bar{\rho}_k$, gdzie $\bar{\rho}_k$ to średnia korelacja Spearmana wyników detektora k z pozostałymi (na walidacji),

oraz **maksimum** znormalizowanych wyników (klasyczna alternatywa dla średniej). Każdy schemat zbadano dla wszystkich detektorów i dla podzbioru wybranego zachłannie na walidacji. Próg decyzji wyznaczano dwoma kryteriami: (1) maksymalizacja F1 na walidacji (F1 równoważy Precision i Recall, a próg wybrany wprost pod raportowaną metrykę jest najprostszy do uzasadnienia), (2) kwantyl $1 - c$ zfuzjowanych wyników walidacyjnych, gdzie c to udział anomalii w walidacji (nie wymaga wskazania, które punkty są anomaliami).

4.4 Warianty własne

Oba warianty własne odpowiadają na to samo pytanie – *jak dobrać detektory i wagi, gdy jakość detektorów da się ocenić tylko na małej walidacji* – ale w przeciwny sposób.

DSF – *diversity-weighted skill fusion.* Założenie: zespół zyskuje na detektorach, które są dobre i wnoszą informację niedostępną dla innych. DSF składa się z rangowej normalizacji (dopasowanej na walidacji), wag $w_k \propto \max(0, \mathrm{AP}_k - \pi) \cdot (1 - \bar{\rho}_k)$ oraz zachłannego wyboru detektorów. Wybór zaczyna od detektora o najlepszej walidacyjnej PR-AUC i dodaje kolejne, dopóki poprawiają walidacyjną PR-AUC fuzji o więcej niż 10^{-3}. Próg wybierany jest przez maksymalizację F1 na walidacji. DSF w pełni ufa walidacji: dopasowuje do niej zarówno skład zespołu, jak i ciągłe wagi.

CBF – *competence-based fusion.* Założenie: przy małej walidacji ciągłe wagi i zachłanny wybór dopasowują się do szumu, a człon różnorodności nagradza detektory słabe (słaby detektor jest z definicji mało skorelowany z dobrymi). CBF:

1. Dla każdego detektora szacuje *niepewność* jego walidacyjnej PR-AUC metodą bootstrap (500 prób losowanych ze zwracaniem osobno z anomalii i obserwacji normalnych części walidacyjnej).
2. Za *kompetentne* uznaje detektory, które w co najmniej 10 % prób bootstrapowych są nie gorsze od detektora najlepszego na walidacji, czyli te, o których dane nie pozwalają powiedzieć, że są gorsze.
3. Detektory kompetentne uśrednia z *równymi* wagami. Równe wagi nie wymagają estymacji, a różnic w jakości i tak nie da się wiarygodnie zmierzyć. Detektory wyraźnie gorsze odrzuca.
4. Normalizuje odpornym z-score dopasowanym na wynikach walidacyjnych, który nie nasyca się i nie zależy od skrajnych wartości.
5. Próg decyzyjny wybiera przez maksymalizację F1 na walidacji.

Gdy jeden detektor wyraźnie dominuje, CBF sprowadza się do niego. Gdy kilka jest nieodróżnialnych, uśrednia je i zmniejsza wariancję. Jest to zasada „uśredniaj tylko to, czego nie umiesz rozróżnić".

5 Wyniki

5.1 Pełna tabela wyników

Tabela 3: Wyniki wszystkich wariantów (część testowa, podziały projektowe, średnia ± odchylenie std.). Czas – łączny czas przygotowania reprezentacji, uczenia i oceny wykorzystanych detektorów oraz agregacji. Pogrubienie – najlepsza wartość na zbiorze.

Zbiór	Wariant	Prec.	Rec.	F1	ROC-AUC	PR-AUC	Czas [ms]
Cardio	IForest	0,517	0,716	0,588 ± 0,062	0,936	0,593 ± 0,098	10791
	LOF	0,544	0,675	0,595 ± 0,064	0,871	0,576 ± 0,064	9
	OCSVM	0,805	0,780	0,787 ± 0,021	0,956	0,836 ± 0,047	2798
	PCA (rekonstr.)	0,430	0,607	0,499 ± 0,100	0,886	0,471 ± 0,123	2
	Najlepszy pojedynczy (wal.)	0,805	0,780	0,787 ± 0,021	0,956	0,836 ± 0,047	2798
	MV 1/4	0,380	0,952	0,541 ± 0,045	0,947	0,740 ± 0,061	13601

Zbiór	Wariant	Prec.	Rec.	F1	ROC-AUC	PR-AUC	Czas [ms]
	MV 2/4	0,594	0,820	0,686 ± 0,041	0,947	0,740 ± 0,061	13601
	MV 3/4	0,774	0,657	0,708 ± 0,077	0,947	0,740 ± 0,061	13601
	MV 4/4	0,995	0,348	0,507 ± 0,116	0,947	0,740 ± 0,061	13601
	Fuzja: maksimum	0,605	0,775	0,674 ± 0,050	0,954	0,662 ± 0,069	13601
	Fuzja: średnia	0,760	0,741	0,748 ± 0,057	0,970	0,842 ± 0,050	13601
	Fuzja: wagi PR-AUC	0,817	0,727	0,764 ± 0,069	0,973	0,867 ± 0,045	13604
	Fuzja: wagi skill	0,833	0,730	0,773 ± 0,065	0,973	0,870 ± 0,045	13604
	DSF (własna)	0,887	0,748	**0,805 ± 0,048**	0,966	**0,872 ± 0,038**	8972
	CBF (własna)	0,805	0,780	0,787 ± 0,021	0,956	0,836 ± 0,047	2799
Arrhythmia	IForest	0,546	0,560	0,533 ± 0,091	0,829	0,571 ± 0,115	1886
	LOF	0,489	0,597	0,522 ± 0,090	0,822	0,597 ± 0,129	1827
	OCSVM	0,523	0,566	0,516 ± 0,090	0,810	0,585 ± 0,134	1764
	PCA (rekonstr.)	0,402	0,609	0,463 ± 0,117	0,813	0,462 ± 0,115	1607
	Najlepszy pojedynczy (wal.)	0,533	0,565	0,531 ± 0,100	0,832	0,590 ± 0,124	1086
	MV 1/4	0,350	0,718	0,466 ± 0,096	0,787	0,470 ± 0,101	7084
	MV 2/4	0,470	0,603	0,516 ± 0,106	0,787	0,470 ± 0,101	7084
	MV 3/4	0,567	0,542	0,532 ± 0,100	0,787	0,470 ± 0,101	7084
	MV 4/4	0,673	0,468	0,528 ± 0,124	0,787	0,470 ± 0,101	7084
	Fuzja: maksimum	0,455	0,588	0,488 ± 0,099	0,828	0,531 ± 0,129	7084
	Fuzja: średnia	0,548	0,559	0,542 ± 0,109	0,831	0,578 ± 0,142	7085
	Fuzja: wagi PR-AUC	0,545	0,559	0,541 ± 0,105	0,831	0,585 ± 0,133	7087
	Fuzja: wagi skill	0,548	0,559	0,541 ± 0,102	0,831	0,588 ± 0,134	7087
	DSF (własna)	0,560	0,547	0,524 ± 0,095	0,836	0,602 ± 0,137	2029
	CBF (własna)	0,600	0,543	**0,551 ± 0,138**	0,831	**0,604 ± 0,133**	4265
WDBC	IForest	0,495	0,794	0,580 ± 0,195	0,987	0,754 ± 0,186	262
	LOF	0,777	0,867	0,789 ± 0,181	0,996	0,916 ± 0,132	5
	OCSVM	0,796	0,900	**0,815 ± 0,155**	0,997	**0,925 ± 0,131**	4
	PCA (rekonstr.)	0,245	0,500	0,287 ± 0,188	0,947	0,459 ± 0,242	2
	Najlepszy pojedynczy (wal.)	0,723	0,867	0,761 ± 0,198	0,994	0,886 ± 0,167	110
	MV 1/4	0,356	0,950	0,496 ± 0,182	0,966	0,710 ± 0,216	273
	MV 2/4	0,642	0,878	0,710 ± 0,189	0,966	0,710 ± 0,216	273
	MV 3/4	0,768	0,811	0,760 ± 0,194	0,966	0,710 ± 0,216	273
	MV 4/4	0,581	0,422	0,458 ± 0,284	0,966	0,710 ± 0,216	273
	Fuzja: maksimum	0,456	0,717	0,511 ± 0,206	0,979	0,587 ± 0,230	273
	Fuzja: średnia	0,668	0,728	0,640 ± 0,217	0,990	0,785 ± 0,193	274
	Fuzja: wagi PR-AUC	0,684	0,733	0,665 ± 0,272	0,992	0,819 ± 0,204	276
	Fuzja: wagi skill	0,684	0,733	0,665 ± 0,272	0,992	0,819 ± 0,204	276
	DSF (własna)	0,733	0,728	0,700 ± 0,234	0,993	0,803 ± 0,201	119
	CBF (własna)	0,714	0,800	0,719 ± 0,240	0,993	0,851 ± 0,196	255
Campaign	IForest	0,377	0,280	0,318 ± 0,008	0,672	0,303 ± 0,008	665
	LOF	0,199	0,381	0,260 ± 0,008	0,634	0,202 ± 0,006	5406
	OCSVM	0,272	0,469	0,341 ± 0,006	0,742	0,276 ± 0,009	97940
	PCA (rekonstr.)	0,315	0,428	0,363 ± 0,007	0,730	0,260 ± 0,010	116
	Najlepszy pojedynczy (wal.)	0,377	0,280	0,318 ± 0,008	0,672	0,303 ± 0,008	665
	MV 1/4	0,219	0,733	0,338 ± 0,009	0,736	0,260 ± 0,006	104127
	MV 2/4	0,303	0,497	0,375 ± 0,006	0,736	0,260 ± 0,006	104127
	MV 3/4	0,393	0,271	0,320 ± 0,014	0,736	0,260 ± 0,006	104127
	MV 4/4	0,462	0,057	0,102 ± 0,010	0,736	0,260 ± 0,006	104127
	Fuzja: maksimum	0,311	0,490	**0,376 ± 0,009**	0,756	0,318 ± 0,010	104127
	Fuzja: średnia	0,279	0,500	0,356 ± 0,013	0,758	0,282 ± 0,007	104129

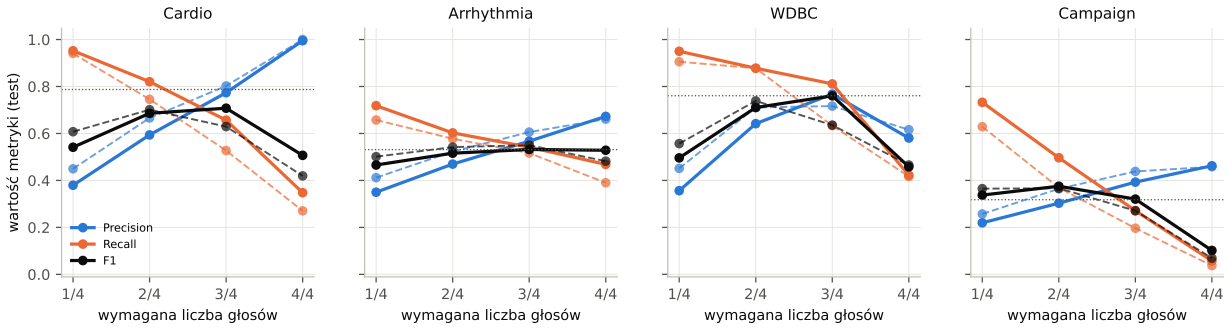
Zbiór	Wariant	Prec.	Rec.	F1	ROC-AUC	PR-AUC	Czas [ms]
	Fuzja: wagi PR-AUC	0,281	0,513	0,360 ± 0,013	0,760	0,292 ± 0,006	104134
	Fuzja: wagi skill	0,286	0,500	0,363 ± 0,011	0,760	0,300 ± 0,007	104134
	DSF (własna)	0,335	0,401	0,360 ± 0,010	0,737	**0,328 ± 0,015**	59213
	CBF (własna)	0,362	0,331	0,331 ± 0,022	0,703	0,320 ± 0,027	38380

Najważniejsze obserwacje z tabeli 3:

- **Zespół przewyższa najlepszy pojedynczy detektor (wybrany na walidacji) na trzech zbiorach.** Na Cardio DSF osiąga PR-AUC 0,872, a fuzja z wagami skill 0,870, wobec 0,836 dla OCSVM na UMAP. Na Arrhythmii CBF i DSF mają 0,604 i 0,602 wobec 0,590, a na Campaign 0,320 i 0,328 wobec 0,303. Przewagi są niewielkie (0,01–0,04), ale dotyczą zbiorów, na których walidacja zawiera kilkadziesiąt lub więcej anomalii.
- **Na WDBC wszystkie zespoły przegrywają**, mimo że ich składniki są dobre: fuzja średnia 0,785, CBF 0,851 wobec 0,886 najlepszego pojedynczego. LOF i OCSVM na jednej składowej PCA mają osobno 0,92–0,93, a dołączenie słabszych IForest (0,75) i rekonstrukcji (0,46) rozmywa ich wynik. Walidacja z 2–3 anomaliami nie pozwala wiarygodnie odrzucić słabszych detektorów. Nawet wybór najlepszego pojedynczego detektora jest tu niestabilny: w 12 z 30 podziałów walidacja wskazała IForest zamiast LOF.
- **Majority Voting** ma niską PR-AUC (ranking z liczby głosów ma tylko 5 poziomów), ale w F1 bywa konkurencyjny: MV 2/4 ma najwyższe F1 na Campaign (0,375 wobec 0,318 najlepszego pojedynczego), a MV 3/4 na Arrhythmii dorównuje najlepszemu pojedynczemu (0,532).
- Fuzja przez **maksimum** (z rangami) jest najgorszym schematem fuzji poza Campaign (średnio 0,524): wzmacnia fałszywe alarmy każdego detektora.

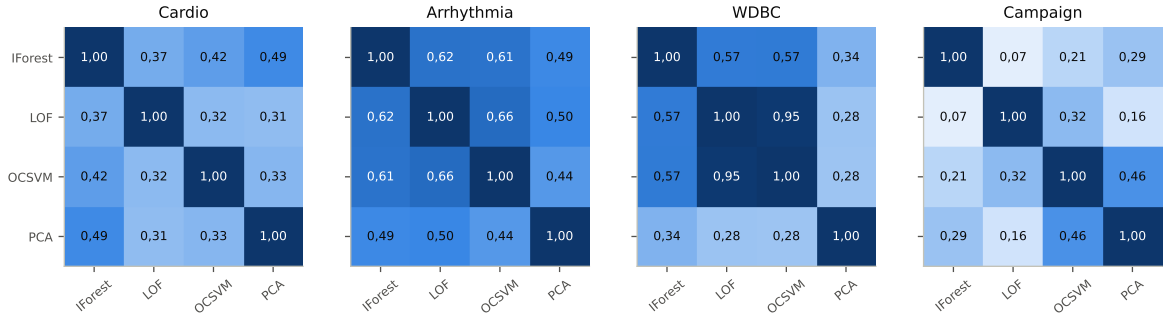
5.2 Majority Voting: wpływ progu

Rysunek 2 pokazuje klasyczny kompromis. Zwiększanie liczby wymaganych głosów podnosi Precision (Cardio: 0,38 przy 1/4, 0,59 przy 2/4, 0,77 przy 3/4, 0,995 przy 4/4) i obniża Recall (0,95 → 0,82 → 0,66 → 0,35). F1 jest najwyższe przy $m = 2$ lub $m = 3$. Reguła AND ($m = 4$) jest zbyt restrykcyjna: na Campaign, gdzie detektory rzadko się zgadzają (Jaccard 0,07–0,46), Recall spada do 0,06. Reguła OR ($m = 1$) daje najwyższy Recall, ale sumuje fałszywe alarmy wszystkich detektorów. Głosowanie przekreśla unikalną wiedzę jednego detektora: na Cardio OCSVM na UMAP wykrywa 75 % anomalii lokalnych, a MV 3/4 tylko 54 %, bo pozostałe detektory ich nie widzą. Progi wyznaczane z udziału anomalii (linie przerywane) dają przy $m = 2$ nieco wyższe F1 niż progi z walidacyjnego F1 na trzech zbiorach (np. WDBC 0,74 wobec 0,71) – przy bardzo małej walidacji próg z jednego kwantyla jest stabilniejszy niż próg optymalizowany na kilku anomaliach.



Rysunek 2: Majority Voting: Precision, Recall i F1 w zależności od wymaganej liczby głosów (linie ciągłe – progi detektorów z walidacyjnego F1, przerywane – z udziału anomalii w walidacji); linia kropkowana – F1 najlepszego pojedynczego detektora.

5.3 Zgodność i komplementarność detektorów

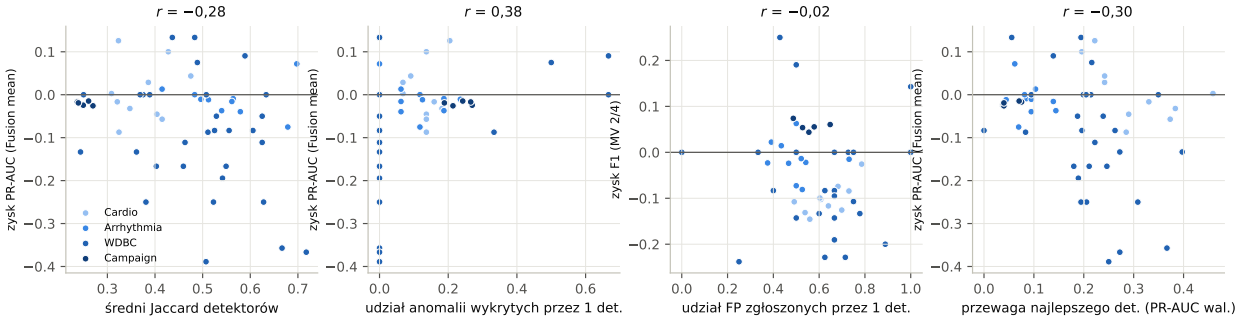


Rysunek 3: Indeks Jaccarda zbiorów obserwacji testowych oznaczonych przez pary detektorów bazowych (średnia po podziałach).

Rysunek 3 pokazuje bardzo różną strukturę zgodności na poszczególnych zbiorach:

- **WDBC**: LOF i OCSVM działają na tej samej, jednej składowej PCA i są praktycznie identyczne (Jaccard 0,95), więc nie są komplementarne. IForest i rekonstrukcja PCA są od nich bardziej niezależne (0,28–0,57), ale słabsze. Zespół nie ma tu z czego zyskać – dodanie słabszych, niezależnych detektorów tylko szkodzi.
- **Arrhythmia**: IForest, LOF i OCSVM są podobnej jakości (PR-AUC 0,57–0,60) i umiarkowanie zgodne (0,61–0,66). Uśrednienie zmniejsza wariancję – CBF w połowie podziałów uśrednia wszystkie trzy.
- **Campaign**: detektory prawie się nie zgadzają (IForest–LOF 0,07), a wszystkie są słabe (0,20–0,30). Niska zgodność oznacza tu w dużej mierze losowość błędów, ale także różne podzbiory wykrywanych anomalii: 24 % anomalii wskazuje dokładnie jeden detektor.
- **Cardio**: OCSVM na UMAP wyraźnie dominuje (0,84 wobec 0,47–0,59), a jego decyzje mało pokrywają się z pozostałymi (0,32–0,42), bo działa w innej reprezentacji. Pozostałe detektory, choć słabsze, niosą informację, której OCSVM nie ma – stąd zysk fuzji ważonej.

Rysunek 4 zestawia miary komplementarności z zyskiem zespołu na poziomie pojedynczych podziałów. Korelacje są słabe ($|r| \leq 0{,}38$): zysk w pojedynczym podziale jest silnie zaszumiony, szczególnie na WDBC. Najwyraźniejszy jest związek z udziałem anomalii wykrytych przez dokładnie jeden detektor ($r = 0{,}38$). Gdy detektory wykrywają różne anomalie, uśrednianie ma co łączyć.



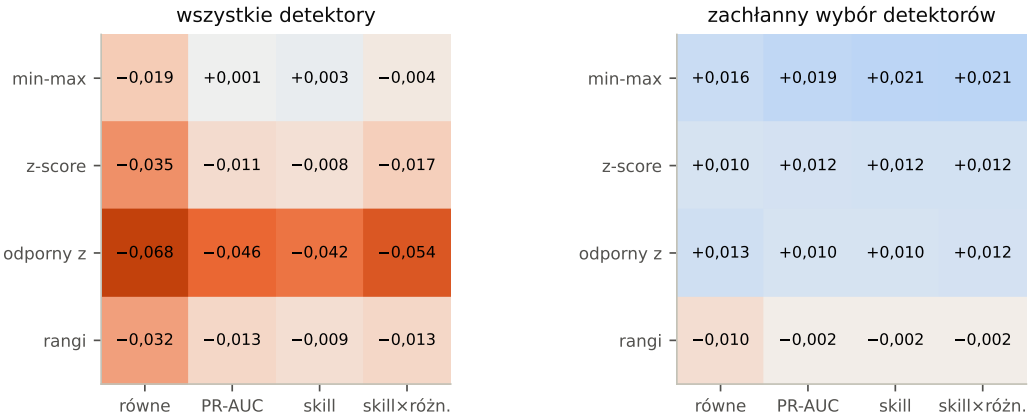
Rysunek 4: Zysk zespołu względem najlepszego pojedynczego detektora (wybranego na walidacji) w poszczególnych podziałach a miary komplementarności: średni Jaccard decyzji, udział anomalii wykrytych przez dokładnie jeden detektor, udział fałszywych alarmów zgłoszonych przez jeden detektor oraz przewaga najlepszego detektora na walidacji.

5.4 Wpływ normalizacji, wag, wyboru detektorów i progu

Tabela 5 i rys. 5 przedstawiają pełną ablację fuzji: 4 normalizacje × 4 schematy wag × 2 sposoby wyboru detektorów × 2 kryteria progu.

Tabela 5: Ablacja fuzji wyników (normalizacja dopasowana na walidacji): średnia PR-AUC i F1 z 4 zbiorów (test) oraz różnica względem najlepszego pojedynczego detektora (Δ); F1 dla progu z walidacyjnego F1 i dla progu z udziału anomalii (c); „Wygrane” – liczba zbiorów, na których fuzja ma wyższą PR-AUC niż najlepszy pojedynczy detektor.

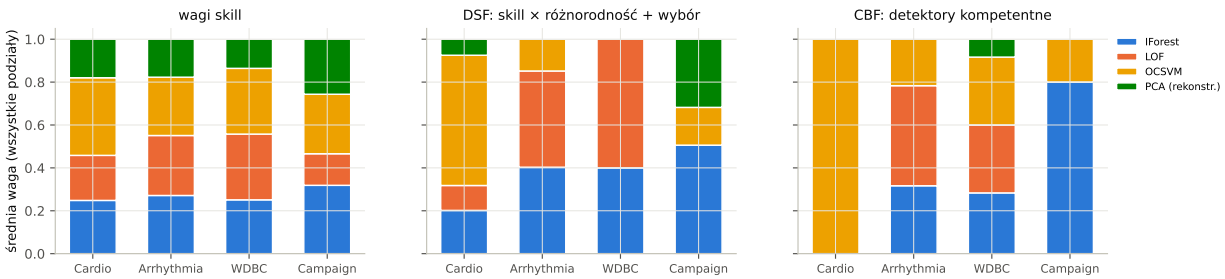
Normalizacja	Wagi	Detektory	PR-AUC	ΔPR-AUC	F1 (próg wal.)	ΔF1	F1 (próg c)	Wygrane (z 4)
min-max	równe	wszystkie	0,635	−0,019	0,596	−0,004	0,584	2
min-max	równe	zachłanny wybór	0,669	+0,016	0,612	+0,013	0,611	3
min-max	PR-AUC	wszystkie	0,655	+0,001	0,608	+0,008	0,600	2
min-max	PR-AUC	zachłanny wybór	0,672	+0,019	0,618	+0,019	0,610	3
min-max	skill	wszystkie	0,657	+0,003	0,608	+0,009	0,601	2
min-max	skill	zachłanny wybór	0,674	+0,021	0,623	+0,024	0,612	3
min-max	skill×różn.	wszystkie	0,649	−0,004	0,605	+0,006	0,593	2
min-max	skill×różn.	zachłanny wybór	0,675	+0,021	0,618	+0,018	0,612	3
z-score	równe	wszystkie	0,618	−0,035	0,590	−0,009	0,577	1
z-score	równe	zachłanny wybór	0,664	+0,010	0,608	+0,009	0,601	2
z-score	PR-AUC	wszystkie	0,643	−0,011	0,612	+0,013	0,589	1
z-score	PR-AUC	zachłanny wybór	0,665	+0,012	0,611	+0,012	0,604	2
z-score	skill	wszystkie	0,645	−0,008	0,611	+0,012	0,592	1
z-score	skill	zachłanny wybór	0,666	+0,012	0,608	+0,009	0,603	2
z-score	skill×różn.	wszystkie	0,636	−0,017	0,604	+0,005	0,587	1
z-score	skill×różn.	zachłanny wybór	0,666	+0,012	0,608	+0,009	0,606	2
odporny z	równe	wszystkie	0,586	−0,068	0,576	−0,023	0,562	1
odporny z	równe	zachłanny wybór	0,666	+0,013	0,605	+0,005	0,603	3
odporny z	PR-AUC	wszystkie	0,608	−0,046	0,592	−0,007	0,574	1
odporny z	PR-AUC	zachłanny wybór	0,664	+0,010	0,608	+0,009	0,604	2
odporny z	skill	wszystkie	0,612	−0,042	0,594	−0,005	0,571	1
odporny z	skill	zachłanny wybór	0,664	+0,010	0,608	+0,008	0,605	3
odporny z	skill×różn.	wszystkie	0,599	−0,054	0,583	−0,016	0,570	1
odporny z	skill×różn.	zachłanny wybór	0,665	+0,012	0,606	+0,007	0,604	3
rangi	równe	wszystkie	0,622	−0,032	0,572	−0,028	0,560	1
rangi	równe	zachłanny wybór	0,644	−0,010	0,598	−0,002	0,584	3
rangi	PR-AUC	wszystkie	0,641	−0,013	0,583	−0,017	0,587	1
rangi	PR-AUC	zachłanny wybór	0,651	−0,002	0,595	−0,004	0,585	3
rangi	skill	wszystkie	0,644	−0,009	0,586	−0,014	0,593	1
rangi	skill	zachłanny wybór	0,652	−0,002	0,597	−0,002	0,585	3
rangi	skill×różn.	wszystkie	0,641	−0,013	0,584	−0,015	0,585	1
rangi	skill×różn.	zachłanny wybór	0,651	−0,002	0,597	−0,002	0,586	3



Rysunek 5: Zmiana średniej PR-AUC fuzji względem najlepszego pojedynczego detektora w zależności od normalizacji i wag (lewo – wszystkie detektory, prawo – zachłanny wybór).

- **Wybór detektorów** ma największy wpływ. Fuzja *wszystkich* detektorów jest zwykle gorsza od najlepszego pojedynczego (do −0,068), a zachłanny wybór daje zysk przy min-max, z-score i odpornym z-score (+0,010 do +0,021) i wygrywa na 2–3 z 4 zbiorów. Przyczyną jest słaby detektor – rekonstrukcja PCA (0,26–0,47) – który w średniej wszystkich detektorów obniża wynik, a zachłanny wybór go pomija.
- **Normalizacja**: przy wyborze zachłannym min-max jest najlepszy (+0,016 do +0,021), a rangi najgorsze. Przy fuzji wszystkich detektorów odporny z-score wypada najgorzej (−0,042 do −0,068): nie ogranicza wartości z góry, więc pojedyncze ekstremalne wyniki słabego detektora dominują w średniej. Min-max i rangi ograniczają wkład każdego detektora do $[0, 1]$. Rangi przy kilkuset punktach walidacyjnych są schodkowe i nasycają się w 1 dla najbardziej skrajnych obserwacji testowych – dokładnie tam, gdzie PR-AUC jest najbardziej czuła.
- **Wagi**: różnice między schematami są małe (do 0,03), mniejsze niż wpływ wyboru detektorów. Przy fuzji wszystkich detektorów równe wagi są najgorsze, bo słaby detektor dostaje tyle samo co dobre.
- **Próg**: próg z walidacyjnego F1 daje średnio nieco wyższe F1 (0,57–0,62) niż próg z udziału anomalii (0,56–0,61).

5.5 Wagi i wybór detektorów w wariantach własnych



Rysunek 6: Średnie wagi detektorów (wszystkie podziały projektowe) w fuzji z wagami skill, w DSF i w CBF.

Rysunek 6 pokazuje różnicę między wariantami. Wagi skill rozkładają się na wszystkie detektory, także słabe (rekonstrukcja PCA). DSF dzięki zachłannemu wyborowi zostawia zwykle jeden do trzech detektorów. Na Cardio łączy OCSVM z innymi (w 8 z 10 podziałów), co daje najlepszy wynik

na tym zbiorze. Na WDBC zawsze zostawia jeden detektor (LOF w 18, IForest w 12 podziałach), czyli wraca do problemu wyboru pojedynczego detektora na 2–3 anomaliach. CBF na Cardio we wszystkich 10 podziałach wybiera wyłącznie OCSVM (przewaga na walidacji jest istotna), na WDBC uśrednia trzy lub cztery detektory (bootstrap na 2–3 anomaliach nie odróżnia ich od najlepszego), na Arrhythmii najczęściej IForest, LOF i OCSVM, a na Campaign IForest sam lub z OCSVM.

5.6 Przypadki poprawy i pogorszenia

Tabela 6 porównuje decyzje zespołów z decyzjami najlepszego pojedynczego detektora dla każdej obserwacji testowej.

Tabela 6: Analiza przypadków (część testowa, suma po podziałach projektowych): anomalie wykryte przez zespół, a pominięte przez najlepszy pojedynczy detektor („uratowane"), i odwrotnie („utracone"), oraz fałszywe alarmy usunięte i dodane przez zespół.

Zbiór	Zespół	Anomalie	Uratowane	Utracone	FP najl. pojed.	FP usunięte	FP dodane
Cardio	MV 2/4	440	39	21	88	42	208
	MV 3/4	440	23	77	88	63	60
	Fuzja: średnia	440	45	62	88	72	90
	DSF (własna)	440	23	37	88	57	15
	CBF (własna)	440	0	0	88	0	0
Arrhythmia	MV 2/4	164	9	3	89	9	35
	MV 3/4	164	3	7	89	27	13
	Fuzja: średnia	164	5	6	89	27	18
	DSF (własna)	164	0	3	89	12	11
	CBF (własna)	164	5	9	89	33	13
WDBC	MV 2/4	79	2	1	35	2	16
	MV 3/4	79	0	4	35	9	0
	Fuzja: średnia	79	4	15	35	5	13
	DSF (własna)	79	0	11	35	8	0
	CBF (własna)	79	3	9	35	11	6
Campaign	MV 2/4	5800	1406	149	2775	1062	4943
	MV 3/4	5800	374	424	2775	1570	1232
	Fuzja: średnia	5800	1510	231	2775	1019	5800
	DSF (własna)	5800	772	72	2775	719	2722
	CBF (własna)	5800	334	36	2775	315	1278

Kiedy zespół pomaga. Na Cardio DSF traci 37 anomalii, ratuje 23, ale usuwa 57 z 88 fałszywych alarmów najlepszego detektora, dodając tylko 15. Precision rośnie z 0,81 do 0,89, a F1 z 0,79 do 0,81. Słabsze detektory „potwierdzają" wysokie wyniki OCSVM tylko dla prawdziwych anomalii. Na Arrhythmii CBF usuwa 33 z 89 fałszywych alarmów, dodając 13. Detektory są tam porównywalnie dobre, a ich błędy w dużej mierze indywidualne, więc uśrednienie zmniejsza wariancję wyniku – klasyczny mechanizm działania zespołów.

Kiedy zespół szkodzi. Na WDBC fuzja średnia traci 15 z 79 anomalii, ratując 4. Mechanizm to *rozmycie dobrego sygnału*: LOF i OCSVM na pierwszej składowej PCA prawie bezbłędnie oddzielają guzy złośliwe, a IForest i rekonstrukcja dodają do średniej szum, który przesuwa część anomalii poniżej progu. Na Campaign MV 2/4 i fuzja średnia ratują ok. 1400–1500 anomalii, ale dodają 4900–5800 fałszywych alarmów. Przy 11 % anomalii i słabych detektorach suma sygnałów obniża precyzję (0,28–0,30) i fuzja średnia ma niższą PR-AUC niż najlepszy pojedynczy detektor.

DSF a CBF. Oba warianty własne mają niemal taką samą średnią (PR-AUC 0,651 i 0,652), ale wygrywają w innych sytuacjach. DSF jest lepszy, gdy walidacja jest duża, a słabsze detektory niosą informację uzupełniającą (Cardio: 0,872 wobec 0,836; Campaign: 0,328 wobec 0,320). Zachłanny wybór ma wtedy wiarygodną podstawę. CBF jest lepszy, gdy walidacja jest bardzo mała (WDBC: 0,851 wobec 0,803). DSF dopasowuje tam skład zespołu do 2–3 anomalii i często wybiera gorszy detektor, a CBF w takiej sytuacji uśrednia, bo nie ma podstaw, by odrzucić którykolwiek z dobrych detektorów. Na Cardio konserwatyzm CBF jest wadą: istotna przewaga OCSVM na walidacji sprawia, że odrzuca pozostałe detektory, choć w połączeniu z OCSVM poprawiłyby wynik. Kryterium „czy detektor jest równie dobry sam" nie mierzy tego, czy jest użyteczny *w zespole*.

5.7 Test potwierdzający na nowych podziałach

Tabela 7: Średnie PR-AUC i F1 (4 zbiory, część testowa) na podziałach projektowych („projekt.") i na nowych podziałach („potw."); „Lepszy niż najl." – liczba zbiorów, na których PR-AUC wariantu jest wyższa niż najlepszego pojedynczego detektora.

Wariant	PR-AUC (projekt.)	F1 (projekt.)	Lepszy niż najl. (projekt.)	PR-AUC (potw.)	F1 (potw.)	Lepszy niż najl. (potw.)
Najlepszy pojedynczy (wal.)	0,654	0,599	0	0,620	0,565	0
MV 2/4	0,545	0,572	0	0,519	0,565	0
Fuzja: średnia	0,622	0,572	1	0,600	0,546	1
Fuzja: wagi skill	0,644	0,586	1	0,620	0,566	2
DSF (własna)	0,651	0,597	3	0,621	0,580	2
CBF (własna)	0,652	0,597	2	0,628	0,579	2

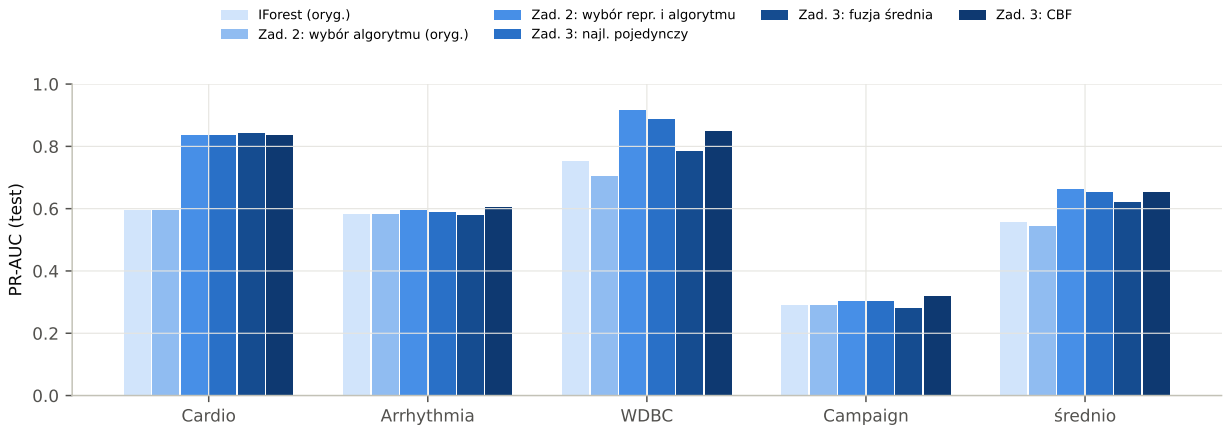
Na nowych podziałach (tabela 7) CBF ma najwyższą średnią PR-AUC (0,628 wobec 0,620 najlepszego pojedynczego, 0,621 DSF i 0,620 wag skill). DSF i CBF przewyższają najlepszy pojedynczy detektor na 2 z 4 zbiorów i mają wyższe średnie F1 (0,580 i 0,579 wobec 0,565). Kierunek efektów jest taki sam jak na podziałach projektowych: DSF wygrywa na Cardio (0,851 wobec 0,801) i Campaign (0,334 wobec 0,309), CBF na WDBC (0,828 wobec 0,815) i Campaign (0,333). Fuzja średnia i MV 2/4 pozostają poniżej najlepszego pojedynczego detektora w PR-AUC. Różnice średnich między wariantami (0,01) są jednak mniejsze od odchyleń między podziałami na Arrhythmii i WDBC (0,13–0,20). Wniosek „zespół jest średnio co najmniej tak dobry jak najlepszy pojedynczy detektor" jest potwierdzony, wniosek „jest lepszy" – tylko dla konkretnych zbiorów.

5.8 Porównanie z zadaniami 1 i 2

Tabela 8 przedstawia PR-AUC uzyskaną na kolejnych etapach projektu na tych samych podziałach. Każdy wybór dokonywany jest na walidacji.

Tabela 8: PR-AUC (test) na kolejnych etapach projektu: domyślny Isolation Forest w danych oryginalnych, wybór algorytmu w danych oryginalnych (zad. 2), wybór reprezentacji i algorytmu (zad. 2), najlepszy pojedynczy detektor bazowy oraz zespoły (zad. 3).

Etap	Cardio	Arrhythmia	WDBC	Campaign	Średnio
IForest (oryg.)	0,595	0,583	0,754	0,292	0,556
Zad. 2: wybór algorytmu (oryg.)	0,596	0,583	0,705	0,292	0,544
Zad. 2: wybór repr. i algorytmu	0,836	0,597	0,916	0,303	0,663
Zad. 3: najl. pojedynczy	0,836	0,590	0,886	0,303	0,654
Zad. 3: fuzja średnia	0,842	0,578	0,785	0,282	0,622
Zad. 3: CBF	0,836	0,604	0,851	0,320	0,652



Rysunek 7: PR-AUC (test) na kolejnych etapach zadań 2 i 3.

Na zbiorach zadań 2 i 3 największy skok jakości daje **wybór reprezentacji**: średnia PR-AUC rośnie z 0,544 do 0,663. Zysk pochodzi głównie z Cardio (UMAP + OCSVM: 0,60 → 0,84) i WDBC (PCA: 0,71 → 0,92). **Wybór algorytmu** w danych oryginalnych spośród trzech detektorów nic tu nie daje (0,556 → 0,544). Isolation Forest jest na tych zbiorach mocnym punktem wyjścia, a na WDBC walidacja wybiera słabszy LOF. Zespół (zadanie 3) utrzymuje poziom najlepszego pojedynczego detektora (CBF 0,652 wobec 0,654), a zwykła średnia go obniża (0,622).

6 Synteza: co miało największy wpływ na jakość detekcji?

Tabela 9 przedstawia dwa rodzaje miar wpływu na PR-AUC. Pierwszy to *rozrzut* (maksimum − minimum), który mówi, ile można zyskać lub stracić danym wyborem. Drugi to *zrealizowany zysk* z zespołu przy wyborze na walidacji.

Tabela 9: Wpływ czynników na PR-AUC (test): rozrzut między 3 detektorami w danych oryginalnych (zad. 2), średni rozrzut jednego detektora między reprezentacjami (zad. 2) oraz zysk zespołu względem najlepszego pojedynczego detektora wybranego na walidacji (zad. 3).

Zbiór	Algorytm (Zad. 2, oryg.)	Reprezentacja	Zespół: średnia	Zespół: CBF
Cardio	0,286	0,206	+0,006	+0,000
Arrhythmia	0,125	0,260	−0,011	+0,014
WDBC	0,055	0,200	−0,102	−0,036
Campaign	0,090	0,078	−0,020	+0,017
średnio	0,139	0,186	−0,032	−0,001

Wybór algorytmu badano też w zadaniu 1 na pięciu innych zbiorach z szerszą siatką pięciu metod. Tam rozrzut PR-AUC między metodami był największy ze wszystkich czynników: średnio 0,40, na Breastw 0,64, na Wine 0,61, na Cardio 0,56. Zrealizowany zysk z wyboru metody na walidacji względem domyślnego Isolation Forest wyniósł średnio +0,15 (0,511 → 0,658), w tym Wine +0,51 (OCSVM) i Cardio +0,16 (OCSVM).

Odpowiedź. Na podstawie wyników trzech zadań:

1. **Wybór algorytmu i reprezentacji mają porównywalny, największy wpływ – ale nie da się ich rozdzielić.** W zadaniu 1 wybór metody podniósł średnią PR-AUC o 0,15, a w zadaniu 2 wybór reprezentacji (łącznie z algorytmem w niej) o 0,12. Oba efekty są skupione na kilku zbiorach (Wine, Cardio, WDBC), a w obu przypadkach kluczowa jest *para*: ta sama

reprezentacja pomaga jednemu detektorowi i szkodzi innemu (UMAP: OCSVM na Cardio +0,24, LOF −0,07), a ten sam algorytm zmienia ranking w zależności od reprezentacji. Detektor to w praktyce para reprezentacja–algorytm.

2. **Reprezentacja ma duży rozrzut (średnio 0,19), w obie strony.** PCA z jedną składową daje na WDBC +0,21 dla LOF, UMAP z OCSVM na Cardio +0,24, a UMAP z IForest na Arrhythmii −0,26. Wybór na walidacji przenosi się na test tam, gdzie walidacja ma dość anomalii.
3. **Połączenie detektorów ma najmniejszy wpływ.** Najlepsze warianty (CBF, DSF) zmieniają średnią PR-AUC o ok. 0,00 (na nowych podziałach +0,01), a zwykła średnia o −0,03. Zespół pomaga, gdy detektory wnoszą różne informacje, a walidacja pozwala to ocenić (Cardio, Arrhythmia, Campaign: +0,01 do +0,04), i szkodzi, gdy dobry sygnał zostaje rozmyty słabszymi detektorami (WDBC: do −0,10).
4. Ponad wszystkimi trzema czynnikami stoi **natura danych**: rozrzut PR-AUC między zbiorami (0,33–0,93 dla najlepszej metody) jest większy niż efekt któregokolwiek wyboru. Na Campaign, gdzie „anomalie" (klienci zakładający lokatę) nie są wyjątkami statystycznymi, ani algorytm, ani reprezentacja, ani zespół nie podniosły PR-AUC powyżej 0,34 przy bazowym 0,11.

7 Rekomendacje: kiedy zespół, a kiedy pojedynczy detektor

- **Pojedynczy detektor**, gdy jeden detektor wyraźnie dominuje i ma unikalną wiedzę, a pozostałe są słabe i z nim skorelowane, albo gdy walidacja jest zbyt mała, by ocenić detektory (WDBC). Uśrednianie rozmyje wtedy dobry sygnał.
- **Fuzja z zachłannym wyborem (DSF, wagi skill)**, gdy walidacja ma dziesiątki anomalii, a detektory działają w różnych reprezentacjach i wykrywają różne anomalie (Cardio, Campaign).
- **CBF**, gdy walidacja jest mała lub nie wiadomo, czy zespół pomoże. Z konstrukcji sprowadza się do najlepszego detektora, gdy ten wyraźnie dominuje, i do średniej, gdy detektory są nieodróżnialne. Na nowych podziałach miał najwyższą średnią PR-AUC.
- **Majority Voting z progiem 2/4 lub 3/4**, gdy priorytetem jest stabilna decyzja binarna, a nie ranking (najwyższe F1 na Campaign).
- **Nie stosować** fuzji przez maksimum ani średniej wszystkich detektorów bez kontroli jakości. Normalizację dopasowywać na wynikach *out-of-sample* (walidacja), a nie na wynikach części uczącej.

8 Ograniczenia

- Części walidacyjne WDBC zawierają 2–3 anomalie, co ogranicza wiarygodność każdej metody doboru wag i progów, a nawet wyboru pojedynczego detektora. Trzydzieści podziałów zmniejsza niepewność średniej, ale nie poprawia decyzji w pojedynczym podziale.
- Dla Campaign użyto 5 podziałów projektowych i 5 potwierdzających (koszt obliczeń). Odchylenia między podziałami są tam małe (0,01–0,03).
- Detektory bazowe przejęto z zadania 2 razem z jego decyzjami. Na WDBC LOF i OCSVM są niemal identyczne, więc zespół ma de facto trzy różne detektory.
- Zbadano zespoły heterogeniczne złożone z 4 detektorów. Nie badano zespołów jednorodnych (np. wielu LOF o różnych k) ani uczenia meta-modelu (stacking) na walidacji, który przy małych walidacjach byłby silnie przeuczony.

9 Wnioski

1. Zespół detektorów nie jest automatycznie lepszy od najlepszego detektora. Najlepsze warianty (DSF, CBF) są średnio tak samo dobre jak najlepszy pojedynczy detektor wybrany na walidacji. Wygrywają na Cardio, Arrhythmii i Campaign (o 0,01–0,04 PR-AUC), a przegrywają na WDBC.
2. O efekcie zespołu decyduje relacja między jakością a komplementarnością detektorów oraz wielkość walidacji. Komplementarność pomaga, gdy słabsze detektory potwierdzają trafienia dobrego, a szkodzi, gdy rozmywają jego prawie bezbłędny sygnał (WDBC).
3. Wybór detektorów do zespołu jest ważniejszy niż schemat wag, a normalizację trzeba dopasować na wynikach out-of-sample. Wyniki in-sample są przesunięte (Campaign: 71 % wyników testowych OCSVM powyżej maksimum wyników uczących), a fuzja przez maksimum z rangami dopasowanymi na nich traci 0,11 PR-AUC.
4. Własne warianty DSF i CBF realizują przeciwne strategie (zaufanie walidacji i ostrożność wobec niej) i sprawdzają się w różnych warunkach: DSF przy dużej walidacji, CBF przy małej. CBF miał najwyższą średnią PR-AUC w teście potwierdzającym.
5. W skali całego projektu o jakości detekcji decydowały kolejno: natura danych, dobór pary algorytm–reprezentacja i dopiero na końcu połączenie detektorów.

10 Odtworzenie wyników

```
python -m task3_ensemble.run_base                    # wymaga wyników zad. 2
python -m task3_ensemble.run_ensembles
python -m task3_ensemble.run_base --confirm          # nowe ziarna
python -m task3_ensemble.run_ensembles --confirm
python -m task3_ensemble.analyze
```

Literatura

[1] S. Han, X. Hu, H. Huang, M. Jiang, Y. Zhao. *ADBench: Anomaly Detection Benchmark*. Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track, 2022. Repozytorium `https://github.com/Minqi824/ADBench`, commit `3dac822`.

[2] S. Rayana. *ODDS Library*. Stony Brook University, Department of Computer Science, 2016. `https://odds.cs.stonybrook.edu`.

[3] G. O. Campos, A. Zimek, J. Sander, R. J. G. B. Campello, B. Micenková, E. Schubert, I. Assent, M. E. Houle. *On the evaluation of unsupervised outlier detection: measures, datasets, and an empirical study*. Data Mining and Knowledge Discovery 30(4), 891–927, 2016. `https://www.dbs.ifi.lmu.de/research/outlier-evaluation/`.

[4] M. Kelly, R. Longjohn, K. Nottingham. *The UCI Machine Learning Repository*. University of California, Irvine. `https://archive.ics.uci.edu`.

[5] W. H. Wolberg, O. L. Mangasarian. *Multisurface method of pattern separation for medical diagnosis applied to breast cytology*. Proceedings of the National Academy of Sciences 87(23), 9193–9196, 1990. (UCI: Breast Cancer Wisconsin (Original)).

[6] W. N. Street, W. H. Wolberg, O. L. Mangasarian. *Nuclear feature extraction for breast tumor diagnosis*. IS&T/SPIE Symposium on Electronic Imaging: Science and Technology, vol. 1905, 861–870, 1993. (UCI: Breast Cancer Wisconsin (Diagnostic)).

[7] K. S. Woods, C. C. Doss, K. W. Bowyer, J. L. Solka, C. E. Priebe, W. P. Kegelmeyer. *Comparative evaluation of pattern recognition techniques for detection of microcalcifications in mammography.* International Journal of Pattern Recognition and Artificial Intelligence 7(6), 1417–1436, 1993.

[8] S. Aeberhard, M. Forina. *Wine.* UCI Machine Learning Repository, 1991.

[9] D. Ayres-de Campos, J. Bernardes, A. Garrido, J. Marques-de-Sá, L. Pereira-Leite. *SisPorto 2.0: a program for automated analysis of cardiotocograms.* Journal of Maternal-Fetal Medicine 9(5), 311–318, 2000. (UCI: Cardiotocography).

[10] S. Moro, P. Cortez, P. Rita. *A data-driven approach to predict the success of bank telemarketing.* Decision Support Systems 62, 22–31, 2014. (UCI: Bank Marketing).

[11] H. A. Güvenir, B. Acar, G. Demiröz, A. Çekin. *A supervised machine learning algorithm for arrhythmia analysis.* Computers in Cardiology 1997, 433–436. (UCI: Arrhythmia).

[12] *Statlog (Heart).* UCI Machine Learning Repository.