Politechnika Łódzka
Wydział Fizyki Technicznej, Informatyki i Matematyki Stosowanej

Analiza danych złożonych z detekcją wyjątków

Zadanie 3

Zespołowa detekcja wyjątków:
projekt własnego rozwiązania

Jędrzej Kostyk
nr indeksu 264339

Jędrzej Małaczyński
nr indeksu 264351

Rok akademicki 2026/2027

Spis treści

1 Cel i zakres **2**

2 Dane i protokół **2**

3 Detektory bazowe **3**

4 Metody łączenia detektorów **3**

4.1 Ujednolicenie wyników 3

4.2 Majority Voting (głosowanie większościowe) 5

4.3 Fuzja wyników (Weighted Score Fusion) 5

4.4 Warianty własne: DSF i CBF 5

5 Wyniki **6**

5.1 Przegląd głównych wariantów 6

5.2 Najlepszy pojedynczy detektor (punkt odniesienia) 7

5.3 Majority Voting 8

5.4 Fuzja wyników: normalizacja, wagi i wybór detektorów 9

5.5 Warianty własne: DSF i CBF 11

5.6 Zgodność i komplementarność detektorów 14

5.7 Test potwierdzający na nowych podziałach 16

5.8 Porównanie z zadaniami 1 i 2 17

6 Synteza: co miało największy wpływ na jakość detekcji? **18**

7 Zalety, ograniczenia i przypadki niepowodzenia **19**

8 Wnioski **20**

A Wyniki wszystkich wariantów **21**

B Wszystkie połączenia fuzji wyników **23**

1 Cel i zakres

Celem zadania jest sprawdzenie, czy połączenie kilku detektorów (*zespół*) wykrywa wyjątki lepiej niż najlepszy pojedynczy detektor. Porównano trzy grupy rozwiązań:

1. **pojedyncze detektory** – cztery detektory bazowe oceniane osobno (punkt odniesienia);
2. **głosowanie większościowe** (*Majority Voting*) – obserwacja jest anomalią, gdy wskaże ją co najmniej m z 4 detektorów;
3. **fuzję wyników** – ważoną średnią wyników detektorów, w tym dwa warianty własne: DSF i CBF.

Ostatnia część raportu (sekcja 6) zbiera wyniki wszystkich trzech zadań i odpowiada na pytanie przewodnie projektu: co miało największy wpływ na jakość detekcji – wybór algorytmu, reprezentacja danych czy połączenie detektorów. Cały kod znajduje się w katalogach `common/` i `task3_ensemble/` repozytorium.

2 Dane i protokół

W tej sekcji opisano dane i sposób oceny; oba są takie same jak w zadaniu 2, więc wyniki można porównywać bezpośrednio.

Tabela 1: Zbiory danych (te same co w zadaniu 2; opis i przykładowe rekordy – raport z zadania 2).

Zbiór danych	Źródło	Co zawiera	Obserwacje	Cechy	Anomalie
Cardio	ADBench	zapisy KTG płodu; anomalia = zapis patologiczny	1 831	21	176 (9,6 %)
Arrhythmia	ODDS	zapisy EKG; anomalia = rzadki typ arytmii	452	274	66 (14,6 %)
WDBC	ADBench	pomiary jąder komórkowych guzów; anomalia = guz złośliwy	367	30	10 (2,7 %)
Campaign	ADBench	kontakty banku z klientami; anomalia = klient założył lokatę	41 188	62	4 640 (11,3 %)

Protokół jest wspólny dla zadań 1–3:

- każdy zbiór danych dzielimy na część uczącą (50 %), walidacyjną (25 %) i testową (25 %), z takim samym udziałem anomalii w każdej części; przykład: Cardio ma 1831 obserwacji, więc 915 trafia do uczenia, 458 do walidacji i 458 do testu;
- detektory uczą się na części uczącej, bez etykiet;
- **walidacja** służy do wyboru wszystkiego, co w zespole trzeba ustalić: progów detektorów, wag, składu zespołu i progu decyzji zespołu;
- **test** służy wyłącznie do końcowej oceny;
- te same ziarna losowe co w zadaniach 1–2 dają te same podziały: 10 podziałów dla Cardio i Arrhythmii, 30 dla WDBC, 5 dla Campaign.

Ważna jest liczba anomalii w walidacji, bo na niej zespół ocenia detektory: WDBC ma ich tylko 2–3, Arrhythmia ok. 17, Cardio 44, a Campaign 1160.

Wszystkie warianty zespołów, w tym oba własne, ustalono przed uruchomieniem ich na danych. Dodatkowo oceniono je na **nowych podziałach** (kolejne ziarna, np. 10–19 dla Cardio), których nie użyto przy projektowaniu. To test potwierdzający (sekcja 5.7).

Miary jakości są te same co w zadaniach 1–2: Precision (ile zgłoszeń to prawdziwe anomalie), Recall (ile anomalii wykryto), F1 (łączy obie), ROC-AUC i PR-AUC (jak wysoko na liście najbardziej podejrzanych obserwacji są anomalie; główna miara porównań).

3 Detektory bazowe

Zespół łączy cztery detektory działające na różnych zasadach:

- **Isolation Forest** – anomalię łatwo odciąć losowymi cięciami;
- **LOF** – anomalia jest rzadsza od swoich sąsiadów;
- **One-Class SVM** – anomalia leży poza granicą obszaru danych;
- **błąd rekonstrukcji PCA** – anomalia źle się odtwarza z kilku głównych składowych.

Każdy detektor działa w reprezentacji i z ustawieniami, które miały najwyższą PR-AUC na walidacji w zadaniu 2 (tabela 2). Detektor bazowy to więc para *reprezentacja + algorytm*, np. OCSVM na dwuwymiarowym UMAP dla Cardio albo LOF na jednej składowej PCA dla WDBC.

Tabela 2: Detektory bazowe (k – liczba składowych PCA lub sąsiadów LOF; m, nn, md – wymiar, liczba sąsiadów i odstęp UMAP; z – wymiar autoenkodera; T – liczba drzew; ν, γ – parametry OCSVM).

Zbiór danych	Detektor	Reprezentacja	Parametry	PR-AUC na walidacji (zadanie 2)
Cardio	IForest	autoenkoder (z=16)	T=200	0,619
	LOF	PCA (k=1)	k=50	0,537
	OCSVM	UMAP (m=2, nn=50, md=0,0)	ν=0,50, γ=0,1/d	0,848
	PCA (rekonstr.)	PCA (k=20)	błąd rekonstrukcji	0,480
Arrhythmia	IForest	PCA (k=8)	T=200	0,530
	LOF	autoenkoder (z=4)	k=50	0,545
	OCSVM	autoenkoder (z=4)	ν=0,50, γ=0,1/d	0,534
	PCA (rekonstr.)	PCA (k=1)	błąd rekonstrukcji	0,400
WDBC	IForest	oryginalna	T=200	0,737
	LOF	PCA (k=1)	k=35	0,871
	OCSVM	PCA (k=1)	ν=0,50, γ=0,1/d	0,871
	PCA (rekonstr.)	PCA (k=20)	błąd rekonstrukcji	0,421
Campaign	IForest	PCA (k=3)	T=200	0,295
	LOF	oryginalna	k=35	0,196
	OCSVM	oryginalna	ν=0,10, γ=10,0/d	0,271
	PCA (rekonstr.)	PCA (k=1)	błąd rekonstrukcji	0,259

4 Metody łączenia detektorów

Ta sekcja opisuje, jak sprowadzić wyniki detektorów do wspólnej skali i jak je połączyć.

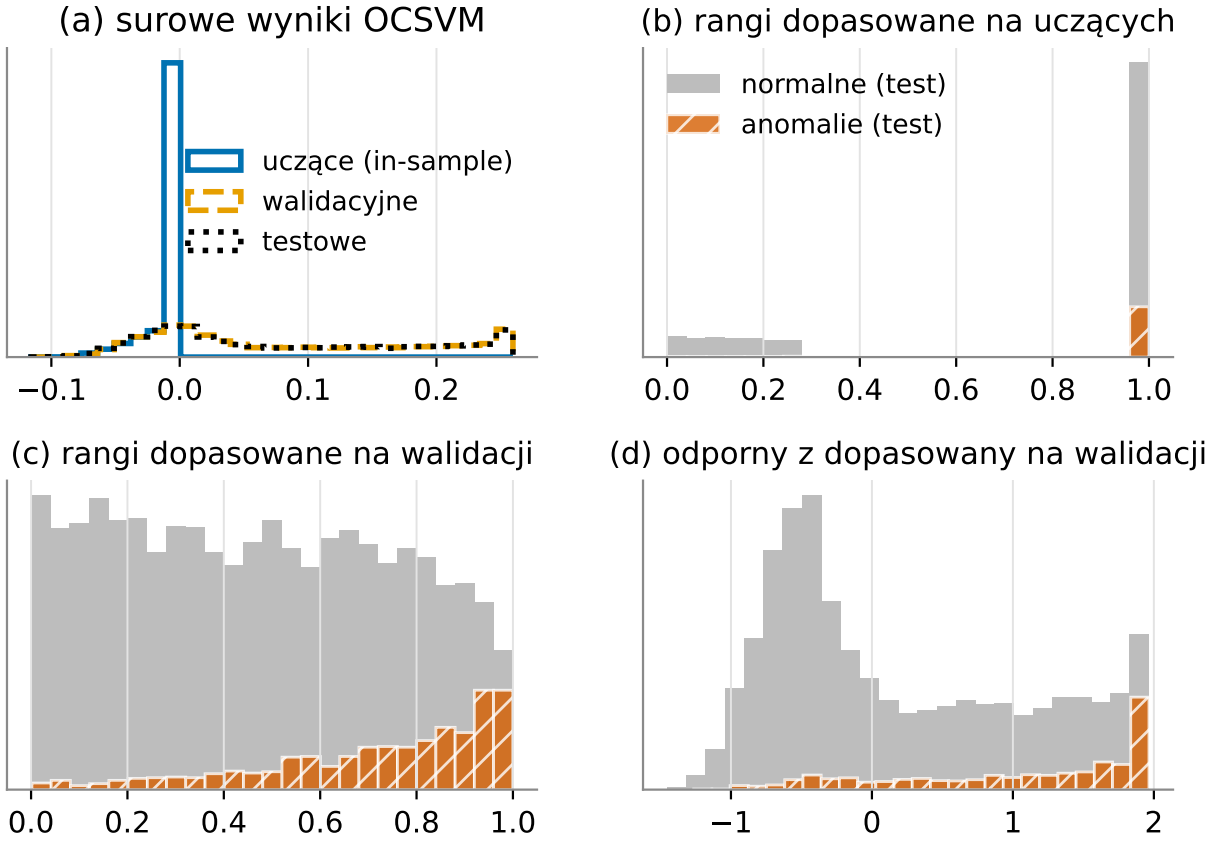
4.1 Ujednolicenie wyników

Każdy detektor daje *wynik anomalii* – liczbę tym większą, im bardziej obserwacja jest podejrzana – ale w innej skali (np. LOF ok. 1–3, błąd rekonstrukcji od 0 do kilkuset). Przed łączeniem każdy wynik *normalizujemy*, czyli przeliczamy na wspólną skalę. Sprawdzono cztery sposoby:

- **min-max** – wynik najmniejszy to 0, największy to 1;
- **z-score** – ile odchyleń standardowych wynik leży od średniej;

- **odporny z-score** – jak z-score, ale z medianą zamiast średniej, więc kilka skrajnych wyników (czyli właśnie anomalie) nie przesuwa skali;
- **rangi** – jaki odsetek wyników jest mniejszy (0 – najmniej podejrzany, 1 – bardziej niż wszystkie).

Ważne jest, **na jakich wynikach** ustalić skalę. Wyniki części uczącej są zaniżone: detektor ocenia punkty, na których się uczył, więc wydają mu się bardzo normalne. Rysunek 1 pokazuje to na OCSVM na Campaign: 71 % punktów testowych ma wynik wyższy niż *każdy* punkt uczący. Rangi liczone względem części uczącej dają im wszystkim wartość 1 i ich kolejność ginie (panel b). Dlatego skalę ustalamy na wynikach części walidacyjnej, bez etykiet.



Rysunek 1: OCSVM na Campaign (ziarno 0): wyniki części uczącej są przesunięte względem walidacji i testu, więc normalizacja dopasowana na nich „nasyca się” w 1 (b), a dopasowana na walidacji – nie (c, d).

Tabela 3: Wpływ normalizacji i części, na której ją dopasowano (średnia PR-AUC z 4 zbiorów danych): fuzja przez średnią i przez maksimum oraz wariant CBF.

Normalizacja	Średnia: na uczących	Średnia: na walidacji	Maksimum: na uczących	Maksimum: na walidacji	CBF: PR-AUC	CBF: F1
min-max	0,589	0,635	0,523	0,585	0,657	0,598
z-score	0,574	0,618	0,483	0,576	0,654	0,597
odporny z	0,573	0,586	0,524	0,537	0,652	0,597
rangi	0,637	0,622	0,412	0,524	0,639	0,583

Fuzja przez maksimum: dopasowanie na walidacji ⇒ PR-AUC 0,412 → 0,524 (rangi) i 0,483 → 0,576 (z-score) (tabela 3). Dopasowanie na walidacji pomaga w 7 z 8 połączeń;

wyjątkiem jest zwykła średnia z rangami, która z rangami z części uczącej wypada nieco lepiej (0,637 wobec 0,622).

4.2 Majority Voting (głosowanie większościowe)

Każdy detektor osobno decyduje „anomalia / nie" według własnego progu. Próg wybieramy na walidacji, tak by dawał najwyższe F1 (wariant główny), albo tak, by detektor zgłaszał tyle obserwacji, ile jest anomalii w walidacji (wariant „c"; z etykiet używa tylko tej jednej liczby). Obserwacja jest anomalią zespołu, gdy wskaże ją co najmniej m z 4 detektorów: $m = 1$ to „którykolwiek", $m = 4$ – „wszystkie". Do PR-AUC służy liczba głosów (0–4), więc ranking ma tylko 5 poziomów.

4.3 Fuzja wyników (Weighted Score Fusion)

Wynik zespołu to ważona średnia znormalizowanych wyników: $S(x) = \sum_k w_k \, \hat{s}_k(x)$, gdzie $\hat{s}_k(x)$ to znormalizowany wynik detektora k dla obserwacji x, a wagi w_k sumują się do 1. Sprawdzono wagi wyznaczane na walidacji:

- **równe** – zwykła średnia;
- **PR-AUC** – waga proporcjonalna do PR-AUC detektora na walidacji;
- **skill** – waga proporcjonalna do przewagi PR-AUC nad zgadywaniem (PR-AUC minus udział anomalii π); detektor nie lepszy od zgadywania dostaje 0;
- **skill** $\times$ **różnorodność** – skill pomnożony przez $1-\bar{\rho}_k$, gdzie $\bar{\rho}_k$ to średnia zgodność rankingu detektora k z pozostałymi (korelacja Spearmana, od -1 do 1); detektor powtarzający innych dostaje mniejszą wagę;

oraz **maksimum** znormalizowanych wyników zamiast średniej. Każdy schemat sprawdzono dla wszystkich detektorów i dla podzbioru wybranego *zachłannie*: zaczynamy od najlepszego detektora na walidacji i dodajemy kolejne, dopóki poprawiają PR-AUC zespołu na walidacji. Próg decyzji zespołu wybieramy na walidacji przez najwyższe F1 albo z udziału anomalii c, jak w głosowaniu.

4.4 Warianty własne: DSF i CBF

Oba warianty odpowiadają na pytanie: *jak dobrać detektory i wagi, gdy jakość detektorów da się ocenić tylko na małej walidacji* – ale w przeciwny sposób.

DSF (*diversity-weighted skill fusion*) – zaufaj walidacji. Zespół zyskuje na detektorach, które są dobre *i* wnoszą coś nowego. DSF: rangi dopasowane na walidacji, wagi skill $\times$ różnorodność, zachłanny wybór detektorów (dodaje detektor, jeśli poprawia PR-AUC zespołu na walidacji o więcej niż 0,001) i próg z walidacyjnego F1.

CBF (*competence-based fusion*) – uważaj na walidację. Przy kilku anomaliach w walidacji wagi i wybór detektorów dopasowują się do przypadku. CBF:

1. 500 razy losuje ze zwracaniem nową wersję walidacji (*bootstrap*) i za każdym razem liczy PR-AUC detektorów;
2. uznaje detektor za *kompetentny*, jeśli w co najmniej 10 % losowań jest nie gorszy od najlepszego – czyli dane nie pozwalają powiedzieć, że jest gorszy;
3. uśrednia detektory kompetentne z równymi wagami, a wyraźnie gorsze pomija;

4. normalizuje odpornym z-score dopasowanym na walidacji, a próg wybiera przez najwyższe F1 na walidacji.

Gdy jeden detektor wyraźnie dominuje, CBF używa tylko jego. Gdy kilka jest nie do odróżnienia, uśrednia je: „uśredniaj tylko to, czego nie umiesz rozróżnić”.

5 Wyniki

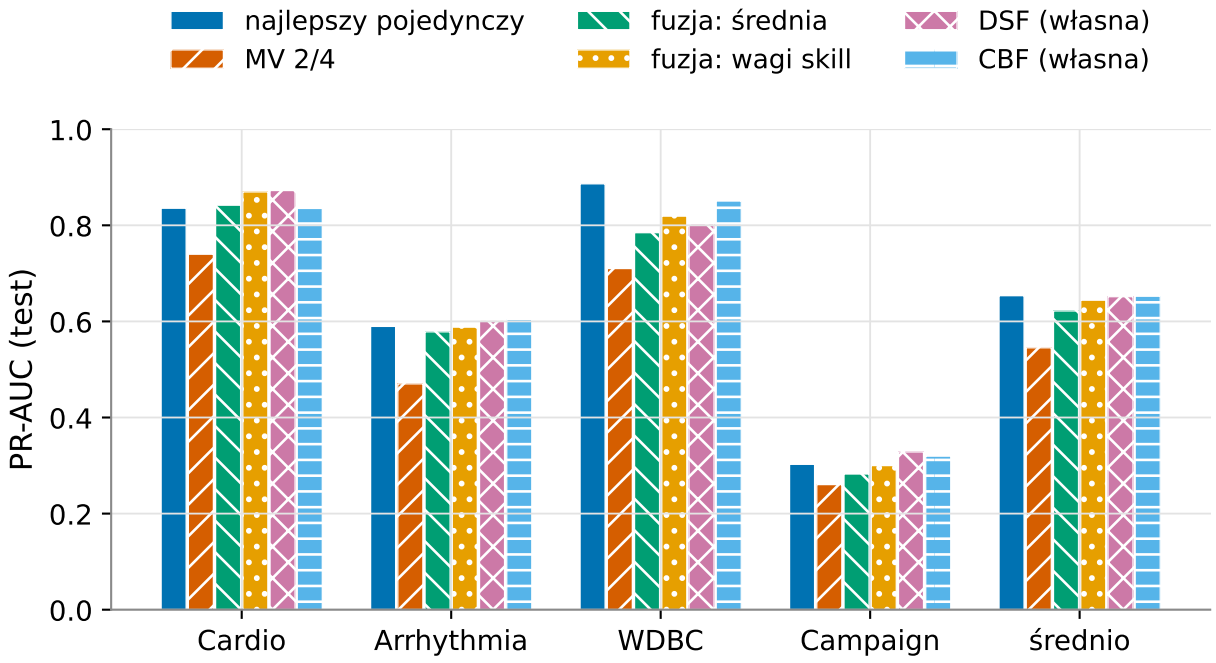
W tej sekcji najpierw zestawiono główne warianty, potem omówiono każdą metodę łączenia w tym samym układzie (wpływ ustawień, wniosek, rysunek „co wykryto”), a na końcu sprawdzono zgodność detektorów, test potwierdzający i porównanie z zadaniami 1–2.

5.1 Przegląd głównych wariantów

Tabela 4 i rys. 2 porównują najlepszy pojedynczy detektor (wybrany na walidacji) z najważniejszymi zespołami; wszystkie warianty są w aneksie A.

Tabela 4: PR-AUC głównych wariantów na każdym zbiorze danych, średnie PR-AUC i F1 oraz średni czas (część testowa; pogrubienie – najlepszy wynik w kolumnie).

Wariant	Cardio	Arrhythmia	WDBC	Campaign	PR-AUC średnio	F1 średnio	Czas średnio [s]
najlepszy pojedynczy	0,836	0,590	**0,886**	0,303	**0,654**	**0,599**	1,2
MV 2/4	0,740	0,470	0,710	0,260	0,545	0,572	31,3
fuzja: średnia	0,842	0,578	0,785	0,282	0,622	0,572	31,3
fuzja: wagi skill	0,870	0,588	0,819	0,300	0,644	0,586	31,3
DSF (własna)	**0,872**	0,602	0,803	**0,328**	0,651	0,597	17,6
CBF (własna)	0,836	**0,604**	0,851	0,320	0,652	0,597	11,4



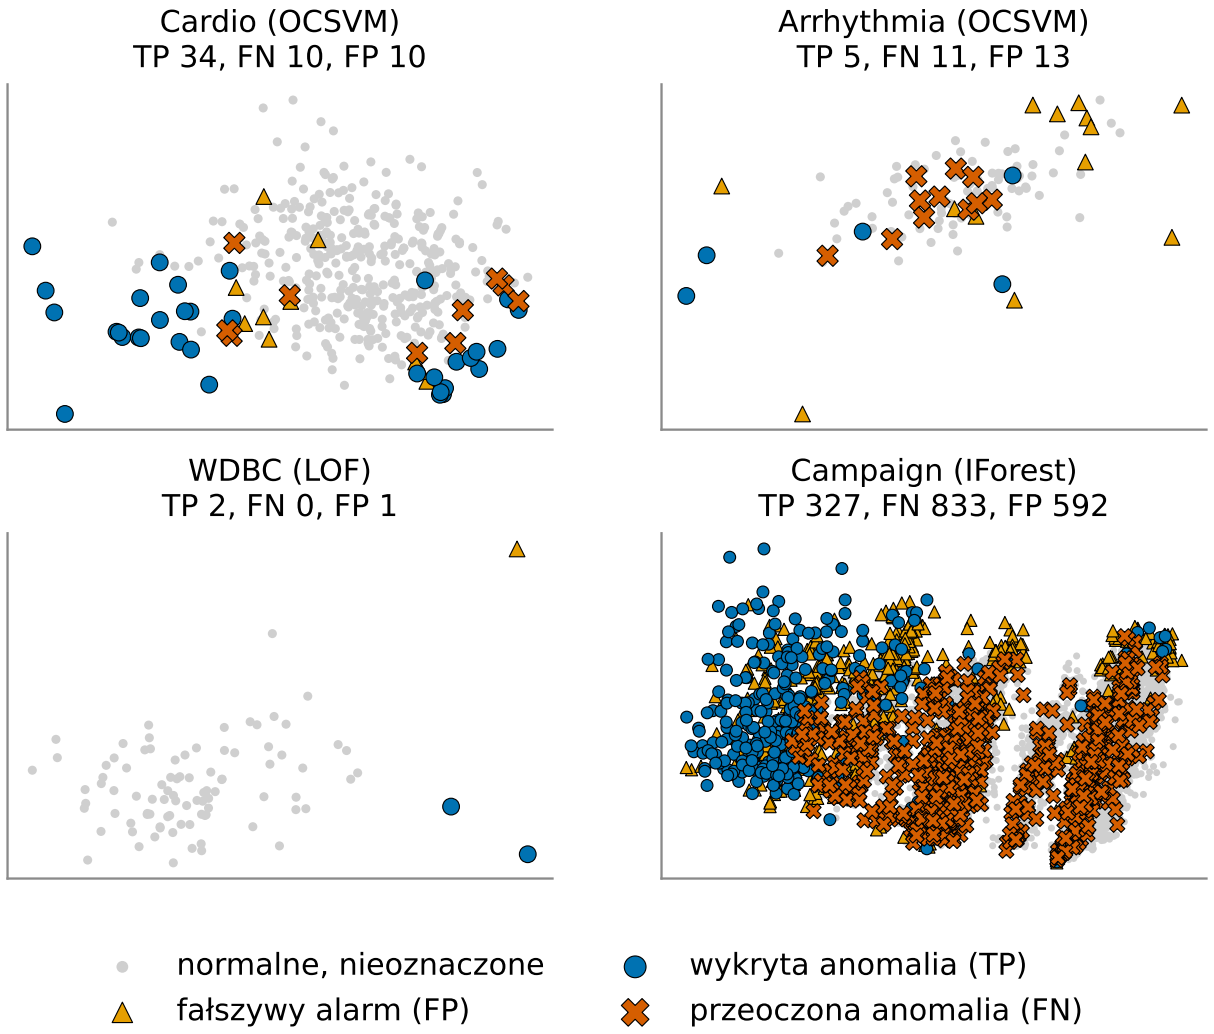
Rysunek 2: PR-AUC najlepszego pojedynczego detektora i zespołów; zespół wygrywa na trzech zbiorach danych i przegrywa na WDBC.

Najlepsze zespoły (DSF, CBF) są średnio tak samo dobre jak najlepszy pojedynczy detektor (0,651–0,652 wobec 0,654). Średnio są lepsze na Cardio (DSF 0,872 wobec 0,836), Arrhythmii (CBF 0,604 wobec 0,590) i Campaign (DSF 0,328 wobec 0,303), ale porównanie podział po podziale (tabela 7) pokazuje, że pewny jest tylko zysk DSF na Campaign i – słabiej – na Cardio; na Arrhythmii różnica mieści się w rozrzucie. **Na WDBC wszystkie zespoły przegrywają** (najlepszy CBF 0,851 wobec 0,886). Zespół kosztuje sumę czasów swoich detektorów: zwykła fuzja średnio 31 s wobec 1,2 s najlepszego pojedynczego, głównie przez OCSVM na Campaign.

Rysunki „co wykryto” w kolejnych podsekcjach pokazują decyzje na części testowej jednego podziału (ziarno 0), w rzucie na dwie pierwsze składowe PCA danych oryginalnych – tym samym dla wszystkich wariantów. Kolory: **TP** – wykryta anomalia, **FN** – przeoczona, **FP** – fałszywy alarm; szare punkty – obserwacje normalne słusznie niezgłoszone. W nawiasie podano detektory użyte w tym podziale. Część testowa WDBC ma w tym podziale tylko 2 anomalie.

5.2 Najlepszy pojedynczy detektor (punkt odniesienia)

Najlepszy pojedynczy detektor to ten detektor bazowy, który ma najwyższą PR-AUC na walidacji w danym podziale.

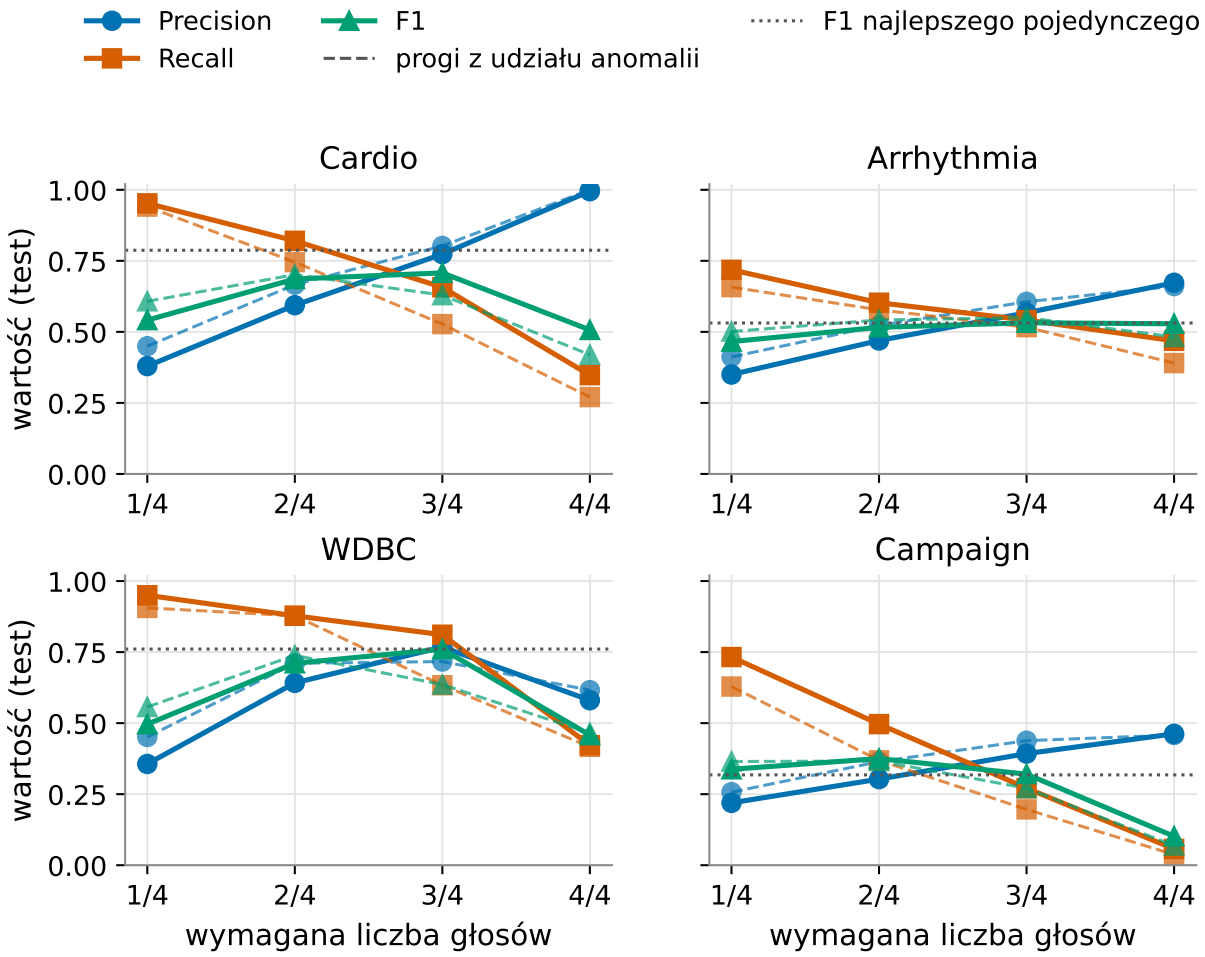


Rysunek 3: Co wykrył najlepszy pojedynczy detektor na każdym zbiorze danych.

Na Cardio OCSVM na UMAP wykrywa 34 z 44 anomalii przy 10 fałszywych alarmach; na Campaign IForest przeocza 833 z 1160 (rys. 3).

5.3 Majority Voting

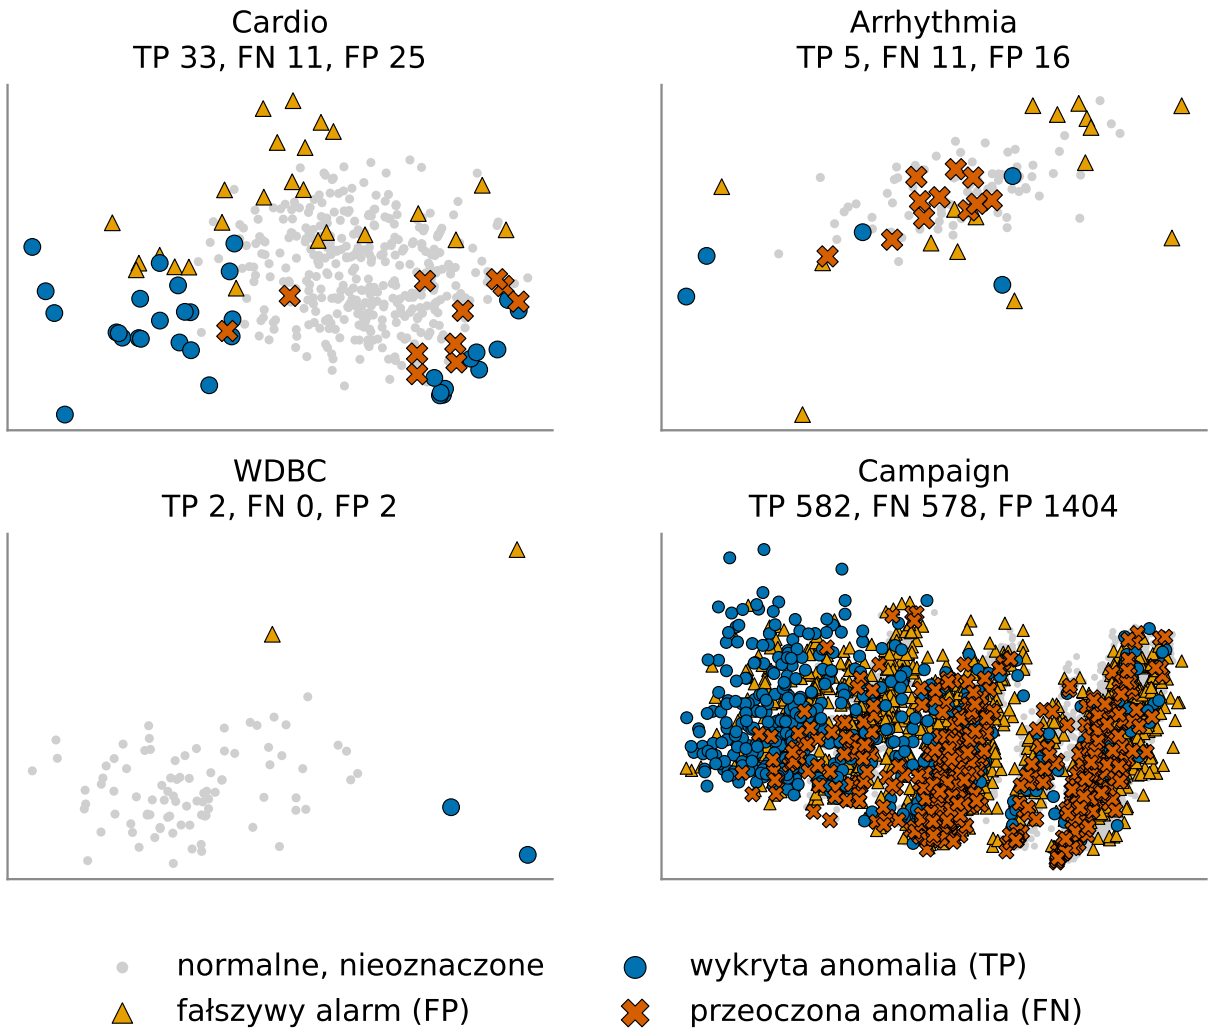
Sprawdzono, jak wymagana liczba głosów m zmienia decyzje zespołu.



Rysunek 4: Majority Voting: więcej wymaganych głosów to wyższa Precision i niższy Recall; F1 jest najwyższe przy 2/4 lub 3/4.

- **Cardio:** $m = 1 \to 4 \Rightarrow$ **Precision 0,38 → 0,995, Recall 0,95 → 0,35** (rys. 4); reguła „wszystkie” jest zbyt surowa – na Campaign, gdzie detektory rzadko się zgadzają, Recall spada do 0,06.
- **Campaign: MV 2/4 ma wyższe F1 niż najlepszy pojedynczy detektor (0,375 wobec 0,318)**, ale niższą PR-AUC (0,260 wobec 0,303), bo ranking z 5 poziomów głosów jest zgrubny.
- **Progi z udziału anomalii** (linie przerywane) dają przy $m = 2$ nieco wyższe F1 niż progi z walidacyjnego F1 na trzech zbiorach danych (np. WDBC 0,74 wobec 0,71): przy kilku anomaliach w walidacji jeden kwantyl jest stabilniejszy niż próg dopasowany do 2–3 punktów.

Głosowanie odrzuca wiedzę, którą ma tylko jeden detektor: na Cardio OCSVM na UMAP wykrywa 75 % anomalii lokalnych, a MV 3/4 tylko 54 %, bo pozostałe detektory ich nie widzą.

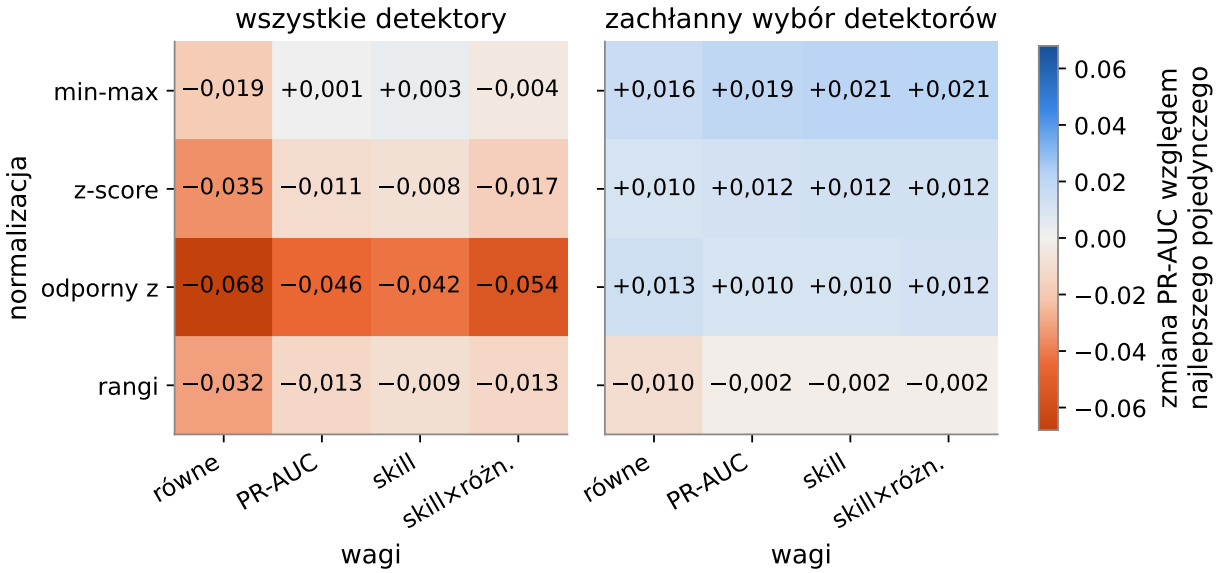


Rysunek 5: Co wykrył Majority Voting 2/4 na każdym zbiorze danych.

MV 2/4 wykrywa więcej anomalii Campaign (582 wobec 327 najlepszego pojedynczego), ale ponad dwa razy więcej fałszywych alarmów (1404 wobec 592); na Cardio wykrywa prawie tyle samo (33 wobec 34) przy 25 zamiast 10 fałszywych alarmach (rys. 5).

5.4 Fuzja wyników: normalizacja, wagi i wybór detektorów

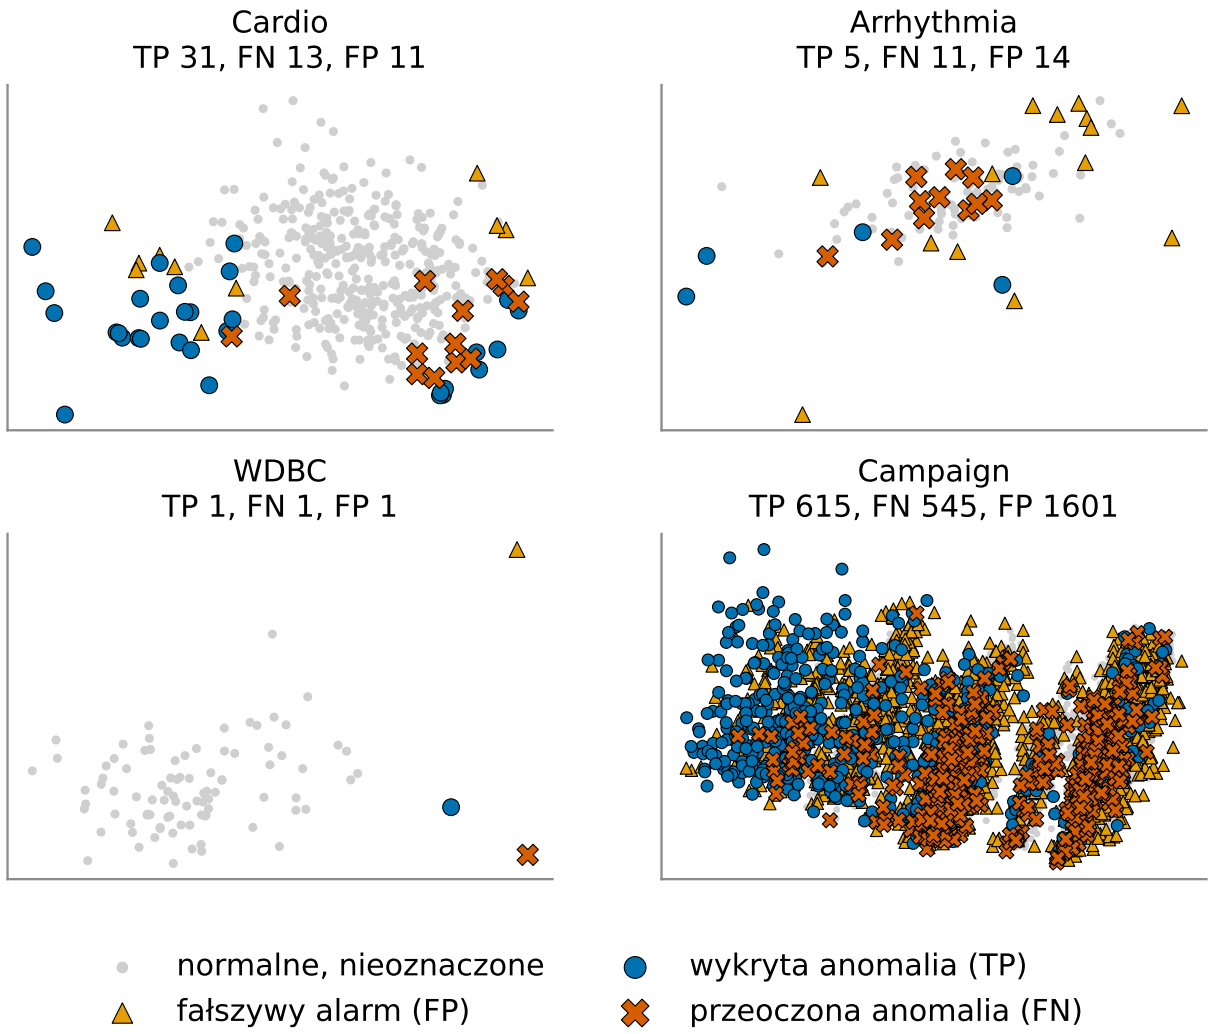
Sprawdzono wszystkie połączenia: 4 normalizacje × 4 schematy wag × 2 sposoby wyboru detektorów × 2 sposoby wyboru progu.



Rysunek 6: Zmiana średniej PR-AUC fuzji względem najlepszego pojedynczego detektora (niebieski – zysk, pomarańczowy – strata); zachłanny wybór detektorów jest ważniejszy niż wagi.

- **Wybór detektorów ma największy wpływ: wszystkie detektory ⇒ do −0,068, zachłanny wybór ⇒ do +0,021** (rys. 6). Słaby detektor – błąd rekonstrukcji PCA (PR-AUC 0,26–0,47) – obniża średnią wszystkich detektorów, a wybór zachłanny go pomija.
- **Normalizacja: najlepszy jest min-max, a odporny z-score przy wszystkich detektorach – najgorszy** (−0,042 do −0,068). Odporny z-score nie ogranicza wartości z góry, więc pojedyncze skrajne wyniki słabego detektora dominują w średniej.
- **Wagi zmieniają wynik najwyżej o 0,03** – mniej niż wybór detektorów; przy łączeniu wszystkich detektorów równe wagi są najgorsze, bo słaby detektor dostaje tyle samo co dobre.
- **Próg z walidacyjnego F1** daje średnio nieco wyższe F1 (0,57–0,62) niż próg z udziału anomalii (0,56–0,61).

Wszystkie 32 połączenia z liczbami są w tabeli 12 w aneksie.

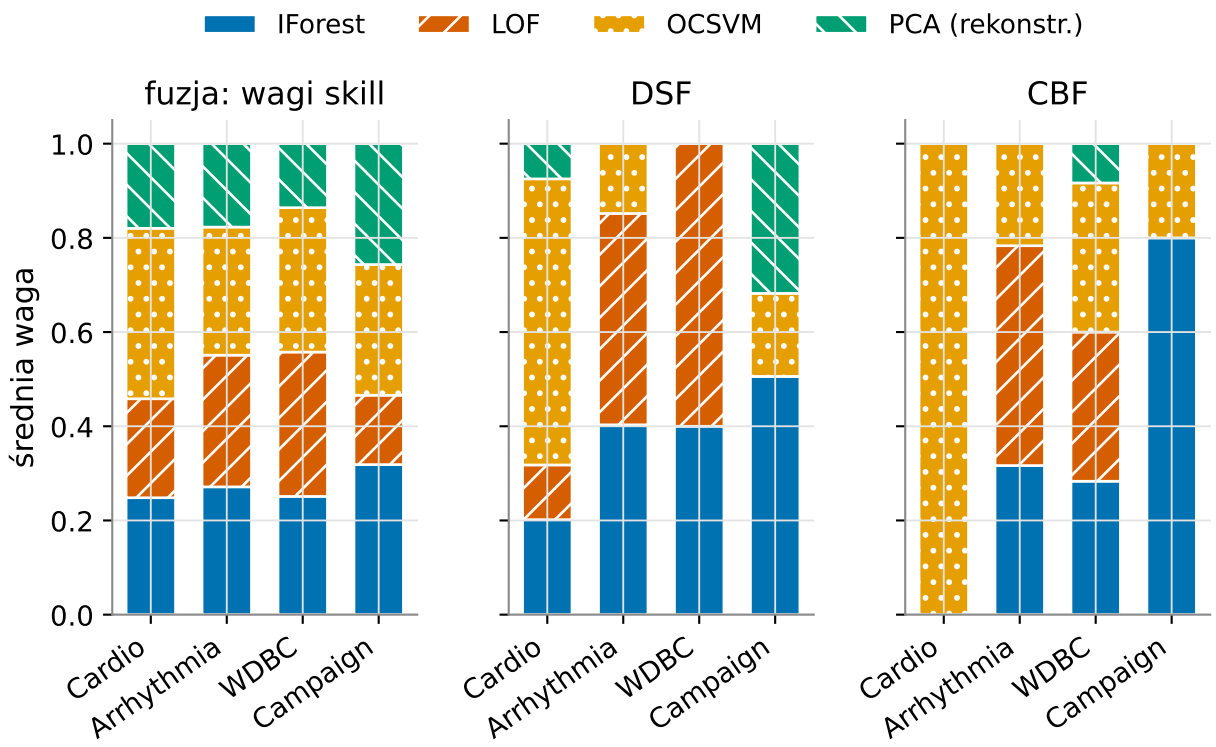


Rysunek 7: Co wykryła fuzja średnia (wszystkie detektory, równe wagi) na każdym zbiorze danych.

Zwykła średnia wszystkich detektorów działa jak głosowanie: więcej wykrytych anomalii Campaign (615), ale najwięcej fałszywych alarmów (1601) (rys. 7). Na Cardio wykrywa mniej anomalii niż najlepszy pojedynczy detektor (31 wobec 34).

5.5 Warianty własne: DSF i CBF

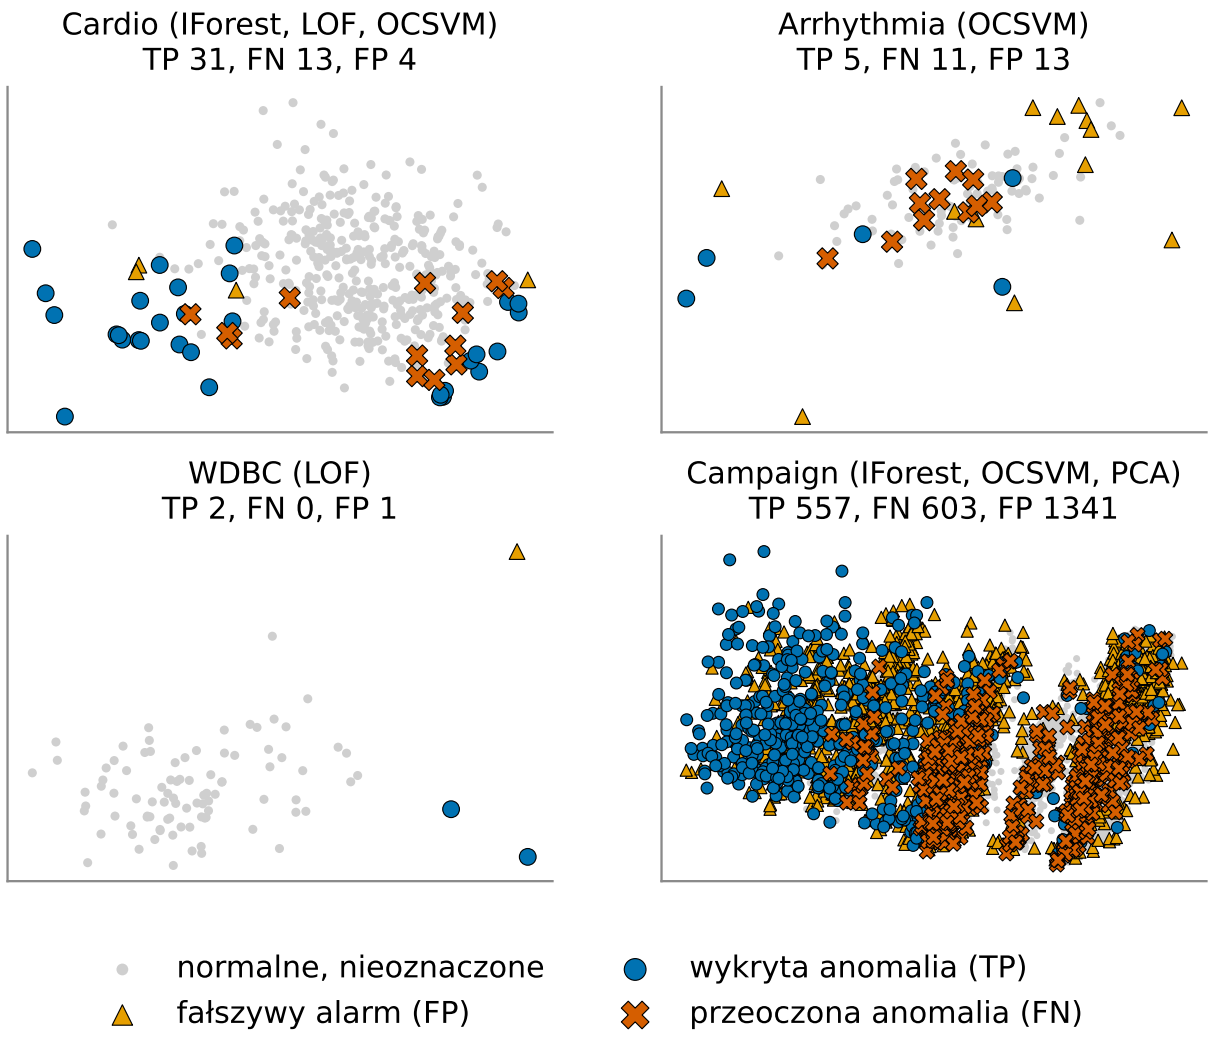
Tu pokazano, jakie wagi i jakie detektory wybierają warianty własne oraz co wykrywają.



Rysunek 8: Średnie wagi detektorów (wszystkie podziały): wagi skill rozkładają się na wszystkie detektory, DSF i CBF zostawiają zwykle 1–3.

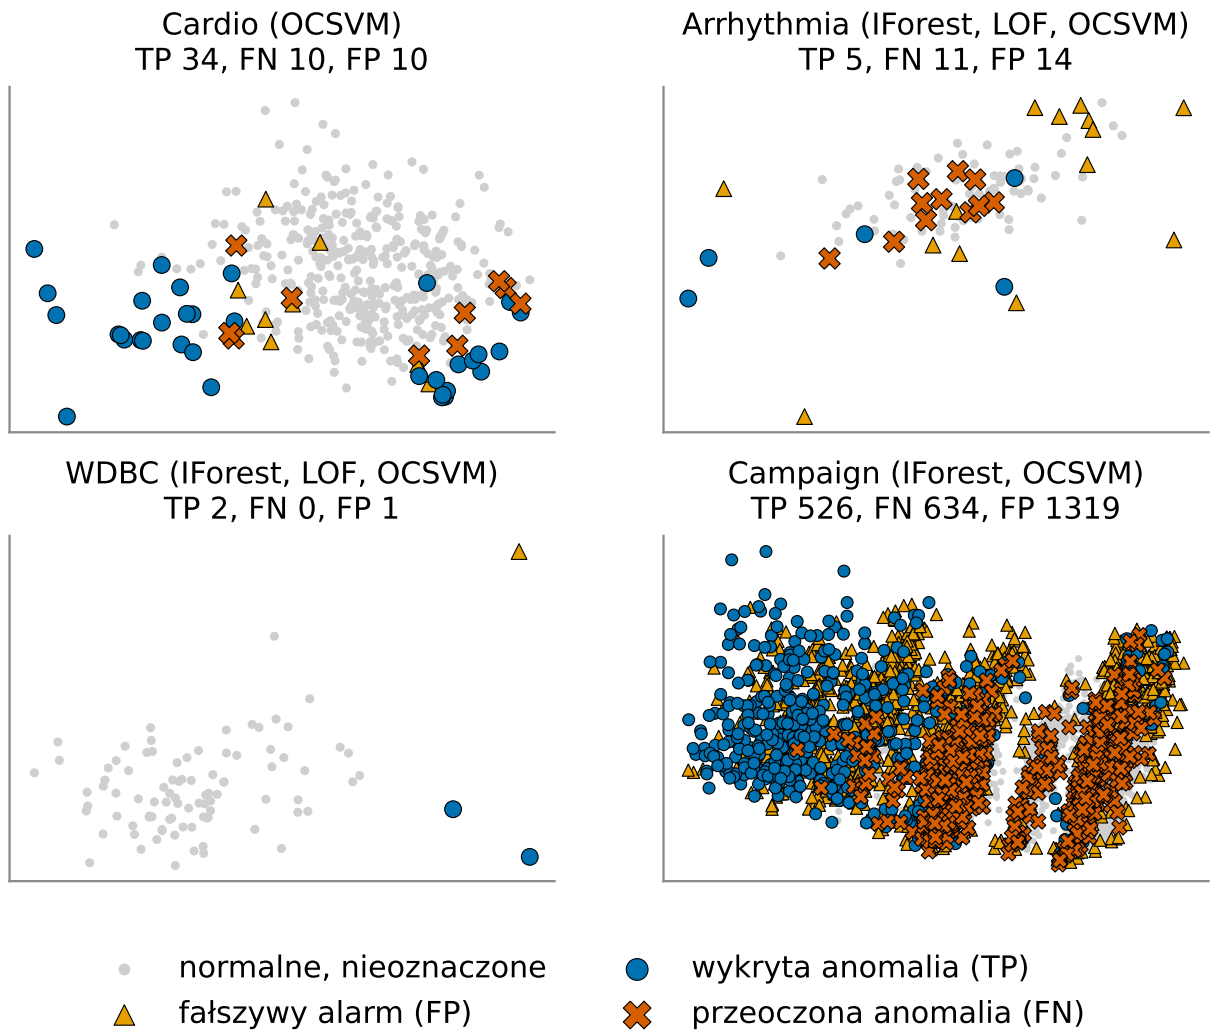
Wagi skill dają wagę także słabemu błędowi rekonstrukcji, a DSF i CBF zwykle go pomijają (rys. 8). Oba warianty zachowują się różnie zależnie od wielkości walidacji:

- **Cardio (44 anomalie w walidacji)**: DSF łączy OCSVM z innymi detektorami (w 8 z 10 podziałów) i daje najlepszy wynik (0,872); CBF we wszystkich 10 podziałach zostawia sam OCSVM, bo jego przewaga na walidacji jest pewna.
- **WDBC (2–3 anomalie)**: DSF zostawia jeden detektor (LOF w 18, IForest w 12 podziałach), czyli często wybiera gorszy; CBF uśrednia trzy lub cztery detektory, bo nie ma podstaw, by odrzucić któryś z dobrych, i wypada lepiej (0,851 wobec 0,803).
- **Arrhythmia i Campaign**: CBF uśrednia najczęściej IForest, LOF i OCSVM (Arrhythmia) albo IForest z OCSVM (Campaign).



Rysunek 9: Co wykrył DSF na każdym zbiorze danych (w nawiasie – wybrane detektory).

DSF na Cardio ma w tym podziale najmniej fałszywych alarmów spośród pokazanych wariantów (4 wobec 10 najlepszego pojedynczego), przy 31 zamiast 34 wykrytych anomaliach (rys. 9). We wszystkich 10 podziałach łącznie DSF usuwa 57 z 88 fałszywych alarmów najlepszego pojedynczego detektora i dodaje 15, ale traci 37 anomalii i ratuje 23 (tabela 10): słabsze detektory „potwierdzają” wysokie wyniki OCSVM głównie dla prawdziwych anomalii.



Rysunek 10: Co wykrył CBF na każdym zbiorze danych (w nawiasie – detektory uznane za kompetentne).

CBF na Cardio używa tylko OCSVM, więc podejmuje te same decyzje co najlepszy pojedynczy detektor, a na Campaign wykrywa więcej anomalii (526 wobec 327) kosztem fałszywych alarmów (1319 wobec 592) (rys. 10).

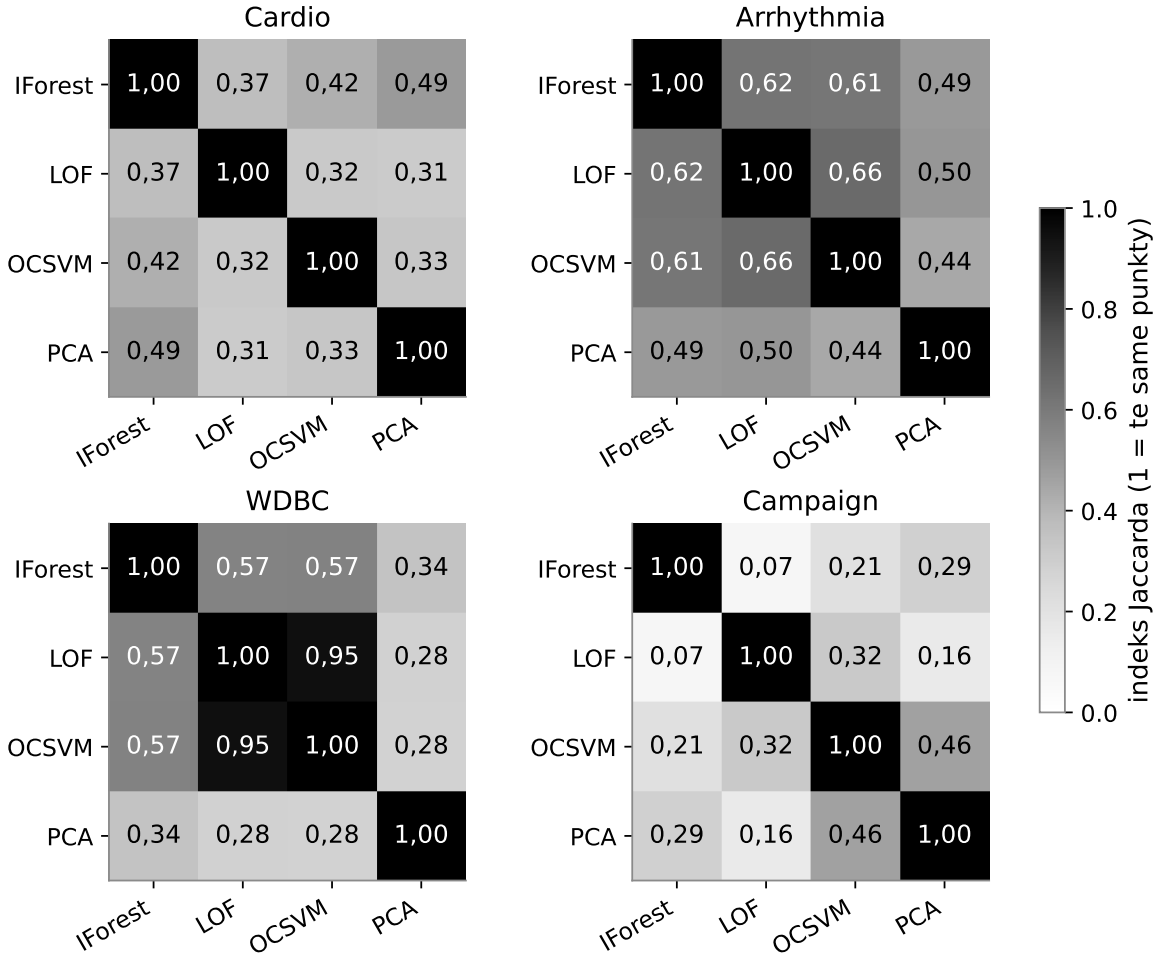
Tabela 5: Liczby z rysunków „co wykryto” (część testowa, ziarno 0): TP / FN / FP – wykryte anomalie / przeoczone anomalie / fałszywe alarmy.

Zbiór danych	Anomalie w teście	najlepszy pojedynczy	MV 2/4	fuzja: średnia	DSF (własna)	CBF (własna)
Cardio	44	34 / 10 / 10	33 / 11 / 25	31 / 13 / 11	31 / 13 / 4	34 / 10 / 10
Arrhythmia	16	5 / 11 / 13	5 / 11 / 16	5 / 11 / 14	5 / 11 / 13	5 / 11 / 14
WDBC	2	2 / 0 / 1	2 / 0 / 2	1 / 1 / 1	2 / 0 / 1	2 / 0 / 1
Campaign	1160	327 / 833 / 592	582 / 578 / 1404	615 / 545 / 1601	557 / 603 / 1341	526 / 634 / 1319

Tabela 5 zbiera liczby z pięciu map: **zespoły zmieniają głównie liczbę fałszywych alarmów**, a na Arrhythmii wszystkie warianty wykrywają tyle samo anomalii (5 z 16).

5.6 Zgodność i komplementarność detektorów

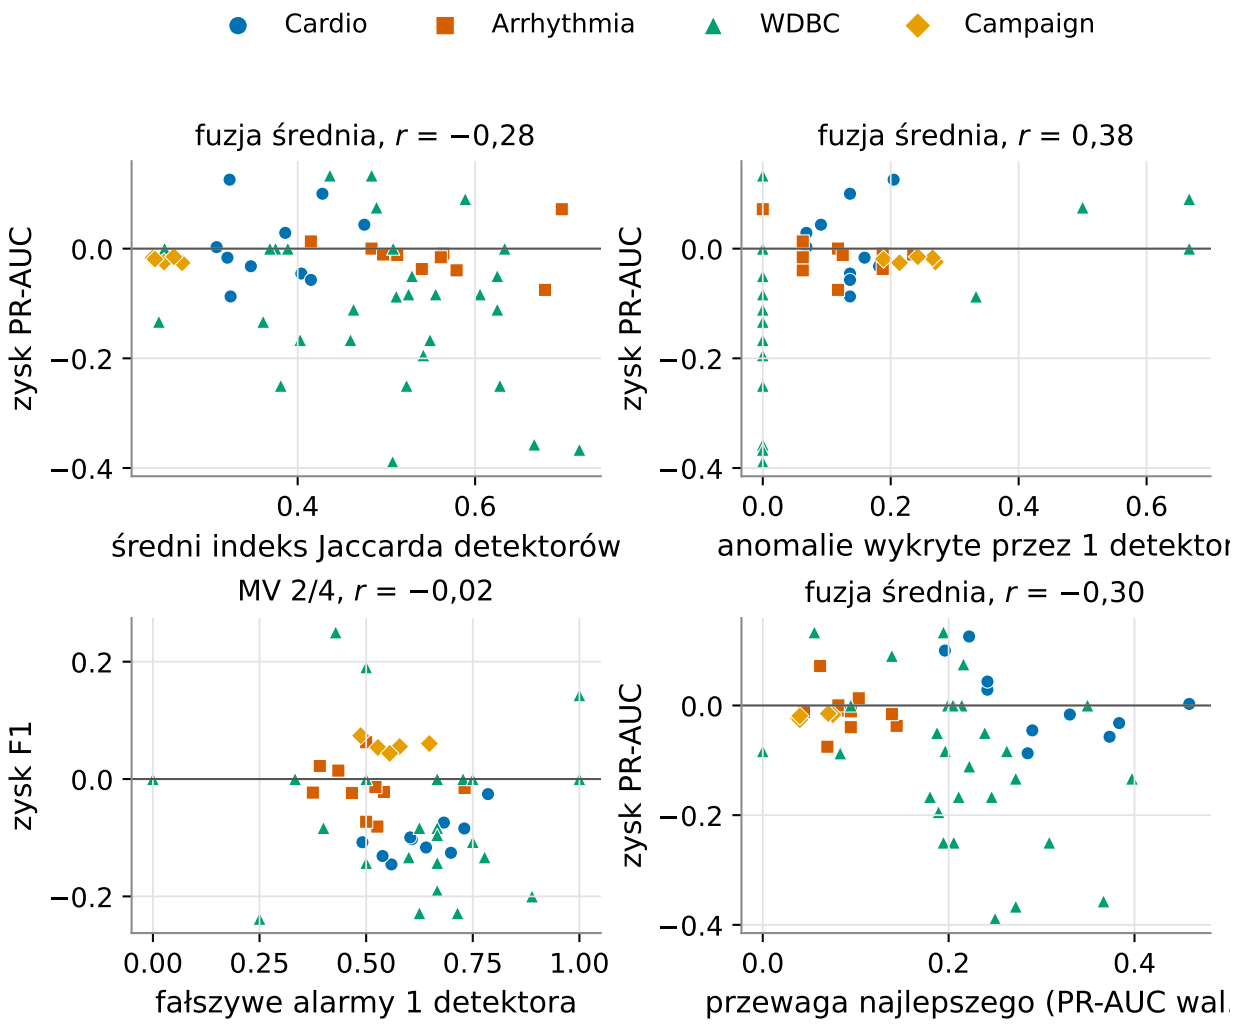
Ta część sprawdza, czy detektory wskazują te same obserwacje i czy różne wskazania przekładają się na zysk zespołu.



Rysunek 11: Indeks Jaccarda par detektorów bazowych (część testowa, średnia po podziałach): na każdym zbiorze danych inna para jest zgodna.

Indeks Jaccarda to liczba obserwacji wskazanych przez oba detektory podzielona przez liczbę wskazanych przez którykolwiek (1 = te same punkty, 0 = zupełnie różne). Na każdym zbiorze danych zgodność wygląda inaczej (rys. 11):

- **WDBC: LOF i OCSVM są prawie identyczne (0,95)**, bo działają na tej samej jednej składowej PCA; IForest i błąd rekonstrukcji różnią się od nich (0,28–0,57), ale są słabsze. Zespół nie ma tu z czego zyskać.
- **Arrhythmia**: IForest, LOF i OCSVM są podobnie dobre i umiarkowanie zgodne (0,61–0,66), więc uśrednianie zmniejsza przypadkowe błędy.
- **Campaign**: detektory prawie się nie zgadzają (IForest i LOF: 0,07), a wszystkie są słabe.
- **Cardio**: OCSVM na UMAP wyraźnie dominuje, a jego decyzje mało pokrywają się z resztą (0,32–0,42), bo działa w innej reprezentacji.



Rysunek 12: Zysk zespołu względem najlepszego pojedynczego detektora w poszczególnych podziałach a miary różnorodności detektorów; r – współczynnik korelacji (0 = brak związku).

Różnorodność detektorów słabo przewiduje zysk zespołu w pojedynczym podziale ($|r| \leq 0{,}38$) (rys. 12). Najsilniejszy związek ma udział anomalii wykrytych przez dokładnie jeden detektor ($r = 0{,}38$): gdy detektory wykrywają różne anomalie, uśrednianie ma co łączyć.

5.7 Test potwierdzający na nowych podziałach

Tu sprawdzono, czy wnioski powtarzają się na podziałach, których nie użyto przy projektowaniu zespołów.

Tabela 6: Średnie PR-AUC i F1 (4 zbiory danych, część testowa) na podziałach projektowych i nowych; Wygrane – na ilu zbiorach danych wariant ma wyższą PR-AUC niż najlepszy pojedynczy detektor.

Wariant	PR-AUC (projektowe)	F1 (projektowe)	Wygrane (projektowe)	PR-AUC (nowe)	F1 (nowe)	Wygrane (nowe)
najlepszy pojedynczy	0,654	0,599	0	0,620	0,565	0
MV 2/4	0,545	0,572	0	0,519	0,565	0
fuzja: średnia	0,622	0,572	1	0,600	0,546	1
fuzja: wagi skill	0,644	0,586	1	0,620	0,566	2
DSF (własna)	0,651	0,597	3	0,621	0,580	2
CBF (własna)	0,652	0,597	2	0,628	0,579	2

Na nowych podziałach CBF ma najwyższą średnią PR-AUC (0,628 wobec 0,620 najlepszego pojedynczego), a DSF i CBF wygrywają na 2 z 4 zbiorów danych i mają wyższe F1 (0,579–0,580 wobec 0,565; tabela 6). Różnice średnich (ok. 0,01) są jednak mniejsze niż rozrzut między podziałami na Arrhythmii i WDBC (0,13–0,20), dlatego tabela 7 porównuje warianty z najlepszym pojedynczym detektorem w każdym podziale osobno.

Tabela 7: Zmiana PR-AUC zespołu względem najlepszego pojedynczego detektora, średnio po podziałach; w nawiasie – w ilu podziałach zespół był lepszy : gorszy (pozostałe to remisy).

Podziały	Wariant	Cardio	Arrhythmia	WDBC	Campaign
projektowe	DSF (własna)	+0,037 (6:4)	+0,013 (6:4)	−0,084 (1:15)	+0,026 (5:0)
	CBF (własna)	0,000 (0:0)	+0,014 (5:3)	−0,036 (5:7)	+0,017 (2:0)
	fuzja: wagi skill	+0,034 (7:3)	−0,002 (5:5)	−0,067 (3:13)	−0,003 (2:3)
	fuzja: średnia	+0,006 (5:5)	−0,011 (3:7)	−0,102 (4:20)	−0,020 (0:5)
nowe	DSF (własna)	+0,050 (7:3)	−0,002 (2:8)	−0,070 (3:14)	+0,025 (5:0)
	CBF (własna)	−0,006 (0:1)	0,000 (4:3)	+0,013 (7:6)	+0,023 (3:0)
	fuzja: wagi skill	+0,041 (7:3)	+0,003 (4:6)	−0,038 (6:8)	−0,006 (2:3)
	fuzja: średnia	+0,008 (4:6)	−0,004 (3:7)	−0,060 (5:11)	−0,024 (0:5)

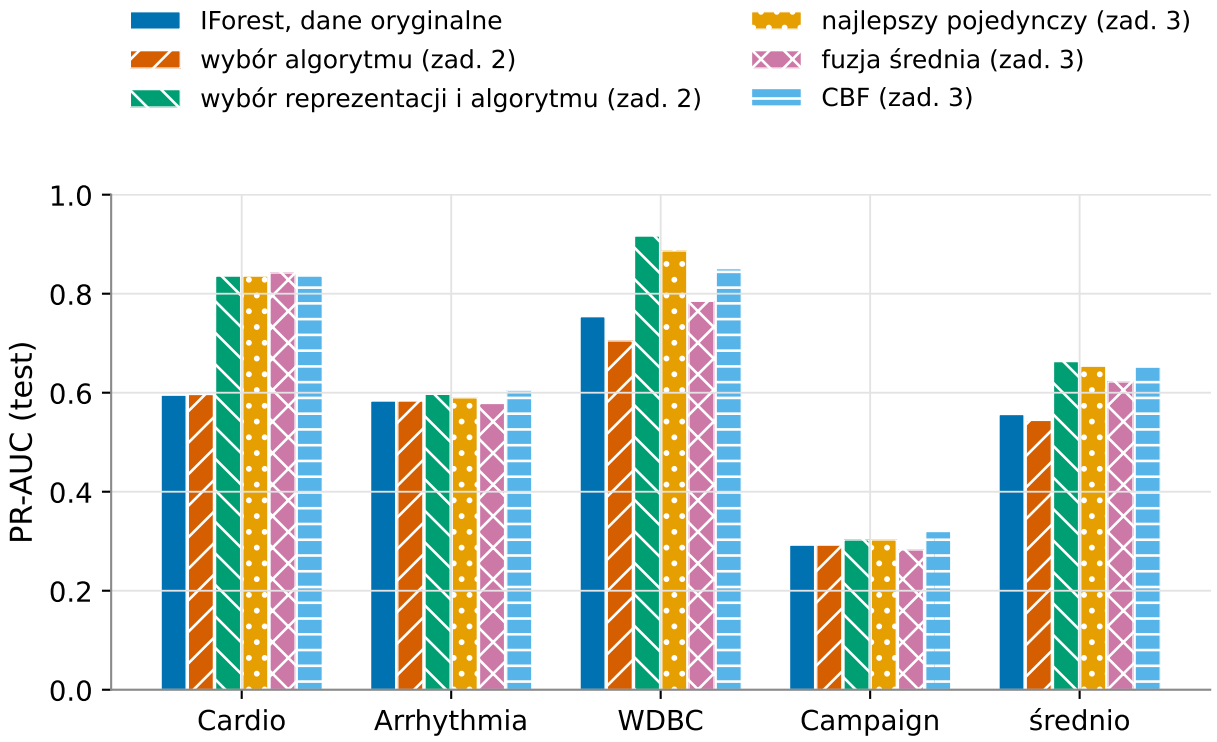
- **Pewny zysk: DSF na Campaign** (+0,025–0,026, lepszy we wszystkich 5 podziałach projektowych i 5 nowych) **i na Cardio** (+0,037–0,050, lepszy w 6–7 z 10 podziałów).
- **Pewna strata: DSF i zwykła średnia na WDBC** (DSF gorszy w 14–15 z 30 podziałów, lepszy w 1–3).
- **Bez rozstrzygnięcia: Arrhythmia i CBF.** Na Arrhythmii znak zmiany odwraca się między podziałami projektowymi a nowymi. CBF na Cardio podejmuje te same decyzje co najlepszy detektor (używa tylko OCSVM), a na WDBC raz przegrywa (−0,036), raz wygrywa (+0,013); w ponad połowie podziałów remisuje.

5.8 Porównanie z zadaniami 1 i 2

Tabela 8 pokazuje PR-AUC na kolejnych etapach projektu, na tych samych podziałach; każdy wybór zrobiono na walidacji.

Tabela 8: PR-AUC (test) na kolejnych etapach projektu.

Etap	Cardio	Arrhythmia	WDBC	Campaign	Średnio
IForest, dane oryginalne	0,595	0,583	0,754	0,292	0,556
wybór algorytmu (zad. 2)	0,596	0,583	0,705	0,292	0,544
wybór reprezentacji i algorytmu (zad. 2)	0,836	0,597	0,916	0,303	0,663
najlepszy pojedynczy (zad. 3)	0,836	0,590	0,886	0,303	0,654
fuzja średnia (zad. 3)	0,842	0,578	0,785	0,282	0,622
CBF (zad. 3)	0,836	0,604	0,851	0,320	0,652



Rysunek 13: PR-AUC na kolejnych etapach zadań 2 i 3: największy skok daje wybór reprezentacji.

Największy skok daje wybór reprezentacji: średnio 0,544 → 0,663 (Cardio: UMAP z OCSVM 0,60 → 0,84; WDBC: PCA 0,71 → 0,92). Wybór jednego z trzech algorytmów w danych oryginalnych nic tu nie daje (0,556 → 0,544), a zespół utrzymuje poziom najlepszego pojedynczego detektora (CBF 0,652 wobec 0,654).

6 Synteza: co miało największy wpływ na jakość detekcji?

Ta sekcja odpowiada na pytanie przewodnie projektu na podstawie wyników trzech zadań.

Tabela 9: Wpływ czynników na PR-AUC (test). Rozrzut – różnica między najlepszym a najgorszym wyborem (algorytmu w danych oryginalnych; średnio dla jednego detektora między reprezentacjami); zysk zespołu – względem najlepszego pojedynczego detektora wybranego na walidacji.

Zbiór danych	Rozrzut: algorytm (dane oryginalne)	Rozrzut: reprezentacja	Zysk zespołu: fuzja średnia	Zysk zespołu: CBF
Cardio	0,286	0,206	+0,006	0,000
Arrhythmia	0,125	0,260	−0,011	+0,014
WDBC	0,055	0,200	−0,102	−0,036
Campaign	0,090	0,078	−0,020	+0,017
średnio	0,139	0,186	−0,032	−0,001

Rozrzut mówi, ile można zyskać lub stracić danym wyborem, a *zysk zespołu* – ile zespół faktycznie dał przy wyborze na walidacji (tabela 9). Wybór algorytmu badano też w zadaniu 1, na pięciu innych zbiorach danych i pięciu metodach: rozrzut wyniósł tam średnio 0,40 (Breastw 0,64, Wine 0,61, Cardio 0,56), a wybór metody na walidacji podniósł średnią PR-AUC z 0,511 (Isolation Forest) do 0,658.

1. **Algorytm i reprezentacja mają podobny, największy wpływ i nie da się ich rozdzielić.** Wybór metody w zadaniu 1 dał średnio +0,15 PR-AUC, a wybór reprezentacji w zadaniu 2 +0,12. Kluczowa jest *para*: UMAP pomaga OCSVM na Cardio (+0,24) i szkodzi LOF (−0,07).
2. **Reprezentacja działa w obie strony** (rozrzut średnio 0,19): PCA na WDBC +0,21 dla LOF, UMAP na Arrhythmii −0,26 dla IForest.
3. **Połączenie detektorów ma najmniejszy wpływ**: najlepsze zespoły zmieniają średnią PR-AUC o ok. 0,00 (na nowych podziałach +0,01), a zwykła średnia o −0,03.
4. **Ponad wszystkim stoi natura danych**: najlepsze wyniki na poszczególnych zbiorach danych różnią się bardziej (0,33–0,93) niż efekt któregokolwiek wyboru. Na Campaign, gdzie „anomalie" (klienci zakładający lokatę) nie odstają od reszty danych, żaden wybór nie dał więcej niż 0,35 przy zgadywaniu 0,11.

7 Zalety, ograniczenia i przypadki niepowodzenia

Ta sekcja pokazuje, kiedy zespół pomaga, kiedy szkodzi i co ogranicza pewność wniosków.

Tabela 10: Decyzje zespołów a decyzje najlepszego pojedynczego detektora (część testowa, suma po podziałach): anomalie wykryte tylko przez zespół (uratowane) i tylko przez detektor (utracone) oraz fałszywe alarmy usunięte i dodane przez zespół.

Zbiór danych	Zespół	Anomalie	Anomalie uratowane	Anomalie utracone	Fałszywe alarmy najlepszego pojed.	Fałszywe alarmy usunięte	Fałszywe alarmy dodane
Cardio	MV 2/4	440	39	21	88	42	208
	MV 3/4	440	23	77	88	63	60
	fuzja: średnia	440	45	62	88	72	90
	DSF (własna)	440	23	37	88	57	15
	CBF (własna)	440	0	0	88	0	0
Arrhythmia	MV 2/4	164	9	3	89	9	35
	MV 3/4	164	3	7	89	27	13
	fuzja: średnia	164	5	6	89	27	18
	DSF (własna)	164	0	3	89	12	11
	CBF (własna)	164	5	9	89	33	13
WDBC	MV 2/4	79	2	1	35	2	16
	MV 3/4	79	0	4	35	9	0
	fuzja: średnia	79	4	15	35	5	13
	DSF (własna)	79	0	11	35	8	0
	CBF (własna)	79	3	9	35	11	6
Campaign	MV 2/4	5800	1406	149	2775	1062	4943
	MV 3/4	5800	374	424	2775	1570	1232
	fuzja: średnia	5800	1510	231	2775	1019	5800
	DSF (własna)	5800	772	72	2775	719	2722
	CBF (własna)	5800	334	36	2775	315	1278

Zalety – kiedy zespół pomaga. Cardio, DSF: usuwa 57 z 88 fałszywych alarmów, dodając tylko 15 (traci 37 anomalii, ratuje 23; tabela 10); Precision rośnie z 0,81 do 0,89. Na Arrhythmii CBF usuwa 33 z 89 fałszywych alarmów, dodając 13: detektory są tam podobnie dobre, a ich błędy w dużej mierze różne, więc uśrednianie je wygładza.

Przypadki niepowodzenia – kiedy zespół szkodzi. WDBC, fuzja średnia: traci 15 z 79 anomalii, ratując 4. LOF i OCSVM na pierwszej składowej PCA prawie bezbłędnie oddzielają guzy złośliwe, a słabsze IForest i błąd rekonstrukcji „rozmywają" ten sygnał. **Campaign, MV 2/4 i fuzja średnia: ratują 1400–1500 anomalii, ale dodają 4900–5800 fałszywych alarmów**; przy słabych detektorach suma sygnałów obniża trafność zgłoszeń.

Ograniczenia.

- Walidacja WDBC ma 2–3 anomalie, więc każdy wybór wag i progów, a nawet wybór najlepszego detektora, jest tam niepewny (w 12 z 30 podziałów walidacja wskazała IForest zamiast LOF).
- Dla Campaign użyto 5 podziałów projektowych i 5 nowych (koszt obliczeń); odchylenia między podziałami są tam małe (0,01–0,03).
- Detektory bazowe przejęto z zadania 2; na WDBC LOF i OCSVM są niemal identyczne, więc zespół ma w praktyce trzy różne detektory.
- Nie badano zespołów z wielu wersji jednego detektora (np. LOF o różnych k) ani modelu uczonego na walidacji do łączenia wyników (*stacking*), który przy małej walidacji silnie by się przeuczył.

8 Wnioski

Najważniejsze wnioski z zadania, każdy poparty liczbami z sekcji 5 i 6.

1. **Zespół nie jest automatycznie lepszy od najlepszego detektora.** DSF i CBF są średnio tak samo dobre (0,651–0,652 wobec 0,654). Porównanie podział po podziale potwierdza tylko zysk DSF na Campaign (+0,026, lepszy w 5 z 5 podziałów, także na nowych) i Cardio (+0,04–0,05, w 6–7 z 10); na Arrhythmii różnica mieści się w rozrzucie, a na WDBC DSF i zwykła średnia wyraźnie przegrywają.
2. **O zysku decyduje relacja jakości i różnorodności detektorów.** Słabsze detektory pomagają, gdy potwierdzają trafienia dobrego (Cardio, DSF: we wszystkich podziałach łącznie 57 z 88 fałszywych alarmów usuniętych, 15 dodanych), a szkodzą, gdy rozmywają prawie bezbłędny sygnał (WDBC: zwykła średnia −0,10).
3. **Wybór detektorów jest ważniejszy niż wagi**: zachłanny wybór daje do +0,021, a fuzja wszystkich detektorów do −0,068; wagi zmieniają wynik najwyżej o 0,03.
4. **Normalizację zwykle lepiej dopasowywać na wynikach walidacji niż części uczącej**: pomaga to w 7 z 8 połączeń, najbardziej fuzji przez maksimum z rangami (+0,11 PR-AUC); wyjątkiem jest zwykła średnia z rangami (0,622 wobec 0,637).
5. **Majority Voting ma słaby ranking i nie poprawia decyzji**: najniższa średnia PR-AUC wśród głównych wariantów (0,545) i niższe średnie F1 niż najlepszy pojedynczy detektor (0,572 wobec 0,599); wyższe F1 ma tylko na Campaign (0,375 wobec 0,318).
6. **DSF i CBF wygrywają w innych warunkach**: DSF jest lepszy od CBF na Cardio (+0,04–0,06), gdzie walidacja ma 44 anomalie, a CBF od DSF na WDBC (+0,05–0,08), gdzie ma 2–3; na Arrhythmii i Campaign remisują. Na nowych podziałach CBF miał najwyższą średnią PR-AUC (0,628), ale tylko o 0,008 wyższą niż najlepszy pojedynczy detektor. Rekomendacja: przy kilku anomaliach w walidacji użyć CBF albo pojedynczego detektora, a DSF tam, gdzie walidacja pozwala ocenić detektory; nie łączyć wszystkich detektorów bez kontroli jakości.
7. **W całym projekcie o jakości decydowały kolejno**: natura danych, dobór pary algorytm–reprezentacja, a dopiero na końcu połączenie detektorów.

A Wyniki wszystkich wariantów

Tabela podaje średnie wyniki części testowej podziałów projektowych (± odchylenie standardowe dla F1 i PR-AUC); czas obejmuje przygotowanie reprezentacji, uczenie i ocenę użytych detektorów oraz łączenie.

Zbiór danych	Wariant	Precision	Recall	F1	ROC-AUC	PR-AUC	Czas [ms]
Cardio	IForest	0,517	0,716	0,588 ± 0,062	0,936	0,593 ± 0,098	10791
	LOF	0,544	0,675	0,595 ± 0,064	0,871	0,576 ± 0,064	9
	OCSVM	0,805	0,780	0,787 ± 0,021	0,956	0,836 ± 0,047	2798
	PCA (rekonstr.)	0,430	0,607	0,499 ± 0,100	0,886	0,471 ± 0,123	2
	najlepszy pojedynczy	0,805	0,780	0,787 ± 0,021	0,956	0,836 ± 0,047	2798
	MV 1/4	0,380	0,952	0,541 ± 0,045	0,947	0,740 ± 0,061	13601
	MV 2/4	0,594	0,820	0,686 ± 0,041	0,947	0,740 ± 0,061	13601
	MV 3/4	0,774	0,657	0,708 ± 0,077	0,947	0,740 ± 0,061	13601
	MV 4/4	0,995	0,348	0,507 ± 0,116	0,947	0,740 ± 0,061	13601
	fuzja: maksimum	0,605	0,775	0,674 ± 0,050	0,954	0,662 ± 0,069	13601
	fuzja: średnia	0,760	0,741	0,748 ± 0,057	0,970	0,842 ± 0,050	13601
	fuzja: wagi PR-AUC	0,817	0,727	0,764 ± 0,069	0,973	0,867 ± 0,045	13604
	fuzja: wagi skill	0,833	0,730	0,773 ± 0,065	0,973	0,870 ± 0,045	13604
	DSF (własna)	0,887	0,748	**0,805 ± 0,048**	0,966	**0,872 ± 0,038**	8972

Zbiór danych	Wariant	Precision	Recall	F1	ROC-AUC	PR-AUC	Czas [ms]
	CBF (własna)	0,805	0,780	0,787 ± 0,021	0,956	0,836 ± 0,047	2799
Arrhythmia	IForest	0,546	0,560	0,533 ± 0,091	0,829	0,571 ± 0,115	1886
	LOF	0,489	0,597	0,522 ± 0,090	0,822	0,597 ± 0,129	1827
	OCSVM	0,523	0,566	0,516 ± 0,090	0,810	0,585 ± 0,134	1764
	PCA (rekonstr.)	0,402	0,609	0,463 ± 0,117	0,813	0,462 ± 0,115	1607
	najlepszy pojedynczy	0,533	0,565	0,531 ± 0,100	0,832	0,590 ± 0,124	1086
	MV 1/4	0,350	0,718	0,466 ± 0,096	0,787	0,470 ± 0,101	7084
	MV 2/4	0,470	0,603	0,516 ± 0,106	0,787	0,470 ± 0,101	7084
	MV 3/4	0,567	0,542	0,532 ± 0,100	0,787	0,470 ± 0,101	7084
	MV 4/4	0,673	0,468	0,528 ± 0,124	0,787	0,470 ± 0,101	7084
	fuzja: maksimum	0,455	0,588	0,488 ± 0,099	0,828	0,531 ± 0,129	7084
	fuzja: średnia	0,548	0,559	0,542 ± 0,109	0,831	0,578 ± 0,142	7085
	fuzja: wagi PR-AUC	0,545	0,559	0,541 ± 0,105	0,831	0,585 ± 0,133	7087
	fuzja: wagi skill	0,548	0,559	0,541 ± 0,102	0,831	0,588 ± 0,134	7087
	DSF (własna)	0,560	0,547	0,524 ± 0,095	0,836	0,602 ± 0,137	2029
	CBF (własna)	0,600	0,543	**0,551 ± 0,138**	0,831	**0,604 ± 0,133**	4265
WDBC	IForest	0,495	0,794	0,580 ± 0,195	0,987	0,754 ± 0,186	262
	LOF	0,777	0,867	0,789 ± 0,181	0,996	0,916 ± 0,132	5
	OCSVM	0,796	0,900	**0,815 ± 0,155**	0,997	**0,925 ± 0,131**	4
	PCA (rekonstr.)	0,245	0,500	0,287 ± 0,188	0,947	0,459 ± 0,242	2
	najlepszy pojedynczy	0,723	0,867	0,761 ± 0,198	0,994	0,886 ± 0,167	110
	MV 1/4	0,356	0,950	0,496 ± 0,182	0,966	0,710 ± 0,216	273
	MV 2/4	0,642	0,878	0,710 ± 0,189	0,966	0,710 ± 0,216	273
	MV 3/4	0,768	0,811	0,760 ± 0,194	0,966	0,710 ± 0,216	273
	MV 4/4	0,581	0,422	0,458 ± 0,284	0,966	0,710 ± 0,216	273
	fuzja: maksimum	0,456	0,717	0,511 ± 0,206	0,979	0,587 ± 0,230	273
	fuzja: średnia	0,668	0,728	0,640 ± 0,217	0,990	0,785 ± 0,193	274
	fuzja: wagi PR-AUC	0,684	0,733	0,665 ± 0,272	0,992	0,819 ± 0,204	276
	fuzja: wagi skill	0,684	0,733	0,665 ± 0,272	0,992	0,819 ± 0,204	276
	DSF (własna)	0,733	0,728	0,700 ± 0,234	0,993	0,803 ± 0,201	119
	CBF (własna)	0,714	0,800	0,719 ± 0,240	0,993	0,851 ± 0,196	255
Campaign	IForest	0,377	0,280	0,318 ± 0,008	0,672	0,303 ± 0,008	665
	LOF	0,199	0,381	0,260 ± 0,008	0,634	0,202 ± 0,006	5406
	OCSVM	0,272	0,469	0,341 ± 0,006	0,742	0,276 ± 0,009	97940
	PCA (rekonstr.)	0,315	0,428	0,363 ± 0,007	0,730	0,260 ± 0,010	116
	najlepszy pojedynczy	0,377	0,280	0,318 ± 0,008	0,672	0,303 ± 0,008	665
	MV 1/4	0,219	0,733	0,338 ± 0,009	0,736	0,260 ± 0,006	104127
	MV 2/4	0,303	0,497	0,375 ± 0,006	0,736	0,260 ± 0,006	104127
	MV 3/4	0,393	0,271	0,320 ± 0,014	0,736	0,260 ± 0,006	104127
	MV 4/4	0,462	0,057	0,102 ± 0,010	0,736	0,260 ± 0,006	104127
	fuzja: maksimum	0,311	0,490	**0,376 ± 0,009**	0,756	0,318 ± 0,010	104127
	fuzja: średnia	0,279	0,500	0,356 ± 0,013	0,758	0,282 ± 0,007	104129
	fuzja: wagi PR-AUC	0,281	0,513	0,360 ± 0,013	0,760	0,292 ± 0,006	104134
	fuzja: wagi skill	0,286	0,500	0,363 ± 0,011	0,760	0,300 ± 0,007	104134
	DSF (własna)	0,335	0,401	0,360 ± 0,010	0,737	**0,328 ± 0,015**	59213
	CBF (własna)	0,362	0,331	0,331 ± 0,022	0,703	0,320 ± 0,027	38380

B Wszystkie połączenia fuzji wyników

Tabela rozwija rysunek 6: wynik każdego połączenia normalizacji, wag i wyboru detektorów.

Tabela 12: Fuzja wyników (normalizacja dopasowana na walidacji): średnia PR-AUC i F1 z 4 zbiorów danych, zmiana względem najlepszego pojedynczego detektora; Wygrane – na ilu zbiorach danych fuzja ma wyższą PR-AUC.

Normalizacja	Wagi	Detektory	PR-AUC	Zmiana PR-AUC	F1 (próg z walidacji)	Zmiana F1	F1 (próg z udziału c)	Wygrane (z 4)
min-max	równe	wszystkie	0,635	−0,019	0,596	−0,004	0,584	2
min-max	równe	zachłanny wybór	0,669	+0,016	0,612	+0,013	0,611	3
min-max	PR-AUC	wszystkie	0,655	+0,001	0,608	+0,008	0,600	2
min-max	PR-AUC	zachłanny wybór	0,672	+0,019	0,618	+0,019	0,610	3
min-max	skill	wszystkie	0,657	+0,003	0,608	+0,009	0,601	2
min-max	skill	zachłanny wybór	0,674	+0,021	0,623	+0,024	0,612	3
min-max	skill×różn.	wszystkie	0,649	−0,004	0,605	+0,006	0,593	2
min-max	skill×różn.	zachłanny wybór	0,675	+0,021	0,618	+0,018	0,612	3
z-score	równe	wszystkie	0,618	−0,035	0,590	−0,009	0,577	1
z-score	równe	zachłanny wybór	0,664	+0,010	0,608	+0,009	0,601	2
z-score	PR-AUC	wszystkie	0,643	−0,011	0,612	+0,013	0,589	1
z-score	PR-AUC	zachłanny wybór	0,665	+0,012	0,611	+0,012	0,604	2
z-score	skill	wszystkie	0,645	−0,008	0,611	+0,012	0,592	1
z-score	skill	zachłanny wybór	0,666	+0,012	0,608	+0,009	0,603	2
z-score	skill×różn.	wszystkie	0,636	−0,017	0,604	+0,005	0,587	1
z-score	skill×różn.	zachłanny wybór	0,666	+0,012	0,608	+0,009	0,606	2
odporny z	równe	wszystkie	0,586	−0,068	0,576	−0,023	0,562	1
odporny z	równe	zachłanny wybór	0,666	+0,013	0,605	+0,005	0,603	3
odporny z	PR-AUC	wszystkie	0,608	−0,046	0,592	−0,007	0,574	1
odporny z	PR-AUC	zachłanny wybór	0,664	+0,010	0,608	+0,009	0,604	2
odporny z	skill	wszystkie	0,612	−0,042	0,594	−0,005	0,571	1
odporny z	skill	zachłanny wybór	0,664	+0,010	0,608	+0,008	0,605	3
odporny z	skill×różn.	wszystkie	0,599	−0,054	0,583	−0,016	0,570	1
odporny z	skill×różn.	zachłanny wybór	0,665	+0,012	0,606	+0,007	0,604	3
rangi	równe	wszystkie	0,622	−0,032	0,572	−0,028	0,560	1
rangi	równe	zachłanny wybór	0,644	−0,010	0,598	−0,002	0,584	3
rangi	PR-AUC	wszystkie	0,641	−0,013	0,583	−0,017	0,587	1
rangi	PR-AUC	zachłanny wybór	0,651	−0,002	0,595	−0,004	0,585	3
rangi	skill	wszystkie	0,644	−0,009	0,586	−0,014	0,593	1
rangi	skill	zachłanny wybór	0,652	−0,002	0,597	−0,002	0,585	3
rangi	skill×różn.	wszystkie	0,641	−0,013	0,584	−0,015	0,585	1
rangi	skill×różn.	zachłanny wybór	0,651	−0,002	0,597	−0,002	0,586	3